



2021.08.01

MIDAS: 混频数据预测通用框架



陈奥林(分析师)

021-38674835

chenaolin@gtjas.com

证书编号 S0880516100001

徐忠亚(分析师)

021-38032692

xuzhongya@gtjas.com

S0880519090002

本报告导读:

我们对 MIDAS 模型框架进行了详细分析,并将其应用到宏观指标预测和行业景气度构建中,取得了较好的效果。

摘要:

- 数据维度的拓宽,频率的提高,引致如下应用问题:一,如何处理不同频率的数据(季度/月度/周度/日度,或其他更高频数据);二,如何处理数据发布时点的不规则,即混频数据预测。
- MIDAS 框架:数据处理方法为 Vertical Realignment,即基于频率差异倍数,将高频数据处理为对应的解释变量,实现数据的对齐;施加结构化约束,减少参数数量;因子化处理同类指标,构建 Factor-MIDAS 模型。通过上述方法,可解决混频数据预测时的问题。
- CPI 预测:使用猪肉、蔬菜、水果和柴油等日度和周度高频数据,对 CPI:当月同比进行预测。从结果看,可更具时效性地追踪 CPI 的变动,且从结果看模型准确度也较高。
- 行业景气度追踪:借助产业链供需分析,从价格、上游成本、产量、库存、下游需求和经济环境等维度选取日度和月度数据,搭建了有色金属行业景气度追踪框架。从结果看,模型结果相比财报数据的发布具有较强的领先性,且能够更及时地对拐点进行判断。
- 研究展望:一方面我们会丰富可得高频指标,这个是模型有效性的关键;其次,对于高频数据噪声和时点对应问题,也会进行更深入的研究,以提高模型的准确性。

金融工程团队:

陈奥林:(分析师)

电话: 021-38674835

邮箱: chenaolin@gtjas.com

证书编号: S0880516100001

杨能:(分析师)

电话: 021-38032685

邮箱: yangneng@gtjas.com

证书编号: S0880519080008

殷钦怡:(分析师)

电话: 021-38675855

邮箱: yinqinyi@gtjas.com

证书编号: S08805190800013

徐忠亚:(分析师)

电话: 021-38032692

邮箱: xuzhongya@gtjas.com

证书编号: S0880519090002

刘晔轶:(分析师)

电话: 021-38677309

邮箱: liubingyi@gtjas.com

证书编号: S0880520050001

吕琪:(研究助理)

电话: 021-38674754

邮箱: lvqi@gtjas.com

证书编号: S0880120080008

赵展成:(研究助理)

电话: 021-38676911

邮箱: Zhaozhancheng@gtjas.com

证书编号: S0880120110019

相关报告

算法交易的历史与现状 2021.07.30

利用高频数据监测机构动向 2021.07.30

ALPHA 再优化:完全市值行业中性法
2021.07.26

基于中美供应链的投资异象 2021.07.26

通胀环境下的投资策略 2021.07.22

目 录


1. 混频预测需要解决的问题.....	3
2. MIDAS 模型对混频数据的处理.....	3
2.1. 模型基本构成：混频数据直接关联.....	4
2.2. 如何纳入日频和周频数据.....	5
2.3. Factor-MIDAS：多维度数据处理.....	5
2.4. 小结	7
3. MIDAS 模型应用	8
3.1. 宏观经济指标预测	8
3.2. 行业景气度指数构建.....	10
3.3. 小结	12
4. 模型应用总结	12
4.1. 模型优势与不足.....	12
4.2. 研究展望	13
5. 结论	14

1. 混频预测需要解决的问题

技术的发展，数据体系的完善，使得我们能够获取的信息种类和数量大幅增加。在经济金融研究中，我们追求信息的全面和及时，因此如何将这些信息整合以便对目标维度进行分析，值得深入分析。在这个过程中，我们需要重点解决两个问题，即如何进行混频预测：一，如何处理不同频率的数据（季度/月度/周度/日度，或其他更高频数据）；二，如何处理数据发布时点的不规则问题。

下图给出了常见的数据发布模式：我们所关注的变量多数频率较低，需要利用高频数据进行拟合。在前期研究中，我们重点关注了季度和月度数据的模型化处理。在实际使用中，我们发现存在一些问题：一，在动态因子模型框架下，需将低频数据高频化近似处理。季度到月度相对容易，季度、月度和周度数据处理为日度相对更困难，所涉参数也较多；二，在原有框架下，需对未发布时点数据进行预测，在一些情况下会引入较大的误差。

图 1 混频数据发布结构



数据来源：国泰君安证券研究；灰色表示数据未发布

对于通用的混频预测框架，我们预期其应满足如下特征：一，能够精确处理不同频率数据，同时能够及时将新发布信息纳入目标值调整中；二，模型参数相对较少，稳定性相对较高。在本报告中，我们着重分析了如下问题：

1. 什么是 MIDAS 模型，如何解决混频数据问题？
2. 相比动态因子模型，MIDAS 模型具有哪些优势和不足？
3. 如何将 MIDAS 模型应用到实际的混频预测中？

2. MIDAS 模型对混频数据的处理

MIDAS（混频数据抽样）回归，即 Mixed Frequency Data Sampling Regression Models。此部分我们对该模型的基本构成、不同频率数据的纳入和 Factor-MIDAS 进行分析，以对模型有较为充分的了解。

2.1. 模型基本构成：混频数据直接关联

MIDAS 的基本原理是，低频变量作为被解释变量，高频数据与之同期对应作为解释变量。单变量模型的一般形式为：

$$y_t = \beta_0 + \beta_1 W(L^{1/m}; \theta) x_t^{(m)} + \varepsilon_t^{(m)}$$

其中， y_t 是低频被解释变量； $x_t^{(m)}$ 是高频解释变量； m 是高频和低频数据之间的倍数：若 y_t 是季度数据， x_t 是月度数据，则 $m=3$ ； $W(L^{1/m}; \theta)$ 为权重滞后多项式， $W(L^{1/m}; \theta) = \sum_{k=0}^K w(k; \theta) L^{k/m}$ ， $L^{1/m}$ 为高频滞后算子， $L^{k/m} x_t^{(m)} = x_{t-k/m}^{(m)}$ 。

权重滞后多项式有多种设定方法，本文采用的是 Almon 多项式，其一般形式为：

$$w(k; \theta) = \frac{\exp(\theta_1 k + \cdots + \theta_q k^q)}{\sum_{k=0}^K \exp(\theta_1 k + \cdots + \theta_q k^q)}$$

对于不同的参数设置，Almon 多项式具有较为灵活的时序特征。常规使用的周度或日度均值，等价于时序权重相同。而此处权重由数据驱动，不同数据对应不同的结构。

用于预测的模型结构为（假设为季度和月度数据）：

$$y_{t_q+h_q} = y_{t_m+h_m} = \beta_0 + \beta_1 W(L^{1/m}; \theta) x_{t_m+w}^{(m)} + \varepsilon_{t_m+h_m}^{(m)}$$

其中 $t_q = 3t_m$ ， h_m 为预测步长； w 为预测季度已发布的月度数据个数。估计得到模型参数后，可得预测值为：

$$y_{T_q+h_q|T_m+w} = \hat{\beta}_0 + \hat{\beta}_1 W(L^{1/m}; \hat{\theta}) x_{t_m+w}^{(m)}$$

若被解释变量存在序列自相关性，则模型可表述为：

$$y_{t_q+h_q} = \beta_0 + \lambda y_{t_m} + \beta_1 W(L^{1/m}; \theta) (1 - \lambda L^{3/m}) x_{t_m+w}^{(m)} + \varepsilon_{t_m+h_m}^{(m)}$$

基于相似方法可估计得到所需参数，得到目标变量预测值。

以 GDP 行业划分中交通运输、仓储和邮政业为例，站在 2021 年 7 月 14 日，行业 GDP 增速公布至 2021Q1；工业增加值公布至 2021 年 5 月，货运量总计公布至 2021 年 6 月，则对行业 GDP 增速进行预测的数据结构见图 2，下面我们对其进行说明。

数据表时间序列为低频变量更新时点，此处为季度，或每一年的 3/6/9/12 月；因为截至该时点货运量总计已公布至 6 月，则无需对其进行时点偏移；工业增加值公布至 5 月，因此需将其序列前移 1 个月：2021Q2 第三个月对应的是 2021 年 5 月，第一个月对应的是 2021 年 3 月，2021Q1 第一个月对应的是 2021 年 2 月，以此类推。因此，对于解释变量，确定与低频数据的倍数后，依次将其分布在各位置点。使用 2021Q1 及之前数据进行参数估计，将 2021Q2 的数据代入，则可得低频变量当季预

国泰君安版权所有 P4

测值。

图 2 MIDAS 数据排列格式示例（季度和月度）

	交通运输	货运量总计			工业增加值			说明
	当季	第三个月	第二个月	第一个月	第三个月	第二个月	第一个月	
2019-03	6.8%	8.5%	3.4%	6.8%	0.9%	6.9%	0.0%	参数估计数据
2019-06	6.6%	6.3%	5.0%	5.4%	5.6%	6.1%	8.6%	
2019-09	6.9%	5.8%	4.4%	4.8%	5.4%	6.8%	5.5%	
2019-12	5.7%	6.9%	6.2%	4.7%	5.6%	2.5%	5.3%	
2020-03	-14.0%	-1.1%	-25.9%	-4.3%	-29.9%	-17.0%	5.1%	
2020-06	1.7%	4.8%	4.4%	3.9%	0.4%	-2.1%	-13.0%	
2020-09	3.9%	6.9%	5.6%	4.8%	4.8%	2.9%	3.9%	
2020-12	7.6%	7.3%	7.0%	6.9%	7.2%	7.2%	5.6%	
2021-03	32.1%	14.1%	52.3%	25.4%	68.9%	38.0%	7.4%	预测
2021-06		8.3%	8.8%	9.8%	12.6%	17.1%	32.9%	

数据来源：Wind，国泰君安证券研究

2.2. 如何纳入日频和周频数据

对于日度和周度数据，常规做法是取每月均值，即可使用上述框架进行模型估计和使用。虽然这两类数据包含的噪声相对更多，但能够贡献更及时的信息，直接将其纳入模型，时效性也相对更高。

与月度数据相比，日度和周度数据的问题是固定区间内的数据点并不确定。以交易日为例，节假日的存在使得各月时点不一。以 2020 年为例，全年共 243 个交易日，Q3 包含 66 个交易日，Q1 包含 58 个交易日；7 月和 12 月包含 23 个交易日，1 月和 10 月包含 16 个交易日。因此，对于日度和周度数据，本文对各区间数据点作如下假设：每个月对应 21 个交易日，30 个日历日；每个月对应 4 个周度数据点。在此假设下，如果当月数据不足，则使用前推月度数据递补；若数据溢出，则顺移至下一个月度区间。对于日度数据计算同比，交易日前推 252 个交易日，日历日前推 360 日；对于周度数据计算同比，前推 48 周进行计算。

2.3. Factor-MIDAS: 多维度数据处理

前文我们对 MIDAS 模型的基本版本进行了较为详细的说明。在实际使用中，还会面临如下问题：同一类指标或有多个数据可对应，如果将其全部纳入模型，对参数估计和预测准确度产生影响。在 Nowcasting 框架下，使用因子化来解决这一问题。将其与 MIDAS 结合，可得 Factor-MIDAS 模型框架，其一般形式为（设为季度和月度数据）：

$$y_{t_q+h_q} = \beta_0 + \beta_1 W(L^{1/m}; \theta) \hat{f}_{t_m+w}^{(m)} + \varepsilon_{t_m+h_m}^{(m)}$$

向前预测值为：

$$y_{T_q+h_q|T_m+w} = \hat{\beta}_0 + \hat{\beta}_1 W(L^{1/m}; \hat{\theta}) \hat{f}_{t_m+w}^{(m)}$$

与一般模型形式的差别是，需要首先对解释变量 $\hat{f}_{t_m+w}^{(m)}$ 进行估计。实际应用中，我们使用动态因子模型框架对潜在因子进行估计，下面进行说明。国泰君安版权所有 P5

设 $y_t = [y_{1,t}, y_{2,t}, \dots, y_{n,t}]'$, $t = 1, \dots, T$, 为标准化的月频平稳时间序列向量, 其可由如下因子模型表述:

$$y_t = \Lambda f_t + \varepsilon_t$$

设 f_t 满足如下 VAR 模型:

$$f_t = A_1 f_{t-1} + A_2 f_{t-2} + \dots + A_p f_{t-p} + u_t \quad u_t \sim i.i.d. N(0, Q)$$

其中, f_t 为 $r \times 1$ 不可观测因子向量, $\varepsilon_t = [\varepsilon_{1,t}, \varepsilon_{2,t}, \dots, \varepsilon_{n,t}]'$ 为与因子不相关的特质因素。

基于上述模型框架, 我们按如下步骤估计得到潜在因子序列: 获取初始输入值, E-M 算法得到参数收敛后的序列。

1. 初始输入值

设模型为:

$$\begin{aligned} y_t &= \Lambda f_t + \varepsilon_t \\ f_t &= A f_{t-1} + u_t \\ \Lambda &= \begin{pmatrix} \Lambda_{N,G} & \Lambda_{N,N} & 0 \\ \Lambda_{R,G} & 0 & \Lambda_{R,R} \end{pmatrix} \end{aligned}$$

考虑如下最优化:

$$(\hat{f}_t, \hat{\Lambda}) = \arg \min_{f_t, \Lambda} \sum_{t=1}^T \sum_{i=1}^n (y_{it} - \Lambda_i f_t)^2$$

定义如下方差协方差矩阵:

$$S = \frac{1}{T} \sum_{t=1}^T y_t y_t'$$

设 D 为 $r \times r$ 的对角阵, 其对角线为 S 的最大的 r 个特征向量; V 为 $n \times r$ 的矩阵, 其每一列为对应的特征向量, 满足 $V'V = I_r$ 。则潜在因子估计值为: $\hat{f}_t = V \hat{y}_t$ 。

2. E-M 估计流程

Expectation-Maximization 算法是一种在存在潜在变量的情况下执行最大似然估计的方法, 首先估算潜在变量的值, 然后优化模型, 重复直到收敛。其包括如下两步:

E-Step:

$$L(\theta, \theta(j)) = E_{\theta(j)} [l(y, f; \theta) | \Omega_T]$$

$l(y, f; \theta)$ 为潜在变量和观测变量联合似然函数; Ω_T 为观测变量集合。E-Step 的目的是, 在给定参数值的条件下, 计算潜在变量的各阶矩估计值, 进而使得似然函数为仅含模型参数的函数。具体来说, 需要得到如下潜在因子期望估计值:

$$\begin{aligned} E_{\theta(j)}[f_t | \Omega_T] &= E_{\theta(j)}[f_t f'_t | \Omega_T] \\ E_{\theta(j)}[f_{t-1} f'_{t-1} | \Omega_T] &= E_{\theta(j)}[f_t f'_{t-1} | \Omega_T] \end{aligned}$$

为得到上述估计值，需首先使用卡尔曼滤波算法进行前推估计，然后使用卡尔曼平滑方法进行后推数值调整，使得估计值准确度更高。

M-Step:


$$\theta(j+1) = \arg \max_{\theta} L(\theta, \theta(j))$$

经 E-Step 处理后，似然函数中仅有模型系数值需要估计，与常见的似然函数问题并无差别。

重复上述流程，直至所得结果收敛，据此可得所需因子值序列。


下面我们以有色金属中的铜、铝、铅、锌和锡为例进行说明。首先计算价格同比/环比序列，然后基于上述方法得到标准化因子序列，结果见下图。

图 3 日度价格同比序列和拟合因子



数据来源：Wind，国泰君安证券研究

图 4 日度价格环比序列和拟合因子



数据来源：Wind，国泰君安证券研究

2.4. 国泰君安版权所有 P7

如何统一纳入不同频率的数据，处理数据发布时点不规则，是进行混频预测时需要考虑的关键问题。MIDAS 模型通过如下方法尝试解决上述问题：一，通过对高频数据的重新排列，将之与低频数据形成对应；通过 Vertical Realignment 方法，即发布时点而非时间本身，将数据依次对应，解决了发布时点不一的问题。据此，MIDAS 模型可较为统一的对季度/月度/周度/日度数据进行统一分析。而在实际使用中，同一类指标对应或有较多代理变量，Factor-MIDAS 模型将因子模型纳入，可解决数据维度过多的问题。


3. MIDAS 模型应用

前文我们已对 MIDAS 模型进行了较为详细的介绍，下面我们将其应用到如下常用混频预测场景：宏观经济指标和行业景气度。通过这些例子我们可以看出，该模型框架具有较强的有效性和通用性。

3.1. 宏观经济指标预测

在前期研究中，我们分别搭建了 Nowcasting 和 GDPNOW 宏观经济状态预测框架。Nowcasting 框架的不足是，无法定量追踪预测误差来源，且模型的调整具有一定的延迟性；GDPNOW 框架中，基于自下而上的 GDP 核算拆分合成，其可解释性和可靠性相对更高，但也存在一定的不足：对于未发布月度高频指标，需使用时序滞后模型进行预测，在特定环境下误差较大。此部分我们尝试将 MIDAS 模型应用于月度高频指标的预测，以能够在 GDPNOW 框架下提供更准确的预测输入。

图 5 GDPNOW 模型框架-经济状态预测框架



数据来源：国泰君安证券研究

此部分我们尝试以高频数据对“CPI:当月同比”指标进行预测。从构成看，CPI 主要包括如下分项：食品烟酒、衣着、居住、生活用品及服务、交通和通信、教育文化和娱乐、医疗保健、其他用品和服务。

基于数据发布频率和时效性，以及与目标变量相关性，我们筛选了如下高频数据对 CPI 同比价格指数进行预测，见下表。图 6 和图 7 中给出的


是日度猪肉价格与 CPI 猪肉，日/周度蔬菜价格和 CPI 鲜菜走势对比，可以发现高频数据能够较好的追踪月度指标走势，且更早出现拐点变化。

表 1: CPI:当月同比高频预测指标

指标名称	更新频率	指标处理方法	发布时点
平均批发价:猪肉	日度	计算价格同比	次日
28 种重点监测蔬菜	日度	计算价格同比	次日
7 种重点监测水果	日度	计算价格同比	次日
零售价:0#柴油	周度	计算价格同比	滞后一周


数据来源: Wind, 国泰君安证券研究

图 6 日度猪肉价格对 CPI 分项趋势一致



数据来源: Wind, 国泰君安证券研究

图 7 日/周度蔬菜价格对 CPI 分项追踪效果较好



数据来源: Wind, 国泰君安证券研究

基于前文所述模型，我们通过下述模型对 CPI:当月同比进行日频预测。数据使用和时点选择说明见表 2，即使用截至时点可得数据对最新一期未发布月度数据进行预测。

$$CPI_{t_q+h_q} = \beta_0 + \beta_1 W(L^{1/m}; \theta) P_{t_m+w}^{(zr)} + \beta_2 W(L^{1/m}; \theta) P_{t_m+w}^{(sc)} + \beta_3 W(L^{1/m}; \theta) P_{t_m+w}^{(sg)} + \beta_4 W(L^{1/m}; \theta) P_{t_m+w}^{(cy)} + \varepsilon_{t_m+h_m}^{(m)}$$

表 2: CPI:当月同比高频预测数据时点选取示例说明

时点	CPI:当月同比	平均批发价:猪肉	28 种重点监测蔬菜	7 种重点监测水果	零售价:0#柴油
2021/07/07	预测期为 2021 年 6 月，模型数据为 2021 年 5 月及之前	模型使用为 2021 年 6 月 30 日之前数据，21 个交易日	模型使用为 2021 年 6 月 30 日之前数据，21 个交易日	模型使用为 2021 年 6 月 30 日之前数据，21 个交易日	模型使用为 2021 年 6 月 30 日之前数据，即 4 周
2021/07/11	预测期为 2021 年 7 月，模型数据为 2021 年 6 月及之前	模型使用为 2021 年 7 月 11 日之前数据，21 个交易日	模型使用为 2021 年 7 月 11 日之前数据，21 个交易日	模型使用为 2021 年 7 月 11 日之前数据，21 个交易日	模型使用为 2021 年 7 月 11 日之前数据，即 4 周

数据来源: 国泰君安证券研究

下面我们对相关结构进行分析。图 8 给出的是 2021 年 6 月 CPI:当月同比的每日预测值，所对应的区间为: 2021/06/10-2021/07/08，最后一期预测值为 1.23%，实际值为 1.10%。从趋势看，CPI:当月同比预测值在逐渐走低，即新发布高频数据显示国内通胀水平在降低。


图 9 给出的是 2021 年 7 月 CPI:当月同比预测值走势（截至 2021/07/23，还未发布实际值），最新预测值为 1.17%，且从趋势看，延续了上月下行的趋势。

图 8 CPI:当月同比-2021 年 6 月预测走势



数据来源: Wind, 国泰君安证券研究; 当月实际值为 1.10%

图 9 CPI:当月同比-2021 年 7 月预测走势



数据来源: Wind, 国泰君安证券研究; 截至 2021/07/23

3.2. 行业景气度指数构建

传统基本面选股范式下，我们一般使用公司已发布财报/预告数据，或分析师预测值。前者存在较长的滞后期，后者调整速度或准确性或存在一定的问题。股价往往先于业绩超预期得以兑现，预测往往难度较大，且偏差相对不可控。与经济状态预测类似，我们希望基于现有可得信息得到行业景气度当前水平值，从其变化趋势中判断拐点是否出现。整体思路是首先基于所得信息对当前实际状态作出预判，而非单纯的外推预测。此部分我们以有色金属行业为例，基于混合高频数据，对行业景气度进行实时预测。

在前期研究中¹，我们搭建了周期行业基本面量化框架。周期板块表现与经济景气度存在较高相关性。周期类公司的利润核心围绕产品价格、销量的变化，其与经济周期强相关，周期公司相较于其他板块更难摆脱周期的影响，因而其业绩表现和股价变动也就与经济景气密切相关。周期板块之所以具有极强的周期性规律，本质是行业供需格局阶段性变化带动市场调整公司业绩预期。

基于上述分析，有色金属行业所涉主要品种价格、产量和库存对行业景气度有重要的影响，下游需求端和所处宏观环境也需考虑在内。考虑高频数据可得性及更新时效性，最终选择的指标及处理方法见表 3。

对于行业景气度，我们以行业 ROE-TTM 作为代理变量，使用高频数据对其进行预测，重点关注拐点及趋势变动。行业 ROE-TTM=成分股归母净利润 TTM/成分股净资产。公司财报发布时点存在较大的差别，我们按如下方式确定预测报告期：假设截至 2020 年 8 月 22 日，成分股第二季度财报发布比例大于 70%，则认为二季度数据已全部发布，预测期为第三季度，反之则为第二季度。对于成分股，截至预测日，要求其上市

¹ 详见《周期板块基本面量化及策略配置》。

至少满半年。


对于高频数据，结合报告中的分析方法，从如下维度进行指标筛选：主要品种价格、产量、库存、下游需求和所处经济环境；同时参考我们关于产业链划分相关报告，选取对应上游 PPI 价格指数作为行业成本端代理变量。如果将所涉变量均单独纳入模型，变量和估计参数较多（共涉及近 50 个高频指标），因此使用 Factor-MIDAS 模型进行框架搭建，最终纳入模型的即为各类分别对应的 6 类因子。

表 3：有色金属行业景气度高频预测指标

指标类型	指标名称	更新频率	指标处理方法
行业景气度	净资产收益率	季频	TTM
价格	铜、铝、铅、锌、锡、钴、锑等价格	日频	环比
上游成本	采掘等相关行业 PPI 价格指数	月频	同比
产量	铜、铝、铅、锌等	月频	同比
库存	LME 和上期所库存指标	日频	环比
下游需求	机械设备、汽车、电力设备等	月频	同比
经济环境	货币、社融指标	月频	同比


数据来源：Wind，国泰君安证券研究

图 10 因子拟合值：上游成本



数据来源：Wind，国泰君安证券研究

图 11 因子拟合值：下游需求



数据来源：Wind，国泰君安证券研究

基于所拟合得到的 6 类因子序列，我们构建了如下 Factor-MIDAS 模型：

$$\begin{aligned}
 ROE_{t_q+h_q}^{TTM} = & \beta_0 + \lambda ROE_{t_q}^{TTM} + \beta_1 W(L^{1/m}; \theta) \hat{f}_{t_q+w}^{(price)} + \beta_2 W(L^{1/m}; \theta) \hat{f}_{t_m+w}^{(cost)} \\
 & + \beta_3 W(L^{1/m}; \theta) \hat{f}_{t_m+w}^{(product)} + \beta_4 W(L^{1/m}; \theta) \hat{f}_{t_q+w}^{(deposit)} \\
 & + \beta_5 W(L^{1/m}; \theta) \hat{f}_{t_m+w}^{(demand)} + \beta_6 W(L^{1/m}; \theta) \hat{f}_{t_m+w}^{(macro)} \varepsilon_{t_q+h_m}^{(m)}
 \end{aligned}$$


基于上述模型，基于每日可得数据，对最近一期未发布 ROE-TTM 进行预测，使用对应时点的高频指标序列作为解释变量。据此，可得每日有色金属行业景气度追踪结果和同期指数价格走势，见图 12（图中给出的是每周最后一个交易日结果）。下面我们对所得结果进行分析。

周期行业业绩/盈利能力对行情有直接影响，而股价是领先于实际业绩的兑现的。基于 Factor-MIDAS 模型给出的景气度追踪结果，可以发现，有色金属行业景气度低点出现在 2020 年 5 月底，之后开始逐渐攀升，

国泰君安版权所有 P11

大幅领先于财报数据，与股价表现基本保持同步。基于这一结果，我们认为从日度、周度或月度高频数据中，能够获取较为领先的低频指标追踪值，且能够领先于业绩数据对拐点进行判断。

图 12 有色金属行业景气度实时预测(2019-2021 年)



数据来源：Wind，国泰君安证券研究；数据截至 2021/07/23；指数使用申万有色金属行业一级

3.3. 小结

在多数情况下，预测是困难的，且准确性也是存疑的。混频预测虽冠以预测，但实际是随着部分数据的发布，对目标变量整体的准确性判断也越准确。不论是前期我们搭建的 Nowcasting 或 GDPNOW 框架，还是本文所使用的 MIDAS 模型，均延续的是这一思路。

在实际经济分析中，我们面临的问题是数据维度较多，且频率不一，发布时点不规则。常用做法是将高频数据低频化，虽然也能过获取较为及时的信息，但无法获取区间内的变化，遗漏拐点的获取。MIDAS 框架的优势是，通过数据的重新组织，将低频数据与区间内高频数据对应，进而精细化将不同频率数据进行模型化对应，从而估计参数获取预测值。此部分我们将其应用到 CPI 预测和行业景气度指标构建，可以发现其具有较好的准确性和较强的领先性。

4. 模型应用总结

此部分我们对 MIDAS 模型框架进行重新梳理，分析其相比动态因子模型所具有的优势，以及在构建过程中需考虑的点以及存在的不足。

4.1. 模型优势与不足

实际使用中我们一般需要处理的高频数据为日频、周频和月频，如果对交易数据进行预测，或涉及小时或分钟数据。对于混频数据，我们需要关注的是不同频和发布时点不一。在 Nowcasting 框架下，我们处理的数据为月度和季度，模型为月频。季度 GDP 为部分时点可观测数据：

$$y_t^Q = \begin{cases} Y_t^Q - Y_{t-3}^Q & t = 3, 6, 9 \dots \\ \text{Unobserved} & \text{Otherwise} \end{cases}$$

则有：

$$y_t^Q \approx \frac{1}{3}(y_t + 2y_{t-1} + 3y_{t-2} + 2y_{t-3} + y_{t-4})$$

其中 y_t 为设定的月度 GDP 增长率。通过此种近似，月度和季度数据均模型化于月频潜在因子。

对于日/周度数据，想要进行此种转换存在一定的困难，且存在误差。MIDAS 处理的思路是 Vertical Realignment，即基于频率差异倍数，将高频数据处理为对应的解释变量数量，实现数据对齐。如果不施加约束，参数会较多，因此可施加结构化参数。对于同类指标较多的情况，借鉴 Nowcasting 动态因子模型，得到 Factor-MIDAS 模型。基于上述处理，较好地解决了在进行混频数据预测中所面临的问题。

总结来说，框架通用性和使用灵活性的 MIDAS 框架最显著的优点，其在宏观经济指标预测、行业景气度追踪中具有较好的应用效果。

MIDAS 框架存在哪些不足呢？首先是变量筛选，即选取哪些数据纳入模型。这里更多的是看使用者的偏好，或者可得的经济逻辑，想要得到最优结果需进行一定样本内优化，不过 Factor-MIDAS 在一定程度上可以解决这个问题。第二个是数据本身，而非 MIDAS 引致的。日度、周度存在虽然能够提供更及时性的信息，但包含的噪声也更多，如何处理也需要更多研究。对于部分指标，我们需要计算其同比增速，然而日/周度数据固定区间样本数不一引致时点对应问题。如何较好地解决这一问题，还需要进行更多研究。

4.2. 研究展望

混频数据预测的核心是：区间内部分数据的发布越多，对于整体的刻画就越准确。因此，日频、周频和月频数据的使用，使得我们能够先于低频指标的发布得到更为及时的信息，这对于拐点和趋势的判断尤其具有重要价值。混频预测的核心是具有信息价值的高频数据，此类数据的整合是关键。后续，我们会在这一方面进行更为深入的研究。

对于模型应用，延续前期 Nowcasting 和 GDPNOW 框架，我们主要对后者进行完善，作为经济状态的预测核心。MIDAS 框架的价值体现在基于日度或周度数据得到月度行业指标的预测值，进而自下而上合成得到综合 GDP 预测值。

对于行业景气度，通过本文有色金属行业的例子，可以发现在综合产业链分析后，从供需角度获取所涉数据，能够得到更具领先性的追踪指标。相比于传统财报或技术分析，景气度追踪的应用前景更广，也更具可解释性和可靠性。

5. 结论

混频预测需要解决的问题是：一，如何处理不同频率的数据（季度/月度/周度/日度，或其他更高频数据）；二，如何处理数据发布时点的不规则。在本报告中，我们对 MIDAS 模型框架进行了详细分析，并给出了其应用流程。

通过数据重新组合和结构化参数约束，能够较好地处理混频数据问题。我们将 MIDAS 框架应用于 CPI 预测，可以发现高频价格数据的纳入，能够较好地追踪其变化趋势，且具有较好的准确性。基于产业链供需分析，从多个维度选取指标，得到有色金属行业景气度追踪指标，其相比于财报数据具有较强的领先性，实用价值较好。

后续研究中，一方面我们会丰富可得高频指标，这个是模型有效性的关键；其次，对于高频数据噪声和时点对应问题，也会进行更深入的研究，以提高模型的准确性。

本公司具有中国证监会核准的证券投资咨询业务资格

分析师声明

作者具有中国证券业协会授予的证券投资咨询执业资格或相当的专业胜任能力，保证报告所采用的数据均来自合规渠道，分析逻辑基于作者的职业理解，本报告清晰准确地反映了作者的研究观点，力求独立、客观和公正，结论不受任何第三方的授意或影响，特此声明。

免责声明

本报告仅供国泰君安证券股份有限公司（以下简称“本公司”）的客户使用。本公司不会因接收人收到本报告而视其为本公司的当然客户。本报告仅在相关法律许可的情况下发放，并仅为提供信息而发放，概不构成任何广告。

本报告的信息来源于已公开的资料，本公司对该等信息的准确性、完整性或可靠性不作任何保证。本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可升可跌。过往表现不应作为日后的表现依据。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。本公司不保证本报告所含信息保持在最新状态。同时，本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。在任何情况下，本报告中的信息或所表述的意见均不构成对任何人的投资建议。在任何情况下，本公司、本公司员工或者关联机构不承诺投资者一定获利，不与投资者分享投资收益，也不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。投资者务必注意，其据此做出的任何投资决策与本公司、本公司员工或者关联机构无关。

本公司利用信息隔离墙控制内部一个或多个领域、部门或关联机构之间的信息流动。因此，投资者应注意，在法律许可的情况下，本公司及其所属关联机构可能会持有报告中提到的公司所发行的证券或期权并进行证券或期权交易，也可能为这些公司提供或者争取提供投资银行、财务顾问或者金融产品等相关服务。在法律许可的情况下，本公司的员工可能担任本报告所提到的公司的董事。

市场有风险，投资需谨慎。投资者不应将本报告作为作出投资决策的唯一参考因素，亦不应认为本报告可以取代自己的判断。在决定投资前，如有需要，投资者务必向专业人士咨询并谨慎决策。

本报告版权仅为本公司所有，未经书面许可，任何机构和个人不得以任何形式翻版、复制、发表或引用。如征得本公司同意进行引用、刊发的，需在允许的范围内使用，并注明出处为“国泰君安证券研究”，且不得对本报告进行任何有悖原意的引用、删节和修改。

若本公司以外的其他机构（以下简称“该机构”）发送本报告，则由该机构独自为此发送行为负责。通过此途径获得本报告的投资者应自行联系该机构以要求获悉更详细信息或进而交易本报告中提及的证券。本报告不构成本公司向该机构之客户提供的投资建议，本公司、本公司员工或者关联机构亦不为该机构之客户因使用本报告或报告所载内容引起的任何损失承担任何责任。

评级说明

1. 投资建议的比较标准

投资评级分为股票评级和行业评级。以报告发布后的 12 个月内的市场表现为比较标准，报告发布日后的 12 个月内的公司股价（或行业指数）的涨跌幅相对同期的沪深 300 指数涨跌幅为基准。

2. 投资建议的评级标准

报告发布日后的 12 个月内的公司股价（或行业指数）的涨跌幅相对同期的沪深 300 指数的涨跌幅。

	评级	说明
股票投资评级	增持	相对沪深 300 指数涨幅 15%以上
	谨慎增持	相对沪深 300 指数涨幅介于 5%~15%之间
	中性	相对沪深 300 指数涨幅介于-5%~5%
	减持	相对沪深 300 指数下跌 5%以上
行业投资评级	增持	明显强于沪深 300 指数
	中性	基本与沪深 300 指数持平
	减持	明显弱于沪深 300 指数

国泰君安证券研究所

	上海	深圳	北京
地址	上海市静安区新闻路 669 号博华广场 20 层	深圳市福田区益田路 6009 号新世界商务中心 34 层	北京市西城区金融大街甲 9 号 金融街中心南楼 18 层
邮编	200041	518026	100032
电话	(021) 38676666	(0755) 23976888	(010) 83939888
E-mail:	gt.jaresearch@gt.jas.com		