

2021 年 8 月 15 日

Black-Litterman 模型研究系列之四

——结合马尔科夫链的行业轮动策略

► 马尔科夫链与 BL 模型结合

在马尔科夫链 (Markov Chain) 模型中, 每一个时间区间内的数据都有自己独特的统计特性, 例如不同的均值和方差。我们可以用状态变量来描述在相邻区间交替的数据变化, 现在状态的走势仅取决于前一状态的走势。

资产涨跌幅的时间序列数据是有关联性的数据, 并且在不同的时间段会体现出不同的规律, 因此我们可以用马尔科夫链模型对过去数据进行分析拟合, 判断此刻资产涨跌幅的状态。

对于某一特定时间区间, 我们用马尔科夫链拟合出资产条件均值及条件方差, 这实际上是对于此刻所处阶段资产涨跌幅走势状态的预测。我们可以将通过马尔科夫链拟合得出的资产条件均值作为 BL 模型的主观观点, 计算 BL 模型后验权重, 作为本阶段的行业选择方案。

► BL-马尔科夫链组合表现较好, 且优于直接马尔科夫链组合和其他加权方法组合

我们用过去三个月的行业指数涨跌幅数据根据马尔科夫链进行拟合, 用拟合结果生成 BL 观点, 得出 BL 后验权重, 每次选取 BL 后验权重最高的三个行业。

为了验证 BL 模型的有效性, 作为对比, 我们根据马尔科夫链拟合得出的资产条件均值, 直接选择排名最靠前的三个行业, 并将其设置为等权, 形成直接马尔科夫链行业组合。同时, 我们也将 BL-马尔科夫链组合与等权加权、市值加权组合进行了对比。

模型回测时, 行业选择范围为全部 28 个申万一级行业, 调仓频率为季频, 回测区间为 2010 年至 2021 年 7 月。

回测区间内, BL-马尔科夫链组合上涨 322.69%, 直接马尔科夫链组合上涨 213.75%, 同期中证全指上涨 47.75%。BL-马尔科夫链组合累计超额收益为 274.94%、且优于直接马尔科夫链组合。同时, BL 后验权重加权也比等权加权、市值加权更为有效。

风险提示

量化报告的结论基于历史统计规律, 当历史规律发生改变时, 报告中的模型和结论可能失效。

评级及分析师信息

分析师: 张立宁

邮箱: zhangln@hx168.com.cn

SAC NO: S1120520070006

分析师: 杨国平

邮箱: yanggp@hx168.com.cn

SAC NO: S1120520070002

助理分析师: 丁睿雯

邮箱: dingrw@hx168.com.cn

请仔细阅读在本报告尾部的重要法律声明

正文目录

1. BL 模型回顾	3
2. 马尔科夫链模型	4
2.1. 模型简介	4
2.2. EM 算法在隐马尔科夫模型中的应用	5
3. BL 模型与马尔科夫链的结合	6
3.1. 均衡收益率与主观观点权重	6
3.2. 马尔科夫链生成主观观点矩阵 P 和收益向量 Q	6
3.3. 观点协方差矩阵 Ω	7
4. BL-马尔科夫链行业组合回测结果	8
4.1. 行业轮动模型参数设置	8
4.2. 行业轮动模型的回测结果	8
4.2.1. BL-马尔科夫链组合优于直接马尔科夫链组合	8
4.2.2. BL 组合权重优于等权加权与市值加权组合	9
4.3. 行业数量的敏感性	10
5. 附录：EM 算法的详细步骤	11
6. 风险提示	12

图表目录

图 1 BL-马尔科夫链组合、直接马尔科夫链组合走势与基准指数对比	9
图 2 BL-马尔科夫链组合和直接马尔科夫链组合对中证全指的超额收益	9
图 3 BL-马尔科夫链组合对行业数量的敏感性	10

1. BL 模型回顾

我们首先简要回顾 BL 模型公式。详细推导过程请参考《Black-Litterman 模型研究系列之一 —— 原理解析》中的相关内容。

BL 后验涨跌幅的均值为：

$$\mu_p = [(\tau\Sigma)^{-1} + P^T\Omega^{-1}P]^{-1}[(\tau\Sigma)^{-1}\Pi + P^T\Omega^{-1}Q] \quad (1)$$

后验涨跌幅的协方差矩阵为

$$\Sigma_p^* = \Sigma + [(\tau\Sigma)^{-1} + P^T\Omega^{-1}P]^{-1} \quad (2)$$

以有 m 个资产、 k 个观点的组合为例，(1)、(2) 中各参数含义如下，

μ_p ：资产的后验涨跌幅

Σ_p^* ：后验涨跌幅的协方差矩阵

τ ：确定主观观点的权重，是一个标量，值越小，主观观点权重占比越低

Π ：均衡涨跌幅向量 ($m \times 1$ 向量)

Σ ： m 个资产涨跌幅的协方差矩阵 ($m \times m$ 矩阵)

P ：主观观点矩阵，矩阵内数值具体表明了观点涉及哪些资产 ($k \times m$ 矩阵)

Q ：主观观点收益向量，即每个观点所对应的涨跌幅 ($k \times 1$ 向量)

Ω ：表明每个主观观点信心的矩阵 ($k \times k$ 对角矩阵)

T ：表示转置矩阵

-1 ：表示逆矩阵

得到式(1)与式(2)的结果后，当无约束条件时通过式(3)计算 BL 组合权重

$$w = (\delta\Sigma_p^*)^{-1}\mu_p \quad (3)$$

当存在约束条件时，可以通过均值-方差优化计算权重。

本篇报告中，我们根据马尔科夫链模型，运用 EM 算法对历史资产涨跌幅数据进行拟合，以计算本阶段资产条件均值向量 $\mu_{average}$ 和资产条件均值方差矩阵 $\Sigma_{average}$ ，并将其作为 BL 模型的主观观点。

2. 马尔科夫链模型

2.1. 模型简介

在马尔科夫链 (Markov Chain) 模型中, 我们可以定义多个连续的时间区间, 每一个时间区间内的数据都有自己独特的统计特性, 例如不同的均值和方差。一个区间可以为任意时间区间, 直到与另一个区间进行交替。在马尔科夫链模型里, 我们用状态变量 (State Variable) 来描述在相邻区间交替的数据变化。现在状态的取值仅取决于前一状态的取值。资产涨跌幅数据是有关联性的数据, 并且在不同的时间段会表现出不同的特征规律, 因此我们可以用马尔科夫链模型对资产涨跌幅来进行分析拟合。

在模型中, 我们有一个马尔科夫链 S 和一个独立的输出变量 Y 。 Y 在 T 时刻的分布取决于变量 S 在 T 时刻的状态。马尔科夫链的状态仅取决于它前一时间区间的状态以及状态的概率转移矩阵。由于我们只能观察到输出变量 Y , 无法观察到状态序列 S , 所以我们无法对于马尔科夫链的状态本身进行分析。

我们下面引入一个两个状态 (S_1 和 S_2) 的马尔科夫链来描述资产涨跌幅数据:

$$\begin{cases} Y_1 = C_1 + \epsilon_1, \epsilon_1 \sim N(0, \sigma_1^2) & \text{if } S = S_1 \\ Y_2 = C_2 + \epsilon_2, \epsilon_2 \sim N(0, \sigma_2^2) & \text{if } S = S_2 \end{cases} \quad (4)$$

其中, 我们的因变量是 Y_1 和 Y_2 。 C_1 和 C_2 是在两个状态下的资产涨跌幅均值。 ϵ_1 和 ϵ_2 是在两个状态下正态随机变量, 服从于均值为 0、方差分别为 σ_1^2 和 σ_2^2 的正态分布。

状态的概率转移矩阵为:

$$Pr = \begin{bmatrix} Pr(S_{t+1} = S_1 | S_t = S_1) & Pr(S_{t+1} = S_2 | S_t = S_1) \\ Pr(S_{t+1} = S_1 | S_t = S_2) & Pr(S_{t+1} = S_2 | S_t = S_2) \end{bmatrix}$$

在上式中, 我们只可以观测到变量 Y (资产涨跌幅) 的取值, 其他参数无法被观测到, 因此此类马尔科夫链被称为隐马尔科夫链。在隐马尔科夫链模型中, 我们需要根据已知的 Y 来估计 C , ϵ 和转移矩阵 Pr 。

我们用 $\alpha_{i,1}$ 来表示在时间 $t = 1$ 时处于状态 i 的概率:

$$\alpha_{i,1} = Pr(S_1 = i | Y_1) = \frac{f(Y_1 | S_1 = i)p_i}{\sum_{j=1}^N f(Y_1 | S_1 = j)p_j} = [f(Y_1 | S_1 = i)p_i]$$

我们可以得到在时间 t 时处于状态 i 的概率:

$$\begin{aligned} \alpha_{i,t} &= Pr(S_t = i | Y_{1:t}) = [f(Y_t | S_t = i)Pr(S_t = i | Y_{1:t-1})] \\ &= [f(Y_t | S_t = i) \sum_{j=1}^N Pr(S_t = i | S_{t-1} = j) \alpha_{j,t-1}] = [f(Y_t | S_t = i) \sum_{j=1}^N p_{j,i} \alpha_{j,t-1}] \end{aligned}$$

请仔细阅读在本报告尾部的重要法律声明

接下来，运用 Maximum Likelihood Formula 来估计参数值。假设一共有 M 个资产以及 N 个状态，那么参数为：

$$\theta = \{p_i, p_{ij}, \mu_i^m, \Sigma_i^m, \Sigma_i^{m,n}\}, i, j \in (1, 2, \dots, N), m, n \in (1, 2, \dots, M)$$

p_i 是初始状态为 i 的概率， p_{ij} 是从状态 i 到状态 j 的概率， μ_i^m 是资产 m 在状态 i 下的涨跌幅均值， Σ_i^m 是资产 m 在状态 i 下的涨跌幅方差， $\Sigma_i^{m,n}$ 是资产 m 和资产 n 在状态 i 下的涨跌幅协方差。

那么完整的对数似然函数 (log likelihood function) 为：

$$\ln(L) = \sum_{t=1}^T \log \sum_{i=1}^N f(Y_t | S_t = i, \theta) Pr(S_t = i)$$

我们通过最大化上面的函数来得到参数。

2.2. EM 算法在隐马尔科夫模型中的应用

在隐马尔科夫模型中，假设 S 是所有可能的状态集合， V 是所有可能的观测的集合， N 是可能的状态数量， M 是可能的观测数量，也就是资产数量，时间长度为 T 。 I 是长度为 T 的隐状态序列，而 Y 是对应的观测序列，即各个时间节点资产的涨跌幅。

$$S = \{S_1, S_2, \dots, S_N\}, V = \{v_1, v_2, \dots, v_M\}, I = \{i_1, i_2, \dots, i_T\}, Y = \{y_1, y_2, \dots, y_T\}$$

我们定义状态概率矩阵为 Pr ， $Pr = [p_{ij}]_{N \times N}$ 。

p_{ij} 表示的是在已知 t 时刻的状态为 S_i 的条件下、 $t+1$ 时刻的状态为 S_j 的概率：

$$p_{ij} = Pr(i_{t+1} = S_j | i_t = S_i), i = 1, 2, \dots, N; j = 1, 2, \dots, N$$

观测概率矩阵为 B ， $B = [b_j(k)]_{N \times M}$ ，表示 M 个资产在 t 时刻处于各个状态的概率：

$$b_j(k) = Pr(y_t | i_t = S_j), k = 1, 2, \dots, M; j = 1, 2, \dots, N$$

初始状态概率向量 Pr_{start} ， $Pr_{start} = (Pr_{start,i})$ ，表示在市场在初始时刻处于各个状态的概率：

$$Pr_{start,i} = Pr(i_1 = S_i), i = 1, 2, \dots, N$$

我们现在用 θ 来表示这个隐马尔科夫模型需要被估计的所有参数。

$$\theta = (Pr, B, Pr_{start}, \mu, \Sigma)$$

那么可以用如下公式表示这里的隐马尔科夫模型：

$$Pr(Y | \theta) = \sum_I Pr(Y, I | \theta) = \sum_I Pr(I | \theta) Pr(Y | I, \theta)$$

接下来，我们用 EM 算法 (Expectation Maximization Algorithm) 来估计参数。EM 算法是一种迭代算法，用于含有隐变量概率模型参数的极大似然估计。EM 算法的具体步骤详见附录。

3. BL 模型与马尔科夫链的结合

3.1. 均衡收益率与主观观点权重

均衡收益率是 BL 模型的起点，是通过逆向优化计算得到的，

$$\Pi = \delta \Sigma w_{eq} \quad (5)$$

我们直接假定风险厌恶系数=2。在每个调仓日，使用过去一年的历史数据计算协方差，并根据当日行业指数自由流通市值权重来计算均衡收益率。

主观观点权重 τ 是一个标量，它的大小与均衡收益率及主观观点之间的权重高低有关， τ 值越小，主观观点的权重越低，均衡收益率权重越高。

本篇报告中设定 $\tau = 0.25$ 。

3.2. 马尔科夫链生成主观观点矩阵 P 和收益向量 Q

首先，我们假设马尔科夫链模型有两个状态，即 $S = \{S_1, S_2\}$ ，需要说明的是， S_1 、 S_2 并没有具体的表现形式。

其次，在每一个状态下，假设资产涨跌幅呈多元正态分布。假设我们有十个资产，状态概率矩阵 Pr 为一个 2×2 矩阵：

$$\begin{aligned} Pr_t &= [Pr(S_{t+1} = S_1) \quad Pr(S_{t+1} = S_2)] \\ &= \begin{bmatrix} Pr(S_{t+1} = S_1 | S_t = S_1) & Pr(S_{t+1} = S_2 | S_t = S_1) \\ Pr(S_{t+1} = S_1 | S_t = S_2) & Pr(S_{t+1} = S_2 | S_t = S_2) \end{bmatrix} \end{aligned}$$

对于其中的每一个元素，有：

$$Pr(S_{t+1} | S_t = S_j) \sim N(\mu_t, \Sigma_t), \mu_t \in \mathcal{R}_{10}, \Sigma_t \in \mathcal{R}_{10 \times 10}$$

在 EM 算法初始化时，也就是生成 Pr_{start} 时， μ_t 中的每一个元素是从 0 到 0.01 的均匀分布中生成的。而为了保证正定对称，我们假设 Σ_t 为一个对角矩阵，对角线上的每个元素为从 0.0001 到 0.0011 的均匀分布中抽取出来的随机值。

我们根据初始化生成的初始状态概率向量 Pr_{start} 、通过对资产涨跌幅历史数据的拟合，得到状态概率矩阵 Pr_t 。如果一个马尔科夫链有遍历性质 (ergodic)，那么存在一个马尔科夫链平稳分布 (stationary distribution) π_{stat} ：

$$\pi_{stat} = \pi_{stat} Pr_t = \lim_{k \rightarrow \infty} (Pr_t)^k$$

这里我们使 $\pi_{stat} = (Pr_t)^{1000} = [\pi_{S1} \quad \pi_{S2}]$ ， π_{S1} 和 π_{S2} 分别表示在平稳分布中市场处于状态 1 和状态 2 的概率。

对于每一个状态，马尔科夫链模型都在隐变量参数的估计中预测了相应的涨跌幅及协方差：

$$\mu = [\mu_{S1} \quad \mu_{S2}]$$

$$\Sigma = [\Sigma_{S1} \quad \Sigma_{S2}]$$

其中,

$\mu_{S_i} = E[Y_t | S_t = S_i]$, 为 10×1 向量

$\Sigma_{S_i} = \text{Var}(Y_t | S_t = S_i)$, 为 10×10 矩阵

接下来, 我们将平稳分布向量 π_{stat} 中的元素作为各个状态下涨跌幅与协方差的权重, 以计算资产条件均值向量 $\mu_{average}$ 和资产条件均值方差矩阵 $\Sigma_{average}$:

$$\mu_{average} = E[Y_n] = \mu \pi_{stat}' = \pi_{S1} \mu_{S1} + \pi_{S2} \mu_{S2}$$

$$\Sigma_{average} = \text{Var}[Y_n]$$

$$\approx \pi_{S1} \Sigma_{S1} + \pi_{S2} \Sigma_{S2} + (\pi_{S1} \pi_{S2}) (\mu_{S1} - \mu_{S2}) (\mu_{S1} - \mu_{S2})'$$

$\Sigma_{average}$ 的前两项表示两个平稳状态下市场波动对于总波动的贡献, 最后一项表示状态转移时市场波动对于总波动的贡献。

我们把所生成的资产条件均值向量 $\mu_{average}$ 作为我们的主观观点, 这里的主观观点均为绝对观点。这里以 10 个行业资产为例, 假设根据马尔科夫链拟合出 10 个行业的资产条件均值向量 $\mu_{average}$ (%) 为:

$$[1 \quad 4 \quad 4 \quad -3 \quad 5 \quad 2 \quad 0 \quad -2 \quad 3 \quad -1]'$$

由于我们对行业的观点都为绝对观点, 因此主观观点矩阵 P 为 10×10 的单位矩阵, 根据

$$P \cdot \mu_{average} = Q$$

我们可以得到收益向量 Q (%) :

$$[1 \quad 4 \quad 4 \quad -3 \quad 5 \quad 2 \quad 0 \quad -2 \quad 3 \quad -1]'$$

我们将绝对观点和过去资产涨跌幅的历史数据结合起来, 根据式(1)和式(2), 来产生 BL 模型的后验收益向量 μ_p 和后验收益协方差矩阵 Σ_p^* 。

3.3. 观点协方差矩阵 Ω

协方差矩阵 Ω 是主观观点的方差, 它反映了主观观点的不确定性。由于假定各观点之间互相独立, 并且本例中投资者有 10 个主观观点, 因此 Ω 是 10×10 的对角矩阵。矩阵对角线元素的数值越大, 则该观点的确信度越低; 元素数值越小, 该观点的确信度越高。

我们运用 He & Litterman(1999)的方法计算 Ω ，假定 Ω 矩阵元素值与资产涨跌幅的波动率成正比：

$\Omega = \tau \cdot \text{diag}(P\Sigma P^T)$ ，其中 $\text{diag}()$ 表示对角矩阵。根据马尔科夫链模型，我们在这里用上文拟合而得出的资产条件均值方差矩阵 $\Sigma_{average}$ 来表示 Σ 。

4. BL-马尔科夫链行业组合回测结果

4.1. 行业轮动模型参数设置

模型回测时，行业选择范围为全部 28 个申万一级行业，我们每个季度从中选取三个行业，回测区间为 2010 年至 2021 年 7 月。我们使用过去三个月的行业指数涨跌幅数据对马尔科夫链模型进行拟合，用拟合结果生成 BL 观点，进而计算 BL 后验权重。

在根据 EM 算法进行马尔科夫链的拟合时，由于受编程工具计算能力的限制，我们无法一次对 28 个行业数据进行拟合。因此我们将申万一级行业按行业代码顺序分为三组，每组分别有 10、10、8 个行业，分别对每组进行拟合。其次，为寻找拟合程度较高的马尔科夫链模型，我们会对每一组进行 10 次的拟合，取最大期望 q 值的马尔科夫链模型参数作为我们的结果。

由于我们直接根据效用函数逆向优化计算资产权重，不添加单个资产的权重约束，资产条件均值向量 $\mu_{average}$ 中为负的元素所对应的资产权重则为负值。在实际投资中，我们将负权重资产剔除，保留正值权重最高的 3 个行业。

为了检验马尔科夫链模型与 BL 模型结合的有效性，首先，我们将 BL-马尔科夫链行业组合与直接马尔科夫链行业组合走势进行了对比。直接马尔科夫链行业组合仅根据拟合得出的资产条件均值 $\mu_{average}$ ，选择排名最靠前的三个行业，并将其设置为等权。其次，我们将 BL-马尔科夫链行业组合与相同行业名单下的等权组合、市值加权组合进行了对比。结果显示，BL-马尔科夫链模型的行业轮动组合是最优的。


4.2. 行业轮动模型的回测结果

4.2.1. BL-马尔科夫链组合优于直接马尔科夫链组合

2010-2021/7/31，BL-马尔科夫链组合上涨 322.69%，直接马尔科夫链组合上涨 213.75%，同期中证全指上涨 47.75%。


BL-马尔科夫链组合累计超额收益为 274.94%，年化涨幅为 13.25%，年化超额收益为 12.37%，走势结果优于基准指数，也优于直接马尔科夫链组合。

图 1 BL-马尔科夫链组合、直接马尔科夫链组合走势与基准指数对比



，注：将中证全指 2009 年末值调整为 1

图 2 BL-马尔科夫链组合和直接马尔科夫链组合对中证全指的超额收益




4.2.2. BL 组合权重优于等权加权与市值加权组合

根据模型理论，由马尔科夫链拟合得出的资产条件均值越高，BL 主观观点中行业的绝对收益越高，BL 后验权重也就越高。为了验证模型有效性，我们进一步保持所选行业名单不变，但使用不同的加权方式，即将 BL 权重组合与等权加权组合、市值加权组合进行对比。结果显示，BL 权重组合优于等权加权、市值加权组合，这说明马尔科夫链模型能够形成较为有效的 BL 主观观点，这验证了模型的有效性。

请仔细阅读在本报告尾部的重要法律声明


图 3 BL-马尔科夫链组合与其他加权方式对比



4.3. 行业数量的敏感性

我们保持 BL 模型中其他参数不变，仅改变所选行业数量，探究行业数量对于组合走势的影响。我们将行业数量分别设定为 1 到 10 个，以 BL 后验权重作为我们的行业组合权重。在 BL-马尔科夫链行业组合中，所选行业数量越少，组合超额收益越高，说明 BL-马尔科夫链模型精度较高，权重排名越靠前的行业表现越好。但由于行业数量减少，组合风险难以分散，组合的波动率也越大。

图 4 BL-马尔科夫链组合对行业数量的敏感性



请仔细阅读在本报告尾部的重要法律声明

5. 附录：EM 算法的详细步骤

EM 算法的每次迭代由两步组成：

1. E 步（求期望），我们需要求期望函数 q ：

$$q(\theta, \tilde{\theta}) = \sum_I \log \Pr(I | \theta) \Pr(Y, I | \tilde{\theta})$$

$$= \sum_I \log \Pr_{start,i} \Pr(Y, I | \tilde{\theta}) + \sum_I \left(\sum_{t=1}^{T-1} \log p_{i_t i_{t+1}} \right) \Pr(Y, I | \tilde{\theta}) + \sum_I \left(\sum_{t=1}^T \log f_{i_t}(y_t) \right) \Pr(Y, I | \tilde{\theta})$$

2. M 步（求极大），我们需要最大化 q 函数。

首先，对于 q 函数的前两项，我们通过递推可以得到状态概率的值：

$$\Pr_{start,i} = \gamma_1(i)$$

$$p_{ij} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)}$$

其中，

$$\gamma_t(i) = \frac{\alpha_t(i) \beta_t(i)}{\sum_{j=1}^N \alpha_t(j) \beta_t(j)} \quad (6)$$

$$\xi_t(i, j) = \frac{\alpha_t(i) \beta_{t+1}(j) p_{ij} f_j(y_{t+1})}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) \beta_{t+1}(j) p_{ij} f_j(y_{t+1})} \quad (7)$$

$$\alpha_t(i) = \Pr(y_1, y_2, \dots, y_t, i_t = S_i | \theta)$$

$$\beta_t(i) = \Pr(y_{t+1}, y_{t+2}, \dots, y_T | i_t = S_i, \theta)$$

这里的 γ_t 是指在当前观测序列和模型参数下市场在时刻 t 处于状态 i 的概率； ξ_t 为当前观测序列和模型参数下在时刻 t 处于状态 i 、且时刻 $t+1$ 处于状态 j 的概率。 $f_j(y_{t+1})$ 是均值为 μ_{jt+1} ，方差为 σ_{jt+1}^2 的多元正态分布所对应的概率密度函数。

对于 $\alpha_t(i)$ 的算法为：

- 1) 初始值： $\alpha_1(i) = \Pr_{start,i} b_i(y_1), i = 1, 2, \dots, N$
- 2) 递推：对 $t = 1, 2, \dots, T-1$

$$\alpha_{t+1}(i) = \left(\sum_{j=1}^N \alpha_t(j) p_{ji} \right) f_i(y_{t+1}), i = 1, 2, \dots, N$$

对于 $\beta_t(i)$ 的算法为：

- 1) 初始值： $\beta_T(i) = 1, i = 1, 2, \dots, N$
- 2) 递推：对 $t = T-1, T-2, \dots, 1$

$$\beta_t(i) = \sum_{j=1}^N p_{ij} f_j(y_{t+1}) \beta_{t+1}(j), i = 1, 2, \dots, N$$

其次，为使 q 函数的第三项最大化：

$$\sum_I \left(\sum_{t=1}^T \log f_{i_t}(y_t) \right) \Pr(Y, I | \tilde{\theta}) = \sum_{j=1}^N \sum_{t=1}^T \log f_{i_t}(y_t) \Pr(Y, i_t = j | \tilde{\theta}) \quad (8)$$

我们对式(8)展开、删掉常数并且乘以-2后：

$$\sum_{j=1}^N \sum_{t=1}^T [\log \det(\Sigma_j) + (Y_t - \mu_j)^T \Sigma_j^{-1} (Y_t - \mu_j)] Pr(Y, i_t = j | \tilde{\theta})$$

对 μ_j 求导并令导数值等于 0 后，我们得到：

$$\mu_j^* = \frac{\sum_{t=1}^T Y_t Pr(Y, i_t = j | \tilde{\theta})}{\sum_{t=1}^T Pr(Y, i_t = j | \tilde{\theta})} = \frac{\sum_{t=1}^T Y_t \alpha_t(j) \beta_t(j)}{\sum_{t=1}^T \alpha_t(j) \beta_t(j)}$$

对 Σ_j 求导并令导数值等于 0 后，我们得到：

$$\Sigma_j^* = \frac{\sum_{t=1}^T [(Y_t - \mu_j)^T (Y_t - \mu_j)] \alpha_t(j) \beta_t(j)}{\sum_{t=1}^T \alpha_t(j) \beta_t(j)}$$

这是每一次迭代得到的 μ_j 和 Σ_j 的新值。

我们最终的算法为：

- 1) 输入：观测数据 $Y = \{y_1, y_2, \dots, y_T\}$
- 2) 初始化：对 $n=0$ ，选取 $p_{ij}^{(0)}, b_j^{(0)}(k), Pr_{start,i}^{(0)}, \mu_i^{(0)}, \Sigma_j^{(0)}$ ，得到

$$\theta^{(0)} = (Pr^{(0)}, B^{(0)}, Pr_{start}^{(0)}, \mu_i^{(0)}, \Sigma_j^{(0)})$$
- 3) 递推：对 $n = 0, 1, 2, \dots$

$$\begin{aligned} Pr_{start,i}^{(n+1)} &= \gamma_1(i) \\ p_{ij}^{(n+1)} &= \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \\ b_j(k)^{(n+1)} &= \frac{\sum_{t=1, y_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)} \\ \mu_j^{(n+1)} &= \frac{\sum_{t=1}^T Y_t \alpha_t(j) \beta_t(j)}{\sum_{t=1}^T \alpha_t(j) \beta_t(j)} \\ \Sigma_j^{(n+1)} &= \frac{\sum_{t=1}^T [(Y_t - \mu_j^{(n+1)})^T (Y_t - \mu_j^{(n+1)})] \alpha_t(j) \beta_t(j)}{\sum_{t=1}^T \alpha_t(j) \beta_t(j)} \end{aligned}$$

等式右边的值根据 Y 和模型 $\theta^{(n)} = (Pr^{(n)}, B^{(n)}, Pr_{start}^{(n)}, \mu_j^{(n)}, \Sigma_j^{(n)})$ 计算。

其中 $\gamma_t(i)$ 和 $\xi_t(i, j)$ 根据式(6)和式(7)计算。

式(6)和式(7)中的 $\alpha_t(i)$ 和 $\beta_t(i)$ 需要用现有的 $\theta^{(n)}$ 递推计算。

- 4) 终止：当 q 函数的取值收敛时，我们终止递推，最终得到所求参数：

$$\theta^{(n+1)} = (Pr^{(n+1)}, B^{(n+1)}, Pr_{start}^{(n+1)}, \mu_j^{(n+1)}, \Sigma_j^{(n+1)})$$

6. 风险提示

量化报告的结论基于历史统计规律，当历史规律发生改变时，报告中的模型和结论可能失效。

分析师与研究助理简介

杨国平：复旦大学博士，华西证券研究所副所长，金融工程首席分析师。曾任申万研究所董事总经理，金融工程部总监，首席分析师，25年证券从业经验。

张立宁：南开大学硕士，华西证券研究所金融工程高级分析师。曾任申万研究所金融工程部资深高级分析师，15年金融工程相关研究经验，在择时、量化选股、指数研究、数据分析等领域具有丰富的研究经验。

丁睿雯：英国剑桥大学金融与经济学硕士，华西证券研究所金融工程助理分析师。

分析师承诺

作者具有中国证券业协会授予的证券投资咨询执业资格或相当的专业胜任能力，保证报告所采用的数据均来自合规渠道，分析逻辑基于作者的职业理解，通过合理判断并得出结论，力求客观、公正，结论不受任何第三方的授意、影响，特此声明。

评级说明

公司评级标准	投资评级	说明
以报告发布日后的6个月内公司股价相对上证指数的涨跌幅为基准。	买入	分析师预测在此期间股价相对强于上证指数达到或超过15%
	增持	分析师预测在此期间股价相对强于上证指数在5%—15%之间
	中性	分析师预测在此期间股价相对上证指数在-5%—5%之间
	减持	分析师预测在此期间股价相对弱于上证指数5%—15%之间
	卖出	分析师预测在此期间股价相对弱于上证指数达到或超过15%
行业评级标准		
以报告发布日后的6个月内行业指数的涨跌幅为基准。	推荐	分析师预测在此期间行业指数相对强于上证指数达到或超过10%
	中性	分析师预测在此期间行业指数相对上证指数在-10%—10%之间
	回避	分析师预测在此期间行业指数相对弱于上证指数达到或超过10%

华西证券研究所：

地址：北京市西城区太平桥大街丰汇园11号丰汇时代大厦南座5层

网址：<http://www.hx168.com.cn/hxzq/hxindex.html>

华西证券免责声明

华西证券股份有限公司（以下简称“本公司”）具备证券投资咨询业务资格。本报告仅供本公司签约客户使用。本公司不会因接收人收到或者经由其他渠道转发收到本报告而直接视其为本公司客户。

本报告基于本公司研究所及其研究人员认为的已经公开的资料或者研究人员的实地调研资料，但本公司对该等信息的准确性、完整性或可靠性不作任何保证。本报告所载资料、意见以及推测仅于本报告发布当日的判断，且这种判断受到研究方法、研究依据等多方面的制约。在不同时期，本公司可发出与本报告所载资料、意见及预测不一致的报告。本公司不保证本报告所含信息始终保持在最新状态。同时，本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者需自行关注相应更新或修改。

在任何情况下，本报告仅提供给签约客户参考使用，任何信息或所表述的意见绝不构成对任何人的投资建议。市场有风险，投资需谨慎。投资者不应将本报告视为做出投资决策的惟一参考因素，亦不应认为本报告可以取代自己的判断。在任何情况下，本报告均未考虑到个别客户的特殊投资目标、财务状况或需求，不能作为客户进行客户买卖、认购证券或者其他金融工具的保证或邀请。在任何情况下，本公司、本公司员工或者其他关联方均不承诺投资者一定获利，不与投资者分享投资收益，也不对任何人因使用本报告而导致的任何可能损失负有任何责任。投资者因使用本公司研究报告做出的任何投资决策均是独立行为，与本公司、本公司员工及其他关联方无关。

本公司建立起信息隔离墙制度、跨墙制度来规范管理跨部门、跨关联机构之间的信息流动。务请投资者注意，在法律许可的前提下，本公司及其所属关联机构可能会持有报告中提到的公司所发行的证券或期权并进行证券或期权交易，也可能为这些公司提供或者争取提供投资银行、财务顾问或者金融产品等相关服务。在法律许可的前提下，本公司的董事、高级职员或员工可能担任本报告所提到的公司的董事。

所有报告版权均归本公司所有。未经本公司事先书面授权，任何机构或个人不得以任何形式复制、转发或公开传播本报告的全部或部分内容，如需引用、刊发或转载本报告，需注明出处为华西证券研究所，且不得对本报告进行任何有悖原意的引用、删节和修改。