

2021 年 09 月 06 日

看好

Wintel 生态壁垒是否会在 AI 芯片领域重演

——全行业 AI 赋能系列深度之四

相关研究

"计算机中报整体如何？北交所刺激券商 IT！-计算机行业周报 20210830-20210903" 2021 年 9 月 4 日
"数据安全主旋律，行业继续高景气——信息安全行业 21Q2 季报回顾" 2021 年 9 月 3 日

证券分析师

蒲梦洁 A0230519110002
pumj@swsresearch.com
施鑫展 A0230519080002
shixz@swsresearch.com
洪依真 A0230519060003
hongyz@swsresearch.com
杨海燕 A0230518070003
yanghy@swsresearch.com
骆思远 A0230517100006
MarkLo@swsresearch.com
刘洋 A0230513050006
liuyang2@swsresearch.com
周海晨 A0230511040036
zhouhc@swsresearch.com

联系人

蒲梦洁
(8621)23297818×转
pumj@swsresearch.com

本期投资提示：

- **本文只探究一个问题：AI 软件生态壁垒是否将成为永远无法跨越的鸿沟，而使得除了英伟达之外的 AI 芯片公司后续都没有从英伟达手中抢夺份额机会了？**目前在数据中心 AI 芯片市场的现状是英伟达凭借 AI 软件生态壁垒占据了 97%以上绝对垄断份额，AMD、谷歌、华为昇腾、寒武纪等公司均为追赶者的角色力争突围。英伟达之所以能长期保持垄断地位靠的就是其 AI 软件所塑造的生态壁垒。
- **如何初步理解 AI 生态壁垒：**与同样生态壁垒非常强的 PC 领域类比，AI 芯片相当于 CPU，深度学习框架相当于 OS。为了最大程度发挥芯片本身性能，PC 需要 OS 厂商和 CPU 厂商一起来做联合优化；AI 需要深度学习框架厂商和 AI 芯片厂商一起来做联合优化。即使 AI 芯片性能本身和英伟达接近，但是深度学习框架厂商不愿意做特定支持，那也无法使得用户更换芯片。
- **AI 芯片的整体性能=AI 芯片硬件性能×（AI 芯片厂商算子库和工具链+深度学习框架支持），AI 基础软件指的是括号内部分，AI 芯片公司需要做的软件是括号内的第一部分。**AI 芯片整体性能取决于芯片硬件以及上层的基础软件两部分，后者主要作用是将 AI 芯片硬件性能充分“压榨”出来，上述两部分任何一个存在短板都将使得整个智能系统低效。基础软件中 AI 芯片公司要做的部分主要是智能编程语言、深度学习算子库、配套工具链（包括编译器、调试器、性能分析工具、系统监控工具）。
- **如何深度理解 AI 生态壁垒：生态壁垒产生的根源在于软硬件的高度耦合，体现在 AI 领域具体是指算子和 AI 芯片硬件的高度耦合。**深度学习框架中的高层算子需要用底层算子去表示，高层算子由深度学习框架厂商进行优化，而底层算子的优化需要靠 AI 芯片公司人工写库函数，做深度学习框架最大的工作量就是对海量算子和特定芯片的支持。但是由于各 AI 芯片指令集和智能编程语言的不同，底层算子无法兼容，所以使得深度学习框架厂商每支持一家 AI 芯片，都需要基于这家公司的芯片把算子重新开发一遍，进而使得其对 AI 芯片的支持相对谨慎，一般只全力支持市占率最大的 1-2 家公司的芯片。
- **目前业界正在探索深度编译器来解决 AI 软硬件高度耦合的问题，有希望使得 AI 系统软件和芯片之间的配合没有 PC 领域“Wintel”那么紧密。**
- **各家 AI 芯片公司采取了不同的路线来突破 AI 生态壁垒：**（1）AMD 在走部分兼容 CUDA 的路线，借力英伟达生态；（2）寒武纪等厂商在走英伟达的路线；（3）谷歌、华为、百度走的是“深度学习框架+AI 芯片”自研路线。
- **但目前各家 AI 芯片公司也都遇到了各自的瓶颈：**（1）AMD：走兼容英伟达 CUDA 的路线其难点在于其更新迭代速度永远跟不上 CUDA 并且很难做到完全兼容。（2）寒武纪等厂商：芯片本身性能以及算子库丰富程度还有追赶空间，没有深度学习框架厂商基于芯片做特定优化；（3）谷歌：不像其他家存在生态壁垒需要突破，其主要问题在于 TPU 本身性能还有进一步提升空间以及过于专用的问题。（4）华为：没有深度学习框架厂商主动支持，其自研的 MindSpore 框架尚未解决 Tensorflow/Pytorch 面临的共同痛点。
- **突破 AI 生态壁垒的三种可能机会：**从苹果 MacOS X 案例可以推测，当任何一家 AI 芯片公司能够从英伟达手中逐渐拿走 10%份额的时候，深度学习框架厂商也大概率会去逐渐投入为该厂商的 AI 芯片去做特定优化。拿到 10%份额的可能机会会有三种：AI 编译器的成熟、芯片性能和英伟达相比具备明显优势、等待英伟达失误。
- **风险提示：**非市场因素导致芯片制造环节遭遇瓶颈风险；关键研发人员流失风险；客户自研 AI 芯片风险。



申万宏源研究微信服务号

投资案件

结论和投资建议

英伟达所建立的 AI 生态壁垒并不是牢不可破的，我们认为当任何一家 AI 芯片公司能够从英伟达手中逐渐拿走 10% 份额的时候，深度学习框架厂商也大概率会去逐渐投入为该厂商的 AI 芯片去做特定优化，生态就会起来。

拿走 10% 份额的机会会有三个：AI 编译器的成熟、芯片性能和英伟达相比具备明显优势、等待英伟达失误。

原因及逻辑

之所以认为 10% 份额是生态突破的关键临界点，是参考了 PC 时代苹果 MacOS X 在 2012 年桌面操作系统的市占率为 9.3%，虽然份额不高，但是软件应用数量是 windows 生态的 62%——这说明虽然苹果 MacOS X 市占率不高，但是开发者非常愿意去为苹果桌面生态开发软件。

之所以认为 AI 编译器成熟是机会之一，是因为 AI 编译器其主要解决的是算子自动开发优化的问题，以及将训练好的模型部署到各种 AI 芯片上的问题，可以使得深度学习框架厂商和 AI 芯片厂商从投入大量人力去支持/开发海量算子的工作中解脱出来，从而实现 AI 软硬件的解耦，破除生态壁垒。

之所以认为芯片性能具备明显优势是机会之二，是因为 AI 芯片整体的性能是由基础软件和芯片硬件本身共同决定的，虽然没有深度学习框架厂商进行针对性优化，但是如果能够靠芯片硬件本身性能非常突出，是有机会使得芯片整体性能具备优势的。

之所以认为等待英伟达失误是机会之三，是参考了 PC 时代 AMD 在英特尔两次犯错时分别获得了明显市占率提升的机会去推演得出的结论。

有别于大众的认识

市场认为 AI 生态壁垒很难突破，我们认为未来有三个机会可以破除 AI 壁垒。

市场过度关注 AI 芯片硬件本身，而忽略了 AI 软件对 AI 芯片整体性能发挥以及生态上的影响。

目录

1.AI 芯片的竞争点不止是芯片本身.....	7
2.前车之鉴：PC 时代的 Wintel 联盟.....	8
2.1 五次失败的冲击：五种不同的致命失误.....	10
2.2 两次成功的冲击：AMD 的崛起+苹果封闭生态的建立.....	17
2.3 总结：不能做错什么？应该做对什么？.....	22
3.AI 芯片生态壁垒如何破局？.....	23
3.1 AI 生态与 PC 生态的相同和不同.....	23
3.2 各家所选取的 AI 生态突围路线.....	30
3.3 后记：生态壁垒是现在的阻碍，但不是永远的阻碍.....	35

图表目录

图 1：在主流的芯片设计中，随工艺节点的演进，设计成本变化的趋势和分布（不包括生产成本）	7
图 2：智能计算系统体系结构层次	7
图 3：以 CPU/GPU/DLP 为基础的计算系统所对应的体系结构以及各软件层编程语言	8
图 4：各厂商 PC 收入（1977-1984 年）	9
图 5：自 1984 年起，PC 产业正式开启 Wintel 时代	9
图 6：IBM、苹果和克隆机厂商 PC 市场份额变化（1981-1994 年）	11
图 7：从 1988 年开始出现了各种版本的 UNIX 操作系统	12
图 8：苹果历代 PC 产品演进（1976-2005 年）	13
图 9：苹果在上世纪 90 年代曾陷入亏损低迷期	15
图 10：历年代表性电脑价格：苹果 PC 定价偏高	15
图 11：RISC（精简指令集）在上世纪 90 年代曾盛极一时	16
图 12：MIPS 和 ARM 商业模式以及定价、生态策略对比	17
图 13：英特尔和 AMD 历年微架构迭代时间轴（1993-2008 年）	18
图 14：PC 旗舰级 CPU 跑分：2003-2006 年 AMD 性能领先于英特尔	19
图 15：PC 旗舰级 CPU 跑分：2006 年 7 月英特尔推出酷睿 2 之后，直至 2017 年英特尔相较于 AMD 一直保持领先优势	19
图 16：英特尔自 2006-2015 年期间严格执行 Tick-Tock 战略，2016 年起由于工艺制程问题限于停滞	19
图 17：AMD 发布的第一代锐龙架构相较于上一代架构性能有大幅提升	20
图 18：2018 年 AMD 第二代锐龙架构已经进入 7nm 制程	20
图 19：PC 旗舰级 CPU 跑分：2017 年 3 月 AMD 推出锐龙架构，性能开始超越英特尔	20
图 20：截至 2021 年 8 月最新 CPU 性能天梯图（最顶部）：AMD 仍然领先于英特尔	20
图 21：台式电脑 CPU 市场份额变化	21
图 22：笔记本电脑 CPU 市场份额变化	21
图 23：2012 年底各类 OS 生态应用软件数量	21

图 24 : MacOS X 市占率变化 (2004-2008 年)	21
图 25 : 冲击 Wintel 的成功和失败案例原因汇总	23
图 26 : 算法开发的三个阶段以及对应的智能计算系统结构	23
图 27 : 高层算子需要调用 CUDA Kernel 函数这样的底层算子原语	24
图 28 : 经深度学习框架厂商特别优化后的算子有时比 cuDNN 直接提供的算子运行更快 (以 Softmax 算子为例 , OneFlow 为国产深度学习框架)	24
图 29 : NV 的软件栈抽象层次 (NV 的智能编程语言是 CUDA)	25
图 30 : 不同 AI 芯片指令集不同 , 因此智能编程语言互不兼容	25
图 31 : 深度学习编译器借鉴了传统编译器原理 (传统编译器以 LLVM 为例)	26
图 32 : 用于深度神经网络的通用编译框架 (虚线框中为算子优化)	27
图 33 : 常用深度学习编译器对比	28
图 34 : 使用 TVM 编译器在某些模型端到端推理性能上能获得 3 倍以上加速 ..	28
图 35 : 使用 TVM 编译器在跨硬件平台时性能表现	28
图 36 : Tensorflow 和 Pytorch 是目前最主流的深度学习框架	29
图 37 : 每年各 AI 顶级研究会议所接收的 PyTorch 论文数占 TensorFlow 和 PyTorch 的论文数总和的比率	29
图 38 : AMD 的 ROCm 是和英伟达 CUDA 对等的智能编程语言	31
图 39 : AMD 的 HIPify 工具可以将英伟达 CUDA 代码转换为 ROCm 代码 ...	31
图 40 : 英伟达的 CUDA 栈	31
图 41 : AMD 的 ROCm 栈	31
图 42 : 华为在 AI 领域全栈自研 : 从底层芯片到智能编程语言再到深度学习框架	34
图 43 : MindSpore 和 Pytorch 结合各类芯片训练速度 (单位 : 张/秒)	34
图 44 : 寒武纪针对原生 TensorFlow 的修改 (深灰色部分)	35
图 45 : 寒武纪的端云一体软件栈架构	35
图 46 : 英伟达在数据中心占据 97% 以上份额	36
表 1 : IBM PS/2 系统初代机的机型与配置	10
表 2 : 国内外主流深度学习框架以及支持的硬件设备	25
表 3 : 谷歌历代推理和训练芯片性能参数	32
表 4 : 英伟达主流推理和训练芯片性能参数	32

表 5：华为主流推理和训练芯片性能参数	33
表 6：寒武纪 AI 芯片性能参数.....	35
表 7：AI 芯片行业重点公司估值表.....	36

1.AI 芯片的竞争点不止是芯片本身

接触或者研究过 AI 芯片的投资者可能会对于这样的现象有诸多费解：

黄仁勋在 2019 年 Q3 季度财报业绩电话会议提到：“英伟达已经成为了一家软件公司”；华为昇腾计算业务总裁许映童在 2020 年昇腾 AI 新品全球发布会上表示：“昇腾 AI 领域目前有 70% 的研发人员投入到软件开发”。


——AI 芯片作为硬科技产品，为何主要厂商对软件开发这么重视？甚至是连英伟达都觉得 AI 芯片公司本质其实是软件公司？

智能计算系统分为硬件和软件两部分：从指令集到物理层是硬件部分，从应用层到指令集是软件部分——大家多度关注前者关于 AI 芯片本身的硬件设计，而忽视了 AI 芯片设计公司已经往上做到了部分软件层的事实。智能计算系统自上而下可以分为应用软件、算法、编程语言、汇编语言、机器码、指令集、微体系结构、门、计算器器件、物理层。其中指令集是智能计算系统软硬件之间的接口，AI 芯片公司定义完指令集后根据指令集去设计微体系结构去支持指令集。从最上层应用软件到指令集为软件部分，从指令集到物理层为硬件部分。针对硬件部分 AI 芯片公司对应的设计工作包括怎样把指令集做得非常快、流水线设计、运算部件怎么做、访存部件怎么做，最后需要软硬件之间的映射等——大家通常理解的 AI 芯片设计公司需要做的工作只有上述关于 AI 芯片本身的硬件部分的设计；而实际上 AI 芯片公司还往上一直做到了编程语言为止的三层软件，这一点往往被绝大多数投资者忽视了。

软件已经成为 AI 新芯片公司 IC 设计成本中最“重”的投入。根据 IBS 的数据，随着工艺制程的演进，主流芯片设计成本中软件将成为占比最大的投入，而 Verification、Validation、IP Qualification 为相较于软件投入占比依次往下。


图 1：在主流芯片设计中，随工艺节点的演进，设计成本变化的趋势和分布（不包括生产成本）

Design Cost Trends with Reduction in Feature Dimensions (Mainstream Designs)



资料来源：StarryHeavensAbove 公众号，IBS，申万宏

图 2：智能计算系统体系结构层次



资料来源：《智能计算系统》，申万宏源研究

2.前车之鉴：PC 时代的 Wintel 联盟

英伟达靠 AI 软件工具链已经塑造出来了强大的生态壁垒和护城河——这已经是产业界和投资界公认的事实，而且英伟达凭借这一优势一直保持数据中心 AI 市场 97%以上绝对垄断的份额。但是相较于现状，大家更关心终局：

AI 软件生态壁垒是否将成为永远无法跨越的鸿沟，而使得除了英伟达之外的 AI 芯片公司后续都没有从英伟达手中抢夺份额机会了？

我们可以从 PC 时代 CPU 从产业初期混战到如今产业成熟这段经典商业史中探索这一问题的启发性答案。CPU、GPU 从产业角度上而言其实有诸多相似之处：龙头垄断市场（CPU 由英特尔垄断；AI 芯片由英伟达垄断）；靠系统软件形成了极强的产业生态（英特尔+微软；英伟达靠 AI 软件工具链+深度学习框架）。

图 3：以 CPU/GPU/DLP 为基础的计算系统所对应的体系结构以及各软件层编程语言

应用程序	各种应用软件	移动APP等	超算、AI应用		AI应用
高级语言	C语言/C++/java/Python/Fortran/BASIC等				
智能编程语言			CUDA	ROCm	BANG
汇编语言	X86汇编	AMD汇编	SASS	?	MLISA
操作系统	Windows	安卓	Tensorflow/Pytorch/Paddle paddle/Jittor等		
机器语言	与指令集中指令相对应，每一个CPU/GPU/DLP机器码都不同				
指令集	CISC	RISC	PTX	GCN	MLU
电子线路					
	X86-CPU	ARM-CPU	GPU	GPU	DLP
	英特尔&AMD	高通&华为	英伟达	AMD	寒武纪

资料来源：申万宏源研究


1975 年，微处理器市场伊始，有 6 个主要玩家参与市场角力。彼时已经发布了 4004、8008 和 8080 微处理器的英特尔并不被看好：大家认为英特尔的芯片不如齐洛格好，不能像摩托罗拉那样大批量生产，不如 MOS Technologies 的便宜，不能顶住德州仪器的价格战。

20 世纪 70 年代后期，苹果占据了小型计算机 PC 市场 90%以上份额，IBM 占据了大型计算机市场 80%以上份额。为了迅速抢夺 PC 市场份额，IBM 想要在不到 1 年时间里就

把自己的个人计算机推向市场。为了完成这一计划，IBM 决定抛弃过去软硬件全自研的做法而采用开放式设计，向外采购 CPU 和操作系统。

1980 年夏天，IBM 分别找到了英特尔和微软。英特尔为 IBM 提供了 8088 中央处理器，微软为 IBM 设计了操作系统 MS-DOS。1981 年 8 月，IBM 个人计算机 PC-XT 推向市场并大获成功。自此苹果市场份额直线下滑，10 年之内其份额下降至个位数。1984 年，IBM 推出了第二代个人计算机 PC AT，里面安装了英特尔 286 处理器，是上一代 PC 计算速度的 3 倍，PC AT 取得巨大成功，一年之内 PC AT 占到所有 PC 销量的 70% 以上。

图 4：各厂商 PC 收入（1977-1984 年）




资料来源：IDC，申万宏源研究

后续由于 IBM 高层认为 PC 只能在市场的低档产品中找到出路，随着 PC 声势越来越大，IBM 为了避免 PC 吞噬其高端产品，所以停止了对 PC 的开发。为了保护低档小型机的销售，IBM 推迟发售装有英特尔 386 芯片的 PC（因为小型机相比于 386 个人计算机功率大不了多少）。

因此英特尔找到康柏合作，康柏在 1986 年首次独家推出搭载 MS-DOS 的 386 计算机（1982 年 6 月，康柏推出了第一台 IBM 兼容机），从而名声大噪，立即成为美国商业界的一个空前范例。IBM 市场份额不断缩小（1983 年 IBM 的份额为 76%，1986 年份额已经下降到 26%），各种克隆机厂商涌入市场，为了和 IBM PC 兼容，这些厂商基本上都采用的英特尔处理器和微软操作系统，自此正式开启了“Wintel”时代。

图 5：自 1984 年起，PC 产业正式开启 Wintel 时代



资料来源：IDC，申万宏源研究

2.1 五次失败的冲击：五种不同的致命失误

20 世纪 80-90 年代对 Wintel 生态主动发起冲击的著名事件一共有 5 次：（1）IBM 自研 OS/2 操作系统；（2）IBM、DEC 等发展 UNIX；（3）IBM、苹果、摩托罗拉联手打造 PowerPC 处理器；（4）苹果经典 MacOS；（5）RISC 阵营兴起。

上述对 Wintel 的冲击均以失败告终，从多个角度反映了生态壁垒难以突破的原因。

第一次冲击：OS/2

受到以康柏为代表的克隆机厂商的冲击，IBM 为了挽回颓势，从两方面出击：一个是软件，一个是硬件。1987 年 4 月，IBM 发布了一体化硬件/软件，硬件叫做 PS/2，运行新的操作系统 OS/2。

软件：OS/2 是 IBM 全公司软件计划的核心部分，由 IBM 负责设计，微软负责编写实际代码；但是与第一次合作不同的是，只有 IBM 拥有将该操作系统的授予第三方的权利。另外 IBM 还计划在 OS/2 上自己开发一整套办公室应用系统（名称为“办公视野”），IBM 希望有了这些应用软件，IBM 就会成为 PC 应用软件市场的主力。

硬件：IBM 在 PS/2 硬件上最大的特点是采用了“微通道总线”电路，但是 CPU 仍然采用的英特尔的 8086/80286/80386 处理器。由于采用了全新的硬件设计和操作系统，使得克隆机厂商不可能在短时间内仿制出类 PS/2 的产品。

表 1：IBM PS/2 系统初代机的机型与配置

机型	价格	操作系统	CPU	速度同 PC 机比较
PS/2 30 型（8530）	2295 美元	PC DOS 3.3	英特尔 8086 80286	比 PC/XT 快 1.9 倍


机型	价格	操作系统	CPU	速度同 PC 机比较
PS/2 50 型 (8550)	3595 美元	PC DOS 3.3 或者 OS/2	英特尔 80286	比 PC/AT 快 2 倍
PS/2 60 型 (8560)	5295 美元	PC DOS 3.3 或者 OS/2	英特尔 80286	比 PC/AT 快 2 倍
PS/2 80 型 (8580)	6995 美元	PC DOS 3.3 或者 OS/2	英特尔 80386	比 PC/AT 快 4 倍

资料来源：《新一代微机 IBM PS/2 及其在核技术领域中的应用》，申万宏源研究

1991 年 IBM 和微软终止了在 OS/2 的开发合作，由 IBM 单方面进行后续开发，另外“办公视野”的项目也被最终取消了。IBM 在 1987 年推出 OS/2 1.0，1988 年推出 OS/2 1.1，1992 年 OS/2 2.0 版本正式发布，这也是 OS/2 的正式可用版本。

在推出之后，IBM PS/2 系列产品在短期内销售得很好(大约在 1988 年 1 月售出了 150 万台)，但相对于 PC 兼容机，其相对较高的价格却让大多数消费者级用户望而却步。对于 IBM 来说更糟糕的是，它在 PS/2 中所做的每一项改进都被或克隆，然后被兼容机厂商超越。PS/2 的销售在上个世纪 80 年代的后期急剧下滑。到 1990 年，IBM 不再主导 PC 兼容机的市场了。1994 年，康柏取代 IBM 成为美国最大的个人 PC 生产商。2005 年 7 月，IBM 宣布在 2005 年底正式停止销售 OS/2。

图 6：IBM、苹果和克隆机厂商 PC 市场份额变化（1981-1994 年）



资料来源：IDC，申万宏源研究

IBM 通过自研 OS/2 对 Wintel 联盟发起的冲击失败，我们认为其主要原因是 IBM 在早期开发上犯错错过了窗口期+再加上定价上的失误进一步导致其生态建立的失败：

- 1、**早期开发上屡屡犯错**：1985 年 10 月英特尔已经发布了性能比 286 更好的 386 处理器，但是 IBM 坚持决定让 OS/2 适配 286 处理器（因为担心基于 386 处理器 PC 会吞噬其小型机市场）；IBM 一再坚持 OS/2 上的应用软件必须与其主计

算机和中型机系统兼容，所以最后第一版 OS/2 开发出来更像笨重复复杂的主计算机 OS 而非桌面 OS，另外 OS/2 与 windows 不兼容，也使得 OS/2 缺乏软件开发者支持没有足够的应用。

- 2、**价格贵**：IBM 对准备复制 PS/2 的克隆机厂商的专利许可费用达到 5%；另外 OS/2 每套的授权价格为 325 美元，比微软 MS-DOS 贵 2 倍。性能弱且定价贵从而更没有电脑商会购买 OS/2 授权。


第二次冲击：UNIX

1988 年春，IBM 与其他计算机生产厂商联手为促销 UNIX 建立了“开放式软件基金会 (OSF)”。UNIX 原是一个 1969 年由 AT&T 公司的贝尔实验室开发出来的操作系统，发展至 1988 年已经衍生出来了各种不同的版本。

微软公司前 CTO 麦沃尔德曾经在一份备忘录中提到微软 DOS 在面临的两个威胁之一就是 UNIX——UNIX 主要有两大魅力：（1）技术：UNIX 可以同时处理很多个计算任务，很容易与其他计算机连接，而不需要修改大量代码就可以工作在其他任何类型的硬件上。（2）实惠：UNIX 是免费的。

但是 UNIX 有一个致命的缺陷：**不存在通用版本**。每家公司都对 UNIX 作了改进，以适应各家公司自己的计算机，结果使得各公司的操作系统之间无法兼容。而微软一直能提供兼容性，因为硬件制造商已经达成协议，禁止对微软的兼容性造成影响的任何修改。

图 7：从 1988 年开始出现了各种版本的 UNIX 操作系统



UNIX 冲击 Wintel 生态失败的原因我们认为主要可以归结为以下两点：

本质原因是一个成员互为竞争对手的组织想要人为制定一个统一的标准是非常困难的。UNIX 开放式软件基金会成员均为 IBM、DEC 等公司，各方都为其自己的 UNIX 版本能够创利而投入，利益冲突的成员之间想要最终达成统一的合作几乎是不可能的。

1991 年，IBM 联合苹果与摩托罗拉也结成一个联盟 AIM，利用苹果操作系统软件的长处，和摩托罗拉结合 IBM 在处理器方面的优势，共同推出 PowerPC 微处理器，以期遏制“Wintel”联盟。

1994 年第一台搭载 Power PC 处理器的苹果电脑 Power Macintosh 发布，此后苹果基于 PowerPC 处理器推出了一系列产品，包括多款 Power Book 笔记本。但是在 2005 年的 WWDC 上，乔布斯宣布停止使用 Power PC 芯片，转而使用英特尔的 X86 架构 CPU；2019 年 8 月 IBM 正式将 PowerPC 架构和指令集开源。

图 8：苹果历代 PC 产品演进（1976-2005 年）



资料来源：Open Computing Facility，申万宏源研究

苹果对外表示放弃 PowerPC 的主要原因是因为功耗问题。2003 年 6 月苹果发布 PowerMac G5，其中搭载的 CPU 是 IBM 的 PowerPC 970 处理器，PowerPC 970 是市面上较早的 64 位芯片，其处理速度和效率远高于英特尔 32 位芯片，但是其制程为 130nm，所以其 1.8GHz 左右的运行频率已经是极限。苹果要求 CPU 运行速度要达到 3GHz，这样就必须在单位面积晶圆上集成更多数量的晶体管，需要用业界正在努力想要达成的 90nm 制造工艺，另外制程越高功耗越低。所以 PowerPC 970 由于散热和功耗的问题无法用于笔记本电脑。

在 PC 领域除了苹果没有其他知名电脑制造商选择 PowerPC 是因为作为苹果为了保证 Mac 机的销量不愿意将 MacOS 对外授权。IBM 研发升级 PowerPC 处理器需要不断投入到芯片研发和编译器维护上，但是 OS 厂商中只有苹果建立在 PowerPC 上，而苹果为了保持自己 PC 的差异化竞争力和高利润，拒绝将 MacOS 对外授权，所以 PowerPC 处理器只有在苹果电脑上有销量。IBM 投入了大量研发却只能获得不到 10% 的 PC 处理器市场份额，这样就使得 IBM 没有持续利润投入到 PowerPC 持续研发上，无法形成商业正循环，PowerPC 性能功耗最终不敌英特尔，另外由于苹果销量很小，也没有足够多的开发者基于 PowerPC 和 MacOS 生态去开发软件，最终导致了生态的失败。

如果苹果不愿意将 MacOS 授权，那么为何 IBM 不自己开发一个适配 PowerPC 的操作系统对外授权从而保证 PowerPC 的销量？其实 IBM 在上世纪 90 年代也做过这样的尝试——IBM 于 1994-1996 年发售过采用 PowerPC 架构处理器的 ThinkPad Power Series 800 系列，兼容 Windows NT、OS/2、AIX、Solaris、Linux 等对应的 PowerPC 版本。但是 IBM ThinkPad Power 系列定价过高（7000 多美元），性能没有显著优势，不兼容 x86，最后也惨淡收场。

第四次冲击：苹果经典 MacOS


苹果 Mac 电脑上的 OS 发展经历了三个阶段——1984-2000 年，经典 MacOS（一直迭代到 MacOS 9）；2001-2011 年，MacOS X；2012 年至今，OS X。

1984 年，苹果推出搭载经典 MacOS 的电脑 Macintosh，麦金塔操作系统是全球首个大众型图形用户界面 OS。MacOS 在图形用户界面（GUI）的友好性上让微软的 MS-DOS 相形见绌。但是 Macintosh 电脑只是在刚推出的一段时间内保持了较高的销量，随后陷入销量低迷的困境。

我们认为苹果经典 MacOS 操作系统在上世纪 90 年代失败的原因主要在于：

- 1、操作系统本身性能不行：**上世纪 90 年代，苹果 Mac OS 给用户的印象就是很不稳定，经常崩溃，因为存在先天不足（单任务、没有内存保护）。苹果计划在 1993 年发布一个全新的 OS，后来这个项目逐渐演变成代号为 Copland 的项目，计划采用微内核技术，推迟至 1996 年发布，但由于开发团队管理问题苹果觉得 Copland 永远不可能开发成功，于是管理层在 1996 年 8 月决定取消 Copland 项目，决定直接通过收购公司向外部购买 OS 技术。于是苹果在 1997 年 2 月收购 NeXT（乔布斯被赶出苹果后创办的公司），乔布斯重新执掌苹果，Apple 合并 NeXT 后，这家公司的操作系统 NeXTSTEP 就演化为 Rhapsody，并最终成为 Mac OS X（2001 年推出）。
- 2、PC 定价高：**当时最畅销的 Commodore Amiga 500（1987 年推出）售价 700 美元，销量超过 600 万台；而苹果 1984 年推出的 Macintosh 售价 2495 美元。
- 3、软件生态不行：**1998 年乔布斯亲自找到 Adobe 公司来基于苹果 MacOS 开发软件都被拒绝，而且 Adobe 还是苹果投资的公司。当时一线软件厂商因为苹果电脑市场份额很低都不愿意基于苹果 OS 开发软件，Adobe 的案例就是一个非常典型的缩影。

图 9：苹果在上世纪 90 年代曾陷入亏损低迷期



资料来源：《Failures of Large Computer Companies》，申万宏源研究

图 10：历年代表性电脑价格：苹果 PC 定价偏高

年份	型号	价格 (美元)	经通胀调整价格 (美元)
1976	Apple I	667	2,778
1977	Apple II	1,298	5,079
1978	IBM 5110	9,875	35,912
1979	Heathkit H-89	1,595	5,232
1980	Commodore VIC-20	299	860
1981	IBM Personal Computer 5150	1,565	4,100
1982	Commodore 64	595	1,462
1983	Apple Lisa	9,995	23,794
1984	Apple Macintosh	2,495	5,694
1985	Commodore Amiga 1000	1,295	2,854
1986	Compaq Portable II	3,499	7,570
1987	Commodore Amiga 500	700	1,467
1988	NeXT Cube	6,500	13,028
1989	Macintosh Portable M5120	7,300	13,959
1990	Poqet PC	1,995	3,619
1991	Apple Macintosh PowerBook	2,299	4,020
1992	IBM ThinkPad	2,375	4,014
1993	Apple Newton MessagePad	700	1,149
1994	IBM ThinkPad 755CD	7,599	12,210
1995	Gateway Solo 2000	3,499	5,467
1996	Gateway Solo 2100	4,149	6,297
1997	Dell Dimension XPS H266	3,979	5,904
1998	iMac	1,299	1,898
1999	Compaq ProSignia Desktop 33	2,699	3,858
2000	Gateway Performance 1500	3,089	4,272
2001	Apple Titanium PowerBook G4	3,499	4,705
2002	Toshiba Satellite 1955	2,499	3,308
2003	Apple Power Mac G5	1,999	2,587

资料来源：247wallst.com，申万宏源研究


第五次冲击：RISC 阵营的挑战

英特尔、AMD 代表的 x86 指令集是典型的 CISC（复杂指令集）。20 世纪 90 年代初，除了 AIM 联盟发起的 Power PC，还有 RISC（精简指令集）阵营也在向“Wintel”

宣战。RISC 阵营的代表芯片有升阳微公司（Sun）的 SPARC，数字设备公司（DEC）的 Alpha，以及 MIPS 公司的处理器、IBM 的 PowerPC。

RISC（精简指令集）在上世纪 90 年代曾盛极一时，20 世纪和 21 世纪最为著名的两家 RISC 阵营的公司分别是 MIPS 和 ARM。连微软在开发 Windows NT（windows OS 内核）时，在对 DOS 进行战略分析时都觉得其最大的威胁之一是 RISC 阵营的新型芯片，觉得速度比英特尔快多了，担心 RISC 芯片如果取代 Intel，微软帝国很有可能崩塌。1989 年微软决定除了将 windows NT 建立在英特尔 386 芯片上之外，同时选择 RISC 阵营最具代表性的公司 MIPS 作为另一个支持的芯片进行同步开发。

图 11：RISC（精简指令集）在上世纪 90 年代曾盛极一时



资料来源：知乎，申万宏源研究


MIPS 和 ARM 的授权可以分为处理器核授权和指令集授权两类：任何一款芯片都包含内核和外设两部分——其中内核包括了寄存器组、指令集、总线、存储器映射规则、中断逻辑和调试组件等；外设包括计时器、A/D 转换器、存储器、ROM 等；其中处理器核授权是指将内核设计授权给第三方，然后第三方可以以内核设计为基础加上自己的外设形成自己的 CPU。

MIPS 和 ARM 的商业上的主要差异在于：

- （1）定价：MIPS 的定价策略是核授权很贵，而指令集授权很便宜；但是 ARM 的指令集授权很贵，但核授权很便宜。

- (2) **生态策略**：MIPS 的架构授权，并不限制任何对 MIPS 架构的更改，允许设计者修改后再将扩展后的指令集进行二次销售；而 ARM 不允许二次销售，而且规定合作伙伴可以参与指令集的制定（设计者可以贡献自己的新指令，但是会不会成为 ARM 指令集的一部分需要由 ARM 和重要合作伙伴协商决定），但禁止私下修改。

图 12：MIPS 和 ARM 商业模式以及定价、生态策略对比



MIPS 虽然获得了微软的支持，但最终挑战英特尔失败走向没落，我们认为其中问题的根源在于：对于指令集控制松散，导致生态过于碎片化，相互不兼容。MIPS 技术的先进性其实在当时是受到包括微软在内的业内明星公司所共同认可的，但是 MIPS 创始人是学术派，不擅长商业策略。其指令集授权定价便宜虽然使得基于 MIPS 指令集的芯片在早期遍地开花，但是其对指令集的控制过于宽松，允许第三方对指令集进行任意扩展，从而使得扩展后指令集所衍生出来的上层应用生态相互不兼容（即基于 MIPS 指令集的 A 芯片上的应用程序无法在基于另一扩展版 MIPS 指令集的 B 芯片上运行）。但是 ARM 吸取 MIPS 的前车之鉴，在指令集授权限制上非常严格，再加上靠低功耗主打嵌入式市场，所以在手机移动生态中一战成名。

2.2 两次成功的冲击：AMD 的崛起+苹果封闭生态的建立

AMD 的崛起


AMD 通过 IBM 和英特尔首次合作 PC 时期“第二货源”的行规获得 x86 指令集永久授权。微软和 IBM 签署商业协议约定 IBM 对 MS-DOS 的未来升级版本不能享有独占使用权和控制权，微软可以向其他 PC 制造商出售 MS-DOS 赚钱。但是在处理器方面，由于当时美国半导体行业存在“第二货源”的行规（起源于 20 世纪 60 年代，当时军方是美国半导体公司的最大采购方，为了保证供应链稳定要求竞标的企业必须提供第二家有生产同一种产品能力的供应商），IBM 向英特尔施压要求提供 8086 第二供应商，于是英特

尔找到 AMD。双方约定：“AMD 可以对英特尔销售的英特尔微型计算机和周边产品中包含的微代码进行复制”，AMD 从此获得了 x86 指令集的永久授权。

AMD 虽然获得了 x86 指令集的永久授权，但是在 2003 年之前的 CPU 领域一直是跟随者的角色，不断生产兼容 Intel 的处理器。AMD 虽然可以靠逆向工程，但是每一代 CPU 推出的时间点都会比英特尔晚几年时间，例如 AMD 在 386 推出时间上落后于英特尔 6 年，在 486 上落后 4 年。因此在非常长一段时间，AMD 在商业上都是主打性价比的策略，只能占据市场约 15% 份额。1990 年底，AMD 推出了 386 的复制品 Am386，AMD 凭借其更为廉价和强大的替代品抢走了 50% 以上的 386 市场。

AMD 率先设计出向下兼容原 x86 架构的 64 位 x86-64 指令集，并于 2003 年 9 月首次推出基于 x86-64 的 64 位 CPU——Athlon 速龙系列，由此开启为期 3 年性能领先于英特尔的第一次成功时期。最早的 64 位架构是英特尔联合惠普设计的——IA-64 架构，对应安腾处理器。但是 IA-64 和之前的 x86 架构完全不兼容，所以所有的应用软件以及操作系统都要使用专门为 IA-64 编译的版本。而 AMD 设计的 x86-64 是在 x-86 架构基础上进行的拓展，向下兼容 x-86 原有的操作指令，原有的 16 位、32 位程序不需要重新编译即可运行，编译器更新也更加容易。2003 年 9 月，AMD 推出首个基于 x86-64 的 Athlon（速龙）PC 处理器。由于 IA-64 在软件兼容性方面处于劣势，导致市场表现远远低于预期。2017 年英特尔宣布停产安腾处理器，正式宣告了 IA-64 的失败。最终，英特尔只能选择和 AMD 交叉授权拿到 AMD64 的使用权。

图 13：英特尔和 AMD 历年微架构迭代时间轴（1993-2008 年）




资料来源：10stripe.com，申万宏源研究

AMD 在 64 位处理器和双内核处理器市场均领先英特尔一步，“64 位”+“双核”战略让 AMD 持续保持了 3 年优势。从 2004H1 开始，AMD 推出的一系列速龙 K8 处理器（所有速龙架构的 64 位桌面 CPU，包括 Athlon64 和 Athlon64 X2）性能明显超越英特尔奔腾 4 和奔腾 D，但是英特尔在 2003 年 12 月接受媒体采访时公司高层仍然表示“目前的市场对 64 位处理器的需求并不大，2005 年再推出 64 位 CPU 也不迟”，英特

尔在 x86-64 架构上的迟疑使得 AMD 不断蚕食英特尔桌面处理器的份额。2005 年 5 月 Intel 发布了世界上第一款双核 CPU 奔腾 D，但是英特尔是将 2 个奔腾 4 Prescott 的核心封装在一起，通过前端总线（FSB）分别连接北桥，通过北桥来连接两个核心（所以速度肯定有瓶颈，而且挑主板），其实是“胶水双核”；几周后便被 AMD 速龙 64 X2 超越，推出了一系列“原生双核”CPU。

**图 14：PC 旗舰级 CPU 跑分：2003-2006 年
AMD 性能领先于英特尔**



资料来源：哔哩哔哩，申万宏源研究

图 15：PC 旗舰级 CPU 跑分：2006 年 7 月英特尔推出酷睿 2 之后，直至 2017 年英特尔相较于 AMD 一直保持领先优势



资料来源：哔哩哔哩，申万宏源研究

2006 年英特尔提出并开始执行 Tick-Tock 战略——每两年升级一次工艺，每两年升级一次架构。每年都有新一代处理器问世，从 45nm 的 Penryn（Core 架构第一代产品）一直持续到了 14nm 工艺的 Broadwell。2006 年 7 月英特尔具有革命意义的酷睿 2 上市，让 AMD 在桌面 CPU 市场优势全无，性能全面超越 AMD。不久英特尔发布首个 4 核 CPU 酷睿 2Q 和 QX；为了应战，AMD 在 2007 年发布了首个 4 核 CPU 羿龙系列（X3/X4），但是性能仍然不如酷睿 2，此后的羿龙 K10 架构也出现容易导致死机的严重漏洞。此后英特尔连续推出的酷睿 i3/i5/i7 性能完爆 AMD，2009 年上半年 AMD 发布的与英特尔酷睿同时期竞争的 FX 推土机（Bulldozer）架构进一步拉开了 AMD 落后于英特尔的差距。

图 16：英特尔自 2006-2015 年期间严格执行 Tick-Tock 战略，2016 年起由于工艺制程问题限于停滞


Core架构		Nehalem架构		Sandy Bridge架构		Haswell架构	
Core2 Duo/Quad 65nm	Penryn 45nm	Nehalem 45nm	Westmere 32nm	Sandy Bridge 32nm	Ivy Bridge 22nm	Hashwell 22nm	Broadwell 14nm
Tock	Tick	Tock	Tick	Tock	Tick	Tock	Tick
2007	2008	2009	2010	2011	2012	2013	2014
Skylake架构				Sunny Cove	Willow Cove	Golden Cove架构	
Skylake 14nm	Kaby Lake 14+nm	Coffeelake 14++nm	Cannon lake 14++nm	Ice Lake 10nm	Tiger Lake 10+nm	Alder Lake 10+++nm	? 7nm
Tock	优化	优化	再优化	Tick	Tock	优化	-
2015	2016	2017	2018	2019	2020	2021	2022

资料来源：英特尔，申万宏源研究

英特尔从 2016 年开始陷入工艺制程的瓶颈与 Tick-Tock 战略脱节，开始“挤牙膏”模式；2017 年 3 月 AMD 发布锐龙架构让其正式开启一个在 PC 领域全面反超 Intel 的时代。2017 年 3 月 AMD 推出第一代锐龙（Ryzen）架构 CPU，第一代锐龙单核性能比英特尔弱，除了凭借更多核心在极个别多线程应用中表现优秀之外，大部分正式应用中其实不如同期英特尔的 CPU。直至 2018 年 4 月 AMD 发布第二代锐龙，单核性能有了大幅提升，也解决了内存上的问题；再加上英特尔 IDM 模式工艺制程升级遇到瓶颈，AMD 依靠台积电代工先英特尔一步进入 7nm 制程，AMD 开始大幅抢夺英特尔份额。


我们认为 AMD 的成功除了对手犯错+性能领先之外，其实 AMD 之所以能达到性能领先还有很重要的原因是在于管理层更聚焦。2014 年苏姿丰临危受命接任 CEO，当时其指出 AMD 最主要的矛盾是“我们有很好的技术，可是同时又发展了太多的产品，没有一个清楚的目标和焦点”，于是果断作出取舍，放弃部分业务（例如放弃了基于 ARM 架构的服务器 CPU 研发），让公司更聚焦。苏姿丰和董事会决定发挥强项——先做好 PC 市场，全力投入在锐龙架构升级上；在云计算兴起后，又迅速抓住机会，重返服务器市场。

图 17：AMD 发布的第一代锐龙架构相较于上一代架构性能有大幅提升




资料来源：anandtech.com，申万宏源研究

图 18：2018 年 AMD 第二代锐龙架构已经进入 7nm 制程




资料来源：AMD，申万宏源研究

图 19：PC 旗舰级 CPU 跑分：2017 年 3 月 AMD 推出锐龙架构，性能开始超越英特尔




资料来源：哔哩哔哩，申万宏源研究

图 20：截至 2021 年 8 月最新 CPU 性能天梯图（最顶部）：AMD 仍然领先于英特尔




资料来源：极空间，申万宏源研究

图 21：台式电脑 CPU 市场份额变化



资料来源：CPU Benchmarks，申万宏源研究

图 22：笔记本电脑 CPU 市场份额变化



资料来源：CPU Benchmarks，申万宏源研究

苹果 MacOS X 封闭生态的成功

2001 年 MacOS X 正式发布，替代经典 MacOS。1997 年 2 月苹果收购 NeXT 后，Mac OS X 吸收了这家公司操作系统 NeXTSTEP 中的 Mach 微内核、Objective-C、面向对象、Bundle、BSD 等技术架构和设计理念。


苹果桌面操作系统 MacOS X 市占率虽然不到 10%，但是软件应用数量是 windows 生态的 62%——这说明虽然苹果 MacOS X 市占率不高，但是开发者非常愿意去为苹果桌面生态开发软件。苹果 MacOS X 在 2012 年桌面操作系统的市占率为 9.3%，windows 市占率为 85.3%；但是当年苹果 MacOS X 生态内软件数量已经达到 1.3 万个，windows 生态内软件数量为 2.1 万个。

图 23：2012 年底各类 OS 生态应用软件数量



资料来源：DISTIMO，申万宏源研究

图 24：MacOS X 市占率变化（2004-2008 年）



资料来源：macinchem.org，申万宏源研究

21 世纪苹果 MacOS X 和前述 20 世纪 90 年代经典 MacOS 软件生态之所以截然不同，我们认为很关键在于苹果变得对开发者更友好了：

苹果开始承认此前从最顶层应用软件到硬件全部都 100% 自己做的专有欲是一种错误。1997 年乔布斯重新执掌苹果，在 1997 年 WWDC 大会上说到：“Mac 的心态就是：我们什么都是专有的——这种傲慢使我们觉得我们可以发明自己的网络甚至一切。所以这里

的智慧不是我们要发明所有的东西，而是明白哪些 10%、20%或者 30%的东西是我们发明的。所以我觉得这种高傲的专有欲深深地伤害了我们，而我们的管理团队却鼓励这种自大，鼓励员工去重复造轮子。”

乔布斯向软件开发者反复强调“基于 MacOS 写软件比其他操作系统快 5-10 倍，可以帮开发者省去 80%的代码”的易开发性。乔布斯在 1997WWDC 大会上提到：“《人月神话》最基本的理念就是：当开发团队达到某个规模的时候，每加入一个新人，与这个新人沟通所花费的精力时间其实比他的贡献还多，所以进度反而更慢，所以产出的最大值就下来了。我们知道开发软件最核心就是要降低管理复杂性，这些工具使你无需为 93%的问题烦恼，消灭你要编写的 80%的代码，让你以 5 倍的速度写一个同样复杂的软件。”

2.3 总结：不能做错什么？应该做对什么？

我们认为五次冲击 Wintel 失败的案例可以总结出来塑造生态绝对不能犯的致命错误有：不兼容导致生态碎片化、性能差、定价高、过于封闭。

比尔·盖茨在《未来之路》中写到：“我们有三种方法可以使得 MS-DOS 名列前茅：第一种就是要使 MS-DOS 成为最好的产品；第二种就是帮助别的公司编写以 MS-DOS 为基础的软件；第三种就是要确保 MS-DOS 价格便宜。……微软一直能提供兼容性，因为硬件制造商已经达成协议，禁止对我们的软件进行任何修改，只要这种修改将引入不兼容性。这意味着数以万计的软件开发者无需为他们的软件将应用于何种个人计算机上而挂怀。”


比尔·盖茨提到的上述三种方法分别对应性能领先、对开发者友好、价格便宜是三种特性，最后提到的是微软将兼容性做到了极致。另外微软在为 IBM 推出第一代 PC 时就特别和 IBM 约定 IBM 不能享有 MS-DOS 的独占使用权和控制权，允许向第三方出售特许权赚钱，微软这种开放的态度再加上前面四个特性使得微软 OS 迅速成为行业标准。

诸如 IBM OS/2、UNIX、经典 Mac OS 等竞争对手的竞品在以上任意一点无法做到和微软一样好，那么都将是致命的弱点，注定无法成为行业标准。

我们认为两次成功的案例可以得到的启发是：

- 1、垄断型的竞争对手难免犯错，对手犯错时确保自己能够坚持走在正确的路上；或者有原始的技术创新进行超越——两者达成其一可以获得市占率的提升。（备注：AMD 抢夺 Intel 份额不存在生态壁垒的问题，因为 Intel 和 AMD 都是 x86 指令集；因此相对于 ARM/PowerPC 等 RISC 阵营的芯片商去突破 Wintel 要相对容易）
- 2、即使只有 10%的市占率，也会有开发者愿意来做生态，但前提是要对开发者足够友好。前述 Mac OS X 已经是例证；而苹果手机 iOS 从 2012-2021 年一直保持 15~16%市占率，但生态依旧繁荣，再次证明这一论断。

图 1：冲击 Wintel 的成功和失败案例原因汇总



资料来源：申万宏源研究

3.AI 芯片生态壁垒如何破局？

3.1 AI 生态与 PC 生态的相同和不同


我们认为生态壁垒产生的根源在于软硬件高度耦合。

相同点：为了最大程度发挥芯片本身性能，PC 需要 OS 厂商和 CPU 厂商一起来做联合优化；AI 需要深度学习框架厂商和 AI 芯片厂商一起来做联合优化。

完整的深度学习开发过程包含算法设计、算法实现、算法运行三个环节——深度学习框架是在“算法实现”环节进行加速，AI 芯片是在“算法运行”环节进行加速。（1）算法设计：例如基于 CNN 的图像检测算法有 R-CNN、YOLO、SSD 等多种不同的类型，这属于算法设计上的不同。（2）算法实现：也就是将算法的设计一步步转化为可以直接在芯片上执行的程序的过程。（3）算法运行：经过算法实现后的程序在芯片上运行计算的过程。

深度学习框架解决的就是“算法实现”的过程。深度学习框架的作用实际上就是把 AI 开发者设计好的神经网络模型转化为用张量（Tensor）和算子（operation）表示的计算图，然后再将计算图进行优化加速，并且将优化加速后的算子映射到 AI 芯片上去去计算的过程。其中张量（Tensor）对应的是数据，算子（OP）对应运算符。AI 应用开发者一般用深度学习框架中的大量现成算子以及少量自定义的算子来完成模型的搭建。

图 26：算法开发的三个阶段以及对应的智能计算系统结构



资料来源：申万宏源研究

深度学习框架的优化分为图优化和算子优化两个环节。深度学习框架主要将神经网络模型转为计算图，再此基础上进行两个层次的优化：（1）计算图高层次优化：例如内存优化技术、操作符的融合、表达式的化简以及无用代码的消除。（2）算子优化：早期主要是靠手写库函数，即人工优化算子（通过精细地选择流水线、指令集、预读、寄存器分配来达到接近最优效果），这个库函数一般由 AI 芯片硬件厂商开发提供。

算子（OP）分为高层算子和底层算子，高层算子需要底层算子去表示；另外算子需要最终映射为能够在 AI 芯片上运行的程序 Kernel；高层算子需要深度学习框架提供商做很多优化整合工作。虽然 AI 芯片厂商会针对自身芯片特性开发一系列算子封装为“深度学习库”（例如英伟达 cuDNN、英特尔 MKL-DNN 这样的基础算子原语库），但是有时还不是最优算子，对于深度学习框架厂商而言在高层算子这一层面还有很多优化整合的空间，以及框架厂商还要考虑系统中存在多种不同的芯片时，计算任务如何在不同芯片上分配和调度的问题。

图 27：高层算子需要调用 CUDA Kernel 函数这样的底层算子原语





图 28：经深度学习框架厂商特别优化后的算子有时比 cuDNN 直接提供的算子运行更快（以 Softmax 算子为例，OneFlow 为国产深度学习框架）




资料来源：OneFlow，申万宏源研究

资料来源：OneFlow，申万宏源研究

我们认为 AI 生态壁垒的出现主要体现在算子（OP）和 AI 芯片硬件的高度耦合；做一个深度学习框架最大的工程量就在于海量算子和众多后端芯片的支持。Tensorflow 要支持 GPU 计算，需要把 Tensorflow 里面所有算子开发一个 GPU 版本；如果要支持寒武纪思元芯片，又需要把每个算子开发一个寒武纪芯片的版本。而目前 Tensorflow 里的算子数量已经达到了 2000 多个，而且后续算子数量会随着算法模型不断发展而层出不穷，但是每一个算子的开发和维护都需要投入巨大的工程量。


我们认为 OP 集和 AI 芯片硬件高度耦合其原因在于每一家 AI 芯片厂商智能编程语言不同；由于各家 AI 芯片厂商编程语言无法兼容，而深度学习框架厂商仅支持一家 AI 芯片就要投入巨大工程量，因此导致其最终只选择市占率最大的 1-2 家进行深度支持——AI 芯片厂商的生态壁垒护城河得以形成。对于 AI 芯片而言之所以需要智能编程语言是传统编程语言（Python、C++、Java 等）难以满足三大鸿沟，而如果用运行效率最高的底层汇编语言写将导致开发门槛过高：（1）语义鸿沟：传统的高级编程语言难以高效描述复杂的智能语义，比如如果用 C++ 写卷积运算的代码，需要 7 重循环；如果用 Python 写，需要 4 重循环。高层的语义不好描述或者描述起来很费时间，要写很多行代码才能实现一个算子。（2）硬件鸿沟：不同 AI 芯片在控制、存储、计算方面都有很强的独立性，AI 芯片需要有专用的编程语言对上述特性进行很好的抽象，如果不让开发者通过编程语言看到底层硬件抽象是无法很好利用底层 AI 芯片的性能的。（3）平台鸿沟：各类 AI 芯片底层指令集不同，由于汇编语言和指令集是一一对应的关系，因此汇编语言也不同，汇编语言之上的智能编程语言也不同，英伟达的智能编程语言 CUDA 在寒武纪、华为昇腾芯片上跑不起来，所以对于寒武纪、华为而言需要自己专有的智能编程语言。

图 29：NV 的软件栈抽象层次（NV 的智能编程语言是 CUDA）



资料来源：StarryHeavensAbove，申万宏源研究

图 30：不同 AI 芯片指令集不同，因此智能编程语言互不兼容



资料来源：申万宏源研究

表 2：国内外主流深度学习框架以及支持的硬件设备

	深度学习框架	公司/机构	发布时间	支持的 AI 芯片
国外	Tensorflow	谷歌	2015 年	CPU/GPU（英伟达 CUDA）/TPU（谷歌）
	Pytorch	Facebook	2016 年	CPU/GPU（英伟达 CUDA）

中国	Paddle Paddle (飞桨)	百度	2016 年	CPU/GPU (英伟达 CUDA+AMD ROCm) / 昆仑 XPU (百度) / 海光 DCU/华为昇腾
	Jittor (计图)	清华	2020 年	CPU/GPU (英伟达 CUDA) / 寒武纪
	Mindspore	华为	2020 年	CPU/GPU (英伟达 CUDA) / 华为昇腾
	MegEngine (天元)	旷视	2020 年	CPU (ARM+x86) / GPU (英伟达 CUDA)

资料来源：Paddle Paddle 官网，旷视天元官网，申万宏源研究

不同点 1：未来有可能发生 AI 系统软件和芯片之间的配合没有 PC 领域“Wintel”那么紧密。

上文提到上层算法模型在不断发展，但是算子集也在随着新算法的出现而不断扩散，存量巨大且不断扩张的算子集对于 AI 芯片的硬件适配将成为巨大的灾难。目前业界正在共同探索用于使得深度学习框架和 AI 芯片解耦的解决方案——“深度学习编译器”。

深度学习编译器可分为图编译器、算子编译器、端侧推理相关的编译器三大类。深度学习编译器实际上借鉴了传统编译器的实现原理：在 PC 发展早期也出现了各种 CPU，不同 CPU 都有专门的编程语言（下图左边红框），需要经过专门的编译器和汇编器翻译成机器码再对应到相应的 CPU 指令集（下图右边红框），随着编程语言的增加，各家厂商编译器维护难度随之增加；现代编译器（下图以 LLVM 为例）为编译器抽象出了编译器前端、中端、后端，并且引入了 IR（中间表示），解决了上述问题——其中编译器前端主要作用是接收 C/C++/Java 等不同语言，进行代码生成，吐出 IR；编译器中端主要作用是接收 IR，进行不同编译器后端可以共享的优化（如常量替换、死代码消除、循环优化等），吐出优化后的 IR；编译器后端接收优化后的 IR，进行不同硬件的平台相关优化与硬件指令生成，吐出目标文件。

图编译器是在前端与硬件无关的优化，深度学习端侧推理相关编译器主要解决的是不同训练框架训练出来的模型部署到各种终端 AI 加速器上时跨平台精度损失的问题。从训练端看，可供大家选择的训练框架有 Tensorflow、Pytorch、Caffe、Mindspore、Paddle Paddle 等等；从推理端看，当模型训练好需要部署到多类具体芯片上，大家往往会选择各家硬件厂商所推出的前向推理框架以达到最优加速效果（例如 Intel CPU/GPU 上使用 OpenVINO，在 Arm 的 CPU/GPU 上使用的是 NCNN/MNN 等，在 Nvidia GPU 上使用的是 TensorRT）——但是当模型从训练框架转到不同推理框架时，会出现各个框架不同而无法读取、支持的算子不同无法对齐、还容易出现在一个芯片平台上可以实现高效推理但是在另一个平台性能骤降的问题。深度学习端推理编译器解决的就是上述困难：用各种深度学习训练框架训练出来的神经网络模型可以类比传统编译器中的各种编程语言，各种模型传入深度学习编译器之后吐出 IR（计算图），计算图 IR 可以做一些计算图优化再吐出 IR 分发给各种硬件使用。通过上述方式，当需要支持一种新训练框架或者新的硬件芯片时，只需要分别在前端或者后端进行支持即可，都用统一的 IR 来表示并优化。


图 31：深度学习编译器借鉴了传统编译器原理（传统编译器以 LLVM 为例）



资料来源：知乎，申万宏源研究

算子编译器可以用来解决 AI 框架算子 (OP) 和 AI 芯片紧耦合的问题。通用的深度学习编译器处理流程可以分为 5 层：前端、中间表示 (IR)、高级优化、低级优化、后端。高级优化对应图优化，低级优化对应与 AI 芯片硬件相关的算子优化 (图中虚线框所示部分)。传统的深度学习框架主要靠 AI 硬件厂商算子开发工程师手写算子库进行优化，算子编译器的作用可以简单理解为“靠 AI 去实现自动优化算子”，上述提到每一个算子的开发和维护都需要 AI 芯片厂商投入巨大的人力精力，但相比之下人的精力是有限的但是机器的算力是无限的。前端每一个深度学习框架都需要支持整合上千个算子，而后端出现的 AI 芯片越来越多，如果支持所有 AI 芯片则会出现“组合爆炸”，因此深度学习框架厂商只选择市占率最高的 1-2 家 AI 芯片进行支持，如果相关算子优化大部分靠机器去自动完成，则可以使得深度学习框架摆脱 OP 集的束缚，实现系统软件和底层硬件之间的解耦。

图 32：用于深度神经网络的通用编译框架（虚线框中为算子优化）



资料来源：清华大学，申万宏源研究

我们认为深度学习端侧推理编译器的意义在于可以在边缘端一定程度打破 NV 垄断，因为如果从训练到推理不存在跨平台精度损失等问题，则云和端不一定要用同一家厂商的 AI 芯片。

我们认为算子编译器的意义在于可以使得深度学习框架和 AI 芯片解耦，直接打破生态壁垒。

虽然业界已经在集中攻关上述“深度学习编译器”，但是目前技术发展的现状是编译器生成的代码不一定能超过工程师手工优化的代码（例如 Tensorflow 的 XLA 编译器受限于编译器技术本身完全没有达到想要直接优化整个计算子图效果；TVM 也仅在部分场景

能够获得超过手工优化的代码，支持的平台主要是通用并行机，对 AI 芯片支持较差）；而深度学习编译器只有在各种场景超过人工优化的传统办法，才有机会真正被采用，到达这一目标之前深度学习编译只是玩具，需要时间等待技术进步成熟。

图 33：常用深度学习编译器对比


		TVM	nGraph	TC	Glow	XLA
	Developer	Apache	Intel	Facebook	Facebook	Google
Frontend	Programming	Python/C++ Lambda expression	Python/C++ Tensor expression	Python/C++ Einstein notation	Python/C++ Layer programming	Python/C++ Tensorflow interface
	ONNX support	✓ tvm.relay.frontend .from_onnx (built-in)	✓ Use ngraph-onnx (Python package)	×	✓ ONNXModelLoader (built-in)	✓ Use tensorflow-onnx (Python package)
	Framework support	tvm.relay.frontend .from_* (built-in) tensorflow/tflite/keras pytorch/caffe2 mxnet/coreml/darknet	tensorflow paddlepaddle (Use *-bridge, act as the backend)	(Define and optimize a TC kernel, which is finally called by other frameworks.) pytorch/other DLPack supported frameworks	pytorch/caffe2 tensorflowlite (Use built-in ONNXIFI interface)	Use tensorflow interface
	Training support	×	✓ Only on NNP-T processor	✓ (Support auto differentiation)	✓ (Limited support)	✓ Use tensorflow interface
	Quantization support	✓ int8/fp16	✓ int8 (include training)	×	✓ int8	✓ int8/int16 (Use tensorflow interface)
IR	High-/low-level IR	Relay/Halide	nGraph IR/None	TC IR/Polyhedral	Its own high-/low-level IR	HLO (Both high- and low- level)
	Dynamic shape	✓ (Any)	✓ (PartialShape)	×	×	✓ (None)
Optimization	Frontend opt	Hardware independent optimizations (refer to Section 4.3)				
	Backend opt	Hardware specific optimizations (refer to Section 4.4)				
		And hybrid optimizations				
Backend	Autotuning	✓ (To select the best schedule parameters)	×	✓ (To reduce JIT overhead)	×	✓ (On default convolution and gemm)
	Kernel libraries	✓ mkl/cudnn/cublas	✓ eigen/mkldnn/cudnn/ Others	×	×	✓ eigen/mkl/ cudnn/tensorrt
	Compilation methods	JIT AOT (experimental)	JIT	JIT	JIT AOT (Use built-in executable bundles)	JIT AOT (Generate executable libraries)
	Supported devices	CPU/GPU/ARM FPGA/Customized (Use VTA)	CPU/Intel GPU/NNP GPU/Customized (Use OpenCL support in PlaidML)	Nvidia GPU	CPU/GPU Customized (Official docs)	CPU/GPU/TPU Customized (Official docs)

资料来源：清华大学，申万宏源研究

图 34：使用 TVM 编译器在某些模型端到端推理性能上能获得 3 倍以上加速


图 35：使用 TVM 编译器在跨硬件平台时性能表现

End to End Inference Performance (Nvidia Titan X)



资料来源：陈天奇 TVM，申万宏源研究

Portable Performance Across Hardware Platforms




资料来源：陈天奇 TVM，申万宏源研究

不同点 2：具备原始创新的深度学习框架未来有可能挑战 Tensorflow 和 Pytorch 双垄断的地位，从而重塑生态。

即使上述能够使得软硬解耦的深度学习编译器技术仍然在探索期，但是深度学习框架自身格局仍有诸多变数，进而有可能使得 AI 生态并不会一直维持“深度学习框架 Tensorflow、Pytorch 双垄断+AI 芯片英伟达一家独大”这样的格局。


目前深度学习训练框架领域呈现 Tensorflow 和 Pytorch 双垄断格局；Tensorflow 在工业界占优势，Pytorch 在学术界占优势。2018 年之前深度学习框架是 Tensorflow 一家独大，但是自 2019 年开始 Pytorch 开始反超 Tensorflow，2019 年各 AI 顶级研究会议中接收到的论文中已经有一半以上研究是用 Pytorch 来做的。Pytorch 已经在学术界市占率全面超越 Tensorflow，但是在工业界大家仍然选择用 Tensorflow 来开发模型。

图 36：Tensorflow 和 Pytorch 是目前最主流的深度学习框架



资料来源：《智能计算系统》，申万宏源研究

图 37：每年各 AI 顶级研究会议所接收的 PyTorch 论文数占 TensorFlow 和 PyTorch 的论文数总和的比率



资料来源：CSDN，申万宏源研究

我们认为 Pytorch 之所以强势反超 Tensorflow 是因为率先引入了“动态图”，做了原始创新；另外侧面也反映出深度学习框架格局并非像 PC 操作系统那般稳固，是存在变动的可能性的。谷歌 Tensorflow 第一个正式版本在 2015 年推出，第一版只有 CPU 版

本，后来才有的 GPU 版本，而且一开始推出的时候 TF 性能并不是很好。之所以现在成为了使用人数最多最受欢迎的深度学习框架是因为投入了大量资源和人力去做生态推广，而且可移植性做得比较好，具有支持多种高级语言输入、更灵活的编程模型等优点。Tensorflow1.0 版本设计理念是“静态图”（先说明数据要怎么计算，然后再放入数据），其缺点是 AI 开发人员难以调试，而且 API 混乱；但是 Pytorch 在 2016 年推出的时候采用了“动态图”编程（运算图是在数据计算的同时构建的），极大解决了上述 TF 的缺陷。2018 年 Tensorflow 2.0 也开始引入动态图编程，但是那时 Pytorch 已经占领了学术界，而且生态也已经起来了。

我们认为如果国产深度学习框架能够通过原始创新具备生态掌控力，国产 AI 芯片厂商进行生态突围的机会也将增加。2016 年百度发布我国第一个国产深度学习框架，2020 年是我国深度学习框架受重视的元年，华为 Mindspore、清华 Jittor、旷视 Megengine 国产深度学习框架相继发布。国产深度学习框架和 Tensorflow、Pytorch 这些国外深度学习框架相比最大的一点不同在于国产框架愿意对国产 AI 芯片和 CPU 进行支持，但是国外框架不会。如果国产框架能够跑出来，国内 AI 芯片厂商生态突围的机会也会相应增加，但是从 Pytorch 后来居上反超 Tensorflow 的案例来看，其前提必然是要基于原始创新，如果只是追随和模仿国外框架，那么国产框架将永远不会具备生态掌控力。

3.2 各家所选取的 AI 生态突围路线


目前 AI 芯片主要玩家应对英伟达塑造的 AI 生态壁垒，选取了不同的商业策略：

- （1）AMD 在走部分兼容 CUDA 的路线；
- （2）寒武纪在走英伟达的路线；
- （3）谷歌、华为、百度走的是“深度学习框架+AI 芯片”自研路线；
- （4）特斯拉走的“算法+训练芯片+推理芯片”自研自用封闭路线，类似苹果在 PC 时代模式；
- （5）地平线走的是垂直领域“算法+芯片”路线。

AMD 选择了部分兼容英伟达 CUDA，借力英伟达生态的路线。AMD 在 2016 年全球超算大会上推出了 ROCm，也就是对标英伟达 CUDA 一样的智能编程语言，ROCm 软件堆栈的结构设计与 CUDA 相似度很高；对标英伟达深度学习库 cuDNN，AMD 推出了 MIOpen；对标英伟达深度学习推理框架 TensorRT，AMD 推出了 Tensile；对标英伟达编译器 NVCC，AMD 推出了 HCC。ROCm 中包含的 HIPify 工具，可以把 CUDA 代码一键转换成 ROCm 栈的 API，减少用户移植成本。


我们认为走兼容英伟达 CUDA 的路线其难点在于其更新迭代速度永远跟不上 CUDA 并且很难做到完全兼容。(1) 迭代永远慢一步：英伟达 GPU 在微架构和指令集上迭代很快，在上层软件堆栈上很多地方也要做相应的功能更新；但是 AMD 不可能知道英伟达的产品路线图，软件更新永远会慢英伟达一步（例如 AMD 有可能刚宣布支持了 CUDA11，但是英伟达已经推出 CUDA12 了）。(2) 难以完全兼容反而会增加开发者的工作量：像 CUDA 这样的大型软件本身架构很复杂，AMD 需要投入大量人力物力用几年甚至十几年才能追赶上；因为难免存在功能差异，如果兼容做不好反而会影响性能（虽然 99%相似了，但是解决剩下的 1%不同之处可能会消耗开发者 99%的时间）。

图 38：AMD 的 ROCm 是和英伟达 CUDA 对等的智能编程语言




资料来源：CSDN《AMD ROCm 平台简介》，申万宏源研究

图 39：AMD 的 HIPify 工具可以将英伟达 CUDA 代码转换为 ROCm 代码




资料来源：CSDN《AMD ROCm 平台简介》，申万宏源研究

图 40：英伟达的 CUDA 栈



资料来源：CSDN《AMD ROCm 平台简介》，申万宏源研究

图 41：AMD 的 ROCm 栈



资料来源：CSDN《AMD ROCm 平台简介》，申万宏源研究

谷歌凭借 Tensorflow 去做 TPU 相对而言不存在太多生态壁垒问题，但是仍然无法撼动英伟达，我们认为其原因在于 TPU 本身性能还有进一步提升空间以及过于专用的问题。理论上谷歌凭借 Tensorflow 在深度学习框架领域实现了垄断地位，是具备绝对的生态掌控力的，会投入大量的 Tensorflow 工程师针对自家 TPU 去做支持和优化，因此

TPU 去挑战英伟达 GPU 其实不存在所谓生态壁垒的问题。但是自谷歌自 2016 年推出第一代 TPU v1 至今已经到第四代 TPU v4 (2021 年 5 月发布)，仍然无法从英伟达手中抢走明显份额，其原因主要在于 TPU 本身性能相比于英伟达同时期 GPU 而言还有一定差距，另外其芯片设计过于专用所以在卷积之外的算法表现上并不算好：

(1) 谷歌在芯片设计上的实力和英伟达相比还有一定差距，谷歌在 TPU 论文中也明确提到由于项目时间比较紧，所以很多优化只能放弃。从性能参数来看谷歌 TPU v2 和英伟达同年推出的 V100 相比，性能功耗比、显存带宽等指标有着明显差距，即使是谷歌在 2018 年推出了第三代 TPU，其性能 (FP32)、功耗等指标仍然和英伟达 V100 相比存在一定差距。

(2) 谷歌采用的是传统脉动阵列机架构，芯片设计上过于专用。TPU 的主要创新在于三点：大规模片上内存、脉动式内存访问、8 位低精度运算。脉动阵列机做卷积时效果不错，但是做其他类型神经网络运算效果不是很好，在一定程度上牺牲了通用性来换取特定场景的高性能。TPU 在芯片设计上只能完成“乘+加+乘+加……”规则的运算，无法高效实现“复数乘法、求倒、求平方根倒数”等常见算法。

现在 AI 芯片的行业趋势是：GPU 在通用性的基础上逐渐增加专用计算单元；而类似 TPU 的 ASIC 芯片在专用性的基础上逐渐增加通用计算单元——两类芯片有逐渐收敛的趋势。英伟达在用于深度学习领域的 GPU 上的设计思路是“在通用的基础上增加专用运算单元”，例如在 Volta 架构上开始增加 TensorCore (专门用于深度学习加速)、在 Turing 架构上开始增加 RTCore (专门用于光线追踪加速)，牺牲通用性为特殊的计算或者算法实现特殊架构的硬件以达到更快的速度。而 AI 芯片一开始走专用路线，但是现在在专用性之外也在架构设计上增加了通用计算单元 (例如谷歌 TPU v1 主要是矩阵乘法运算单元占了 24% 芯片面积，但是 TPU v2 也开始增加浮点 ALU 做 SIMD)。

表 3：谷歌历代推理和训练芯片性能参数

型号	TPU v1	TPU v2	TPU v3	TPU v4
发布年份	2016 年	2017 年	2018 年	2021 年
场景	推理	推理+训练	推理+训练	训练*
制程	28nm	20nm (估计)	16nm/12nm (估计)	7nm (估计)
性能	92TOPS (INT8) 23TOPS (INT16)	45TOPS (FP16) 3TOPS (FP32)	123TOPS (FP16) 4TOPS (FP32)	TPU v3 性能的两倍
功耗	75W	280W	450W	500W (估计)
显存带宽	34 GB/s	700 GB/s	900 GB/s	不详
芯片面积	<331	<611	<648	不详

备注*：是否能做推理尚不确定

资料来源：nextplatform.com，blog.inten.to，申万宏源研究

表 4：英伟达主流推理和训练芯片性能参数

型号	P100	V100	A100
发布年份	2016 年	2017 年	2020 年
场景	推理+训练	推理+训练	推理+训练

型号	P100	V100	A100
架构	Pascal	Volta	Ampere
制程	16nm	12nm	7nm
性能	21TOPS (FP16) 11TOPS (FP32)	125TOPS(FP16) 16TOPS(FP32)	624TOPS (INT8) 312TOPS (FP16) 20TOPS (FP32)
功耗	300W	300W	400W
显存带宽	732 GB/s	900 GB/s	1555 GB/s
芯片面积	610	815	826

资料来源：英伟达官网，申万宏源研究

华为在 2019 年 8 月发布的昇腾 910 与英伟达在 2020 年 5 月发布的 A100 性能相当，但是我们认为华为的主要问题在于不具备深度学习框架生态掌控力。即使其芯片性能与英伟达水平差不多，但是由于 Tensorflow/Pytorch 两大主流深度学习训练框架没有基于华为昇腾 910 做特定的优化，所以算法结合上述两大训练框架在昇腾 910 上实际跑出来的性能其实不如英伟达 A100；目前仅华为自研的深度学习框架 MindSpore 对昇腾 910 和昇腾 310 做了特别优化，由于华为 MindSpore 大部分精力都是放在对昇腾芯片的算子支持和优化上，对英伟达 GPU 的支持还不够（见下图，英伟达的 GTX 2080Ti 结合 MindSpore 的训练速度明显不如 GTX 2080Ti 结合 Pytorch1.5 的训练速度），所以只有同时使用华为的深度学习框架和昇腾芯片才能同时发挥出两者的最佳性能。

上述我们提到要想在深度学习训练框架要想打破 Tensorflow 和 Pytorch 的垄断必须要靠原始创新，而目前包括华为 MindSpore 在内的国产深度学习框架尚未很好解决上述两大训练框架的痛点。Caffe 之所以能够在早期获得开发者欢迎是因为解决了深度学习框架从 0 到 1 的过程，Tensorflow 之所以可以取代 Caffe 是因为解决了其不够灵活、不能自动求导、对非计算机视觉任务支持不好等问题，Pytorch 之所以明显抢夺 Tensorflow 的份额是因为 Pytorch 引入了动态图解决了 Tensorflow 是静态图设计调试困难的问题。但是目前国产的三个深度学习框架百度 Paddle Paddle、旷视 Megengine、华为 MindSpore 还没有完美解决开发者在用 Tensorflow 和 Pytorch 所遇到的痛点。

我们认为 Tensorflow 和 Pytorch 目前共同的痛点在于对海量算子和各种 AI 芯片支持的难度，华为正在探索靠 AI 编译器的技术来解决上述问题，但是目前编译技术仍然还达不到人工优化的效果。华为全面布局了三个层次的 AI 编译器，包括图灵完备的图灵 IR 设计、使用 poly 技术的图算融合/算子自动生成技术（以 TVM 编译器的设计思想推出算子开发工具 TBE 来解决算子开发自动优化的问题）。

表 5：华为主流推理和训练芯片性能参数

型号	昇腾 310	昇腾 910	昇腾 610
发布年份	2018 年	2019 年	2020 年（研发中）
场景	边缘计算	训练	推理
架构	达芬奇	达芬奇	-
制程	12nm	7nm	-
性能	16TOPS (INT8)	640TOPS (INT8)	100+TOPS (INT8)

型号	昇腾 310	昇腾 910	昇腾 610
	8TOPS (FP16)	320TOPS (FP16)	50+TOPS (FP16)
功耗	8W	310W	-
显存带宽	-	1200 GB/s	-
芯片面积	-	456	-


资料来源：知乎，海思官网，申万宏源研究

图 42：华为在 AI 领域全栈自研：从底层芯片到智能编程语言再到深度学习框架



资料来源：华为官网，申万宏源研究

图 43：MindSpore 和 Pytorch 结合各类芯片训练速度（单位：张/秒）



资料来源：知乎，申万宏源研究

我们认为寒武纪芯片硬件性能相比于英伟达还有追赶空间，上层软件堆栈与英伟达相似，全自研不是兼容路线；不同之处在于寒武纪需要自己对原生深度学习框架进行修改以支持思元芯片，而英伟达有谷歌原厂支持。硬件方面，从一些表观的性能参数对比来看，寒武纪最新一代训练芯片思元 290 和英伟达 A100、昇腾 910 相比性能还有追赶的空间。软件方面，寒武纪是自己对原生的 Tensorflow 和 Pytorch 深度学习框架去针对自己的思


元芯片去做修改而非像华为一样自研深度学习框架去进行优化，也不想英伟达一样因为芯片市占率高，有 Pytorch/Tensorflow 原厂去做 GPU 算子的优化和设备的支持。另外寒武纪相比英伟达的算子库丰富程度以及软件工具链的完善程度还有一定差距，需要时间去追赶。

表 6：寒武纪 AI 芯片性能参数

型号	思元 290	思元 270	思元 100	思元 220
发布年份	2021 年	2019 年	2018 年	2019 年
场景	训练	推理	推理	边缘计算
架构	MLUv02	MLUv02	MLUv01	MLUv02
制程	7nm	16nm	16nm	16nm
性能	512 TOPS (INT8) 256 TOPS (INT16) 64 TOPS (CINT32)	128 TOPS (INT8) 64 TOPS (INT16)	32 TOPS (INT8) 16 TOPS (FP16)	8 TOPS (INT8) 4 TOPS (INT16)
功耗	350W	70W	75W	8.25W
内存带宽	1228 GB/s	102 GB/s	102.4 GB/s	-
芯片面积	-	369.6mm ²	326.5mm ²	94.8mm ²

资料来源：寒武纪官网，申万宏源研究

图 44：寒武纪针对原生 TensorFlow 的修改（深灰色部分）



资料来源：寒武纪，申万宏源研究

图 45：寒武纪的端云一体软件栈架构



资料来源：寒武纪，申万宏源研究

3.3 后记：生态壁垒是现在的阻碍，但不是永远的阻碍

从第二节苹果 MacOS X 的案例可以看到，即使市占率在 10% 上下，只要对开发者足够友好，开发者也是非常愿意去为苹果做生态的。与之类比，当任何一家 AI 芯片公司能够从英伟达手中逐渐拿走 10% 份额的时候，深度学习框架厂商也大概率会去逐渐投入为该厂商的 AI 芯片去做特定优化。

那如何从英伟达手中拿走 10% 份额？——我们认为可能性有很多：

- (1) AI 编译器解决了海量算子集与硬件适配的问题，使得软硬解耦，破除生态壁垒；
- (2) AI 芯片公司研发出来了性能明显超越英伟达 GPU 的芯片，即使深度学习框架厂商主动支持不够，芯片结合定制后的框架、算子库、工具链也具有优越的性价比；
- (3) 等待英伟达失误。但前提之一是自己得先练好“内功”，不能像早期 PC 时代 OS/2、MacOS 一样性能差，不能像 UNIX、MIPS 一样犯下生态碎片化的致命错误；前提之二是必须得活到英伟达犯错的时候，不能像早期 PC 时代 PowerPC 一样无法持续造血支持研发，无法形成商业正循环最终消亡。

关于最后一点，英特尔前 CEO 鲍勃·斯万（Bob Swan）在 2019 年曾经提到：“专注于 90% 的 CPU 市场份额是英特尔错失转型的一个原因……这种维持在 CPU 方面的大多数份额的心态已经导致英特尔变得自满，并错过了一些重要的机会。”英特尔第一次犯错是在 x86-64 位指令集上，AMD 靠兼容性获得了市占率提升；英特尔第二次犯错是从 2016 年开始陷入工艺制程的瓶颈与 Tick-Tock 战略脱节，AMD 推出锐龙架构 CPU 不断蚕食英伟达在 PC 领域的份额。

垄断过久难免会导致自满心态而放慢技术产品迭代的速度或是走上了一条错误的路上。比尔·盖茨在《未来之路》中曾经提到：“你不能高枕在从前的桂冠上休息，因为总有竞争对手从你身后向你逼近。没有任何产品能不经改进而一直处于领先地位。在高科技领域，此刻领先甚至不能保证在不远的将来还会领先。”

AI 生态壁垒看似牢不可破但其实不缺机会，大家不妨期待在 AI 芯片领域谁会是下一个不掉队的 AMD 或者是具有原始创新精神的革命者……

图 46：英伟达在数据中心占据 97% 以上份额

Share of Compute Instance Types with Dedicated Accelerators
Offered by the Top Four Public Clouds
(Alibaba Cloud, Amazon Web Services, Google Cloud & Microsoft Azure)

Company	Accelerator	March 2019	April 2019	May 2019
NVIDIA	GPU	97.0%	97.3%	97.4%
AMD	GPU	1.2%	1.1%	1.0%
Xilinx	FPGA	1.1%	1.0%	1.0%
Intel	FPGA	0.6%	0.6%	0.6%
Total Types	All	1,852	1,990	2,027

资料来源：Liftr Cloud Insights，申万宏源研究

表 7：AI 芯片行业重点公司估值表

证券代码	证券简称	2021-09-03		PB	Wind 一致预期 EPS				PE		
		收盘价(元/美元)	总市值(亿元/亿美元)		2020A	2021E	2022E	2023E	2021E	2022E	2023E
688256.SH	寒武纪	91.41	366	6	-1.15	-1.77	-1.85	-1.23	-52	-50	-74

NVDA.O	英伟达	228.43	5,711	34	7.02	2.75	3.27	3.81	83	70	60
AMD.O	AMD	109.92	1,333	23	2.10	1.84	2.26	2.60	60	49	42
GOOGL.O	谷歌	2,874.79	19,234	9	59.15	98.14	103.68	120.24	29	28	24
TSLA.O	特斯拉	733.57	7,262	33	0.74	4.39	8.23	13.80	167	89	53
9888.HK	百度集团	158.60	4,416	2	8.19	10.95	7.09	8.66	14	22	18

资料来源：Wind 资讯、申万宏源研究

风险提示：（1）非市场因素导致芯片制造环节遭遇瓶颈风险：国内晶圆代工产业环节薄弱，相关国内公司有可能受类似华为所收到的非市场因素扰动导致芯片无法正常生产。（2）关键研发人员流失风险：半导体企业在近一年成立数量众多，半导体人才紧缺，由此带来的工资上涨和核心人员流失可能成为业务潜在风险。（3）客户自研 AI 芯片风险：特斯拉近期发布了自研 AI 训练芯片 Dojo D1，谷歌、百度、阿里纷纷自研 AI 芯片满足自身内部业务发展需要，这给第三方 AI 芯片公司市场需求带来一定不确定性。

信息披露

证券分析师承诺

本报告署名分析师具有中国证券业协会授予的证券投资咨询执业资格并注册为证券分析师，以勤勉的职业态度、专业审慎的研究方法，使用合法合规的信息，独立、客观地出具本报告，并对本报告的内容和观点负责。本人不曾因，不因，也将不会因本报告中的具体推荐意见或观点而直接或间接收到任何形式的补偿。

与公司有关的信息披露

本公司隶属于申万宏源证券有限公司。本公司经中国证券监督管理委员会核准，取得证券投资咨询业务许可。本公司关联机构在法律许可情况下可能持有或交易本报告提到的投资标的，还可能为或争取为这些标的提供投资银行服务。本公司在知晓范围内依法合规地履行披露义务。客户可通过 compliance@swsresearch.com 索取有关披露资料或登录 www.swsresearch.com 信息披露栏目查询从业人员资质情况、静默期安排及其他有关的信息披露。

机构销售团队联系人

华东 A 组	陈陶	021-23297221	chentao1@swsresearch.com
华东 B 组	谢文霓	18930809211	xiewenni@swsresearch.com
华北组	李丹	010-66500631	lidan4@swsresearch.com
华南组	陈左茜	0755-23832751	chenzuoxi@swsresearch.com

股票投资评级说明

证券的投资评级：

以报告日后的 6 个月内，证券相对于市场基准指数的涨跌幅为标准，定义如下：

买入 (Buy)	：相对强于市场表现 20% 以上；
增持 (Outperform)	：相对强于市场表现 5% ~ 20%；
中性 (Neutral)	：相对市场表现在 - 5% ~ + 5% 之间波动；
减持 (Underperform)	：相对弱于市场表现 5% 以下。

行业的投资评级：

以报告日后的 6 个月内，行业相对于市场基准指数的涨跌幅为标准，定义如下：

看好 (Overweight)	：行业超越整体市场表现；
中性 (Neutral)	：行业与整体市场表现基本持平；
看淡 (Underweight)	：行业弱于整体市场表现。

我们在此提醒您，不同证券研究机构采用不同的评级术语及评级标准。我们采用的是相对评级体系，表示投资的相对比重建议；投资者买入或者卖出证券的决定取决于个人的实际情况，比如当前的持仓结构以及其他需要考虑的因素。投资者应阅读整篇报告，以获取比较完整的观点与信息，不应仅仅依靠投资评级来推断结论。申银万国使用自己的行业分类体系，如果您对我们的行业分类有兴趣，可以向我们的销售员索取。

本报告采用的基准指数：沪深 300 指数

法律声明

本报告仅供上海申银万国证券研究所有限公司（以下简称“本公司”）的客户使用。本公司不会因接收人收到本报告而视其为客户。客户应当认识到有关本报告的短信提示、电话推荐等只是研究观点的简要沟通，需以本公司 <http://www.swsresearch.com> 网站刊载的完整报告为准，本公司并接受客户的后续问询。本报告首页列示的联系人，除非另有说明，仅作为本公司就本报告与客户的联络人，承担联络工作，不从事任何证券投资咨询服务业务。

本报告是基于已公开信息撰写，但本公司不保证该等信息的准确性或完整性。本报告所载的资料、工具、意见及推测只提供给客户作参考之用，并非作为或被视为出售或购买证券或其他投资标的的邀请或向人作出邀请。本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可能会波动。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。

客户应当考虑到本公司可能存在可能影响本报告客观性的利益冲突，不应视本报告为作出投资决策的惟一因素。客户应自主作出投资决策并自行承担投资风险。本公司特别提示，本公司不会与任何客户以任何形式分享证券投资收益或分担证券投资损失，任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。本公司未确保本报告充分考虑到个别客户特殊的投资目标、财务状况或需要。本公司建议客户应考虑本报告的任何意见或建议是否符合其特定状况，以及（若有必要）咨询独立投资顾问。在任何情况下，本报告中的信息或所表述的意见并不构成对任何人的投资建议。在任何情况下，本公司不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。市场有风险，投资需谨慎。若本报告的接收人非本公司的客户，应在基于本报告作出任何投资决定或就本报告要求任何解释前咨询独立投资顾问。

本报告的版权归本公司所有，属于非公开资料。本公司对本报告保留一切权利。除非另有书面显示，否则本报告中的所有材料的版权均属本公司。未经本公司事先书面授权，本报告的任何部分均不得以任何方式制作任何形式的拷贝、复印件或复制品，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。所有本报告中使用的商标、服务标记及标记均为本公司的商标、服务标记及标记。