

2021 年 09 月 22 日

# 超越 AlphaGo，自我学习规则的 MuZero 有何突破？

——机器学习系列报告之三

## 相关研究

《量化投资新起点——机器学习系列报告之一》2020 年 9 月 1 日  
《机器学习合成非线性因子，增强效果如何？——机器学习系列报告之二》2021 年 3 月 12 日

## 证券分析师

于光希 A0230520060002  
yugx@swsresearch.com  
邓虎 A0230520070003  
denghu@swsresearch.com

## 联系人

于光希  
(8621)23297818×转  
yugx@swsresearch.com

## 本期投资提示：

- **MuZero 自我学习规则，降低了对环境信息的依赖，具有更强的泛化能力。**2020 年底，DeepMind 提出 MuZero。MuZero 取得的一项突破进展是可以对规则进行自我学习，降低了对环境信息的依赖。在之前的几个版本中，应用场景主要还是棋类游戏。而 MuZero 在 Atari 游戏中，也可以取得很好的效果。
- **AlphaGo 成功地将深度神经网络、强化学习以及蒙特卡洛树搜索结合到了一起，通过深度神经网络和强化学习来指导蒙特卡洛树搜索。**在训练过程中，基于监督学习方法学习策略网络的参数，再使用强化学习中的策略梯度方法进行优化。在对弈过程中，AlphaGo 基于大量自我对弈棋局，对策略进行评估，得到新的价值网络。
- **深度卷积神经网络是 AlphaGo 中使用的重要技术之一。**卷积神经网络通过引入卷积层和池化层，将原始图像转换为一系列特征图，学习数据特征。早在 2014 年，DeepMind 和 Google Brain 就将下棋当成一个图像识别问题，尝试使用深度卷积神经网络，直接表示和学习围棋对弈的知识。通过监督学习训练出的 12 层卷积神经网络，可以达到业余 6 段左右的水平，但距离人类顶尖棋手差距还较大。
- **强化学习是一类特殊的机器学习算法，强化学习研究的是个体如何基于环境而行动，以取得最大化的预期奖励。**无模型强化学习直接与环境的交互中学习价值函数，在这种情况下，深度学习强大的函数逼近能力自然成为首选。**深度强化学习将深度学习的感知能力和强化学习的决策能力相结合，用强化学习定义问题和优化目标，用深度学习进行建模。**借助深度学习中的神经网络，拟合强化学习中的价值函数和策略函数。
- **蒙特卡洛树搜索是一种经典的启发式搜索算法，以极大极小树搜索算法为基础。**在极大极小树搜索中，每次轮到黑棋走时，选择对黑棋最有利的；轮到白棋走时，选择对白棋最有利的。蒙特卡洛树搜索是一个由底向上的过程：搜索树先画到可以承受的深度，然后逐层往上取最大值或最小值回溯，可以通过 Alpha-Beta 剪枝缩减搜索树的大小。
- **MuZero 与之前的版本相比，核心技术仍然是强化学习、深度神经网络和蒙特卡洛树搜索。**不同的是，MuZero 由 3 个神经网络组成：**编码器、生成器和预测器。**MuZero 接收观测值作为输入，并将其转换为隐藏状态，通过一个接收之前隐藏状态和动作的循环进程迭代地更新隐藏状态。在每一步中，模型都会产生一个策略、价值函数和即时奖励的预测。
- **MuZero 在深度神经网络和 MCTS 的运行过程中，没有使用规则。**在 AlphaGo Zero 和 AlphaZero 中，使用一个模拟器模拟环境的动态（如游戏规则），学习搜索树中的状态转换、搜索树中每个节点的动作、搜索树中的终止情形。而 MuZero 不再需要模拟器，从数据中学习得到一个动态函数。在该模型下，树中的每个节点可以通过相应的隐藏状态表示，通过向模型提供一个隐藏状态和一个动作，算法可以生成一个新的隐藏状态。
- **风险提示：**模型根据历史数据构建，历史表现不代表未来，市场环境发生重大变化时可能失效。



申万宏源研究微信服务号

## 目录

---

|                                                |           |
|------------------------------------------------|-----------|
| <b>1. 强化学习：交互式的学习方法 .....</b>                  | <b>4</b>  |
| 1.1 机器学习的重要分类 .....                            | 4         |
| 1.2 基本要素 .....                                 | 5         |
| 1.3 两大特点 .....                                 | 6         |
| 1.4 马尔可夫决策过程 .....                             | 6         |
| 1.5 贝尔曼方程 .....                                | 7         |
| 1.6 策略迭代 vs 价值迭代 .....                         | 8         |
| <b>2. AlphaGo：深度学习、强化学习、蒙特卡洛搜索树的完美结合 .....</b> | <b>11</b> |
| 2.1 AlphaGo 强在哪里？ .....                        | 11        |
| 2.2 卷积神经网络 .....                               | 12        |
| 2.3 深度强化学习 .....                               | 15        |
| 2.4 蒙特卡洛树搜索 .....                              | 17        |
| <b>3. MuZero：超越 AlphaGo，自我学习规则 .....</b>       | <b>18</b> |
| 3.1 三个深度神经网络 .....                             | 18        |
| 3.2 转换隐藏状态 .....                               | 19        |
| 3.3 自我学习规则 .....                               | 20        |
| <b>4. 参考文献 .....</b>                           | <b>21</b> |

## 图表目录

|                                     |    |
|-------------------------------------|----|
| 图 1: 机器学习主要分类 .....                 | 4  |
| 图 2: 强化学习过程示例 .....                 | 5  |
| 图 3: 主要强化学习算法 .....                 | 7  |
| 图 4: 强化学习示例冰面行走游戏 .....             | 8  |
| 图 5: 策略迭代 .....                     | 9  |
| 图 6: 价值迭代 .....                     | 10 |
| 图 7: AlphaGo 以 4: 1 击败世界冠军李世石 ..... | 11 |
| 图 8: AlphaGo 中的策略网络和价值网络 .....      | 12 |
| 图 9: LeNet 结构示意图 .....              | 12 |
| 图 10: 卷积神经网络中的卷积层 .....             | 13 |
| 图 11: 卷积神经网络中的池化层 .....             | 14 |
| 图 12: 深度卷积神经网络前 N 个预测的正确率 .....     | 14 |
| 图 13: 基于模型的强化学习 .....               | 15 |
| 图 14: 无模型强化学习 .....                 | 15 |
| 图 15: AlphaGo 带来围棋中的新定式 .....       | 16 |
| 图 16: 蒙特卡洛树搜索 .....                 | 17 |
| 图 17: MuZero 模型组成 .....             | 18 |
| 图 18: MuZero 模型迭代过程 .....           | 19 |
| 图 19: MuZero 中的 MCTS .....          | 20 |
| 表 1: MuZero 模型组成 .....              | 19 |
| 表 2: MuZero 与 AlphaGo 比较 .....      | 21 |

# 1. 强化学习：交互式的学习方法

## 1.1 机器学习的重要分类

近年来，强化学习特别是深度强化学习取得了令人瞩目的成就，广泛应用于游戏和工业等领域。强化学习是一类特殊的机器学习算法，个体通过与环境不断进行交互完成学习过程。机器学习一般可以分为三类，包括监督学习、无监督学习和强化学习。

**监督学习是一种有标记的学习方法，输入是带标签的数据，学习目标是输入到输出的函数。**函数的输出可以是连续值，也可以是离散值。在监督学习中，每一个输入数据都有一类标签，标签为算法提供了“标准答案”，更好地学习输入和输出之间的内在逻辑关系。多数机器学习算法属于监督学习，包括线性回归、决策树、支持向量机、神经网络等。

**无监督学习的输入是不带标签的数据，学习目标是描述数据结构的函数。**无监督学习从训练数据中自动推断结论，探索数据的内部结构。最典型的无监督学习包括聚类分析和主成分分析。

**强化学习研究的是个体如何基于环境而行动，以取得最大化的预期奖励。**强化学习的本质是一个决策问题，即个体自动进行决策。强化学习是一个动态的过程，个体通过与环境不断进行交互，并通过环境反馈的奖惩来决定下一步行动，学习最优策略。

图 1：机器学习主要分类



资料来源：申万宏源研究

强化学习与监督学习的区别主要在于三点：

1、输入数据形式。监督学习是有标记的学习方法，强化学习不需要带标签的数据，通过环境给出的奖惩来进行学习。监督学习模型从有标签的数据中学习，样本标签即为模型表现的上限；而强化学习的训练数据没有标签，奖励也是没有对错之分的；

2、学习过程。监督学习的学习过程是静态的，代理与环境之间没有进行交互。而强化学习模型人类的决策方式，学习过程是动态的。代理基于环境而行动，在与环境的交互中逐渐学习；


3、训练目标。监督学习关注的是模型预测值和数据标签的误差，而强化学习看重长期的累积奖励。

## 1.2 基本要素

Richard S. Sutton (2018) 将强化学习定义为“个体在环境中学习做什么，即如何将环境中的状态映射到动作，从而获得最大化的累积奖励”<sup>1</sup>。代理 (Agent) 和环境 (Environment) 是强化学习系统中的两大主体，并且不断进行交互。

代理可以感知外界环境的状态，接收环境给予的反馈的奖励，并进行学习和决策。根据外界环境的状态做出不同的动作，学习如何根据环境的奖励来调整策略。环境指代理外部的所有事物，受到代理动作的影响而改变状态，并给予代理相应的反馈（奖励）。

图 2：强化学习过程示例



资料来源：申万宏源研究

强化学习中有五个基本要素，分别是状态、动作、奖励、策略、价值。

**状态 (State)：**代理可以获得的所有环境信息，是对环境的完整描述，状态可以是位置、动态等一切环境信息；

**动作 (Action)：**对代理行为的描述，是代理所有可能动作的集合。动作可以是离散或连续的，通常基于环境，不同的环境导致不同的动作；

**奖励 (Reward)：**代理在一种状态之下，采取特定行动之后，所得到环境的反馈。通常是一个实数；

**策略 (Policy)：**在一种状态下，代理应该采取什么样的行动。策略是一个从状态到行动的函数，可以分为确定性策略和随机性策略；

**价值 (Value)：**代理采取行动的预期回报函数，包括状态价值函数、状态行动价值函数，策略函数取决于价值函数。

<sup>1</sup> Reinforcement learning is learning what to do--how to map situations to actions--so as to maximize a numerical reward signal.

## 1.3 两大特点

试错学习 (Trial and Error) 和延迟奖励 (Delayed Reward) 是强化学习最重要的两个特点。

试错学习：环境没有给出直接的“标准答案”，而是给出奖励。代理要不断与环境进行交互，通过试错的方式学习最佳策略。以下棋为例，相较于对照棋谱学习的监督学习方法，代理每一次落子没有好坏之分，只有奖惩之别。在不断下棋试错的过程中，学习哪一步价值最大；

延迟奖励：在强化学习中，代理采取的部分行动可能没有即时的奖励，但是每一步行动对最终的结果都会产生影响。一个动作的全部影响，只有等到整个决策过程结束时，才能进行判断。因此强化学习中，需要学习过去行动的价值。

## 1.4 马尔可夫决策过程

代理与环境的交互，可以描述为一个马尔可夫决策过程。代理从初始状态 $s_0$ 开始，产生相应的动作 $a_0$ 。这时环境发生相应改变，进入新状态 $s_1$ ，并且反馈给代理一个奖励 $r_1$ ，如此循环反复。

马尔可夫性是概率论中的一个重要概念，指一个随机过程在给定现在状态及所有过去状态的情况下，未来状态仅依赖于当前状态。当前状态包含了所有历史信息，只要当前状态可知，所有的历史信息都不再需要。即下一时刻的状态 $s_{t+1}$ 只取决于当前状态 $s_t$ ：

$$p(s_{t+1}|s_t, \dots, s_0) = p(s_{t+1}|s_t)$$

马尔可夫决策过程在此基础上，加入了动作的影响。即下一时刻的状态 $s_{t+1}$ 不仅与 $s_t$ 相关，而且和动作 $a_t$ 相关：

$$p(s_{t+1}|s_t, a_t, \dots, s_0, a_0) = p(s_{t+1}|s_t, a_t)$$

$s \in S$ ：状态集合， $s$ 表示某个特定状态；

$a \in A$ ：动作集合， $a$ 表示某个特定动作；

$P(s'|s, a)$ ：状态转移模型，根据当前状态 $s$ 和动作 $a$ 预测下一个状态 $s'$ ， $P$ 表示从状态 $s$ 采取行动 $a$ 转移到 $s'$ 的概率；

$R_{t+1}$ ：代理在 $t$ 时刻采取动作 $a$ 后的即时奖励；

$\pi(s) \rightarrow a$ ：根据当前状态产生动作， $\pi(a|s) = P[a|s]$ ，表示某种状态下执行某个动作的概率。

## 1.5 贝尔曼方程

给定策略 $\pi(a|s)$ ，总回报是代理和环境一次交互过程的所收到的累积奖励：

$$G_t = \sum_{t=0}^{T-1} R_{t+1}$$

当环境中存在终止状态时，到达终止状态一次交互过程结束。当 $T = \infty$ 时，没有终止状态，总回报此时可能为无穷大。需要引入折扣率 $\gamma$ ，计算折扣率加权的总回报：

$$G_t = \sum_{t=0}^{T-1} \gamma^t R_{t+1}$$

强化学习的目标是学习一个策略，使得预期奖励最大化。通过价值函数，可以评估策略的期望回报。状态价值函数表示从状态 $s$ 开始，执行策略 $\pi$ 的期望总回报：

$$V_{\pi}(s) = E_{\pi}[G_t | S_t = s]$$

状态动作价值函数不仅仅指策略对应的价值，而是在特定状态 $s$ ，采取某种动作，然后执行策略 $\pi$ 的期望总回报：

$$Q_{\pi} = E_{\pi}[G_t | S_t = s, A_t = a]$$

价值函数可以进一步分解为两部分：1、当前时刻获得的及时收益；2、下一个状态价值函数的折扣回报：

$$\begin{aligned} V_{\pi}(s) &= E_{\pi}[G_t | S_t = s] \\ &= E_{\pi}[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots | S_t = s] \\ &= E_{\pi}[R_{t+1} + \gamma(R_{t+2} + \gamma R_{t+3} + \dots) | S_t = s] \\ &= E_{\pi}[R_{t+1} + \gamma G_{t+1} | S_t = s] \\ &= E_{\pi}[R_{t+1} + \gamma V_{\pi}(S_{t+1}) | S_t = s] \end{aligned}$$

上式也被称为贝尔曼方程。动作价值函数同样也可以分解为两部分，得到 Q 函数的贝尔曼方程：

$$Q_{\pi}(s, a) = E_{\pi}[R_{t+1} + \gamma Q_{\pi}(S_{t+1}, A_{t+1}) | S_t = s, A_t = a]$$


贝尔曼最优方程：

$$\begin{aligned} V_*(s) &= \max_{\pi} V_{\pi}(s) \\ Q_*(s, a) &= \max_{\pi} Q_{\pi}(s, a) \end{aligned}$$

求解最优策略有多种方法，一般采用近似的方式，常用方法包括价值迭代、策略迭代、Q 学习、SARS 算法等。

### 图 3：主要强化学习算法






资料来源：《神经网络与深度学习》，申万宏源研究

## 1.6 策略迭代 vs 价值迭代

策略迭代和价值迭代是两种常用的动态规划算法。下面我们以冰面行走游戏为例，说明两种方法的迭代过程。在这个游戏中，代理需要寻找从开始状态（人所在的位置）到目标状态（有撒花图样的位置）的最优路线。

图 4：强化学习示例冰面行走游戏



资料来源：申万宏源研究

首先说明在这个游戏中强化学习的基本要素。

**动作：**所有可能动作的集合。 $A=\{\text{上、下、左、右}\}$ ，即代理在每个单元格可以行走的方向；

**状态：**所有状态的集合。即  $3\times 3$  棋盘每个单元格的位置坐标，其中代理当前位于(1, 1)，目标位于(3, 2)；

**奖励：**代理可能收到的奖励。这里我们定义，如果代理每移动一步，奖励  $r=-1$ ；如果到达目的地，奖励  $r=0$ ，同时游戏结束；

**收益：**从当前时刻 0 开始的累积收益，可以取  $T=\infty$ 。




### 1.6.1 策略迭代

策略迭代是动态规划中最常用的方法之一，借助贝尔曼方程，不断进行策略的评估和更新，最终得到逐次改进的最优策略。价值迭代间接地寻找最优策略，而在策略迭代中，直接存储和更新策略。策略迭代可以分为两个步骤，包括策略评估和策略提升：

- 1、随机初始化策略 $\pi$ ，根据贝尔曼方程，迭代计算当前状态的价值函数 $V_{\pi}(s)$ ；
- 2、根据价值函数，更新策略得到 $\pi^*$ ，直到策略收敛为止。

从以上迭代过程可以看出，策略迭代中策略评估和策略提升交替进行。而策略评估中需要根据贝尔曼方程再进行内部迭代，因此策略迭代的主要时间花在策略评估这一步骤上。如果是一个复杂的强化学习，策略评估时间会随着状态的增多指数级增长，这个步骤的时间就相对较长。

图 5：策略迭代



资料来源：申万宏源研究

- 1、初始化：随机选择一个策略为初始值，例如一律往下走；
- 2、策略评估：根据当前的策略计算价值函数；
- 3、策略提升：计算当前状态的最优动作 $\max_a \{Q(s, a)\}$ ，更新策略 $\pi(s) = \operatorname{argmax}_a \{Q(s, a)\}$ 。

策略迭代首先初始化策略，即不论什么状态，一律往下走。通过策略评估发现，只有撒花正上方的状态可以到达，价值函数分别为[-2, -1, 0]。在这种策略下，其余状态均不能达到目标，价值函数为负无穷。然后进行策略提升，对于撒花正上方的状态，策略保持不变；对于不在正上方的状态，根据公式更新策略，最优策略为横向移动一步。通过这种循环迭代的方式进行策略评估，更新各状态的价值函数，直到策略不再更新变化，即可得到最优策略。

## 1.6.2 价值迭代

价值迭代可以理解为策略迭代的一个改进版本，将策略评估和策略提升两个步骤合并。在价值迭代中，首先遍历环境中的每一个状态。对每一个状态，依次尝试所有可能的动作。并计算每个动作的价值，即状态动作价值函数，当前状态的最优动作即为最大化价值函数的动作。重复以上过程，直到每个状态的价值函数不再发生变化，此时即可找到最优策略。

价值迭代直接使用贝尔曼最优方程，寻找最优策略，每一步计算最大化价值函数。找到最优价值函数，对应的即为最优策略 $\pi^*$ ：

$$V_*(s) = \max_a E_{\pi^*} [R_{t+1} + V_*(S_{t+1}) | S_t = s, A_t = a]$$

$$Q_*(s, a) = E_{\pi^*} [R_{t+1} + \gamma \max_{a'} Q_*(S_{t+1}, a') | S_t = s, A_t = a]$$

与策略迭代相比，价值迭代的时间复杂度大大降低。价值迭代不需要等到价值函数收敛再调整策略，而是随着价值函数的迭代，及时调整策略。价值迭代直接使用贝尔曼最优方程更新价值函数，最优价值函数即对应最优策略。策略迭代使用贝尔曼方程更新价值函数，根据价值函数改进策略。

图 6：价值迭代

|     |       |       |       |
|-----|-------|-------|-------|
|     |       |       |       |
| 初始化 | 第一轮迭代 | 第二轮迭代 | 第三轮迭代 |

资料来源：申万宏源研究

首先，初始化所有状态的价值为 0。然后在每一轮迭代中，对每一个状态  $s$  依次进行迭代更新：

- 1、分别尝试{上、下、左、右}四个动作，记录代理到达的新状态 $s'$ 和奖励 $r$ ；
- 2、计算每个动作的价值 $Q(s, a) = r + V(s')$ ；
- 3、根据最大化状态动作价值函数，选择最优动作 $\max_a \{Q(s, a)\}$ ；
- 4、更新 $s$ 状态价值函数 $V(s) = \max_a \{Q(s, a)\}$ 。

在第一轮迭代中，初始价值函数均为 0。除撒花位置的状态外，其余状态每移动一步，奖励 $r = -1$ 。根据 $V(s) = r + V(s')$ ，可得更新后的价值函数为-1。在第二轮迭代中，和撒花位置相邻的状态，最优动作可以走一步到达目标位置。而其余状态只能一步到达 $V(s') = -1$ 的状态，每移动一步，奖励 $r = -1$ ， $V(s)$ 继续更新为-2。之后

的迭代方式保持一致，在第三轮迭代之后，所有价值函数不再发生变化。此时从开始状态出发，每一步选择最优动作，即可到达目标状态，路线即为最优策略。

以上迭代过程即运用了贝尔曼方程，对价值函数进行更新：

$$V_*(s) = \max_a E[r + V_*(s') | S_t = s, A_t = a]$$

## 2. AlphaGo：深度学习、强化学习、蒙特卡洛搜索树的完美结合

### 2.1 AlphaGo 强在哪里？

围棋起源于中国，是世界上最古老的棋类运动之一，至今已经有几千年的历史。围棋中的落点极多、计算量极大，“弃子争先”、“势孤取和”等术语也说明围棋中对局势的判断较为复杂。因此早在 1997 年，电脑程序“深蓝”就已经击败国际象棋世界冠军，而一直难以战胜围棋职业棋手。

而在 2016 年 3 月，经过数以万计的自我对弈练习，由 DeepMind 开发的人工智能围棋程序 AlphaGo 以 4:1 击败世界冠军李世石，同时也成为第一个在不让子情况下击败围棋职业九段棋手的电脑程序。AlphaGo 的胜利是里程碑式的，而其后 AlphaGo Zero 仅训练 40 天就超越了所有旧版本。

图 7：AlphaGo 以 4:1 击败世界冠军李世石




资料来源：Maclean's，申万宏源研究

AlphaGo 成功地将深度神经网络、强化学习（监督学习）以及蒙特卡洛树搜索结合到了一起，通过深度神经网络和强化学习来指导蒙特卡洛树搜索。在面对其他围棋程序时，达到了高达 99.8% 的胜率。在 AlphaGo 中，深度神经网络包括策略网络（policy network）和价值网络（value network）。其中，策略网络又分为监督学习和强化学习两种训练模式，作用是在给定当前棋局的情况下，预测下一步的落子。价值网络的作用是在给定当前棋局的情况下，评估双方的胜率。

AlphaGo 的生产过程可以分为两个阶段，分别是训练过程和对弈过程。在训练过程中，基于监督学习方法学习策略网络的参数，再使用强化学习中的策略梯度方法进行优化。在对弈过程中，AlphaGo 基于大量自我对弈棋局，对策略进行评估，得到新的价值网络。

图 8: AlphaGo 中的策略网络和价值网络




资料来源：《Mastering the game of Go with deep neural networks and tree search》，申万宏源研究

## 2.2 卷积神经网络

深度卷积神经网络是 AlphaGo 中使用的重要技术之一。在神经网络中，基本单位神经元构成了层，层与层之间通过不同的连接方式构成网络。多层次结构是神经网络区别于其他机器学习算法的特点，学习过程也被称为“深度学习”。卷积神经网络是目前深度学习领域应用最为广泛的神经网络之一，在图像相关领域取得了众多突破性的进展。

1998 年，Yann LeCun 提出 LeNet5 网络，卷积神经网络开始引起学术界的关注。LeNet5 通过引入卷积层和池化层，将原始图像转换为一系列特征图。并且将网络通过卷积和池化运算学习到的特征，传递给全连接的神经网络，对图像进行分类。在 LeNet5 网络之后，由于当时计算机硬件条件的限制，卷积神经网络发展相对缓慢。直到 2012 年，AlexNet 出现并赢得了当年 ImageNet 大规模视觉识别挑战赛的冠军，奠定了卷积神经网络在深度学习应用中的地位。此后，深度学习在图像识别领域发展迅速，不断有新的网络结构出现，包括 VGGNet、ResNet、GoogLeNet 等。

图 9: LeNet 结构示意图



资料来源：《Gradient-based Learning Applied to Document Recognition》，申万宏源研究


卷积神经网络中有两类特殊的层结构，卷积层和池化层。

## 2.2.1 卷积层

卷积层是卷积神经网络的核心。卷积层的核心思想是通过局部连接和权值共享的网络结构，有效地保存输入图像的关键信息，同时大大降低模型的复杂度。卷积层的参数是一组可以学习图像数据特征的卷积核，维度一般小于输入数据。

在卷积运算中，卷积核沿着输入图像以一个像素的步幅不断滑动，在每一个滑动的位置，计算两个矩阵对应元素的乘积并求和。每一次卷积运算的最终结果是一个数字，同时也是输出矩阵的一个元素，输出矩阵又被称为特征图。在下图中，绿色矩阵是一个  $3 \times 3$  的图像输入数据，黄色矩阵是一个  $2 \times 2$  的卷积核。通过卷积运算，生成  $2 \times 2$  的红色特征图，其第一个元素即为卷积核与输入数据相应位置进行的卷积运算结果， $2 \times 1 + 1 \times 3 + 1 \times 1 + 0 \times 0 = 6$ 。

图 10：卷积神经网络中的卷积层



资料来源：申万宏源研究


## 2.2.2 池化层

池化层是卷积神经网络中另一种重要的结构，又被称为子采样（subsampling）或下采样（downsampling）。为了有效获得图像的特征，池化层通过不同的非线性

池化方法，将关键的信息被提取出来。作用在于降低特征图的维数，从而简化网络复杂度，保留最重要的信息。常用的池化方法包括最大值、平均值、求和等。

以最大池化为例，首先定义特征图中的一个子区域，并提取这个区域中元素的最大值。然后按照这种方式，依次遍历所有的子区域，提取出的最大元素就组成一个新矩阵。这样就实现了数据降维，图像维度由  $4 \times 4$  降低到  $2 \times 2$ 。

图 11：卷积神经网络中的池化层



资料来源：《机器学习在量化金融中的应用》，申万宏源研究

卷积神经网络的两个特点是权值共享和局部连接。


1、共享权值。在卷积层中，神经元对应的权值是相同的，因此可以大大减少训练的参数数量。在卷积运算过程中，输入数据的不同区域与卷积核进行运算，共享了卷积核的权值。

2、局部连接。一般的深度神经网络会将每一个神经元连接到上一层中所有神经元，当处理图像这类高维数据时，这样的连接方式是不现实的。因此在卷积神经网络中，每一个神经元只连接到输入图像的一个局部区域，从而减少参数训练的数量。

早在 2014 年，DeepMind 和 Google Brain 就将下棋当成一个图像识别问题，尝试使用深度卷积神经网络，直接表示和学习围棋对弈的知识。首先，观察人类棋手的围棋对弈棋局。在每一个状态  $s$ ，都会对应一个人类棋手的动作  $a$ 。将  $s$  看做一个  $19 \times 19$  的二维图像，输入卷积神经网络进行训练。给定某个状态  $s$ ，模型首先计算出人类棋手所有可能动作的概率分布，然后每一步都选择概率最高的动作，如此循环往复落子。通过监督学习训练出的 12 层卷积神经网络，在与传统围棋程序 GnuGo 的对弈中拥有 97% 的胜率。可以达到业余 6 段左右的水平，但距离人类顶尖棋手差距还较大。

图 12：深度卷积神经网络前 N 个预测的正确率






资料来源:《Move Evaluation In GO Using Deep Convolutional Neural Networks》,  
申万宏源研究

## 2.3 深度强化学习

通过策略迭代和价值迭代求解强化学习问题,一般需要较多的迭代次数才能找到最优策略。这是一种基于模型的强化学习,实际上是一种动态规划方法。基于模型的强化学习构建了一个关于环境的模型,一般可以由两个部分组成的马尔可夫决策过程表示:一个状态转移模型,预测给定行动的下一个状态;一个奖励模型,预测转移过程中的预期回报。


但在实际应用中,当面对状态和动作数量较多的任务时,基于模型的强化学习应用会受到限制。首先要求模型已知,即概率转移矩阵 $P$ 和回报函数 $R$ 已知或存在估计。但很多问题概率转移矩阵很难估计,如基于像素的图片维度过高,直接学习像素空间上的概率转移矩阵难度很大。不管是策略迭代还是价值迭代,随着状态和动作数量的增加,迭代过程中的计算量过大,导致无法求解。如围棋棋盘 $19 \times 19$ ,每一个位置都有三种状态(黑子、白子、无子),共计 $3^{361}$ 。

图 13: 基于模型的强化学习



资料来源: 申万宏源研究

图 14: 无模型强化学习



资料来源: 申万宏源研究



### 2.3.1 无模型强化学习

而无模型强化学习直接从与环境的交互中学习价值函数,常用的方法包括蒙特卡洛方法、时序差分方法等。 $Q$ 学习是一种基于时序差分学习的方法,结合了蒙特卡洛方法以及动态规划的思想,可以直接从原始数据中学习,选择最优的 $Q$ 函数。

简单来说,二者的区别在于是否已知当前的状态、动作转移至下一状态及获得奖励的分布,如果已知,则是基于模型的强化学习。在这个过程中,代理没有跟环境进行交互,环境的所有信息已经在模型中。在无模型强化学习中,代理需要跟环境进行交互,才能获取环境信息改进策略。

### 2.3.2 深度强化学习

在强化学习中,很多实际问题的输入数据是高维数据,如图像、声音等。经典的无模型强化学习算法,仍然受限于“维数灾难”。如在 $Q$ 学习中, $Q$ 函数值存储在一个二维表格中,状态和动作需要预先设计,应用仍然局限于状态和动作数量较少的情况。为了解决这些问题,可以引入一个复杂的函数,增强代理对环境状态的感知能力,建立更复杂的策略。在这种情况下,深度学习强大的函数逼近能力自然成为了首选。


深度强化学习将深度学习的感知能力和强化学习的决策能力相结合,用强化学习定义问题和优化目标,用深度学习进行建模。借助深度学习中的神经网络,拟合强化学习中的价值函数和策略函数。如同样由DeepMind提出的深度 $Q$ 网络,使用卷积神经网络拟合价值函数( $Q$ 函数),输出执行各种动作所能得到 $Q$ 函数的极大值。

### 2.3.3 探索 vs 利用

在强化学习的训练过程中,为了构建最优策略,代理面临一个两难问题:根据已有经验选择最佳策略,但决策过程有可能受限于已有经验;如果尝试新的状态,则有可能不是最优选择,需要不断“试错”。

显然,探索(Exploration)和利用(Exploitation)相互矛盾。为了最大化预期奖励,代理需要在两者之间寻找一个平衡。即根据已有经验学习最优策略的同时,尽可能探索新状态。在几千年的发展过程中,人类已经总结出了围棋中的很多固定下法,我们称之为“定式”。而借助深度强化学习和蒙特卡洛树搜索算法,AlphaGo在训练过程中探索新的走法,在对弈中带来了很多新定式,包括开局点三三、大雪崩定式、妖刀定式等等。

#### 图 15: AlphaGo 带来围棋中的新定式



资料来源：《Mastering the Game of Go without Human Knowledge》，申万宏源研究


## 2.4 蒙特卡洛树搜索

当进入到对弈阶段时，AlphaGo 采用的是蒙特卡洛树搜索（Monte Carol Tree Search, MCTS）搜索方法。蒙特卡洛树搜索是一种经典的启发式搜索算法，以样本与结果为导向，避免了传统棋类游戏的暴力搜寻方式，极大减轻了计算机的处理负担。

蒙特卡洛树搜索以极大极小树搜索（MiniMax Tree Search）算法为基础。传统的蒙特卡洛方法倾向于选择平均胜率最高的下法，在应用于围棋时会遇到以下问题。此时黑棋有 A1 和 A2 两种选择，其中 A1 的平均胜率 51%，A2 的平均胜率 53%。按照蒙特卡洛方法，应该选择 A2。但如果黑棋下 A2，白棋下 B4，黑棋胜率为 43%；黑棋下 A1，白棋下 B2，黑棋胜率为 47%。显然，选择 A1 黑棋的最低胜率更高。因此在极大极小树搜索中，每次轮到黑棋走时，选择对黑棋最有利的；轮到白棋走时，选择对白棋最有利的。

蒙特卡洛树搜索是一个由底向上的过程：搜索树先画到可以承受的深度，然后逐层往上取最大值或最小值回溯，可以通过 Alpha-Beta 剪枝缩减搜索树的大小。

图 16：蒙特卡洛树搜索



资料来源：申万宏源研究

### 3. MuZero：超越 AlphaGo，自我学习规则

2020 年底，DeepMind 再次提出了 MuZero。在之前 AlphaGo 各个版本的基础上，对模型架构和训练方法进行了改进。MuZero 取得的一项突破进展是模型可以自行学习环境并进行决策，降低了对环境信息（游戏规则）的依赖，将应用场景从棋类游戏进一步扩展到了 Atari 游戏。


#### 3.1 三个深度神经网络

MuZero 与之前的版本相比，核心技术仍然是强化学习、深度神经网络和蒙特卡洛树搜索。不同的是，AlphaZero 只有一个神经网络，而在 MuZero 中，神经网络模型由 3 部分组成：

- 1、编码器  $h$  (representation function)：将对环境的历史观测值（如围棋棋盘或 Atari 屏幕），转换为初始状态  $s_0$ ；
- 2、生成器  $g$  (dynamics function)：表示系统中的动态变化。给定前一个隐藏状态  $s_{t-1}$  和一个动作  $a_t$ ，生成一个即时奖励  $r_t$  和一个新的隐藏状态  $s_t$ ；
- 3、预测器  $f$  (prediction function)：策略  $p$  以及价值函数  $V$  是通过预测器，从前一个隐藏状态中计算得到。

三个深度神经网络模型的参数相同，使用同一个损失函数联合优化。在棋类游戏中，仍然使用 MSE 损失函数。但在 Atari 游戏中，交叉熵损失函数表现更加稳定。

图 17：MuZero 模型组成



资料来源：《Mastering Atari, Go, Chess and Shogi by Planning with a Learned Model》，申万宏源研究

表 1: MuZero 模型组成

|                      | 输入           | 输出        |
|----------------------|--------------|-----------|
| 编码器 (representation) | 历史观测值        | 初始隐藏状态    |
| 生成器 (dynamics)       | 前一个隐藏状态和一个动作 | 即时奖励和隐藏状态 |
| 预测器 (prediction)     | 当前隐藏状态       | 策略函数和价值函数 |


资料来源:《Mastering Atari, Go, Chess and Shogi by Planning with a Learned Model》, 申万宏源研究

## 3.2 转换隐藏状态

MuZero 接收观测值作为输入, 并将其转换为隐藏状态。然后, 通过一个接收之前隐藏状态和动作的循环进程迭代地更新隐藏状态。在每一步中, 模型都会产生一个策略 (预测要进行的动作)、价值函数 (预测累积奖励) 和即时奖励的预测。为了对策略、价值函数和奖励进行准确的估计, 模型进行了端到端的训练。转换得到的隐藏状态, 不需要匹配环境的未知或真实状态, 也没有对状态做规则上的约束。隐藏状态可以表示任何正确估计策略、价值函数和奖励的状态, 即代理可以内部创造任何动态。

首先编码器  $h$  通过观察环境的初始情况, 通过编码器  $h$  产生初始隐藏状态  $S_0$ 。同时  $S_0$  也作为生成器  $g$  的输入, 加上当前的动作  $a_t$ , 生成下一个隐藏状态  $S_1$  及奖励  $r_t$ 。同时  $S_0$  作为预测器  $f$  的输入, 生成当前的策略  $p$  和价值函数  $V$ 。在之后的行动中, 便可以使用生成器  $g$  去循环计算下一个隐藏状态。

图 18: MuZero 模型迭代过程



资料来源:《Mastering Atari, Go, Chess and Shogi by Planning with a Learned Model》, 申万宏源研究

在 MuZero 中, 蒙特卡洛树搜索包括四个主要阶段: 选择、扩展、模拟和回溯。通过重复执行这些阶段, 蒙特卡洛树搜索根据节点可能的动作序列逐步构建搜索树。树中每个节点表示环境状态, 节点之间的线表示从一个状态到下一个状态的动作。


**选择阶段:** 从树的根节点出发, 即环境或游戏的当前位置。在每个节点 (状态  $S$ ), 每次选择一个子节点, 直到未扩展的子节点, 即从未遇到过的走法;

**扩展阶段:** 把未访问节点添加到树中, 然后对该节点进行模拟, 以便进行更深入的搜索。在 MuZero 中, 扩展阈值为 1, 即每个节点在首次访问后都会立即扩展;

**模拟阶段:** 从未扩展的子节点开始, 使用评分函数  $U(S, a)$  比较不同的动作  $a$ , 并选择最优动作。MuZero 中使用的评分函数是将先前的估计  $p(s, a)$  与  $v(s')$  的值结合起来, 即  $U(S, a) = v(s') + c * p(s, a)$ ;

**回溯阶段:** 将神经网络的值估计传播回搜索树, 沿着搜索路径逐一更新节点信息, 重新回到根节点。即对当前节点和路径上的所有节点, 更新访问次数, 并对奖励进行累加。

图 19: MuZero 中的蒙特卡洛树搜索



资料来源: 《Mastering Atari, Go, Chess and Shogi by Planning with a Learned Model》, 申万宏源研究

### 3.3 自我学习规则

在 AlphaGo Zero 和 AlphaZero 中, 使用一个模拟器模拟环境的动态 (如游戏规则), 学习三方面内容: 搜索树中的状态转换; 搜索树中每个节点的动作; 搜索树中的终止情形。而 MuZero 不再需要模拟器, 从数据中学习得到一个动态函数。在该模型下, 树中的每个节点可以通过相应的隐藏状态表示, 通过向模型提供一个隐藏状态和一个动作, 算法可以生成一个新的隐藏状态。MuZero 在深度神经网络和蒙特卡洛树搜索的运行过程中, 没有使用规则。

AlphaGo 的学习需要人类数据、领域知识和游戏规则; AlphaGo Zero 和 AlphaZero 无需人数的对弈数据, 可以通过自我对战进行学习, 但仍然需要游戏规则; 而 MuZero 无需告知规则, 可以对规则进行自我学习。因此 MuZero 必须创建自己的动态环境模型, 并在此模型中进行优化来学习如何玩游戏。

由于 MuZero 可以自我学习规则，因此降低了对环境信息的依赖。学习的环境模型不依赖于先验知识，具有更强的泛化能力。在之前的几个版本中，应用场景主要还是棋类游戏。而 MuZero 在 Atari 游戏中，也可以取得很好的效果。

**表 2: MuZero 与 AlphaGo 比较**

| 算法           | 领域               | 知识             | 特征            |
|--------------|------------------|----------------|---------------|
| AlphaGo      | 围棋               | 人类数据、领域知识、游戏规则 | 第一个精通围棋的电脑程序  |
| AlphaGo Zero | 围棋               | 游戏规则           | 无需人类数据，自我对战学习 |
| AlphaZero    | 围棋、国际象棋、将棋       | 游戏规则           | 还能学会国际象棋和将棋   |
| MuZero       | 围棋、国际象棋、将棋、Atari |                | 可以自我学习规则      |

资料来源: DeepMind, 申万宏源研究

## 4. 参考文献

- [1] Sutton R S, Barto A G. Reinforcement learning: An introduction[M]. MIT press, 2018.
- [2] 邱锡鹏, 神经网络与深度学习, 机械工业出版社, <https://nndl.github.io/>, 2020.
- [3] Silver D, Huang A, Maddison C J, et al. Mastering the game of Go with deep neural networks and tree search[J]. nature, 2016, 529(7587): 484-489.
- [4] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [5] Maddison C J, Huang A, Sutskever I, et al. Move evaluation in Go using deep convolutional neural networks[J]. arXiv preprint arXiv:1412.6564, 2014.
- [6] Schrittwieser J, Antonoglou I, Hubert T, et al. Mastering atari, go, chess and shogi by planning with a learned model[J]. Nature, 2020, 588(7839): 604-609.



## 信息披露

### 证券分析师承诺

本报告署名分析师具有中国证券业协会授予的证券投资咨询执业资格并注册为证券分析师，以勤勉的职业态度、专业审慎的研究方法，使用合法合规的信息，独立、客观地出具本报告，并对本报告的内容和观点负责。本人不曾因，不因，也将不会因本报告中的具体推荐意见或观点而直接或间接收到任何形式的补偿。

### 与公司有关的信息披露

本公司隶属于申万宏源证券有限公司。本公司经中国证券监督管理委员会核准，取得证券投资咨询业务许可。本公司关联机构在法律许可情况下可能持有或交易本报告提到的投资标的，还可能为或争取为这些标的提供投资银行服务。本公司在知晓范围内依法合规地履行披露义务。客户可通过 [compliance@swsresearch.com](mailto:compliance@swsresearch.com) 索取有关披露资料或登录 [www.swsresearch.com](http://www.swsresearch.com) 信息披露栏目查询从业人员资质情况、静默期安排及其他有关的信息披露。

### 机构销售团队联系人

|        |     |               |                                                                |
|--------|-----|---------------|----------------------------------------------------------------|
| 华东 A 组 | 陈陶  | 021-23297221  | <a href="mailto:chentao1@swhyse.com">chentao1@swhyse.com</a>   |
| 华东 B 组 | 谢文霓 | 18930809211   | <a href="mailto:xiewenni@swhyse.com">xiewenni@swhyse.com</a>   |
| 华北组    | 李丹  | 010-66500631  | <a href="mailto:lidan4@swhyse.com">lidan4@swhyse.com</a>       |
| 华南组    | 陈左茜 | 0755-23832751 | <a href="mailto:chenzuoxi@swhyse.com">chenzuoxi@swhyse.com</a> |

### 法律声明

本报告仅供上海申银万国证券研究所有限公司（以下简称“本公司”）的客户使用。本公司不会因接收人收到本报告而视其为客户。客户应当认识到有关本报告的短信提示、电话推荐等只是研究观点的简要沟通，需以本公司 <http://www.swsresearch.com> 网站刊载的完整报告为准，本公司并接受客户的后续问询。本报告首页列示的联系人，除非另有说明，仅作为本公司就本报告与客户的联络人，承担联络工作，不从事任何证券投资咨询服务业务。

本报告是基于已公开信息撰写，但本公司不保证该等信息的准确性或完整性。本报告所载的资料、工具、意见及推测只提供给客户作参考之用，并非作为或被视为出售或购买证券或其他投资标的的邀请或向人作出邀请。本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可能会波动。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。

客户应当考虑到本公司可能存在可能影响本报告客观性的利益冲突，不应视本报告为作出投资决策的惟一因素。客户应自主作出投资决策并自行承担投资风险。本公司特别提示，本公司不会与任何客户以任何形式分享证券投资收益或分担证券投资损失，任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。本公司未确保本报告充分考虑到个别客户特殊的投资目标、财务状况或需要。本公司建议客户应考虑本报告的任何意见或建议是否符合其特定状况，以及（若有必要）咨询独立投资顾问。在任何情况下，本报告中的信息或所表述的意见并不构成对任何人的投资建议。在任何情况下，本公司不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。市场有风险，投资需谨慎。若本报告的接收人非本公司的客户，应在基于本报告作出任何投资决定或就本报告要求任何解释前咨询独立投资顾问。

本报告的版权归本公司所有，属于非公开资料。本公司对本报告保留一切权利。除非另有书面显示，否则本报告中的所有材料的版权均属本公司。未经本公司事先书面授权，本报告的任何部分均不得以任何方式制作任何形式的拷贝、复印件或复制品，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。所有本报告中使用的商标、服务标记及标记均为本公司的商标、服务标记及标记。