

分析师:

郑兆磊

S0190520080006

宫民

S0190521040001

系统化资产配置系列之十三: 动态协方差矩阵估计与组合构建

2021 年 12 月 06 日

报告关键点

本文介绍了多种协方差矩阵的预测方法,并比较了不同方法的预测误差和样本外最小方差组合的构建准确度。测算结果显示,相比传统的历史协方差方法,指数移动平均法和两种 GARCH 方法均能够显著降低协方差预测误差。我们将动态协方差预测方法应用于风险预算组合的构建,发现协方差预测的越准确,组合表现越优异。

相关报告

《系统化资产配置系列之十二: 战略资产配置中的股票长期收益率预测》2021-02-19

《系统化资产配置系列之十一: 基于量化视角的利率债择时体系研究》2020-12-20

《系统化资产配置系列之十: 利用基金仓位信息对市场择时》2020-07-21

《系统化资产配置系列之九: 基于保值、避险和投机因子的黄金择时模型》2020-07-09

投资要点

- 协方差矩阵估计是组合风险优化的核心要素,在实际操作中常用的方法是直接将历史协方差矩阵作为估计值,比如用过去 10 年的收益率计算。但这种方法隐含假设了资产本身的波动率以及资产间相关性是恒定的,而实际上它们往往是时变的。
- 本文介绍了多种协方差矩阵的预测方法,并比较了不同方法的预测误差和样本外最小方差组合的构建准确度。具体来说我们首先选取了中国大类资产组合、中国股票行业组合、全球大类资产组合和全球股票行业组合作为测算基准,然后测试了历史协方差法、收缩历史协方差、指数移动平均法、DCC-GARCH 模型和 GO-GARCH 模型的预测能力。
- 测算结果显示,相比传统的历史协方差方法,指数移动平均法和两种 GARCH 方法均能够显著降低协方差预测误差。举例来说,对于中国大类资产组合,GO-GARCH 能够减少 31%的协方差预测误差。对于全球大类资产组合,DCC-GARCH 也能够减少大约 15%的预测误差。
- 我们将动态协方差预测方法应用于风险预算组合的构建,发现协方差预测的越准确,组合表现越优异。以股、债和黄金构建的月度调仓风险预算组合为例,假设股票风险预算为 75%,债券和黄金等权分配剩余 25%的预算。结果显示,历史协方差法只能实现 7.15%的年化收益,1.90 的收益风险比,最大回撤 7.67%。假设理想情况下我们已知下月真实样本协方差,则基于此构建的组合可以实现 8.72%的年化收益,2.51 的收益风险比,最大回撤仅有 3.86%。而基于 DCC-GARCH 的动态协方差预测方法可以实现 8.21%的年化收益,2.13 的收益风险比,最大回撤也降低到 4.91%。我们仅仅通过改进协方差矩阵的预测方法就可以明显改进经典风险预算组合的表现,是一种低成本组合增强的方法。

风险提示: 模型结论基于历史数据,在市场环境转变时模型存在失效的风险。

目录

1、引言	4 -
2、协方差估计方法综述	7 -
2.1、历史协方差	7 -
2.2、收缩历史协方差	8 -
2.3、指数移动平均法 (EWMA)	8 -
2.4、GARCH 类模型	9 -
2.4.1、VEC-GARCH 模型	9 -
2.4.2、CCC-GARCH 模型	9 -
2.4.3、DCC-GARCH 模型	10 -
2.4.4、GO-GARCH 模型	11 -
3、测算说明	12 -
3.1、数据说明	12 -
3.2、如何在 Python 中调用 R 语言	13 -
3.3、协方差矩阵评价方法	14 -
3.3.1、协方差矩阵均方差	14 -
3.3.2、最小方差组合	14 -
4、实证结果	15 -
4.1、中国大类资产组合	15 -
4.2、中国股票行业组合	16 -
4.3、全球大类资产组合	17 -
4.4、全球股票行业组合	18 -
5、动态协方差风险预算组合	19 -
6、总结	23 -
图表 1. 中国股票指数月度波动率	4 -
图表 2. 中国债券指数月度波动率	5 -
图表 3. 中国股债月度相关系数	5 -
图表 4. 美国股票指数月度波动率	6 -
图表 5. 美国债券指数月度波动率	6 -
图表 6. 美国股债月度相关系数	7 -
图表 7. 测试组合底层资产构成	12 -
图表 8. Python 调用 R 语言中的 GO-GARCH 模型代码示例	13 -
图表 9. 中国大类资产组合协方差矩阵预测均方根误差 (RMSE)	16 -
图表 10. 中国大类资产组合最小方差组合均方根跟踪误差 (RMSTE)	16 -
图表 11. 中国股票行业组合协方差矩阵预测均方根误差 (RMSE)	17 -
图表 12. 中国股票行业组合最小方差组合均方根跟踪误差 (RMSTE)	17 -
图表 13. 全球大类资产组合协方差矩阵预测均方根误差 (RMSE)	18 -
图表 14. 全球大类资产组合最小方差组合均方根跟踪误差 (RMSTE)	18 -
图表 15. 全球股票行业组合协方差矩阵预测均方根误差 (RMSE)	19 -
图表 16. 全球股票行业组合最小方差组合均方根跟踪误差 (RMSTE)	19 -
图表 17. 股债黄金组合协方差矩阵预测均方根误差 (RMSE)	20 -
图表 18. 动态协方差风险预算组合表现 (风险平价)	21 -
图表 19. 动态协方差风险预算组合表现 (股票风险预算 50%, 债券黄金风险预算相同)	21 -

图表 20、动态协方差风险预算组合表现（股票风险预算 75%，债券黄金风险预算相同）	- 22 -
图表 21、动态协方差风险预算组合表现（股票风险预算 80%，债券黄金风险预算相同）	- 22 -
图表 22、动态协方差风险预算组合表现（股票风险预算 90%，债券黄金风险预算相同）	- 22 -
图表 23、动态协方差风险预算组合净值示例（股票风险预算 90%，债券黄金风险预算相同）	- 23 -

1、引言


在过去的资产配置系列报告中，我们已经构建了各大类资产的择时模型，包括股票、债券、黄金等；也对大类资产的长期预期收益率的预测方法进行了综述和研究；并基于均值方差、风险预算等经典模型提出了融入择时观点的各类战术配置模型，取得了优异的历史表现。

但是关于协方差矩阵的估计和预测研究在系列中目前尚未涉及，本文的主要目的就是进一步完善兴证金工资产配置框架，补上这重要的一环。在经典的马科维茨组合优化框架中，协方差矩阵是预期收益率之外的另一重要模型输入。协方差矩阵的估计准确与否直接影响了模型输出的最优权重和组合最终表现。一系列著名的基于风险的组合构建策略如风险平价组合、最小方差组合以及最大分散化组合等也均需要准确估计资产协方差矩阵。

协方差矩阵估计是组合风险优化的核心要素，在实际操作中常用的方法是直接将历史协方差矩阵作为估计值，比如用过去 10 年的收益率计算。但这种方法隐含假设了资产本身的波动率以及资产间相关性是恒定的，而实际上它们往往是时变的。


我们分别以 Wind 全 A 和中债总财富总值指数作为中国股债资产的代表，计算了它们每个月的波动率和相关系数。从图表可以看到，股票的波动率呈现明显的时变性，在 2015 年市场动荡的月份可以达到 80% 的高波动，而在 2017 年的一些月份波动率低于 10%。股债相关性的变动同样剧烈，相关系数最高可以超过 0.6，而最低时达到 -0.8。

图表 1. 中国股票指数月度波动率




资料来源：Wind，兴业证券经济与金融研究院整理

图表 2. 中国债券指数月度波动率



资料来源：Wind，兴业证券经济与金融研究院整理


图表 3. 中国股债月度相关系数



资料来源：Wind，兴业证券经济与金融研究院整理


资产波动率和相关性的时变性并不是中国市场特有的，而是一种普遍的现象。我们以标普 500 指数和彭博美国债券综合指数作为美国股债资产的代表，计算了美国股债的历史波动率和相关系数月度变化情况。从下图可以看到美国股债波动率和相关性同样具有明显的时变性。

图表 4. 美国股票指数月度波动率




资料来源：Wind，兴业证券经济与金融研究院整理

图表 5. 美国债券指数月度波动率



资料来源：Wind，兴业证券经济与金融研究院整理

图表 6. 美国股债月度相关系数



资料来源：Wind，兴业证券经济与金融研究院整理

2、协方差估计方法综述

从前面的图表我们看到大类资产的波动率和相关性往往是随时间变化的，直接使用历史协方差作为未来协方差矩阵的预测不是最优方法，在本章节我们将先从理论上介绍几种协方差矩阵的估计方法。

为了保证足够的数量，我们使用日度数据来计算收益率协方差矩阵，并假设日度资产收益率向量满足如下等式：

$$r_t = \mu + \varepsilon_t$$

其中 μ 是资产收益率均值向量， ε_t 是均值为 0 的 t 日收益率随机扰动向量，则 t 日资产收益率的协方差矩阵可表示为 $\Sigma_t = \varepsilon_t \varepsilon_t'$ 。

在本文其余部分，我们均假设在每月末预测下一个月的协方差矩阵，并不断向后滚动。

2.1、历史协方差

预测协方差矩阵最简单的方法是直接将历史样本协方差矩阵作为对其未来的预测。具体来说，我们首先选择一个固定的回看窗口长度 L，比如 10 年。则下一个月的日度协方差矩阵预测值可表示为：

$$\hat{\Sigma}_t^{Hist} = \frac{1}{L} \sum_{i=t-L}^{t-1} \varepsilon_i \varepsilon_i'$$

历史协方差法是一种无条件协方差估计量，之后将作为本文介绍的其他预测方法的比较基准。

2.2、收缩历史协方差

当协方差矩阵维度较大而数据量有限时，直接根据历史样本计算协方差矩阵可能会有较大的估计误差，协方差矩阵中的某些数值可能会因为少数极端样本而出现较大偏差。为了减少协方差矩阵的预测误差，学界发明了收缩估计法，将历史估计值和某一个收缩目标进行加权平均后得到最终协方差矩阵，它可写为如下形式：

$$\hat{\Sigma}_t^{Shrink} = (1 - \delta_t) \hat{\Sigma}_t^{Hist} + \delta_t \hat{\Sigma}_t^{Target}$$

其中 δ_t 表示 t 日的收缩参数且满足 $0 < \delta_t < 1$ ， $\hat{\Sigma}_t^{Hist}$ 表示回看期为 L 设定下的协方差历史估计值， $\hat{\Sigma}_t^{Target}$ 是假设回看期为 L 时得到的收缩目标。

我们参考了 Ledoit 和 Wolf[2004] 的方法，利用常数相关系数模型（Constant Correlation Model）得到收缩目标矩阵。常数相关系数模型假设资产间的两两相关系数是相等的，具体等于所有两两样本相关系数的均值，而资产方差则直接用各资产样本方差进行估计。我们用 $\hat{R}_t^{Hist}$ 表示历史样本相关系数矩阵， $r_{i,j}$ 表示第 i 行、第 j 列的相关系数， N 表示资产数量，则常数相关系数 $\bar{r}$ 可表示为：

$$\bar{r} = \frac{2}{N(N-1)} \sum_{i=1}^N \sum_{j=i+1}^N r_{i,j}$$

将 $\bar{r}$ 作为相关系数矩阵的非对角项，然后根据资产历史方差向量便可得到收缩目标 $\hat{\Sigma}_t^{Target}$ 。

2.3、指数移动平均法（EWMA）

前面介绍的协方差计算方法属于无条件协方差估计，没有考虑协方差矩阵在时间序列上的时变特征。考虑到这个问题，学界提出了指数移动平均法计算条件协方差矩阵。这种方法的思路是给予近期样本较高的权重，而远期样本较低的权重，从而捕捉到协方差矩阵在时序上的变动。

这种方法是 RiskMetrics 使用的协方差估计模型，它的计算方法可表示为如下递归的形式：

$$\hat{\Sigma}_t^{EWMA} = (1 - \lambda) \varepsilon_{t-1} \varepsilon_{t-1}' + \lambda \hat{\Sigma}_{t-1}^{EWMA}$$

其中 $0 < \lambda < 1$ ，是衰减常数。根据 RiskMetrics 的推荐，当我们使用日度数据预测未来 1 个月的协方差矩阵时可以选取 $\lambda=0.97$ 来计算。

2.4、GARCH 类模型

2.4.1、VEC-GARCH 模型

另一类估计条件协方差的模型是 GARCH 模型即广义条件异方差模型，我们假设资产收益率向量满足：

$$\begin{aligned} r_t &= \mu + \varepsilon_t \\ \varepsilon_t &= \Sigma_t^{1/2} \eta_t \end{aligned}$$

其中 Σ_t 表示条件协方差矩阵， η_t 表示均值为 0，方差为 1 的标准白噪声过程。

VEC-GARCH 模型是对单变量 GARCH 模型的一种直接推广，相当于对协方差矩阵的每一项都建立 GARCH 模型：

$$\text{vech}(\Sigma_t) = c + \sum_{j=1}^q A_j \text{vech}(\varepsilon_{t-j} \varepsilon_{t-j}^T) + \sum_{j=1}^p B_j \text{vech}(\Sigma_{t-1})$$

其中 c 为一列参数向量， $\text{vech}()$ 表示把矩阵的下三角部分按照每列叠加成一个向量， A 和 B 分别是两个参数矩阵。从公式可以看出，每一期的条件协方差矩阵都是过去 q 期误差向量乘积以及过去 p 期条件协方差矩阵的函数。

理论上说这个模型非常灵活，可以捕捉到条件协方差的时序特征。但正因为这种灵活性，模型的参数过多，比如 A 和 B 均是维度达 $N(N+1)/2 \times N(N+1)/2$ 的矩阵。当资产数量 N 增大时，参数量以 N 的 4 次方的速度增加，这导致模型估计存在巨大困难。另外由于对 A 和 B 没有约束，得到的预测矩阵 Σ_t 无法保证正定性。

为了解决这个问题，Engle 和 Kroner (1995) 提出了 BEKK 模型，对 A 和 B 矩阵形式进行了约束。虽然 BEKK 模型减少了一部分待估参数，但模型估计依然存在较大困难，因此实际应用中较少使用这一类 GARCH 模型。

2.4.2、CCC-GARCH 模型

前面介绍的 VEC-GARCH 模型是直接对协方差矩阵建模，模型估计难度较大。这里我们介绍一种将资产方差和相关系数矩阵分开估计，然后得到协方差矩阵的方法 CCC-GARCH 模型。

收益率协方差矩阵被分解成标准差矩阵和相关系数矩阵：

$$\hat{\Sigma}_t^{DCC-GARCH} = D_t R D_t$$

其中 $D_t = \text{diag}(\sigma_{1t}, \dots, \sigma_{nt})$ 即包含各资产收益率标准差的对角矩阵， $R = [\rho_{ij}]$ 表示相关系数矩阵。此模型中我们假设相关系数矩阵为常数，不随时间

变化，可以直接用历史相关系数矩阵代替。这样一来，我们只需要对各资产方差进行建模即可得到协方差矩阵。举例来说，我们用 GARCH (1,1) 模型分别对 N 个资产方差建模：

$$\sigma_{it}^2 = \alpha_{0i} + \alpha_{1i}\varepsilon_{it-1}^2 + \beta_{1i}\sigma_{it-1}^2$$

然后我们预测资产的标准差矩阵 D_t ，叠加相关系数矩阵 R 后便可以得到协方差矩阵的预测。可以看到这种方法里需要估计的参数数量较少，但假设相关系数为常数的设定过于苛刻，无法捕捉其时变性。

2.4.3、DCC-GARCH 模型

为了解决前面 CCC-GARCH 模型中无法捕捉资产间相关性的时变性，学界又提出了动态条件相关性 GARCH 模型。在此模型中，收益率协方差矩阵同样被分解成标准差矩阵和相关系数矩阵：

$$\hat{\Sigma}_t^{DCC-GARCH} = D_t R_t D_t$$

其中 $D_t = \text{diag}(\sigma_{1t}, \dots, \sigma_{nt})$ 即包含各资产收益率标准差的对角矩阵， $R_t = [\rho_{ijt}]$ 表示时变的相关系数矩阵。

然后我们对每个资产的方差进行建模，本文均假设使用 DCC-GARCH (1,1) 模型：

$$\sigma_{it}^2 = \alpha_{0i} + \alpha_{1i}\varepsilon_{it-1}^2 + \beta_{1i}\sigma_{it-1}^2$$

然后用各个资产收益率经过 GARCH (1,1) 建模后得到的标准化残差来估计 DCC-GARCH (1,1) 模型中的相关系数矩阵：

$$R_t = Q_t^{*-1} Q_t Q_t^{*-1}$$

其中：

$$Q_t = (1-a-b)\bar{Q} + ae_{t-1}e_{t-1}' + bQ_{t-1}$$

$e_t = D_t^{-1}\varepsilon_t$ 是标准化误差， $\bar{Q} = E[e_t e_t']$ 是标准化误差的无条件协方差矩阵。

Q_t^* 是对角阵，其对角元素是 Q_t 对角元素的平方根，即 $Q_t^* = (\text{diag}(Q_t))^{1/2}$ 。

我们使用日度数据和长度为 L 的窗口滚动估计 DCC-GARCH(1,1) 模型，然后

利用估计出的模型向后预测 N_m 天的协方差矩阵。类似的，下一个月度协方差矩阵预测值可通过对 N_m 天的日度协方差矩阵预测值取均值得到：

$$\hat{\Sigma}_m^{DCC-GARCH} = \frac{1}{N_m} \sum_{i=0}^{N_m-1} \hat{\Sigma}_{t+i}^{DCC-GARCH}$$

其中 $\hat{\Sigma}_{t+i}^{DCC-GARCH}$ 是 $t+i$ 日的协方差矩阵预测值。

2.4.4、GO-GARCH 模型

前面我们介绍了直接对资产间协方差建模的 VEC-GARCH 模型和将协方差矩阵分解为方差和相关系数矩阵分别建模的 DCC-GARCH 模型。这里我们再介绍使用另一种思路构建的广义正交 GARCH 模型（GO-GARCH）。在此模型中，日度收益率的随机误差向量 ε_t 被认为是 n 个不可观测的独立因子 f_t 的线性组合：

$$\varepsilon_t = Zf_t$$

其中 Z 是 $n \times n$ 的可逆矩阵，它连接了不可观测和可观测的变量。我们通过正规化使不可观测的 f_t 具有单位方差，从而使得 ε_t 的无条件协方差矩阵满足：

$$\bar{\Sigma} = E[\varepsilon_t \varepsilon_t'] = ZZ'$$

本文使用 GO-GARCH(1,1)模型，用单变量 GARCH (1,1) 来分别对相互独立的因子 f_t 建模。我们定义 $H_t = \text{diag}(h_{1t}, \dots, h_{nt})$ ，其对角线元素表示 f_t 的方差，则有：

$$h_{it} = \alpha_{0i} + \alpha_{1i} f_{it-1}^2 + \beta_{1i} h_{it-1} \quad (2)$$

ε_t 的条件协方差 $\hat{\Sigma}_t^{GO-GARCH}$ 可表示为：

$$\hat{\Sigma}_t^{GO-GARCH} = ZH_tZ'$$

通过奇异值分解，我们可以将 Z 分解为如下形式：

$$Z = P\Lambda^{1/2}U'$$

其中 P 是由无条件协方差矩阵 $\bar{\Sigma}$ 经过特征值分解得到的正交矩阵，

$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ 是 $\bar{\Sigma}$ 的特征值矩阵, 而 $\bar{\Sigma}$ 可以由 $\frac{1}{L} \sum_{i=t-L}^{t-1} \varepsilon_i \varepsilon_i'$ 一致的估计出来。

U 是 $n \times n$ 的正交矩阵, 它可以根据条件协方差矩阵 Σ_t 的结构被估计出来。

与前面滚动估计 DCC-GARCH(1,1) 的方法相同, 我们使用日度数据和长度为 L 的窗口滚动的估计 GO-GARCH(1,1) 模型。然后利用估计出的模型向后预测 N_m 天的协方差矩阵。同样的, 下一个月度协方差矩阵预测值可通过对 N_m 天的日度协方差矩阵预测取均值得到:

$$\hat{\Sigma}_m^{GO-GARCH} = \frac{1}{N_m} \sum_{i=0}^{N_m-1} \hat{\Sigma}_{t+i}^{GO-GARCH}$$

其中 $\hat{\Sigma}_{t+i}^{GO-GARCH}$ 是 $t+i$ 日的协方差矩阵预测值。

3、测算说明

3.1、数据说明

为了更好的评估各协方差矩阵预测方法的优劣, 我们选取多种资产组合进行测试。具体来说包括全球大类资产、全球股票行业、中国大类资产和中国股票行业组合。其中全球股票行业组合由 MSCI 全球行业指数构成, 中国股票行业组合由选取的 10 个申万行业指数构成。

下表给出了各组合的细分资产以及数据的起止时间。由于选取的各类数据历史长度不同, 因此后续测算的历史时段也会略有不同。

图表 7、测试组合底层资产构成

组合名称	细分资产	数据起止时间
中国大类资产	万得全 A 指数、中债总财富总值指数、南华商品指数、AU9999 黄金现货	2004/06-2021/09
中国股票行业	农林牧渔、采掘、化工、钢铁、有色金属、电子、家用电器、食品饮料、纺织服装、轻工制造	2000/01-2021/09
全球大类资产	美国 30 年期综合国债指数、MSCI 欧洲指数、MSCI 新兴市场指数、MSCI 亚太地区指数、MSCI 美国价值型指数、MSCI 美国 REITs 指数、标普 GSCI 商品指数	1998/12-2021/09
全球股票行业	能源、原材料、工业、非日常消费品、日常消费品、医疗保健、金融、信息科技、电信业务、公用事业	2000/01-2021/09

资料来源: Wind, 兴业证券经济与金融研究院

3.2、如何在 Python 中调用 R 语言

我们使用 Python 语言进行所有的测试和回测。本文第二部分介绍的几种协方差估计方法中历史协方差、收缩历史协方差以及指数移动平均法都可以在 Python 中比较容易的实现。但一系列基于 GARCH 模型的预测方法则难以在 Python 中直接实现。目前 Python 语言对于计量模型的支持还比较弱，没有找到公认模型设定灵活且准确的多元 GARCH 模型的包。

我们当然可以尝试自己写 GARCH 模型的估计代码。但是一方面多元 GARCH 模型的估计较为复杂，自己写代码的实现难度过大。另一方面即使完成了代码也难以保证其准确和有效性。幸运的是，R 语言作为一种通用的统计学语言，对于统计计量模型的覆盖度非常高。R 语言中的 ccgarch 包实现了 CCC-GARCH 模型，而 rmgarch 包实现了 DCC-GARCH 和 GO-GARCH 模型。

为了统一在 Python 中进行测试，我们需要在 Python 中调用 R 语言的功能，这一点可以通过 rpy2 包实现。rpy2 包可以在 Python 进程中打开一个 R 语言的子进程，并实现数据的互相传输。rpy2 的 objects 函数可以将 R 语言的代码文本转化为一个可以在 Python 中调用的对象。举例来说，下图给出了调用 GO-GARCH 模型的示例。我们首先在 R 语言中构建了一个以资产收益率数据 r_rets 和预测天数 n_days 为参数，并输出 GO-GARCH 模型拟合结果和协方差预测结果的函数文本。然后利用 rpy2.objects 调用，便将其转化为一个可以在 Python 中调用的函数 r_gogarch。通过 r_gogarch(r_rets, n_days) 的形式，可以得到任意资产组合的协方差预测结果，其中 r_rets 是 np.array 类型的数据，n_days 是 int 类型的数据。

图表 8、Python 调用 R 语言中的 GO-GARCH 模型代码示例

```

1 import rpy2.objects as objects
2
3 #####
4 # 定义gogarch函数
5 r_gogarch_code = """
6
7         library(rmgarch)
8         set.seed(42)
9         function(r_rets, n_days){
10             univariate_spec <- ugarchspec(mean.model = list(armaOrder = c(1,1)),
11                                     variance.model = list(garchOrder = c(1,1),
12                                                         variance.targeting = FALSE,
13                                                         model = "sGARCH"),
14                                     distribution.model = "norm")
15
16             n <- dim(r_rets)[2]
17             go_spec <- gogarchspec(uspec = multispec(replicate(n, univariate_spec)),
18                                 dcoOrder = c(1,1),
19                                 distribution = "mvnorm")
20             go_fit <- gogarchfit(go_spec, data=r_rets)
21             forecasts <- gogarchforecast(go_fit, n.ahead = n_days)
22             list(go_fit, rcov(forecasts))
23         }
24         """
25 r_gogarch = objects.r(r_gogarch_code)

```

资料来源：兴业证券经济与金融研究院绘制

3.3、协方差矩阵评价方法

3.3.1、协方差矩阵均方差

我们通过比较预测协方差和真实协方差的差异来评估协方差矩阵预测结果的准确性。我们首先定义第 m 个月的收益率真实协方差矩阵为 $\Sigma_m = [\sigma_{ij,m}]$ ，它由第 m 月的日度收益率计算得到：

$$\Sigma_m = \frac{1}{n-1} (r_i - \bar{r})(r_i - \bar{r})^T$$

我们用 $\hat{\Sigma}_m = [\hat{\sigma}_{ij,m}]$ 表示我们在第 $m-1$ 月底对 Σ_m 的预测，则第 m 个月资产 i 和 j 的收益率协方差的平方预测误差（SFE）可表示为 $(\sigma_{ij,m} - \hat{\sigma}_{ij,m})^2$ 。为了防止重复计算，我们只对 Σ_m 的包括对角线在内的上三角部分的协方差预测误差进行加总，得到完整的第 m 个月的协方差矩阵预测均方根误差：

$$RSFE_m = \sqrt{\sum_{i=1}^n \sum_{j=1}^i (\sigma_{ij,m} - \hat{\sigma}_{ij,m})^2}$$

则整个样本外预测区间的协方差矩阵预测均方根误差为：

$$RMSE = \frac{1}{M} \sum_{m=1}^M RSFE_m$$

其中 M 为整个样本外预测区间的月份数。

3.3.2、最小方差组合

除了直接比较协方差矩阵的差异，我们还将测试何种协方差预测方法能更准确的构建出样本外最小方差组合。我们假设组合的调整频率为月度，在每月底最后一天更新最优权重。

假设有 N 个资产， r_m 表示第 m 个月的风险资产收益率向量， w_m 表示第 m 个月的风险资产权重向量， Σ_m 表示第 m 个月的风险资产组合收益率协方差矩阵，则第 m 个月的风险资产组合的收益率和波动率可分别表示为：

$$r_{Pm} = w_m' r_m, \sigma_{Pm} = \sqrt{w_m' \Sigma_m w_m}$$

我们用 $\hat{\Sigma}_m$ 表示基于第 $m-1$ 月底前数据对第 m 月风险资产收益率协方差矩阵的预测，则构建第 m 个月的风险资产最小化方差组合等价于求解一个带约束二次规

划问题:

$$\begin{aligned} \min_{w_m} : & \frac{1}{2} w_m' \hat{\Sigma}_m w_m \\ \text{st. } & w_m' 1 = 1, w_m \geq 0 \end{aligned}$$

其中 1 和 0 分别表示 $n \times 1$ 的元素为 1 和 0 的向量。我们用 $\hat{w}_m$ 表示根据 $\hat{\Sigma}_m$ 计算得到的第 m 个月先验最小方差组合权重, w_m 表示根据 Σ_m 得到的第 m 个月后验最小方差组合权重, 即真实最小方差组合权重。

我们也同时构建一个允许做空的最小化方差组合:

$$\begin{aligned} \min_{w_m} : & \frac{1}{2} w_m' \hat{\Sigma}_m w_m \\ \text{st. } & w_m' 1 = 1, w_m \geq -1 \end{aligned}$$

我们用 σ_{Pm}^{oos} 表示先验(样本外)最小方差组合在第 m 个月实现的真实波动率, 用 σ_{Pm}^{is} 表示后验(样本内)最小方差组合在第 m 个月的真实波动率。我们定义第 m 个月最小方差组合波动率的跟踪误差(RSTE)为先验和后验最小方差组合真实波动率差值的平方根:

$$RSTE_m = \sqrt{(\sigma_{Pm}^{oos} - \sigma_{Pm}^{is})^2}$$

最后我们用整个样本外预测区间的最小方差组合波动率的平均跟踪误差(RMSTE)来衡量不同协方差预测方法的表现:

$$RMSTE = \frac{1}{M} \sum_{m=1}^M RSTE_m$$

其中 M 为整个样本外预测区间的月份数。

4、实证结果


4.1、中国大类资产组合

我们以股票、债券、黄金和商品指数组成中国大类资产组合, 并使用 5 种不同方法预测月度协方差矩阵。具体来说我们在每月底使用过去 1500 个交易日的数据拟合模型并预测未来一个月的协方差矩阵。下面我们给出 2010 年 7 月至 2021 年 9 月的预测结果。

从下图看，历史样本法和收缩法的矩阵预测误差较大，而指数移动平均和两种 GARCH 模型均明显减少了误差。其中 GO-GARCH 表现最好，相比历史样本法减少了大约 31% 的矩阵预测误差。

从各方法与后验最小方差组合的波动率跟踪误差来看，指数移动平均和两种 GARCH 方法也比历史样本和收缩法表现更好一些，大约可以减少接近 10% 左右的跟踪误差。

图表 9、中国大类资产组合协方差矩阵预测均方根误差 (RMSE)



资料来源：Wind，兴业证券经济与金融研究院绘制

图表 10、中国大类资产组合最小方差组合均方根跟踪误差 (RMSTE)

预测方法	纯多头	多空
HIST	1.19E-02	1.30E-02
SHRINKAGE	1.20E-02	1.30E-02
EWMA	1.11E-02	1.26E-02
GO-GARCH	1.14E-02	1.28E-02
DCC-GARCH	1.11E-02	1.22E-02

资料来源：Wind，兴业证券经济与金融研究院


4.2、中国股票行业组合

我们选取了 10 个申万指数组成中国股票行业组合，并使用 5 种不同方法预测月度协方差矩阵。具体来说我们在每月底使用过去 2000 个交易日的数据拟合模型并预测未来一个月的协方差矩阵。下面我们给出 2008 年 4 月至 2021 年 9 月的预测结果。

从下图看，历史样本法和收缩法的矩阵预测误差较大，而指数移动平均和两种 GARCH 模型均明显减少了误差。其中指数移动平均法表现最好，相比历史样本法减少了大约 21% 的矩阵预测误差。

从各方法与后验最小方差组合的波动率跟踪误差来看，指数移动平均和两种 GARCH 方法也比历史样本和收缩法表现更好一些。当无法做空时，EWMA 方法跟踪误差最小，相比 HIST 方法减少了 18% 的误差。当可以做空时，DCC-GARCH 方法表现最好，相比 HIST 方法减少了 10% 的跟踪误差。

图表 11、中国股票行业组合协方差矩阵预测均方根误差 (RMSE)



资料来源：Wind，兴业证券经济与金融研究院绘制

图表 12、中国股票行业组合最小方差组合均方根跟踪误差 (RMSTE)

预测方法	纯多头	多空
HIST	5.22E-02	7.95E-02
SHRINKAGE	5.21E-02	7.92E-02
EWMA	4.28E-02	7.24E-02
GO-GARCH	4.64E-02	7.46E-02
DCC-GARCH	4.43E-02	7.19E-02

资料来源：Wind，兴业证券经济与金融研究院

4.3、全球大类资产组合


我们选取了包含股票、债券、商品和房地产的 7 种指数组成全球大类资产组合，并使用 5 种不同方法预测月度协方差矩阵。具体来说我们在每月底使用过去 2000 个交易日的数据拟合模型并预测未来一个月的协方差矩阵。下面我们给出 2007 年 9 月至 2021 年 9 月的预测结果。

从下图看，历史样本法和收缩法的矩阵预测误差较大，而指数移动平均和两种 GARCH 模型均明显减少了误差。其中 DCC-GARCH 法表现最好，相比历史样本法减少了大约 15% 的矩阵预测误差。

从各方法与后验最小方差组合的波动率跟踪误差来看，指数移动平均和两种

GARCH 方法也比历史样本和收缩法表现更好一些。当无法做空时，DCC-GARCH 方法跟踪误差最小，相比 HIST 方法减少了 16% 的误差。当可以做空时，同样是 DCC-GARCH 方法表现最好，相比 HIST 方法减少了 11% 的跟踪误差。

图表 13、全球大类资产组合协方差矩阵预测均方根误差 (RMSE)



资料来源：Bloomberg，兴业证券经济与金融研究院绘制

图表 14、全球大类资产组合最小方差组合均方根跟踪误差 (RMSTE)

预测方法	纯多头	多空
HIST	4.84E-02	5.86E-02
SHRINKAGE	4.82E-02	5.86E-02
EWMA	4.35E-02	5.26E-02
GO-GARCH	4.63E-02	5.85E-02
DCC-GARCH	4.05E-02	5.21E-02

资料来源：Bloomberg，兴业证券经济与金融研究院

4.4、全球股票行业组合


我们选取了 MSCI 全球行业指数构成组合，并使用 5 种不同方法预测月度协方差矩阵。具体来说我们在每月底使用过去 2000 个交易日的数据拟合模型并预测未来一个月的协方差矩阵。下面我们给出 2008 年 4 月至 2021 年 9 月的预测结果。

从下图看，历史样本法和收缩法的矩阵预测误差较大，而指数移动平均和两种 GARCH 模型均明显减少了误差。其中 GO-GARCH 法表现最好，相比历史样本法减少了大约 12% 的矩阵预测误差。

从各方法与后验最小方差组合的波动率跟踪误差来看，指数移动平均和 GO-GARCH 方法表现更好一些。当无法做空时，EWMA 方法跟踪误差最小，相比 HIST 方法减少了 7% 的误差。当可以做空时，DCC-GARCH 方法表现最好，相比 HIST 方法减少了 2% 的跟踪误差。相比前几种资产组合，我们发现对于全球股

票行业组合的协方差预测效果比较一般。这可能是由于全球行业组合的成分股构成是从全球范围的股票中筛选的，不同国家的同行业股票可能相关性不够稳定，导致协方差预测的困难。

图表 15. 全球股票行业组合协方差矩阵预测均方根误差(RMSE)



资料来源：Wind，兴业证券经济与金融研究院绘制

图表 16. 全球股票行业组合最小方差组合均方根跟踪误差 (RMSTE)

预测方法	纯多头	多空
HIST	3.36E-02	6.34E-02
SHRINKAGE	3.34E-02	6.34E-02
EWMA	3.13E-02	6.25E-02
GO-GARCH	3.31E-02	6.30E-02
DCC-GARCH	3.39E-02	6.22E-02

资料来源：Wind，兴业证券经济与金融研究院

5、动态协方差风险预算组合

前面我们测试了在不同资产组合上协方差预测方法的表现，发现 EWMA 和 GARCH 方法的确能够减少协方差的估计误差，并能够更准确的构建最小方差组合。那么通过更好的预测协方差矩阵能够帮助我们获得更高的收益和更低的回撤吗？


风险预算组合是一种基于风险的组合构建方法，它只需要协方差矩阵作为模型输入。我们曾经在《系统化资产配置系列之五：基于择时的目标风险和风险预算配置模型》中介绍过风险预算模型，并构建了基于股债黄金的风险预算组合。那篇报告中我们直接使用历史样本协方差输入模型，在不加入择时信号前的风险

预算组合表现较为一般。这里我们将基于动态协方差构建风险预算组合，并观察其特征。

从逻辑上说，更准确的估计协方差矩阵不一定能够提升风险预算组合的收益，它只是能保证组合中各资产的风险贡献与风险预算更接近。但是在一些情况下，比如当资产的收益率与其波动率呈反比时，更准确的协方差预测可以提升组合收益。当预测某资产波动率较高时，风险预算模型会降低其权重，从而规避风险；预测某资产波动率较低时，风险预算模型会提高其权重，从而获得更高的收益。通过这种权重的变化，组合的表现可以获得提升。

我们用万得全 A、中债总财富总值指数和 AU9999 黄金现货代表股债黄金资产。首先来看几种协方差预测方法在股债黄金组合上的表现。下方给出了 2014 年 9 月以来各方法的协方差预测误差。可以看到，相比历史样本法，EWMA 和两种 GARCH 模型能够有效减少估计误差。其中 DCC-GARCH 表现最好，可以减少大约 28% 的误差。

图表 17、股债黄金组合协方差矩阵预测均方根误差（RMSE）



资料来源：Wind，兴业证券经济与金融研究院绘制

为了测算协方差预测准确性对风险预算组合表现的影响，我们在每月底利用过去 1500 个交易日数据构建模型，并预测未来一个月的协方差矩阵，然后根据风险预算计算出最优权重向量并调整仓位。我们同时也会测算假设已知下一个月真实协方差矩阵的理想情况下组合的表现。这里我们以普通股票型基金指数和中长期纯债型基金指数作为股债的配置标的，回测的时间范围是 2014 年 9 月至 2021 年 9 月。

下方给出了不同风险预算设定下各个组合的回测表现。首先我们可以看到，假设我们已知下一个月的实际协方差矩阵，则基于此构建的风险预算组合表现最为优异，收益率最高、波动率和最大回撤最低。举例来说，当给定股票风险预算 80% 时，理想组合可以实现 9.17% 的年化收益，而波动率仅有 3.79%，最大回撤仅 3.94%。相比之下，传统基于历史协方差的风险预算组合收益率只有 7.39%，波动率达到 4.12%，最大回撤超过 8.5%。也就是说准确预测协方差矩阵的确能够提升年风险预算组合的表现。

我们发现，由于 EWMA、GO-GARCH 和 DCC-GARCH 方法均能够更好的预测协方差矩阵，相应的风险预算组合表现也有明显提升，其中 DCC-GARCH 方法相对更好。以 75%股票风险预算组合为例，历史协方差组合可以实现 7.15%的年化收益，1.90 的收益风险比，最大回撤 7.67%。而 DCC-GARCH 组合可以实现 8.21%的年化收益，2.13 的收益风险比，最大回撤降低到 4.91%。

当我们提高股票风险预算到 90%时，历史法组合只能实现 8.17%的年化收益，而最大回撤达到 11.75%。理想组合可以实现 10.70%的年化收益，最大回撤只有 4.32%。而基于 DCC-GARCH 的动态协方差组合可以实现 9.52%的年化收益，最大回撤 7.05%。GO-GARCH 组合表现也不错，可以实现 10.11%的年化收益，最大回撤略微提高到 7.89%。从净值曲线也可以看出，各动态协方差组合的表现明显优于历史法和收缩法组合。通过对比不同风险预算设定下的组合我们可以看到，DCC-GARCH 方法总是可以实现更低的回撤和更高的收益风险比，并且收益依然很高。

图表 18、动态协方差风险预算组合表现（风险平价）

	HIST	SHRINKAGE	EWMA	GO-GARCH	DCC-GARCH	实际
年化收益率	6.08%	6.06%	6.59%	6.81%	6.70%	6.71%
年化波动率	2.41%	2.42%	2.55%	2.68%	2.51%	2.28%
收益风险比	2.52	2.50	2.58	2.55	2.67	2.94
最大回撤	-4.12%	-4.14%	-3.83%	-3.35%	-3.29%	-3.44%
年均双边换手次数	0.26	0.26	0.93	1.23	1.24	1.95

资料来源：Wind，兴业证券经济与金融研究院

图表 19、动态协方差风险预算组合表现（股票风险预算 50%，债券黄金风险预算相同）

	HIST	SHRINKAGE	EWMA	GO-GARCH	DCC-GARCH	实际
年化收益率	6.41%	6.40%	7.07%	7.36%	7.19%	7.33%
年化波动率	2.77%	2.79%	2.95%	3.13%	2.90%	2.61%
收益风险比	2.31	2.29	2.40	2.35	2.48	2.81
最大回撤	-5.20%	-5.24%	-4.68%	-3.92%	-3.51%	-3.57%
年均双边换手次数	0.27	0.27	1.05	1.37	1.33	2.18

资料来源：Wind，兴业证券经济与金融研究院

图表 20、动态协方差风险预算组合表现（股票风险预算 75%，债券黄金风险预算相同）

	HIST	SHRINKAGE	EWMA	GO-GARCH	DCC-GARCH	实际
年化收益率	7.15%	7.16%	8.05%	8.55%	8.21%	8.72%
年化波动率	3.76%	3.81%	3.95%	4.30%	3.86%	3.48%
收益风险比	1.90	1.88	2.04	1.99	2.13	2.51
最大回撤	-7.67%	-7.75%	-6.67%	-5.48%	-4.91%	-3.86%
年均双边换手次数	0.31	0.31	1.35	1.65	1.52	2.85

资料来源：Wind，兴业证券经济与金融研究院

图表 21、动态协方差风险预算组合表现（股票风险预算 80%，债券黄金风险预算相同）

	HIST	SHRINKAGE	EWMA	GO-GARCH	DCC-GARCH	实际
年化收益率	7.39%	7.42%	8.35%	8.92%	8.53%	9.17%
年化波动率	4.12%	4.18%	4.30%	4.71%	4.20%	3.79%
收益风险比	1.80	1.77	1.94	1.90	2.03	2.42
最大回撤	-8.50%	-8.59%	-7.35%	-6.00%	-5.39%	-3.94%
年均双边换手次数	0.32	0.33	1.45	1.74	1.58	3.11


资料来源：Wind，兴业证券经济与金融研究院

图表 22、动态协方差风险预算组合表现（股票风险预算 90%，债券黄金风险预算相同）

	HIST	SHRINKAGE	EWMA	GO-GARCH	DCC-GARCH	实际
年化收益率	8.17%	8.26%	9.25%	10.11%	9.52%	10.70%
年化波动率	5.37%	5.50%	5.48%	6.08%	5.33%	4.85%
收益风险比	1.52	1.50	1.69	1.66	1.79	2.20
最大回撤	-11.75%	-11.95%	-9.68%	-7.89%	-7.05%	-4.32%
年均双边换手次数	0.36	0.37	1.81	2.01	1.74	4.07

资料来源：Wind，兴业证券经济与金融研究院

图表 23、动态协方差风险预算组合净值示例（股票风险预算 90%，债券黄金风险预算相同）



资料来源：Wind，兴业证券经济与金融研究院绘制

6、总结

协方差矩阵估计是组合风险优化的核心要素，在实际操作中常用的方法是直接将历史协方差矩阵作为估计值，比如用过去 10 年的收益率计算。但这种方法隐含假设了资产本身的波动率以及资产间相关性是恒定的，而实际上它们往往是时变的。

本文介绍了多种协方差矩阵的预测方法，并比较了不同方法的预测误差和样本外最小方差组合的构建准确度。具体来说我们首先选取了中国大类资产组合、中国股票行业组合、全球大类资产组合和全球股票行业组合作为测算基准，然后测试了历史协方差法、收缩历史协方差、指数移动平均法、DCC-GARCH 模型和 GO-GARCH 模型的预测能力。

测算结果显示，相比传统的历史协方差方法，指数移动平均法和两种 GARCH 方法均能够显著降低协方差预测误差。举例来说，对于中国大类资产组合，GO-GARCH 能够减少 31% 的协方差预测误差。对于全球大类资产组合，DCC-GARCH 也能够减少大约 15% 的预测误差。

我们将动态协方差预测方法应用于风险预算组合的构建，发现协方差预测的越准确，组合表现越优异。以股、债和黄金构建的月度调仓风险预算组合为例，我们假设股票风险预算为 75%，债券和黄金等权分配剩余 25% 的预算。结果显示，历史协方差法只能实现 7.15% 的年化收益，1.90 的收益风险比，最大回撤 7.67%。假设理想情况下我们已知下月真实样本协方差，则基于此构建的组合可以实现

请务必阅读正文之后的信息披露和重要声明

8.72%的年化收益，2.51 的收益风险比，而最大回撤仅有 3.86%。而 DCC-GARCH 方法可以实现 8.21%的年化收益，2.13 的收益风险比，最大回撤降低到 4.91%。我们仅仅通过改进协方差矩阵的预测方法就可以明显改进经典风险预算组合的表现，是一种低成本的组合增强的方法。

风险提示：模型结论基于历史数据，在市场环境转变时模型存在失效的风险。

分析师声明

本人具有中国证券业协会授予的证券投资咨询执业资格并注册为证券分析师，以勤勉的职业态度，独立、客观地出具本报告。本报告清晰准确地反映了本人的研究观点。本人不曾因，不因，也将不会因本报告中的具体推荐意见或观点而直接或间接收到任何形式的补偿。

投资评级说明

投资建议的评级标准	类别	评级	说明
报告中投资建议所涉及的评级分为股票评级和行业评级(另有说明的除外)。评级标准为报告发布日后的12个月内公司股价(或行业指数)相对同期相关证券市场代表性指数的涨跌幅。其中：A股市场以上证综指或深圳成指为基准，香港市场以恒生指数为基准；美国市场以标普500或纳斯达克综合指数为基准。	股票评级	买入	相对同期相关证券市场代表性指数涨幅大于15%
		审慎增持	相对同期相关证券市场代表性指数涨幅在5%~15%之间
		中性	相对同期相关证券市场代表性指数涨幅在-5%~5%之间
		减持	相对同期相关证券市场代表性指数涨幅小于-5%
		无评级	由于我们无法获取必要的资料，或者公司面临无法预见结果的重大不确定性事件，或者其他原因，致使我们无法给出明确的投资评级
	行业评级	推荐	相对表现优于同期相关证券市场代表性指数
		中性	相对表现与同期相关证券市场代表性指数持平
		回避	相对表现弱于同期相关证券市场代表性指数

信息披露

本公司在知晓的范围内履行信息披露义务。客户可登录 www.xyzq.com.cn 内幕交易防控栏内查询静默期安排和关联公司持股情况。

使用本研究报告的风险提示及法律声明

兴业证券股份有限公司经中国证券监督管理委员会批准，已具备证券投资咨询业务资格。

本报告仅供兴业证券股份有限公司（以下简称“本公司”）的客户使用，本公司不会因接收人收到本报告而视其为客户。本报告中的信息、意见等均仅供客户参考，不构成所述证券买卖的出价或征价邀请或要约。该等信息、意见并未考虑到获取本报告人员的具体投资目的、财务状况以及特定需求，在任何时候均不构成对任何人的个人推荐。客户应当对本报告中的信息和意见进行独立评估，并应同时考量各自的投资目的、财务状况和特定需求，必要时就法律、商业、财务、税收等方面咨询专家的意见。对依据或者使用本报告所造成的一切后果，本公司及/或其关联人员均不承担任何法律责任。

本报告所载资料的来源被认为是可靠的，但本公司不保证其准确性或完整性，也不保证所包含的信息和建议不会发生任何变更。本公司并不对使用本报告所包含的材料产生的任何直接或间接损失或与此相关的其他任何损失承担任何责任。

本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可升可跌，过往表现不应作为日后的表现依据；在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告；本公司不保证本报告所含信息保持在最新状态。同时，本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现。过往的业绩表现亦不应作为日后回报的预示。我们不承诺也不保证，任何所预示的回报会得以实现。分析中所做的回报预测可能是基于相应的假设。任何假设的变化可能会显著地影响所预测的回报。

本公司的销售人员、交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。本公司没有将此意见及建议向报告所有接收者进行更新的义务。本公司的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。

本报告并非针对或意图发送予或为任何就发送、发布、可得到或使用此报告而使兴业证券股份有限公司及其关联子公司等违反当地的法律或法规或可致使兴业证券股份有限公司受制于相关法律或法规的任何地区、国家或其他管辖区域的公民或居民，包括但不限于美国及美国公民（1934年美国《证券交易所》第15a-6条例定义为本「主要美国机构投资者」除外）。

本报告的版权归本公司所有。本公司对本报告保留一切权利。除非另有书面显示，否则本报告中的所有材料的版权均属本公司。未经本公司事先书面授权，本报告的任何部分均不得以任何方式制作任何形式的拷贝、复印件或复制品，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。未经授权的转载，本公司不承担任何转载责任。

特别声明

在法律许可的情况下，兴业证券股份有限公司可能会持有本报告中提及公司所发行的证券头寸并进行交易，也可能为这些公司提供或争取提供投资银行业务服务。因此，投资者应当考虑到兴业证券股份有限公司及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。投资者请勿将本报告视为投资或其他决定的唯一信赖依据。

兴业证券研究

上海	北京	深圳
地址：上海浦东新区长柳路36号兴业证券大厦15层	地址：北京西城区锦什坊街35号北楼601-605	地址：深圳市福田区皇岗路5001号深业上城T2座52楼
邮编：200135	邮编：100033	邮编：518035
邮箱：research@xyzq.com.cn	邮箱：research@xyzq.com.cn	邮箱：research@xyzq.com.cn