

海外文献-7 基于 Tweet 的舆情交易策略：用社交媒体文本挖掘和稀疏矩阵分解预测股市波动

核心观点：

- **基于 Tweet 文本信息预测股市。**研究以用户微博中的文本信息预测股市的潜在效果。用 Wong 等人提出的“潜空间模型”(2014)，将股价和社交媒体内容的变动联系起来。本研究与以往研究所用的模型有两个显著的区别：(1) 充分利用包含在大量社交媒体中的市场信息而非新闻文章中的市场信息 (2) 不评估情绪。本文用 2011 年到 2015 年之间 S&P 500 大多数成分股数据测试模型，发现此模型优于基准回归。最后，本文提出一个收益率和夏普比率较好的交易策略。

分析师

吴俊鹏

☎: 010-80927631

✉: wujunpeng@chinastock.com.cn

分析师登记编码: S0130517090001

相关研究

《海外文献-1 基于谷歌趋势的量化交易》

《海外文献-2 社交媒体胜过新闻吗》

《海外文献-3 Google 趋势搜索可否被用于分散风险？》

《海外文献-4 通过量化维基百科的使用模式预测股市变动》

《海外文献-5 量化财经新闻与股市的关系》

《海外文献-6 Twitter 情绪指数能用于预测加密货币走势吗》

目 录

一、引言	3
二、文献综述.....	3
三、数据	4
四、方法	6
五、结果	10
六、结果	14
七、风险提示.....	16

本文研究了以用户微博中的文本信息预测股市的潜在效果。用 Wong 等人提出的“潜空间模型”(2014)，将股价和社交媒体内容的变动联系起来。本研究与以往研究所用的模型有两个显著的区别：(1) 充分利用包含在大量社交媒体中的市场信息而非新闻文章中的市场信息(2) 不评估情绪。本文用 2011 年到 2015 年之间 S&P 500 大多数成分股数据测试模型，发现此模型优于基准回归。最后，本文提出一个收益率和夏普比率较好的交易策略。

一、引言

自 Fama 于 1970 年首次提出有效市场假说以来，可获得的公共信息急剧增长。除了传统信息源如新闻、分析师报告和财务报表数据的增长外，社交媒体上的用户数据也不断增加。例如，Twitter 主页上报道有 3.2 亿月度活跃用户每天发约 5 亿条推特。Kalampokis 等人 (2013) 对关于社交媒体数据扩张的研究进行综述，强调社交媒体的在各种场景下的预测潜力。社交媒体数据已经成为一种流行的市场预测数据源，而且已被广泛用于探究与金融市场间的关系。

本文提出了一个基于文本分析的股价预测模型，并同时用样本内和样本外评估方法，探讨了该模型基于利用本文提出的交易策略的有效性。

二、文献综述

2.1 基于传统新闻的文本挖掘

用文本挖掘(即自然语言数据的统计分析)收集数据是当前研究人员关注的焦点。Loughran & McDonald (2011) 通过分析 10-K 文件寻找能更好地反映财务语境的替代词。他们试着找出包含金融市场信息的特定词语，并将这些词与收益、交易量和和其他市场指标联系起来。Nassirtussi 等人 (2014) 总结了以文本预测资产价格变动的研究，并综合评价了对各种数据源以各种文本挖掘方法预测各类资产的效果差异。

最早将语言的量化指标与股价联系起来的论文之一是 Tetlock (2007)，他检验了媒体报道和股市之间互动关系，发现可以利用投资者悲观情绪预测市场的变化模式。此外，Tetlock 等人 (2008) 用“单词包”方案收集 Wall Street Journal(WSJ)和 Dow Jones News Service (DJNS) 上的所有单词，并依据哈佛-IV-4 心理学词典将其区分为积极和消极型词语。他们发现财经媒体中使用的消极词汇常预示着企业的低利润，而且市场价格对新闻文本信息的反映仅有轻微的延迟。

Schumaker 等 (2012) 也试图用其自己开发的金融文本量化系统——亚利桑那州金融文本 (AZFinText) 系统，评估文本和股价变动之间的相关性。研究过程分为两步：情绪分析和价格预测。所用的数据源为雅虎财经，先区分文本是客观的还是主观的，然后将主观文本筛选出来并准确将情绪进行分类，依据 MPQA 观点库校对类别划分。其中，MPQA 是一个包含大量新闻报道的数据库，该数据库手工对报道中的观点和其他私人状态，如情感、信仰和情感等进行了注释。以 MPQA 为标准，Schumaker 等的情绪分析准确率达 74%。他们发现，以 AZFinText 系统提取主观文本中的情绪并预测股价变动的准确率达 59%。此外，反映积极情绪的文章发布后股价下跌的概率为 53.5%，反映消极情绪的文章发布后股价增长的概率为 52.4%，由此可推出一个异于常规的交易策略：利好消息冲击时做空，不利消息冲击时做多。

Mamaysky 和 Glasserman (2015) 的研究表明，文本数据也可以预测市场波动。他们汇总

了 1996 年至 2014 年间 36 万多篇关于 50 家大型金融公司的文章，并研究 n-grams 即 n 个反映积极或消极情绪单词的词频序列。发现消极词汇词频的异常增加往往伴随后续几个月市场波动性（以 VIX 指数衡量）的提高。

通常，将文本分析与股市预测联系起来的方法第一步先对文本源进行情感分类。相反，Wong 等（2014）采用了一种忽视情绪评估的方法。他们首先统计出《华尔街日报》2008 年到 2011 年的文章中出现频率最高的 1354 个单词，并收集了每篇文章报道公司在每个交易日的股价。用潜在因素表示法将词频与每只股票的对数收益率联系起来，他们开发了一个以文章词频预测收盘价的模型。Wong 等（2014）提出的方法与大多数研究的不同之处主要有两点：（1）不评估情绪，避免任何积极消极情绪的划分错误（2）可以推广预测华尔街日报中未提及的股票的价格。鉴于该方法的简洁性和稳健性，本文在第 4 节中运用类似的方法。

2.2 基于社交媒体的文本挖掘

长期以来学者们一直在探索社交媒体数据的预测能力；Kalampokis 等（2013）对社交媒体如何用于各类预测的研究进行了汇总。例如，有研究以谷歌数据跟踪流感类疾病的传播情况，以亚马逊评论预测产品销售情况、以推特发帖数据预测降雨情况等。最早探究社交媒体对股市影响的实证研究之一是 Antweiler & Frank 于 2004 年开展的，该研究聚焦于用雅虎财经留言板中的文本预测股市的波动性。这些研究表明从社交媒体信息中可以得出对市场有预测力的指标。

近期，学者们对以 Twitter 作为社交媒体内容来源进行市场预测的有效性进行了探索。尽管每条帖子或推文的字数限制在 140 个字以内，但总体而言，Twitter 被认为可以准确反映公众情绪。通过分析 tweet 文本和股票的上市表现，Liew & Wang（2016）发现，股票上市的推特平均人气与股票上市首日的收益率之间存在显著的正相关性，这种关系不仅在首个交易日，而且在上市前三天都是显著的。进一步检验推文和财报公告之间的关系，Liew et al.（2016）发现，不仅利用公众对盈利的一致预期能更精确地预测股价表现（准确度约提高了 60%），而且财报公布前推文中反映的公众情绪也能用于预测财报公布后经风险调整的股票超额收益率。此外，Azar&Lo（2016）的研究表明，联邦公开市场委员会（FOMC）开会期间 Tweet 上推文中包含的信息可用于预测股市收益和构建表现优于基准收益的投资组合。

另一个值得一提是 Liew & Budavri 在 2016 年开展的基于 StockTwits 数据的研究。该研究表明，社交媒体中的数据能有效地解释收益率时间序列的波动。他们随后提出对预测收益有重要意义的，区别于 Fama-French 模型中五个因素的第六个因素，即“社交媒体因素”。本文首次将 Wong 等（2014）提出的算法应用于社交媒体数据，具体为每日和日内 StockTwits 上的数据，深化了金融文本挖掘领域的研究。

三、数据


本节描述相关数据并解释预处理过程。

3.1 源自 StockTwits 的文本数据

该研究使用的文本数据来自 StockTwits.com。StockTwits®是一个专注于个股和股票市场的以投资者为目标用户的财经交流平台。\$TICKER 标签有助于从全网筛选并汇总关于股票和市场的信息“流”。截至 2016 年，StockTwits 上 30 万多名用户发帖的全球浏览量达四千万次。发帖内容可以与许多其他财经网站的内容集成，如雅虎财经、CNMoney、Reuters、

TheStreet.com、Bing.com 和 The Globe and Mail 等。StockTwits 在过滤掉非财经相关内容方面投入了大量精力，为文本挖掘提供了大量高质量文本。


图 1: Plot of per day number of mentions and price of “oil” and “aapl” against time



资料来源: A. Sun et al. / International Review of Financial Analysis 48 (2016) 272–281, 银河证券研究院

本文获取了 StockTwits 上 2011 年 1 月 1 日至 2015 年 8 月 31 日约 4500 万条信息。每条数据有约 40 种不同属性，包括内容、追随者数、点赞数、发布时间和标签信息等。然而，本文只关注发帖内容和时间。用 StockTwits 数据前，本文用 R library tm 进行数据预处理。第一步，将一天内的数据合并。对于日内交易，进一步将数据分为上午、中午和下午的数据。文本数据合并完成后，剔除非单词文本如网页链接和表情等。第二步，剔除如 “the” 和 “it” 等可能造成额外干扰的“停顿词”和标点符号，并为便于比较，将所有文本调整为小写。本文的探索性分析揭示了关键字出现次数的趋势。图 1 通过绘制单词 “oil” 和 “aapl” 的词频和价格随时间的变动检验两者的关系。本图中字频与价格之间是否存在显著关系并不明确。“oil” 的词频与布伦特原油价格似乎呈负相关关系，而 “aapl” 的词频与苹果公司股价间无明显相关性。Loughran & McDonald (2011) 的研究表明，原始词频可能不是词汇语境的最佳衡量标准，而且特殊的权重调整可能使文本分析更有效。

图 2: Plot of word counts on StockTwits



资料来源: A. Sun et al. / International Review of Financial Analysis 48 (2016) 272–281, 银河证券研究院

此外，在本文的研究期间内，StockTwits 的使用量明显增加了。图 2(a)显示，每日词频几

乎呈现指数式增长，部分原因是用户基数的扩大。特别地，由 2(b)可见 StockTwits 用户量的增长既体现为每年平均词频的增加，又体现为每年内词频总量变动的加剧。词频的偏度几乎是大量社交媒体文本信息的副产品。尽管 StockTwits 的成长伴随着偏度增加的副作用，作者相信数据集的高容量属性将提供有价值的市场指标并有利于探索你能纠正偏度的标准化方法，这部分在第 4 节进一步展开讨论。

3.2 股价数据

本文预测标普 500 指数成分股的股价。涉及的股票为 2011 年 1 月 1 日到 2015 年 8 月 31 日之间上市交易的标普成分股。此外，剔除了交易量极低的股票如 Berkshire Hathaway B Shares (BRK-B)后，本文最终以 420 支成分股为样本。

本文用 R 语言 quantmod 包获取了 2011 年 1 月 1 日至 2015 年 8 月 31 日期间 420 支成份股所有交易日的历史收盘价，并以 CRSP 数据补充空缺值。计算样本股票在所有 1173 个交易日的对数收益率，并保存在以成分股为行交易日为列构成的 420×1173 的矩阵中。

对于日内的检验，本文从纽交所 Trade and Quote (TAQ)获取了 2011 年 1 月 1 日至 2015 年 8 月 31 日之间的所有交易日的股票开盘价、中午价和收盘价，并计算这些股票在所有 3519 个交易日的对数收益率，并以同样的格式保存在 420×3519 的矩阵中。

本文数据源与以往研究的数据源之间存在两个主要差异。首先，许多既有研究以新闻报道作为文本信息的来源。具体而言，关注业内常见的新闻来源如《华尔街日报》或者 DJNS。相应地，新闻报道是高质量但数量较少（与社交媒体比）的信息源，而 StockTwits 反之。本文用 StockTwits 的筛选功能筛选文本，并剔除非文字（如表情符号和网站网址）和停顿词以提高文本数据质量。本文分析的价格之外的文本数据仅限于可从社交媒体尤其 StockTwits 获取的数据。其次，多数研究将 Twitter 作为初始的社交媒体文本数据源。尽管 Twitter 或许对本文的方法而言也是很好的数据源，但本文不区分用户情绪类别，大量的 Twitter 文本会为以算法预测股市添加干扰。例如，“我爱 NYC”“分析师持乐观态度”类似的短语都包含积极情绪，但是只有后者与股市有关。因此，本文以与 Twitter 很像的 StockTwits 为数据源，利用社交媒体搜集财经相关文本。


四、方法

本节介绍该研究所用的方法。

4.1 文本挖掘

本文建模第一步是通过文本挖掘统计出每年最频繁出现的词汇并将其与 420 只成分股的 tickers 匹配起来，以构建文本词典。其中有些 ticker 由于提及过少被移除。本文构建的文本词典中的样本词汇包括典型的交易信号如“做多/买”、“做空/卖”、“持有”、“appl”、“spy”等。然后以文本词典中的词为行，文档为列，创建词汇-文档矩阵。其中，每个“文档”都是连续的交易日，且矩阵中每格是所对应词汇在对应交易日的词频。下文中以 Y 代表词汇-文档矩阵，并以 $y_{i,t}$ 代表词汇 i 在第 t 天的词频。

图 3: Plot of normalized term frequencies



资料来源: A. Sun et al. / International Review of Financial Analysis 48 (2016) 272–281, 银河证券研究院

各种赋权方案如简单平均加权(tf)、词频逆文档频率加权(tf-df)和修正版本如 Loughran & McDonald (2011)提出的一种修正方法, 都尝试后, 发现 Salton & Buckley 于 1988 年提出的一种词频加权方案对本文的方法最有效。因为词频中包含的文本信息每天都会变, 所以通过余弦标准化(据向量的模归一化)将每天的文本信息进行标准化, 其中每天的文本信息被视为一个向量并除以欧几里得范数(向量的模)。若第 t 天的词频记作 y_t , 则 $y_t/\|y_t\|_2$ 即余弦标准化结果。图 3 展示了标准化的结果, 可见经标准化处理明显削弱了前述趋势。注意, 前几年方差较大是合理的, 正如预期的那样, 随 StockTwits 越加流行, 其用户产生的文本量也越加稳定。

最后, 对每个词的词频进行标准化处理。如果将第 i 个词在第 t 天的词频记作 y_{it} , 则以 z-score 标准化的结果为

$$\frac{y_{it} - \mu_i}{\sigma_i}$$

其中 μ_i 和 σ_i 分别是研究期间第 i 个词汇的词频均值及标准差。本文剔除了 y_{it} 标准化后为负数的值和超出 3 倍标准差的值。其中, 剔除负数是因为直觉中, 被提及次数低于平均次数的 y_{it} 不会对股价产生影响, 剔除超出 3 倍标准差的值是为了减少异常值的影响。经上述预处理后, 得到了一个标准化的、归一化且调整偏度后的词汇-文档矩阵。

4.2 稀疏矩阵分解模型

本文所用的稀疏矩阵分解(SMF)严格按照 Wong 等(2014)提出的方法, 该方法用于预测价格时有两个显著的优势: (1) 当 $d \ll s$ 时, 矩阵 U 和 W 的秩都比较低 (2) 稀疏矩阵只选择与预测股市最相关的参数, 最大限度地减少了过拟合的问题, 更详细的模型参数如下。

4.2.1 基础矩阵分解框架

使用的矩阵分解模型将文本和股票都映射到一个维数为 d 的联合潜在因子空间。每一只股票 i 都与潜在因子向量 $u_i \in \mathbb{R}^d$ 相关, 每一个在 t 内的文本数据都与 $u_i \in \mathbb{R}^d$ 相关。 $u_i^T v_t$ 抓住了股票 i 与交易日 t 之间的关联, 从而可以用来估计对数回报率, 换句话说, 即:

$$\hat{r}_{it} = u_i^T v_t$$

4.2.2 文本数据处理说明

引入一个文本向量 y_t ，它包含第 4.1 节中创建的调整后的词汇-文档矩阵中每个交易日中的词汇频率。然后，从频率推断出当天的潜在文字向量。给定 m 个词汇，创建一个新的矩阵 $W \in \mathbb{R}^{d \times m}$ ，它代表着每一个词汇从 y_t 到 v_t 的线性映射。则对于给定的股票 i ，其对数收益率可表示为：

$$\hat{r}_{it} = u_i^T W y_t$$

则接下来的目标就是利用 s 天的历史数据找到特征向量 u_i 和映射矩阵 W 。用矩阵的形式，将收益率记作 $R = [r_{it}] \in \mathbb{R}^{n \times s}$ ，且 $U \in \mathbb{R}^{n \times d}$ ， $W \in \mathbb{R}^{d \times m}$ ， $Y = [y_1 \dots y_s] \in \mathbb{R}^{m \times s}$ 。其中 R 是行为股票、列为日期的收益率矩阵。 U 是反应 n 只股票和 d 个因子的潜在因子矩阵。 W 为反应 d 个因子和 m 个词汇的潜在因子矩阵。 Y 是词汇为行、日期为列的频数矩阵。则可以得到如下的目标函数：

$$\min_{U \geq 0, W} \frac{1}{2} \|R - UWY\|_F^2$$

并解出 U 和 W 。

4.2.3 稀疏性限制

求解 U 和 W 存在过拟合问题。比如说，若有 700 个词汇（一个较小的词典）和仅仅 10 个潜在因子便要估计 7000 个参数。所以，需要对该规划问题添加限制条件。可以通过在矩阵 W 上添加稀疏性条件来确保非 0 参数的数目较少。直观上来说，限制非 0 参数的做法是可靠的，因为不是每一个词汇都与预测一只特定股票的对数收益率相关。所以通过添加稀疏性限制的方法，文献中解决了 3.1 中所提到的噪声词汇的问题。

由此，本文引入了稀疏群 lasso 回归。其目标方程为：

$$\lambda \sum_{j=1}^m \frac{1}{2} \|W_j\|_2 + \mu \|W\|_1$$

可以发现，该式子中有两项。为了在每个潜在因子中只选择少量的词汇，文献中最小化第一项 λ ，其中 j 对应 W 中的第 j 个词语。第一项的引入可以保证 W 中只有少数列为非 0，而第二项的引入可以保证每一个词只与少数潜在因子相关。即第二项 μ 的引入 减少了每一列中的非零参数。于是，规划问题转化为：

$$\min_{U, W} \frac{1}{2} \|R - UWY\|_F^2 + \lambda \sum_{j=1}^m \|W_j\|_2 + \mu \|W\|_1$$

Wong 等人证明了该规划问题可以用交替方向乘子法（ADMM）来解得局部最小值。该方法将这个问题用辅助变量 A, B 重写为：

$$\min_{A, B, U, W} \frac{1}{2} \|R - ABY\|_F^2 + \lambda \sum_{j=1}^m \|W_j\|_2 + \mu \|W\|_1 + I_+(U)$$

其中： $U \geq 0$ 时， $I_+(U) = 0$ ，其它情况下 $I_+(U) = \infty$ 。

接着文献中引入拉格朗日 C 和 D ，得到增广拉格朗日式：

$$L_p(A, B, U, W, C, D) = \frac{1}{2} \|R - ABY\|_F^2 + \lambda \sum_{j=1}^m \|W_j\|_2 + \mu \|W\|_1 + I_+(U) + \text{tr}(C^T(A - U)) + \text{tr}(D^T(B - W)) + \frac{\rho}{2} \|A - U\|_F^2 + \frac{\rho}{2} \|B - W\|_F^2$$

附录中可见运用 ADMM 方法的解。当得到了矩阵 U 和 W 之后，可以利用当日数据对第二天的月收益率进行预测。

4.3 训练与预测

文献中，将从每日和日内两种频率来预测股价走势。在每天的层次上，通过输入 StockTwits 的数据流，文献中预测了在每个交易日结束时的对数收益率。而在日内的层次上，文献中预测了每个交易日在中午和结束时的对数收益率。

4.3.1 每日的预测

数据集被划分成了训练集、验证集和测试集。训练集包括了从 2011 年 1 月 1 日到 2012 年 12 月 31 日的 502 个交易日数据。验证集包括了从 2013 年 1 月 1 日到 2013 年 12 月 31 日的 252 个交易日数据。测试集包括了从 2014 年 1 月 1 日到 2014 年 12 月 31 日的 252 个交易日数据和从 2015 年 1 月 1 日到 2015 年 8 月 31 日的 167 个交易日数据，即总共包括了 419 个交易日数据。

主要的变量有：

n 支股票， m 个词汇以及 s 天

r_{it} ：第 i 支股票在第 t 天的对数收益率

y_{jt} ：词汇 j 在第 t 天的调整后频率

p_{it} ：第 i 支股票在第 t 天的收盘价

u_i ：第 i 支股票的潜在因子向量

文献中的方法如下所示：在第 t 天通过历史数据 $[r_{it}]$ 和 $[y_{jt}]$ ($t' < t, [\cdot]$ 表示该数据所组成的矩阵) 计算出 U 和 W ，并利用调整后的词汇频率矩阵 y_{jt} 来预测 $[r_{it}]$ 。并将预测的价格走势与真实的价格走势进行对比，以此计算正确率。最后，可以重新通过收益计算出价格。

4.3.2 日内预测

如同每日的预测一样，数据集被划分为训练集，验证集和测试集。训练集包括了从 2011 年 1 月 1 日到 2012 年 12 月 31 日的 1506 个交易日数据。验证集包括了从 2013 年 1 月 1 日到 2013 年 12 月 31 日的 756 个交易日数据。测试集包括了从 2014 年 1 月 1 日到 2015 年 8 月 31 日的 1257 个交易日数据。

文献中日内预测和每日预测的方法是相同的，但是对于日内预测来说， t 代表的是总的交易时期而不是交易天数。

超参数	描述
s	用于预测第 t 天价格的历史天数
d	潜在因子的数量

λ	稀疏群 lasso 第一项的惩罚参数
μ	稀疏群 lasso 第二项的惩罚参数
ρ	拉格朗日惩罚参数

首先，文献中设置 $d=10$ ，以确保 W 只有 10 个潜在因子，接着执行网格搜索：文献中对比了每一组超参数所对应的预测准确率以及接下来在验证集上的预测。此外，仅在使得矩阵保持稀疏的范围内选择 λ 和 μ 。

五、结果

5.1 样本内结果

对于给定的表示过去 s 天， n 支股票收益率的矩阵 R ，可以得到 U 和 W ，并课通过文献中的方法得到对于收益率 r_{it} 的预测。表格一中显示，在训练之后，对于股票价格运动方向的预测准确率达到到了 70.12%（也是对训练集中的数据进行预测）。文献中也用精度和召回率两个指标来评价样本内预测的效果，定义如下：

$$Precision = \frac{tp}{tp + fp} \quad Recall = \frac{tp}{tp + fn}$$


表 1 Test accuracy comparison (%)

Year	In-sample	Ex-sample					
	Daily	Daily			Intraday		
	2011–2012	2013	2014	2015	2013	2014	2015
Accuracy	70.12	51.18	51.42	51.58	50.23	48.61	49.03
Precision	68.93	54.14	53.72	51.25	53.12	50.80	48.28
Recall	75.05	53.99	46.34	53.41	49.66	49.29	44.60


资料来源：A. Sun et al. / *International Review of Financial Analysis* 48 (2016) 272–281，银河证券研究院

其中 tp , fp , tn , fn 分别为正确预测增加的次数，错误的预测增加的次数，正确的预测减少的次数，错误的预测减少的次数。在此模型中，精度可以被用来评价预测的准确性，回撤率可以被用来评价预测的完备性。该模型的精度为 68.93%，而回撤率为 75.05%。

图 4: In-sample accuracy.



a: In-sample accuracy by stock



b: In-sample accuracy by day

资料来源: A. Sun et al. / *International Review of Financial Analysis* 48 (2016) 272–281, 银河证券研究院

图 4(a)中显示, 所有股票的预测准确率都高于 60%。类似的, 图 4(b)中的虚线表示 50% 的准确性, 可以发现文献中的模型在样本内预测中, 可以在大部分的日期内以高于 50% 的准确性进行预测。

5.2 样本外结果

表一中列出了模型在测试集中 (2014-2015) 的预测准确率。同时也列出了验证集中的表现来作为参考。接下来将会将文献中的 SMF 模型与其他基本模型进行对比。

*以过去的价格和收益率作为对未来价格和收益率的预测: 预测的收益率和价格与先前保持一致

*自回归模型(AR): 用自回归模型来进行预测每只股票的收益率和股价

*随机模型: 基于市场计时器进行随机的收益率预测

表 2 总结了文献中模型和基本模型的结果, 其显示出不论在哪一年, SMF 模型对于股价走势的预测都比其他基本模型的预测要更准确。此外, 由于有效市场假说表明文献中的模型不应比随机模型表现更好。所以一个点的增长可能显示出文献中模型强大的预测能力。文献中将在 5.4 中通过提出一个交易策略的方法来对该算法进行进一步的探索。

表 2 Model accuracy (%).

Model	Daily			Intraday		
	2013	2014	2015	2013	2014	2015
SMF	51.12	51.42	51.58	50.23	48.61	49.03
Previous return	49.55	49.65	49.15	48.67	48.07	48.53
Previous price	48.66	48.16	49.31	46.52	47.38	47.11
AR on return	50.61	50.80	50.31	49.66	51.04	48.87
Random	49.39	49.74	49.65	48.89	49.07	49.17

资料来源: A. Sun et al. / *International Review of Financial Analysis* 48 (2016) 272–281, 银河证券研究院

5.3 日内的结果

除了每日的测试, 文献中也进行了日内的测试, 表 1 也报告了对验证集(2013 年)和测试集

(2014-2015 年)的日内测试结果。像每日测试一样，文献中也比较了日内 SMF 与基本模型的结果。表 2 总结了评估结果。结果显示，来自 SMF 模型的日内预测并不会每年都超过基线，并且事实上，SMF 模型在 2014 年和 2015 年的表现不如随机模型。

5.4 交易策略

一个用来测量投资组合表现的指标是夏普比率 (SR),假设无风险回报为零，这是研究期间的短期合理假设。Lachanski(2015)在他的论文中指出，可以使用一个封闭形式的表达式来计算市场时机策略的 SR:

$$SR = \frac{g}{\sqrt{\kappa - g^2}} \quad \kappa = \frac{E[r_t^2]}{4E[r_t]^2} \quad g = p - \frac{1}{2}$$

其中 p 是模型做出正确预测的概率，k 的取值可以用投资组合日超额收益率来衡量。

使用此市场时机 SR 的定义，可以计算文献中策略的 SR，并将其与 S&P 500 交易所交易基金 (ETFs): SPDR S&P 500 ETF, iShares Core S&P 500 ETF 和 Vanguard 500 Index Fund 进行比较。表 3 中显示，文献中策略的 SR 明显低于其他市场 ETF。但是，值得注意的是，根据封闭式表达式计算出的 SR 是一个下限，并且交易策略可能会利用股票之间的相关性来生成更高的 SR。因此，提出以下交易策略。

- 1.根据一天的文字信息，预测股票的涨跌方向
- 2.将所有资金平均投资于预期会上涨的股票
- 3.在交易日结束时卖出所有资产
- 4.在每一个交易日重复进行

将策略与其他交易策略进行比较，包括等权重投资组合(EW)和全局最小方差投资组合(GMV)。

表 3 Sharpe ratio of the market timing model and comparable ETFs

Portfolio	Sharpe ratio
SMF Market Timing	0.38
SPDR S&P 500 ETF	0.97
iShares Core S&P 500 ETF	0.98
Vanguard 500 Index Fund	0.98

资料来源: A. Sun et al. / International Review of Financial Analysis 48 (2016) 272–281, 银河证券研究院

表 4 Portfolio performance comparison.

Portfolio	Cumulative return	Annualized return	SR	Worst day return	Best ray return
SMF	1.55	1.18	1.35	-0.038	0.035
SMF Weighted	1.38	1.13	1.01	-0.038	0.036
SPDR S&P 500 ETF	1.38	1.13	0.98	-0.043	0.038
GMV ^a	1.22	1.08	1.61	-0.012	0.010
EW	1.19	1.07	0.71	-0.042	0.021

资料来源: A. Sun et al. / International Review of Financial Analysis 48 (2016) 272–281, 银河证券研究院

EW 组合即对所有资产等权投资，而 GMV 组合则使得投资组合的收益率取得最小的标准

差。请注意，文献中的策略是对选定的所有资产进行平均投资。文献中还展示了令一种策略，根据模型中预测收益的大小赋予权重，并模拟在 2011 年 1 月 1 日至 2015 年 8 月 31 日之间的所有交易日的交易。

表 4 列出了累积收益，年化收益，SR，最低日收益和最高日收益。可以看到，文献中的基本策略与 SPDR S&P 500 ETF 相比获得了最高的回报，而加权策略与 ETF 的回报相当。同时，文献中的策略获得了 1.35 的 SR，远远高于下限，也高于所有 ETFs 的 SR。注意到尽管 GMV 组合的收益较低，其 SR 在所有组合中却是最高的。这一现象被认为是 SR 未必总是衡量基金业绩的最佳标准的原因之一。尽管如此，文献中的策略在所有指标的衡量下都超过了指数型 ETF。


图 5: Graph of portfolio performance



资料来源: A. Sun et al. / International Review of Financial Analysis 48 (2016) 272–281, 银河证券研究院

图5显示了文献中的交易策略在交易期间(2013年1月-2015年8月)与其他组合的对比图。黑线区分开了 2013 年、2014 年和 2015 年的不同时间段。

图 6: Model accuracy plotted against magnitude of return.



资料来源: A. Sun et al. / International Review of Financial Analysis 48 (2016) 272–281, 银河证券研究院

可以发现,文献中的策略在2013年表现最差,但在2014年和2015年有所改善。这种改进很可能是由于文献中的预测准确率从2013年到2015年的提高所导致。可以假设文献中的交易策略比基准投资组合在整体上来看表现更好,尽管总体准确性有小幅提高。因为本文策略在收益率增加时预测准确率更高。图6显示了收益率大小与预测准确率之间的关系,更具体地说,是两者之间的正相关关系。这种正相关性表明,文献中的交易策略能够更好地利用巨大的正回报,而避免巨大的负回报——这使得该策略表现得比指数更好。这些结果表明,是能够利用 StockTwits 流中固有的市场指标而比其他模型更好地预测股票市场。

六、结果

第5节中描述的结果表示,能够使用 SMF 方法从 StockTwits 流中提取市场指标来预测股票价格方向。这些发现支持 Wong 等人(2014)的主张,即 SMF 方法可用于结合文本挖掘来预测股市。

本文有两个主要结论。第一,使用 SMF 模型和 StockTwits 流进行的市场时机策略比大多数数基本模型表现更好。样本外结果表明,在每一个测试年份,文献中的策略都能够击败基准方法(这些基准方法在未来预测中不使用任何历史价格以外的信息)。每日预测(以天为单位)的预测精度为 51.37%。直觉上看,大多数投资者不会认为 51% 的预测准确率有多高,而且很少有人愿意为一个正面朝上的概率为 51% 的硬币支付溢价。然而,在文献中的模型中,若文献中的数据预测精度为 60%,那么夏普比率(Sharpe ratio)的下限为 2.87,这比 Morningstar 上除两只以外的所有基金都要高。所以事实上,我们预测的准确率可能表明 StockTwits 上包含了对资产经理和投资者有用的信息。而基于该预测,文献中构造了一个 SR 为 1.35,年化收益率为 1.18 的投资策略。

第二,增加预测的频率似乎并没有提高预测的准确性。由于 StockTwits 的留言性质,预测的准确性应该会随着频率的增加而增加。因为与《华尔街日报》等高质量的新闻来源不同, StockTwits 的信息可能只需要几个小时就可以整合到市场中。然而,文献中的研究结果却显示了相反的结果——准确率似乎并没有随着频率的增加而增加,有时还会被随即预测所击败。通过研究 StockTwits 上用户之间的互动,文献中假设上述现象可能是由于网站上的内容共享。许多信息流并不是原创内容和观点,而是来自于转发和其他平台。StockTwits 的这种次级性质导致了信息传播的延迟,使得信息在被纳入市场价格后才公布。这减少了文本信息在每日级别的预测效果,并消除了它在日内级别的效果。另一方面,像那些来自华尔街日报的新闻文章是主要来源,可以反映新的和原创的内容。这两种新闻来源之间的差异可以解释为什么 Wong 等人(2014)能够利用华尔街日报的文章在每日水平上获得更高的预测精度。

有效市场假说意味着不可能预测市场和在风险调整后并考虑交易成本的情况下一直打败指数策略。本文作了两个简化假设。首先,文献中没有考虑交易成本。因此,为了更加准确地比较文献中的方法与市场指数或其他共同基金经理的表现,必须在模型中考虑交易成本。然而,我们注意到共同基金和其他资产管理公司收取的费用可能也相当于增加了交易成本。第二,文献中假设无风险利率为零。这可能无关紧要,因为 2015 年 3 个月期美国国债利率为 0.02%,非常接近于 0。调查发现,在策略期间的市场状况——零利率和股票市场的上涨——都有利于积极策略的表现,检验这种交易策略是否能在其他情况下继续表现良好将是很有趣的。

该文主要观点来自:《Trade the tweet: Social media text mining and sparse matrix factorization for stock market prediction》 Andrew Sun, Michael Lachanski, Frank J. Fabozzi, International Review of Financial Analysis 48 (2016) 272–281

参考文献:

Antweiler, W., & Frank, M. Z. (2004). Is all that talk just noise? The information content of internet stock message boards.. Journal of Finance, 59(3), 1259–1294.

Azar, P., & Lo, A. W. (2016). The wisdom of Twitter crowds: Predicting stock market reactions to FOMC meetings via Twitter feeds. Journal of Portfolio Management,

Boyd, S. (2010). Distributed optimization and statistical learning via the alternating direction method of multipliers. FNT in Machine Learning, 3(1), 1–122.

Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. Journal of Finance, 25(2), 383–417.

Gentzkow, M. & Shapiro, J. M. (2014). Code and Data for the Social Sciences: A Practitioner’s Guide. University of Chicago mimeo. Last updated January 2014.

Kalampokis, E., Tambouris, E., & Tarabanis, K. (2013). Understanding the predictive power of social media. Internet Research, 23(5), 544–559.

Lachanski, M. (2015). Not another market timing scheme! Detecting type I errors with ‘good deal’ bounds. Working paper.

Liew, J. K.-S., & Budavri, T. (2016). The ‘sixth’ factor – Social media factor derived directly from tweet sentiments. SSRN Electronic Journal,

Liew, J. K.-S., Guo, S., & Zhang, T. (2016). Tweet sentiments and crowd-sourced earnings estimates as valuable sources of information around earnings releases. Journal of Alternative Investments,

Liew, J. K.-S., & Wang, G. Z. (2016). Twitter sentiment and IPO performance: A cross-sectional examination. Journal of Portfolio Management, 42(4), 129–135.

Loughran, T., & McDonald, B. (2011). When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. Journal of Finance, 66(1), 35–65.

Mamaysky, H., & Glasserman, P. (2015). Does unusual news forecast market stress? Working papers in financial research.

Nassirtoussi, A. K., Aghabozorgi, S., Wah, T. Y., & Ngo, D. C. L. (2014). Text mining for market prediction: A systematic review. Expert Systems with Applications, 41(16), 7653–7670.

Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. Information Processing & Management, 24(5), 513–523.

Schumaker, R. P., Zhang, Y., Huang, C.-N., & Chen, H. (2012). Evaluating sentiment in financial news articles. Decision Support Systems, 53(3), 458–464.

请务必阅读正文最后的中国银河证券股份公司免责声明。

Tetlock, P. C. (2007). Giving content to investor sentiment: The role of media in the stock market. *Journal of Finance*, 62(3), 1139–1168.

Tetlock, P. C., Saar-Tsechansky, M., & Macskassy, S. (2008). More than words: Quantifying language to measure firms' fundamentals. *Journal of Finance*, 63(3), 1437–1467.

Wong, F. M. F., Liu, Z., & Chiang, M. (2014). Stock market prediction from WSJ: Text mining via sparse matrix factorization. *IEEE International Conference on Data Mining*.

Zhang, Y. (2010). An alternating direction algorithm for nonnegative matrix factorization. *Rice technical report*.

七、风险提示

报告结论基于历史文献，所以报告结论有可能无法正确预测市场发展，报告阅读者需审慎参考报告结论。文中观点仅供参考，不构成投资建议。

插图目录

图 1: Plot of per day number of mentions and price of “oil” and “aapl” against time.....	5
图 2: Plot of word counts on StockTwits.....	5
图 3: Plot of normalized term frequencies.....	6
图 4: In-sample accuracy.	10
图 5: Graph of portfolio performance.....	13
图 6: Model accuracy plotted against magnitude of return.....	13

表格目录

表 1 Test accuracy comparison (%).....	10
表 2 Model accuracy (%).	11
表 3 Sharpe ratio of the market timing model and comparable ETFs	12
表 4 Portfolio performance comparison.	12

分析师承诺及简介

本人承诺，以勤勉的执业态度，独立、客观地出具本报告，本报告清晰准确地反映本人的研究观点。本人薪酬的任何部分过去不曾与、现在不与、未来也将不会与本报告的具体推荐或观点直接或间接相关。

吴俊鹏：金融工程分析师，中国人民大学理学硕士，2015 年加入中国银河证券，从事证券研究工作 6 年。

评级标准

行业评级体系

未来 6-12 个月，行业指数（或分析师团队所覆盖公司组成的行业指数）相对于基准指数（交易所指数或市场中主要的指数）

推荐：行业指数超越基准指数平均回报 20%及以上。

谨慎推荐：行业指数超越基准指数平均回报。

中性：行业指数与基准指数平均回报相当。

回避：行业指数低于基准指数平均回报 10%及以上。

公司评级体系

推荐：指未来 6-12 个月，公司股价超越分析师（或分析师团队）所覆盖股票平均回报 20%及以上。

谨慎推荐：指未来 6-12 个月，公司股价超越分析师（或分析师团队）所覆盖股票平均回报 10%—20%。

中性：指未来 6-12 个月，公司股价与分析师（或分析师团队）所覆盖股票平均回报相当。

回避：指未来 6-12 个月，公司股价低于分析师（或分析师团队）所覆盖股票平均回报 10%及以上。

免责声明

本报告由中国银河证券股份有限公司（以下简称银河证券）向其客户提供。银河证券无需因接收人收到本报告而视其为客户。若您并非银河证券客户中的专业投资者，为保证服务质量、控制投资风险、应首先联系银河证券机构销售部门或客户经理，完成投资者适当性匹配，并充分了解该项服务的性质、特点、使用的注意事项以及若不当使用可能带来的风险或损失。

本报告所载的全部内容只提供给客户做参考之用，并不构成对客户的投资咨询建议，并非作为买卖、认购证券或其它金融工具的邀请或保证。客户不应单纯依靠本报告而取代自我独立判断。银河证券认为本报告资料来源是可靠的，所载内容及观点客观公正，但不担保其准确性或完整性。本报告所载内容反映的是银河证券在最初发表本报告日期当日的判断，银河证券可发出其它与本报告所载内容不一致或有不同结论的报告，但银河证券没有义务和责任去及时更新本报告涉及的内容并通知客户。银河证券不对因客户使用本报告而导致的损失负任何责任。

本报告可能附带其它网站的地址或超级链接，对于可能涉及的银河证券网站以外的地址或超级链接，银河证券不对其内容负责。链接网站的内容不构成本报告的任何部分，客户需自行承担浏览这些网站的费用或风险。

银河证券在法律允许的情况下可参与、投资或持有本报告涉及的证券或进行证券交易，或向本报告涉及的公司提供或争取提供包括投资银行业务在内的服务或业务支持。银河证券可能与本报告涉及的公司之间存在业务关系，并无需事先或在获得业务关系后通知客户。

银河证券已具备中国证监会批复的证券投资咨询业务资格。除非另有说明，所有本报告的版权属于银河证券。未经银河证券书面授权许可，任何机构或个人不得以任何形式转发、转载、翻版或传播本报告。特提醒公众投资者慎重使用未经授权刊载或者转发的本公司证券研究报告。

本报告版权归银河证券所有并保留最终解释权。

联系

中国银河证券股份有限公司 研究院

深圳市福田区金田路 3088 号中洲大厦 20 层

上海浦东新区富城路 99 号震旦大厦 31 层

北京丰台区西营街 8 号院 1 号楼青海金融大厦 15 层

公司网址：www.chinastock.com.cn

机构请致电：

深广地区：崔香兰 0755-83471963 cuixianglan@chinastock.com.cn

上海地区：何婷婷 021-20252612 hetingting@chinastock.com.cn

北京地区：唐媛玲 010-80927722 tangmanling_bj@chinastock.com.cn