



东兴证券  
DONGXING SECURITIES

# 基于动态因子调整的可持续量化选股策略

## ——海外文献速览系列之十二

2021年12月14日

金融工程 定期报告

分析师 | 高智威 电话：0755-82832012 邮箱：gaozhw@dxzq.net.cn

执业证书编号：S1480521030002

### 投资摘要：

在开发量化投资策略时，海外优秀论文往往能够提供新的思路和方法，为了能够让各位投资者更有效率地吸收海外的经验，东兴金工团队推出海外文献速览系列报告。我们将定期从海外文献中筛选思路较为新颖且有潜力应用于国内市场投资的文章，以速览的形式呈现给各位投资者，内容涵盖资产配置、量化选股、基金评价以及衍生品投资等多个方面。

本篇报告作为该系列报告的第十二篇，我们选取了 Yi Fu, Shuai Cao, Tao Pang 的文献《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》。

量化选股是一个热门的学术研究领域。尽管在量化模型和过程方面已经做了很多工作，但仍有一些地方可以改进。首先，在预测目标的设定上，以往的研究往往以股票收益率或价格是上涨还是下跌作为预测目标，但收益率往往包含一些噪声，而两种分类（上涨还是下跌）的设定并没有捕捉到很多现有信息。其次，在因子选择方面，以往的研究往往是静态地选择因子，但因子通常在一段时间内是有效的，之后可能不再有效。在本文中，作者提出了一种可持续的量化选股策略，它能在长期内在熊市、牛市和波动市场上运作良好。

在本文中，作者使用随机森林模型为训练集在每个时期动态选择因子，以确保每个时期可以选择的因子是当期的最优因子。同时，对股票收益进行分类概率预测（CPP）。该方法可以有效兼顾收益预测的准确性，避免噪声对收益率的干扰。

CPP 量化选股策略设计的基本思路可简单概括为如下几步：第一步，将每只股票按月收益率分入 5 个区间，通过随机森林（RF）模型将因子筛选到模型中；第二步，通过重新组合每个时期的因子和收益率区间来构建训练集和测试集；第三步，使用 RF 模型来预测每个训练集的因子的重要性，并按重要性降序排列，采用动态因子选择法来选择当期最重要的因子；第四步，使用 XGBoost CPP 方法进行分类预测，将每只股票分入 5 个收益率区间并按概率降序排列，将概率最高的前 20 只股票纳入股票池，调整仓位时卖出股票池之外的股票并买入池中的新股票。

作者指出，拟合选股方法容错性相对较低，并且收益中的噪声通常很大，回归错误的概率通常很高，容易造成较大的最大回撤。多类概率预测选股策略不是选择预测收益率最高的股票，而是要在确定预期收益率的区间之后，选择该区间内收益率最高的股票，这种方式使得选股准确率和容错率都得到了提高。历史回测表明，基于动态因子调整的 CPP 量化选股策略表现优于传统的机器学习选股方法，在大部分回测期内均能跑赢同期的沪深 300 指数。

作者对量化选股策略的研究方法值得我们学习和借鉴。作者运用机器学习方法在因子动态调整方面的创新值得我们关注。

### 风险提示：

本报告内容来源于相关文献，不构成投资建议。文中的结果基于原作者对历史数据的回测，当市场环境发生变化时，存在模型失效的风险。

## 目 录

|                           |    |
|---------------------------|----|
| 1. 研究背景.....              | 3  |
| 2. CPP 量化选股策略设计的基本思路..... | 4  |
| 3. CPP 量化选股策略回测分析.....    | 7  |
| 3.1 动态因子调整分析.....         | 8  |
| 3.2 回测收益.....             | 9  |
| 4. 总结.....                | 15 |
| 5. 我们的点评.....             | 15 |
| 6. 参考文献.....              | 16 |
| 7. 风险提示.....              | 16 |
| 相关报告汇总.....               | 17 |

## 插图目录

|                                         |    |
|-----------------------------------------|----|
| 图 1: 因子动态调整与分类概率预测 (CPP) 量化选股策略流程图..... | 4  |
| 图 2: 范围标准 (月回报率).....                   | 5  |
| 图 3: 因子列表.....                          | 5  |
| 图 4: 训练数据集和测试数据集的构建.....                | 6  |
| 图 5: ATR 14 中的 IC.....                  | 6  |
| 图 6: EBIT 中的 IC.....                    | 7  |
| 图 7: 被选中概率最高的 10 个因子.....               | 8  |
| 图 8: 策略回测的参数设置.....                     | 9  |
| 图 9: XGBoost 分类的主要参数.....               | 10 |
| 图 10: XGBoost 多类预测评估.....               | 10 |
| 图 11: 分类模型的混淆矩阵.....                    | 10 |
| 图 12: XGBoost 回归的主要参数.....              | 11 |
| 图 13: 回归和分类选股的回测收益图.....                | 12 |
| 图 14: XGBoost 回归和分类的选股策略回测指标.....       | 12 |
| 图 15: 随机森林的主要参数.....                    | 13 |
| 图 16: 收益率回测.....                        | 13 |
| 图 17: 不同模型的回测指标.....                    | 14 |
| 图 18: CPP 选股回测收益率图.....                 | 14 |
| 图 19: CPP 量化选股策略在不同时期的超额收益.....         | 15 |

## 1. 研究背景

在开发量化投资策略时，海外优秀论文往往能够提供新的思路和方法，为了能够让各位投资者更有效率地吸收海外的经验，东兴金工团队推出**海外文献速览系列**报告。我们将定期从海外文献中筛选思路较为新颖且有潜力应用于国内市场投资的文章，以速览的形式呈现给各位投资者，内容涵盖**资产配置、量化选股、基金评价以及衍生品投资**等多个方面。

本篇报告作为该系列报告的第十二篇，我们选取了 Yi Fu, Shuai Cao, Tao Pang 的文献《**A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment**》。

在现代投资中，算法交易越来越受到个人和机构投资者的关注。“算法交易是一种使用自动预编程交易指令执行交易命令的方法，该指令考虑了时间、价格和交易量等变量”。它会考虑时间、价格和交易量等市场上的可观察变量，并根据预设算法向市场发送指令。算法交易，一方面可以防止交易者频繁重复观察和手动发送交易指令；另一方面，也可以防止交易者的决策受到主观情绪的干扰。根据 Research and Markets 2019 年 5 月的一份报告，“研究人员预测，全球算法交易市场规模将从 2019 年的 111 亿美元增长到 2024 年的 188 亿美元，2019-2024 年的复合年增长率为 11.1%。算法交易市场的主要增长动力包括对快速有效交易命令执行的需求不断增加，以及降低交易成本”。

随着机器学习等新技术的发展，当前的算法交易不仅包括交易指令的自动发送，还包括算法在交易时间、交易对象、交易数量方面的自动决策。量化选股作为算法交易的重要组成部分，其重点是利用各种算法选择股票组合，以实现基准回报率。

量化选股是一个热门的学术研究领域。Fama 和 French (1993)、Lakonishok (1994) 和 Song (1994) 建立了股票超额收益的线性模型，并提出超额收益可以用当前股票价格、股权账面价值和每股收益很好地解释。与经典的线性多因子模型相比，机器学习模型更注重模型的预测能力。它可以捕捉到更详细的市场信号并通过构建预测目标与因子之间的非线性关系，获得更稳定的超额收益。Jigar Patel 等人 (2015) 研究并比较了人工神经网络 (ANN)、支持向量机 (SVM)、随机森林 (RF) 和朴素贝叶斯四种预测模型的性能。他们的研究表明，随机森林模型的整体性能优于其他三种预测模型。Liu 等人 (2017) 提出了卷积神经网络和长短期记忆 (CNN-LSTM) 模型来分析量化选股策略。在他们的研究中，CNN-LSTM 神经网络模型可以成功应用于量化策略的制定，并获得比基本动量策略和基准指数更好的回报。Li 和 Zhang (2018) 使用 XGBoost 模型建立动态加权多因子选股策略。他们使用 XGBoost 机器学习方法来预测各种因子的信息系数 (IC)。实证结果表明，XGBoost 模型在预测 IC 方面是有效的，基于 XGBoost 模型的动态权重可以提高多因子选股策略的表现。Yang 和 Chen (2019) 结合股票预测和选股，形成了一种新的混合选股方法。他们以中国 A 股市场的研究样本为基础，表明新的混合方法在市场回报方面优于传统方法。Chen 和 Ge (2019) 研究了基于 LSTM 网络的股价走势预测，并将注意力 LSTM (AttLSTM) 模型与 LSTM 模型进行了比较。他们的结果验证了注意力机制在基于 LSTM 的预测方法中的有效性。

尽管在量化模型和过程方面已经做了很多工作，但仍有一些地方可以改进。首先，在预测目标的设定上，以往的研究往往以股票收益率或价格是上涨还是下跌作为预测目标，但收益率往往包含一些噪声，而两种分类（上涨还是下跌）的设定并没有捕捉到很多现有信息。其次，在因子选择方面，以往的研究往往是静态地选择因子，但因子通常在一段时间内是有效的，之后可能不再有效。因此，整个策略设计需要动态地选择因子，例如剔除失效的因子，引入有效的因子。


在本文中，作者提出了一种可持续的量化选股策略，使用 RF 动态调整因子来预测每个时期训练集的重要性。这些因子按降序排列。所选因子的累积重要性必须达到 80%，以确保每个时期所选的因子都是最重要的因子。然后，作者使用 XGBoost 或 RF 模型将每只股票分入 5 个固定收益率区间。对于每个收益率区间，作者按概率降序对股票进行排序，将前 20 只最有可能的股票放入股票池并买入。作者称其为分类预测概率（CPP）策略。2013 年 11 月至 2019 年 12 月的回测结果表明，基于 XGBoost 或 RF CPP 方法的选股策略可以显著跑赢中证 300（沪深 300）指数。此外，作者发现 XGBoost CPP 在收益方面比 RF CPP 方法表现更好。最后，所提出的策略是一种可持续的投资策略，因为它能在长期内在熊市、牛市和波动大的市场上运作良好。

## 2. CPP 量化选股策略设计的基本思路

CPP 量化选股策略设计的一般步骤如下（另见图 1）。

第一步，将中国 A 股市场的所有股票（不包括特殊处理的“ST”股票和上市时间少于 60 天的新股）作为股票池，并按月收益率对股票进行分类。特别地，作者将每只股票按月收益率分入 5 个区间（见图 2）。作者考虑了九大类因子：质量因子、基本面因子、情绪因子、成长因子、风险因子、股票因子、动量因子、技术因子和风格因子。然后，作者从 9 个类别中选取了 45 个因子作为初始因子池。本文中的因子来自 JoinQuant 的因子池。图 3 显示了本文模型因子池中的 45 个因子。这些因子通过随机森林（RF）模型被动态地筛选到模型中。

图1：因子动态调整与分类概率预测（CPP）量化选股策略流程图



资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020 年 5 月

**图2：范围标准（月回报率）**

Figure 1. Flow diagram of factor dynamic adjustment and classification probability of prediction (CPP) quantitative stock selection strategy.

**Table 1. Range criteria (monthly rate of return).**

|          | Range 1   | Range 2 | Range 3 | Range 4 | Range 5      |
|----------|-----------|---------|---------|---------|--------------|
| Criteria | above 10% | 5–10%   | 0–5%    | –10–0%  | –10% or less |

资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020 年 5 月

**图3：因子列表**

| No. | Classification     | Factors                                 | No. | Classification   | Factors                         |
|-----|--------------------|-----------------------------------------|-----|------------------|---------------------------------|
| 1   | Quality factor     | net_profit_to_total_operate_revenue_ttm | 24  | Risk factor      | Skewness20                      |
| 2   | Quality factor     | DEGM                                    | 25  | Risk factor      | sharpe_ratio_60                 |
| 3   | Quality factor     | roe_ttm                                 | 26  | Stock factor     | net_asset_per_share             |
| 4   | Quality factor     | GMI                                     | 27  | Stock factor     | net_operate_cash_flow_per_share |
| 5   | Quality factor     | ACCA                                    | 28  | Stock factor     | eps_ttm                         |
| 6   | Fundamental factor | financial_liability                     | 29  | Stock factor     | retained_earnings_per_share     |
| 7   | Fundamental factor | cash_flow_to_price_ratio                | 30  | Stock factor     | cashflow_per_share_ttm          |
| 8   | Fundamental factor | market_cap                              | 31  | Momentum factor  | ROC20                           |
| 9   | Fundamental factor | net_profit_ttm                          | 32  | Momentum factor  | Volume1M                        |
| 10  | Fundamental factor | EBIT                                    | 33  | Momentum factor  | TRIX10                          |
| 11  | Emotional factor   | VOL20                                   | 34  | Momentum factor  | Price1M                         |
| 12  | Emotional factor   | DAVOL20                                 | 35  | Momentum factor  | PLRC12                          |
| 13  | Emotional factor   | VOSC                                    | 36  | Technical factor | MAC20                           |
| 14  | Emotional factor   | VMACD                                   | 37  | Technical factor | boll_down                       |
| 15  | Emotional factor   | ATR14                                   | 38  | Technical factor | boll_up                         |
| 16  | Growth factor      | PEG                                     | 39  | Technical factor | MF14                            |
| 17  | Growth factor      | net_profit_growth_rate                  | 40  | Style factors    | size                            |
| 18  | Growth factor      | operating_revenue_growth_rate           | 41  | Style factors    | beta                            |
| 19  | Growth factor      | net_asset_growth_rate                   | 42  | Style factors    | momentum                        |
| 20  | Growth factor      | net_operate_cashflow_growth_rate        | 43  | Style factors    | book_to_price_ratio             |
| 21  | Risk factor        | Variance20                              | 44  | Style factors    | liquidity                       |
| 22  | Risk factor        | sharpe_ratio_20                         | 45  | Style factors    | growth                          |
| 23  | Risk factor        | Kurtosis20                              |     |                  |                                 |

资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020 年 5 月

第二步，通过重新组合每个时期的因子和收益率区间来构建训练集和测试集。其中，第 i-3 期因子与第 i-2 期的月收益率相结合，第 i-2 期因子与第 i-1 期的月收益率相结合，第 i-1 期因子与第 i 期的月收益率相结合。将所有这些结合起来构成第 i 期的训练集。第 i 期的因子和第 i+1 期的月收益率构成了第 i 期的测试集。有关说明，请参见图 4。



图4：训练数据集和测试数据集的构建

|            | i-3 | i-2 | i-1 | i | i+1 | i+2 | ... |
|------------|-----|-----|-----|---|-----|-----|-----|
| Yield Rate |     |     |     |   |     |     |     |
| Factors    |     |     |     |   |     |     |     |


Figure 2 illustrates the construction of training and test datasets. The training set (Train) covers the period from  $i-3$  to  $i$ , and the test set (Test) covers the period from  $i+1$  to  $i+2$ . The Yield Rate and Factors are used for both training and testing.

Figure 2. Training data and test data construction.


资料来源：东兴证券研究所

第三步，作者使用 RF 模型来预测每个训练集的因子的重要性，并按重要性降序排列。作者选择了最重要的因子，以确保所选因子的累积重要性达到 80%。由于因子有各自的有效期，不同时期因子的 IC 值并非完全不变。如图 5 和图 6 所示，因子 ATR14 和 EBIT 的 IC 值在不同时期发生了变化。因此，适用于不同时期的因子也不同。为此，作者采用动态因子选择法来选择当期最重要的因子，提高选股的准确性。

图5：ATR 14 中的 IC



资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020 年 5 月

**图6：EBIT 中的 IC**


资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020 年 5 月

第四步，使用 XGBoost CPP 方法进行分类预测（上月因子预测月收益率区间），根据第三步动态选择的因子，将每只股票分入 5 个收益率区间。分组收益率区间内的股票按概率降序排列，将概率最高的前 20 只股票纳入买入股票池。每月最后一个交易日调整仓位。调整仓位时，卖出买入股票池之外的股票，买入买入股票池中的新股票。然后，作者进入对下一个时期训练集的研究。

动态因子调整的 CPP 量化选股策略具有一些明显的优势。量化投资的核心是模型，模型的核心是因子。在市场容量巨大的中性 Alpha 策略中尤其如此。因此，如何找到一个稳定有效的因子成为制定成熟的盈利量化策略的第一步。随机森林（RF）模型是用于分类、回归和其他任务的集成学习方法。RF 模型不仅可以有效解决决策树模型中的过拟合问题，还可以给出每个输入变量的重要性（importance）。1995 年，Ho 提出了 RF 算法，一些学者扩展了该算法并进行了后续研究（例如，参见 Breiman、Lin 和 Jeon）。在本文中，作者使用 RF 模型来预测训练集中因子的重要性，并按降序排列因子的重要性。然后，作者使得所选因子的累积重要性达到 80%，确保每个时期的因子都是最优选择。通过这样做，作者增强了因子的影响。

据作者所知，大多数基于机器学习的量化选股策略都是使用回归方法来准确预测股票的未来收益，然后购买有较高预测收益率的股票。拟合选股方法似乎比多类概率预测选股方法更准确，但其容错性相对较低。一旦出现预测错误，将对整体收益产生较大影响。而且，收益中的噪声通常很大，回归错误的概率通常很高。因此，很容易造成较大的最大回撤。本文提出的多类概率预测选股策略是不选择预测收益率最高的股票，而是要在确定预期收益率的区间之后，选择该区间内收益率最高的股票。这种方式虽然牺牲了一些好处，但是准确率和容错率都得到了提高，而且随着准确率的提高，一些牺牲的好处也将得到弥补。

### 3. CPP 量化选股策略回测分析

在本章节中，作者对 2013 年 11 月至 2019 年 12 月的市场数据进行了 74 次回测分析，数据源来自 JoinQuant 量化平台。

选股的目标是获得高回报，作者没有将投资策略局限于任何特定的投资风格。因此，以整体市场回报率为基准是很自然的。在本文中，作者选择沪深 300 指数作为基准。

### 3.1 动态因子调整分析

在这 45 个因子中，风格类别最有可能被选中（见图 7）。流动性因子（liquidity）被选中的概率高达 98.65%。市值因子（size）以 94.59% 的概率被选中，贝塔因子（beta）以 68.92% 的概率被选中。前十大因子中有 3 个成长因子，其中净资产增长率（net\_asset\_growth\_rate）被选中的概率为 95.95%，净利润增长率（net\_profit\_growth\_rate）被选中的概率为 79.73%，市盈率（P/E）相对于盈利增长率（PEG）被选中的概率为 71.62%。前十名中有两个风险因子。特别地，20 天年化收益率的方差（Variance20）被选中的概率为 95.95%，20 天夏普比率（sharpe\_ratio\_20）被选中的概率为 74.32%。最后，在前十个因子中，有一个情绪因子和一个动量因子，选择交易量冲击（VOSC）的概率 93.24%，选择单月价格（Price1M）的概率为 90.54%。

图7：被选中概率最高的 10 个因子

| Rank | Factor                 | Selected Times | Total Times | Selected Probability |
|------|------------------------|----------------|-------------|----------------------|
| 1    | liquidity              | 73             | 74          | 98.65%               |
| 2    | Variance20             | 71             | 74          | 95.95%               |
| 3    | net_asset_growth_rate  | 71             | 74          | 95.95%               |
| 4    | size                   | 70             | 74          | 94.59%               |
| 5    | VOSC                   | 69             | 74          | 93.24%               |
| 6    | Price1M                | 67             | 74          | 90.54%               |
| 7    | net_profit_growth_rate | 59             | 74          | 79.73%               |
| 8    | sharpe_ratio_20        | 55             | 74          | 74.32%               |
| 9    | PEG                    | 53             | 74          | 71.62%               |
| 10   | beta                   | 51             | 74          | 68.92%               |

资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020 年 5 月

这里考虑的市值因子不同于传统的市值因子。它是指公司总市值的自然对数。流动性因子的公式为：

$$\text{Liquidity Factor} = 0.35 \times \text{STOM} + 0.35 \times \text{STOQ} + 0.3 \times \text{STOA}, \quad (1)$$

其中，STOM 是一个月的股票周转率，由过去 21 天内股票周转率总和的对数表示；STOQ 是过去三个月的平均周转率，由过去三个月的平均单月周转率的对数表示；STOA 是过去十二个月的平均周转率，由过去十二个月的平均单月周转率的对数表示。净资产增长率的公式为：

$$\text{Net asset growth rate} = \frac{\text{shareholder equity for the current quarter}}{\text{shareholder equity before the third quarter}} - 1. \quad (2)$$



## 3.2 回测收益

在本节中，作者将比较和分析不同回溯测试下的收益。参数设置见图 8。

图8：策略回测的参数设置

| Item                     | Detail                                                                                                                                          |
|--------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------|
| Object of transaction    | all stocks after screening (excluding ST shares, new shares, secondary shares, and stocks suspended within 20 days)                             |
| Returns of the benchmark | Index gains for the CSI 300                                                                                                                     |
| Time of back-testing     | 1 November 2013 (Fri.) to 31 December 2019 (Tue.)                                                                                               |
| Days of back-testing     | 1507 trading days                                                                                                                               |
| Data sources             | JoinQuant quantitative investment platform                                                                                                      |
| Initial funding          | 10 million                                                                                                                                      |
| Overnight or not         | yes                                                                                                                                             |
| Stop's way               | RSRS stop loss                                                                                                                                  |
| Number of the position   | 20 stocks                                                                                                                                       |
| Adjustable frequency     | one month                                                                                                                                       |
| Slippage                 | 0.2%                                                                                                                                            |
| Commission charge        | 0.03% commission when buying, 0.03% commission plus 0.1% stamp duty when selling, commission for each transaction a minimum deduction of 5 yuan |
| Software language        | Python                                                                                                                                          |

资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020 年 5 月

### 3.2.1 XGBoost 分类预测和 XGBoost 回归预测

2015 年，Chen 等人提出了 XGBoost 模型，它针对快速并行树构建进行了优化。“作为许多机器学习比赛获胜团队的首选算法，它最近受到了广泛的欢迎和关注”。由于 XGBoost 模型的良好性能，作者选择 XGBoost 模型来预测股票的收益率。

本文的核心模型是 XGBoost 多类预测模型，模型参数如图 9 所示。2013 年 11 月至 2019 年 12 月，作者使用 XGBoost 多类预测模型进行回测，共进行了 74 次分类预测。预测的综合评价见图 10。其中，准确度、灵敏度 C1 和精确度 C1 的定义与二分类相似。具体公式由方程 (3) - (5) 给出，其中  $x_{ij}$  在图 11 中给出。

$$accuracy = \frac{\sum_{i=1}^5 x_{ii}}{\sum_{i=1}^5 \sum_{j=1}^5 x_{ij}} \quad (3)$$

$$sensitivity\ C1 = \frac{x_{11}}{\sum_{i=1}^5 x_{i1}} \quad (4)$$

$$precision\ C1 = \frac{x_{11}}{\sum_{j=1}^5 x_{1j}} \quad (5)$$

图9: XGBoost 分类的主要参数

Table 5. Main parameters of XGBoost classification.

| Parameter        | Value |
|------------------|-------|
| max_depth        | 10    |
| learning_rate    | 0.1   |
| n_estimators     | 500   |
| min_child_weight | 5     |
| colsample_bytree | 0.7   |
| reg_lambda       | 0.4   |
| scale_pos_weight | 0.8   |
| subsample        | 0.8   |

资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020 年 5 月

图10: XGBoost 多类预测评估

Table 6. XGBoost Multi-class prediction evaluation.

| Item           | Mean  | Stdev | Max   | Min   |
|----------------|-------|-------|-------|-------|
| accuracy       | 51.7% | 7.9%  | 67.0% | 37.5% |
| sensitivity C1 | 75.4% | 7.8%  | 87.7% | 59.3% |
| precision C1   | 62.1% | 10.3% | 78.2% | 41.2% |

资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020 年 5 月

图11: 分类模型的混淆矩阵

Table 7. Confusion matrix of 5 classification model.

|                     |           | True Condition  |                 |                 |                 |                 |
|---------------------|-----------|-----------------|-----------------|-----------------|-----------------|-----------------|
|                     |           | Category1       | Category2       | Category3       | Category4       | Category5       |
| Predicted Condition | Category1 | x <sub>11</sub> | x <sub>12</sub> | x <sub>13</sub> | x <sub>14</sub> | x <sub>15</sub> |
|                     | Category2 | x <sub>21</sub> | x <sub>22</sub> | x <sub>23</sub> | x <sub>24</sub> | x <sub>25</sub> |
|                     | Category3 | x <sub>31</sub> | x <sub>32</sub> | x <sub>33</sub> | x <sub>34</sub> | x <sub>35</sub> |
|                     | Category4 | x <sub>41</sub> | x <sub>42</sub> | x <sub>43</sub> | x <sub>44</sub> | x <sub>45</sub> |
|                     | Category5 | x <sub>51</sub> | x <sub>52</sub> | x <sub>53</sub> | x <sub>54</sub> | x <sub>55</sub> |

资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020 年 5 月

选股标准是持有预测属于第一类且概率排在前 20 名的股票。因此，灵敏度 C1 和精确度 C1 对于评估预测能力更为重要。其中，灵敏度 C1 表示第一类股票中能够正确预测的股票比例，精确度 C1 表示真正属于第一类的股票比例。在 74 次预测中，灵敏度 C1 的平均值为 75.4%，标准差为 7.8%；精确度 C1 的平均值为 62.1%，标准偏差为 10.3%。74 次预测的平均准确率为 51.7%，标准差为 7.9%。虽然整体准确度不是很高，但该指标对回测回报的整体表现影响不大。作者认为精确度 C1 指标是三个指标中最重要。该指标值越高，表明该模型能够以高概率筛选出高收益股票。

接下来，对 XGBoost 分类预测和 XGBoost 回归预测进行比较。在 XGBoost 分类预测中，作者使用 XGBoost 模型来预测回测阶段各期的收益率区间；即进行多类预测。在 XGBoost 回归预测（参数见图 12）中，作者预测了回测阶段各期的收益率值，即收益率回归，并持有预测收益最高的 20 只股票。两种方法都使用 RSRS 指数（阻力支撑的相对强度）止损模块来止损。

**图12：XGBoost 回归的主要参数**


**Table 8. Main parameters of XGBoost regression.**

| Parameter        | Value |
|------------------|-------|
| max_depth        | 10    |
| learning_rate    | 0.3   |
| gamma            | 0.1   |
| min_child_weight | 3     |
| colsample_bytree | 0.7   |
| lambda           | 3     |
| subsample        | 0.5   |

资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020 年 5 月

如图 13 和图 14 所示，基于 XGBoost 多类预测的量化选股策略在 2013 年 11 月至 2019 年 12 月的回测区间内表现远优于沪深 300 指数。在年化收益率、夏普比率、最大回撤和卡尔马比率方面，XGBoost 多类预测方法的表现明显优于同期基于 XGBoost 回归和 XGBoost 二分类的量化选股策略。因此，作者认为 XGBoost 多类概率预测的量化选股策略具有更好的回测性能。

图13：回归和分类选股的回测收益图



资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020年5月

图14：XGBoost 回归和分类的选股策略回测指标

| +                       | Model and Stop-Loss       |                               |                          |
|-------------------------|---------------------------|-------------------------------|--------------------------|
|                         | XGBoost-Regression + RSRS | XGBoost-Classification + RSRS | XGBoost-Dichotomy + RSRS |
| Annual yield rate       | 0.26                      | 0.57                          | 0.36                     |
| Accumulated yield rate  | 3.65                      | 7.76                          | 4.91                     |
| Annualized Volatility   | 0.25                      | 0.23                          | 0.24                     |
| Sharpe Ratio            | 0.62                      | 2.21                          | 1.42                     |
| Calmar Ratio            | 0.90                      | 2.71                          | 1.33                     |
| Stability_of_timeseries | 0.71                      | 0.84                          | 0.57                     |
| Maximum Drawdown        | 0.29                      | 0.21                          | 0.27                     |
| Sortino Ratio           | 0.90                      | 3.03                          | 1.81                     |
| Information Ratio       | 0.96                      | 1.92                          | 1.05                     |
| Alpha                   | 0.16                      | 0.54                          | 0.31                     |
| Beta                    | 0.70                      | 0.36                          | 0.58                     |

资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020年5月

### 3.2.2 不同模型的回测收益

接下来，为了比较不同模型和止损模块的组合回测效果，作者比较了带有RSRS指数（阻力支撑的相对强度）止损模块和MACD（异同移动平均线）止损模块的XGBoost和随机森林决策模型的不同组合的性能（RF模型的参数如图15所示）。回测结果如图16和图17所示。


图15：随机森林的主要参数

Table 10. Main parameters of random forest.

| Parameter         | Values |
|-------------------|--------|
| max_depth         | 5      |
| min_samples_leaf  | 2      |
| n_estimators      | 200    |
| min_samples_split | 2      |
| criterion         | gini   |

资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020年5月

图16：收益率回测



资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020年5月



图17：不同模型的回测指标

| Index                   | Model and Stop-Loss |           |           |                |
|-------------------------|---------------------|-----------|-----------|----------------|
|                         | XGBoost + RSRS      | RF + RSRS | RF + MACD | XGBoost + MACD |
| Annual yield rate       | 0.57                | 0.41      | 0.37      | 0.28           |
| Accumulated yield rate  | 7.76                | 5.63      | 4.96      | 3.84           |
| Annualized Volatility   | 0.23                | 0.24      | 0.33      | 0.35           |
| Sharpe Ratio            | 2.21                | 1.54      | 1.02      | 0.65           |
| Calmar Ratio            | 2.71                | 1.86      | 0.71      | 0.51           |
| Stability_of_timeseries | 0.84                | 0.82      | 0.72      | 0.70           |
| Maximum Drawdown        | 0.21                | 0.22      | 0.51      | 0.55           |
| Sortino Ratio           | 3.03                | 2.57      | 1.01      | 0.92           |
| Information Ratio       | 1.92                | 1.26      | 1.18      | 0.98           |
| Alpha                   | 0.54                | 0.41      | 0.24      | 0.17           |
| Beta                    | 0.36                | 0.48      | 0.83      | 0.79           |

资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020年5月


如图16和图17所示，XGBoost模型与RSRS指数止损模块组合的回测收益高于随机森林模型。这表明，在RSRS指数止损模块给出择时的情形下，XGBoost多类概率预测比随机森林模型更准确。然而，在MACD止损模块给出择时的情形下，XGBoost模型的收益率低于随机森林模型。在机器学习模型相同的情形下，RSRS指数止损模块的性能明显强于MACD止损模块。因此，作者决定选择XGBoost模型和RSRS指数止损模块的组合作为CPP量化选股策略的主要模型。

对于本文提出的CPP量化选股策略，年化收益率达到57%，夏普比率为2.21，最大回撤为21%，卡尔马比率为2.71，胜率为63.5%。该策略的回报在2014年1月10日达到最低值-3.85%，并在2019年10月14日达到最高点，当时该策略的累计收益率为788.52%。自2013年12月19日以来，CPP量化选股策略的累计收益率一直优于同期沪深300指数的累计收益率。

### 3.2.3 CPP 量化选股回测收益

在确定主要模型是XGBoost多类预测和RSRS指数止损模块的组合后，本文在2013年11月1日至2019年12月31日的回测区间进行回测，结果如图18和图19所示。

图18：CPP 选股回测收益率图



资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020年5月

**图19：CPP 量化选股策略在不同时期的超额收益**
**Table 12. Excess returns of CPP quantitative stock selection strategy at different time periods.**

| Different Period                | State of Market | Excess Rate of Return |
|---------------------------------|-----------------|-----------------------|
| 1 November 2013–31 August 2014  | volatile market | 30.29%                |
| 1 September 2014–31 May 2015    | bull market     | 94.40%                |
| 1 June 2015–31 December 2015    | bear market     | 80.58%                |
| 1 January 2016–31 December 2019 | volatile market | 86.63%                |

资料来源：《A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment》，2020 年 5 月

在市场的不同时期，适用的策略会有所不同，一个策略很难在所有时期都表现良好。CPP 量化选股策略在不同时期拥有不同水平的超额收益。如图 18 和图 19 所示，2013 年 11 月 1 日至 2014 年 8 月 31 日是牛市前的水平价格波动期（波动的市场），CPP 量化选股策略在这 10 个月期间实现了 30.29% 的超额收益率。2014 年 9 月 1 日至 2015 年 5 月 31 日，CPP 量化选股策略实现了 94.4% 的超额收益率。2015 年 6 月 1 日至 2015 年 12 月 31 日，在股市暴跌后，CPP 量化选股策略实现了 80.58% 的超额收益率。2016 年 1 月 1 日至 2019 年 12 月 31 日，另一个水平价格波动期（波动的市场），CPP 量化选股策略实现了 86.63% 的超额收益率。正如作者所看到的，本文提出的 CPP 量化选股策略是一种可持续的投资策略，在包括牛市、熊市和波动市场状态的广泛时期内运作良好。

## 4. 总结

在本文中，作者使用随机森林模型为训练集在每个时期动态选择因子，以确保每个时期可以选择的因子是当期的最优因子。同时，对股票收益进行分类概率预测（CPP）。该方法可以有效兼顾收益预测的准确性，避免噪声对收益率的干扰。历史回测表明，基于动态因子调整的 CPP 量化选股策略表现优于传统的机器学习选股方法，在大部分回测期内均能跑赢同期的沪深 300 指数。这是一种可持续的投资策略，无论是在牛市、熊市还是波动的市场状态下，基于动态因子调整的 CPP 量化选股策略都可以获得更高的超额收益。

需要说明的是，本文所有结果均来自历史数据回测，结果可能与实际投资结果存在差异。由于作者使用历史数据进行回测时未考虑市场流动性的影响，以及该策略对其他市场参与者决策的影响等。因此，不能保证该策略适用于真实的市场投资。对于因实施该策略而造成的任何损失，作者概不负责。

## 5. 我们的点评

在本文中，作者提出了一种可持续的量化选股策略，它能在长期内在熊市、牛市和波动市场上运作良好。作者使用随机森林模型为训练集在每个时期动态选择因子，以确保每个时期可以选择的因子是当期的最优因子，同时，对股票收益进行分类概率预测（CPP）。该方法可以有效兼顾收益预测的准确性，避免噪声对收益率的干扰。

作者指出，拟合选股方法容错性相对较低，并且收益中的噪声通常很大，回归错误的概率通常很高，容易造成较大的最大回撤。多类概率预测选股策略是不选择预测收益率最高的股票，而是要在确定预期收益率的区间之后，选择该区间内收益率最高的股票，这种方式使得选股准确率和容错率都得到了提高。历史回测表明，基于动态因子调整的 CPP 量化选股策略表现优于传统的机器学习选股方法，在大部分回测期内均能跑赢同期的沪深 300 指数。

作者对量化选股策略的研究方法值得我们学习和借鉴。作者运用机器学习方法在因子动态调整方面的创新值得我们关注。

本篇文章使用历史数据进行回测时未考虑市场流动性的影响，以及该策略对其他市场参与者决策的影响等，当市场环境发生变化的时候，实施该策略是否能获得良好的效果值得进一步研究。

## 6. 参考文献

Yi Fu and Shuai Cao and Tao Pang. A Sustainable Quantitative Stock Selection Strategy Based on Dynamic Factor Adjustment[J]. Sustainability, 2020, 12(10): 3978.

## 7. 风险提示

本报告内容来源于相关文献，不构成投资建议。文中的结果基于原作者对历史数据的回测，当市场环境发生变化的时候，存在模型失效的风险。

## 相关报告汇总

| 报告类型     | 标题                                      | 日期         |
|----------|-----------------------------------------|------------|
| 金融工程普通报告 | 基金市场跟踪：首批三只增强策略 ETF 上市，消费主题基金表现出色       | 2021-12-13 |
| 金融工程普通报告 | 量化市场观察：量价择时胜率略有下降，反转因子表现突出              | 2021-12-12 |
| 金融工程深度报告 | “基”不可失系列之十四：东吴基金周健：用量化思维管理绝对收益产品        | 2021-12-10 |
| 金融工程深度报告 | 焦点洞察系列之二：通过数据探究北上资金因子失效的原因              | 2021-12-10 |
| 金融工程深度报告 | 金融工程 2022 年度投资策略：量化破局新思路（PPT）           | 2021-12-07 |
| 金融工程普通报告 | 基金市场跟踪：军工主题基金表现出色，首批 QDII -FOF-LOF 产品申报 | 2021-12-07 |
| 金融工程深度报告 | 金融工程 2022 年度投资策略：量化投资破局新思路              | 2021-12-06 |
| 金融工程普通报告 | 量化市场观察：行业轮动策略获正超额，价值因子持续反弹              | 2021-12-05 |
| 金融工程普通报告 | 基金市场跟踪：有色金属主题基金表现出色，MSCI 中国 A50ETF 持续活跃 | 2021-12-01 |
| 金融工程深度报告 | “基”不可失系列之十三：景顺长城中证 500 增强策略 ETF 投资价值分析  | 2021-11-30 |

资料来源：东兴证券研究所

## 分析师简介

### 高智威

东兴证券金融工程首席分析师，北京大学物理学博士，6 年左右金融工程研究经验，曾就职于兴业证券、招商证券，2021 年 2 月加入东兴证券研究所。长期从事金融工程领域研究，擅长量化选股、资产配置、基金研究以及衍生品投资策略等。2015 年、2016 年、2017 年和 2020 年作为团队核心成员上榜新财富最佳分析师。

## 分析师承诺

负责本研究报告全部或部分内容的每一位证券分析师，在此申明，本报告的观点、逻辑和论据均为分析师本人研究成果，引用的相关信息和文字均已注明出处。本报告依据公开的信息来源，力求清晰、准确地反映分析师本人的研究观点。本人薪酬的任何部分过去不曾与、现在不与、未来也将不会与本报告中的具体推荐或观点直接或间接相关。

## 风险提示

本证券研究报告所载的信息、观点、结论等内容仅供投资者决策参考。在任何情况下，本公司证券研究报告均不构成对任何机构和个人的投资建议，市场有风险，投资者在决定投资前，务必要审慎。投资者应自主作出投资决策，自行承担投资风险。

## 免责声明

本研究报告由东兴证券股份有限公司研究所撰写，东兴证券股份有限公司是具有合法证券投资咨询业务资格的机构。本研究报告中所引用信息均来源于公开资料，我公司对这些信息的准确性和完整性不作任何保证，也不保证所包含的信息和建议不会发生任何变更。我们已力求报告内容的客观、公正，但文中的观点、结论和建议仅供参考，报告中的信息或意见并不构成所述证券的买卖出价或征价，投资者据此做出的任何投资决策与本公司和作者无关。

我公司及其所属关联机构可能会持有报告中提到的公司所发行的证券头寸并进行交易，也可能为这些公司提供或者争取提供投资银行、财务顾问或者金融产品等相关服务。本报告版权仅为我公司所有，未经书面许可，任何机构和个人不得以任何形式翻版、复制和发布。如引用、刊发，需注明出处为东兴证券研究所，且不得对本报告进行有悖原意的引用、删节和修改。

本研究报告仅供东兴证券股份有限公司客户和经本公司授权刊载机构的客户使用，未经授权私自刊载研究报告的机构以及其阅读和使用者应慎重使用报告、防止被误导，本公司不承担由于非授权机构私自刊发和非授权客户使用该报告所产生的相关风险和责任。

## 行业评级体系

公司投资评级（以沪深 300/恒生指数为基准指数）：

以报告日后的 6 个月内，公司股价相对于同期市场基准指数的表现为标准定义：

强烈推荐：相对强于市场基准指数收益率 15% 以上；

推荐：相对强于市场基准指数收益率 5%~15% 之间；

中性：相对于市场基准指数收益率介于-5%~+5% 之间；

回避：相对弱于市场基准指数收益率 5% 以上。

行业投资评级（以沪深 300/恒生指数为基准指数）：

以报告日后的 6 个月内，行业指数相对于同期市场基准指数的表现为标准定义：

看好：相对强于市场基准指数收益率 5% 以上；

中性：相对于市场基准指数收益率介于-5%~+5% 之间；

看淡：相对弱于市场基准指数收益率 5% 以上。

## 东兴证券研究所

北京

西城区金融大街 5 号新盛大厦 B 座 16 层

邮编：100033

电话：010-66554070

传真：010-66554008

上海

虹口区杨树浦路 248 号瑞丰国际大厦 5 层

邮编：200082

电话：021-25102800

传真：021-25102881

深圳

福田区益田路 6009 号新世界中心 46F

邮编：518038

电话：0755-83239601

传真：0755-23824526