

证券研究报告—深度报告

金融工程

数量化投资

金融工程专题研究

2022 年 01 月 05 日

专题报告

相关研究报告:

《基金研究：公募基金持仓还原及其实践应用》——2021-12-16

《学术文献研究系列第 28 期：如何更合理的刻画基金业绩基准》——2021-12-21

《学术文献研究系列第 29 期：基于 A 股市场概念动量的股票投资策略》——2021-12-28

《基金评价报告：复苏在即，布局优质赛道——华夏中证细分食品饮料产业主题 ETF 投资价值分析》——2021-12-22

《金融工程专题研究：当好 Beta 遇上高 Alpha——长城中证 500 指数增强基金投资价值分析》——2021-12-21

证券分析师：杨怡玲

电话：021-60875176

E-MAIL: yangyiling@guosen.com.cn

证券投资咨询执业资格证书编码：S0980521020001

证券分析师：张欣慰

电话：021-60933159

E-MAIL: zhangxinwei1@guosen.com.cn

证券投资咨询执业资格证书编码：S0980520060001

如何理解动量与反转？

● 股票的近期回报可以预测未来风格因子的贝塔

我们发现动量和长期反转能够可以捕捉未来风险因子的贝塔，动量是未来一年市场资产定价因素（例如 Fama-French 五因子模型）的强大预测指标。中长期历史回报与未来贝塔值之间的联系表明，与动量和长期反转相关的溢价可能与条件风险敞口有关，动量捕捉到了随时间变化的风险补偿。

● IPCA 条件因子定价模型能够捕捉动量溢价

动量特征（过去 12 个月的回报）包含了股票潜在定价因子风险的时变暴露，因此直接对过去 12 个月的回报进行排序对未来回报并没有显著预测能力。因此控制这种随时间变化的风险敞口后才能够捕捉到动量溢价。作者提出基于 IPCA 捕捉潜在定价因子，并以时变的因子载荷对股票进行定价。作者对比了传统动量、IPCA 潜在因子带时变载荷后动量、以及残差动量的效果，发现传统动量原始信号并没有收益预测能力，转为截面排序后有一定收益预测效果，而 IPCA 模型下预测模型非常显著，多空年化回报能够达到 33.6%，而残差动量几乎没有预测能力。并且，在控制了 IPCA 模型的条件预期收益后，传统动量不再有预测能力。

风险提示：本报告基于相关文献，不构成投资建议。

独立性声明：

作者保证报告所采用的数据均来自合规渠道，分析逻辑基于本人的职业理解，通过合理判断并得出结论，力求客观、公正，结论不受任何第三方的授意、影响，特此声明。

内容目录

文献来源	4
引言	4
历史回报预测贝塔	6
数据	6
市场贝塔预测结果	7
多因子贝塔预测结果	8
模型	9
IPCA	10
工具化 Fama-French 模型	10
动量模型	10
条件模型是否能解释动量和反转?	11
IPCA 模型	11
IPCA 样本外	13
解释	14
结论	15
国信证券投资评级	16
分析师承诺	16
风险提示	16
证券投资咨询业务的说明	16

图表目录

图 1: 基于特征预测已实现市场贝塔.....	8
图 2: 基于特征预测多因子贝塔.....	9
图 3: 动量和 IPCA 模型	12
图 4: 动量和 IPCA 模型 (样本外)	14

文献来源

文献来源：Kelly, Bryan T., Tobias J. Moskowitz, and Seth Pruitt. "Understanding momentum and reversal." *Journal of Financial Economics* 140.3 (2021): 726-743..

文献亮点：作者提出了条件因子定价模型，其基于 IPCA 构建潜在定价因子，并动态估计其时变因子载荷，基于该模型可以显著解释相当大一部分动量和长期反转的回报，并可用于产生非常显著回报的收益预测。

引言

自 Jegadeesh 和 Titman (1993) 提出动量异象以来，动量异象一直是金融经济学中最受广泛研究的主题之一。它构成了整个资产管理行业使用策略的基础，也是大量共同基金和交易产品的基础。尽管它对金融业产生了广泛的影响，但动量仍然是一种较为神秘的异象。虽然从行为和理性上都已经提出了各种理论来解释动量，但没有一个被广泛接受。经验资产定价模型如 Fama 和 French (2015) 五因子模型无法解释动量异象，目前的研究也尚未找到风险暴露能够解释与近期股价相关的横截面回报溢价。因此，动量通常是市场是否有效的辩论核心。

本文的目的是通过条件经验资产定价模型的视角重新评估动量异象。有多少动量溢价可以用条件风险敞口来解释？我们的核心发现是，股票的条件风险溢价的变化通过不同的因子敞口从而与动量密切相关，这些因子敞口在动量风险溢价的变化中占主导地位。在我们的数据中，经典的动量策略（按过去 t-2 至 t-12 个月原始收益排序股票的前五分之一对冲后五分之一）产生了 8.3% 的显著年化收益。然而，当从我们的条件模型中剔除其他定价因素的敞口时，残差动量策略（对与条件因子无关的收益的残差成分进行排序）每年产生 4.4% 的边际显著收益。相反，根据来自条件模型的收益的预测成分对股票进行排序会产生三到四倍的动量收益。由此可见，我们条件模型中的因子很好地解释了大部分无条件动量效应。相对于静态 Fama 和 French(2015) 五因子模型，动量策略的年化 alpha 为 9.2% (t-stat=3.0)，而相对于我们的动态因子，它的 alpha 为负且不显著(alpha 为 -3.2%, t-stat=-1.2)。

通过仔细构建更准确地代表条件风险回报的因子，并适当指定这些因子的时变条件贝塔系数，我们发现动量异象收益对常见的风险敞口有大量暴露。虽然我们不是第一个尝试用条件风险模型作为对动量(Conrad 和 Kaul(1998); Jegadeesh 和 Titman(2002); Grundy 和 Martin(2001); Chordia 和 Shivakumar(2002))或长期反转(Kothari 和 Shanken(1992))，我们提取条件风险溢价的方法在解释这些过去的回报现象方面更加成功。我们探索并解释了我们方法如何以及为什么会取得如此成功。

我们首先建立了动量可解释的必要条件，即动量可以捕捉因子风险敞口的因子定价模型。我们可以看到动量是未来一年市场回报本身以及其他流行资产定价因素（例如 Fama 和 French(2015) 五因子模型）的强大预测指标。动量特征对未来贝塔的预测能力在统计上和经济上都很强。例如，市场贝塔系数的估计预测系数表明，当一只股票从动量特征的第 10 个百分点移动到第 90 个百分点时，其市场贝塔系数增加 0.20。这是动量捕捉条件风险敞口的初步迹象。同样，长期反转，另一个历史回报特征，对贝塔系数有类似的预测能力，但短期反转

对贝塔系数的预测能力要弱得多。中长期历史回报与未来贝塔值之间的联系表明，与动量和长期反转相关的溢价可能至少部分与条件风险敞口有关。然而，仅凭条件市场贝塔系数的增加幅度不足以解释高动量和低动量（或长期反转）股票之间的回报差异。因此，资本资产定价模型（CAPM）的有条件版本无法解释这些回报。

为了严格研究贝塔可预测性是否在数量上合理化了与价格趋势相关的平均回报模式，我们需要一个不仅仅包含市场因子的资产定价模型。为了研究这个想法，我们分析了一个通用的条件因子定价模型，形式为

$$r_{i,t+1} = \beta'_{i,t} f_{t+1} + \epsilon_{i,t+1}, E_t[r_{i,t+1}] = \beta'_{i,t} \lambda_t \quad (1)$$

在此框架中，条件预期收益 $\mu_{i,t}$ 仅从对一组常见风险因子和相关因子溢价 ($\lambda_t = E_t[f_{t+1}]$) 的暴露 ($\beta_{i,t}$) 得出。一个成功的模型至少需要解释与历史回报异常相关的三个事实：1) 过去一年回报最高五分之一的股票与最低五分之一的股票的平均年回报率相差很大，约为 9%，或就每单位风险的平均回报而言，夏普比率约为每年 0.50；2) 12-2 个月的移动平均线比其他移动平均线窗口产生更好的回报预测；3) 一年后发生的略显著的长期反转模式。

考虑一下上述等式的静态版本，对所有 t 有 $\mu_{i,t} = \beta'_i \lambda$ 。那么一个充分大的 β_i 才可以与动量的大平均回报相匹配。但这种情况也意味着一个非常长的移动平均窗口可以提供对 β_i 的最佳估计，因为对于静态贝塔，较长的范围提供更多数据可以精确估计贝塔。这意味着更长的历史回报窗口是未来回报的最佳预测指标，这与众所周知的数据模式相矛盾，即动量在中间范围内表现最佳，就像大多数研究中使用传统 12 个月过去回报一样。传统的 12 个月动量倾向于在高低五分之一的股票成分中快速换手。股票从极端五分位中移出的概率约为每月 38%。这种移出不仅仅是噪音——更长的移动平均窗口会机械地减少换手，但它们也会降低预测能力。长期反转对贝塔行为提出了一组类似的动态要求。

这些事实的含义是，具有最高和最低条件预期回报的股票的身份随着时间的推移（迅速）变化。对于像上式中这样的因子模型来匹配数据，它需要成为一个条件模型。保持因子溢价固定，动态贝塔 ($\beta_{i,t}$) 会引起 $\mu_{i,t}$ 面板的变化。这种变化会搅动 $\mu_{i,t}$ 分布中顶部和底部的股票列表，尤其是在有多个因子时。

虽然条件因子模型为动量和其他价格趋势模式提供了潜在的概念解释，但它们难以估计。一种估计方法是使用可观察因子并估计滚动贝塔系数。然而，可观察因子可能会被错误指定——特别是如果在它们最初被构建为用作无条件因子（例如，Fama-French 因子）时被重新解释为条件因子，并且滚动贝塔可能会遭受“陈旧偏差”，因为它们只是缓慢地纳入条件信息。另一种选择是根据较高频率（例如，每日）数据估算每月已实现的贝塔系数。但仅用每月 20 次的日度样本，已实现贝塔往往是嘈杂的，并且扩展到几个月会重新引入潜在的陈旧性。另外，这些都不能解决可观察因子中的错误指定问题。

相反，我们遵循 Kelly 等人(2019)的条件因子建模方法，下文中简称为 KPS，他们使用 instrumented principal components analysis (IPCA) 的方法通过将 $\beta_{i,t}$ 参数化为可观察资产特征的函数来估计潜在因子和因子暴露。通过根据可观察的时变特征调节贝塔，该模型可以根据特征更新快速更新风险敞口。通过估计与条件风险敞口最相关的因子，IPCA 摆脱了使用容易出现错误指定的预指定因子。KPS 表明，与其他替代方案（如 Fama-French 因子与滚动贝塔系数）相比，通过 IPCA 估计的条件因子模型在描述风险和回报的横截面方面提供了显著改进。

我们从我们的条件因子模型中发现 $\mu_{i,t}^{IPCA} = \beta'_{i,t} \lambda$ 的估计值比传统的动量效应

具有经济上大且统计上显著的回报预测改进。我们运行样本外面板预测回归来比较基于模型的预期回报估计的回报预测能力与动量和反转特征的预测能力。例如，股票级面板预测 R^2 基于动量每月 0.02%，基于长期反转为 0.01%，基于 $\mu_{i,t}^{IPCA}$ 为 0.32%。此外， $\mu_{i,t}^{IPCA}$ 和动量的双变量回归的联合 R^2 也是 0.32%。换句话说，在考虑了条件因素风险补偿后，动量对股票预期收益的贡献可以忽略不计。股票动量和长期反转策略的有效性在很大程度上可以通过条件因子敞口来解释，基于条件预期收益估计的排序比简单动量排序产生更强的收益可预测性。例如，我们样本中的基线多空五分之一价差动量策略为每年 8.3%（ t 统计量为 3.30，年化夏普比率为 0.48）。但是来自条件因子回报的多空策略每年产生 33.6% 的平均回报（ t 统计量为 14.5）。因此，该模型不仅在解释预期收益的行为方面比价格趋势特征更有效，而且还捕获了解释大部分动量效应的因子敞口的补偿，并且可以产生更强和更多精确的回报可预测性。

我们的研究问题与有关动量和长期反转的文献中的四个前期研究最密切相关。首先，Conrad 和 Kaul（1998）认为股票预期收益的差异可以解释动量收益。Jegadeesh 和 Titman（2002）反对这种解释，因为它基于无条件预期并没有足够的分散度来解释动量回报。此外，如上所述，基于无条件预期的解释不会导致动量策略所涉及的股票多空排序的变化，也无法解释长期反转的结果。另一方面，基于条件期望的解释可以并且确实解释了这些模式。

其次，Grundy 和 Martin（2001）将收益分解为系统风险成分（捕获为暴露于 Fama 和 French 三因子，1993）和特定于股票的残差，并且发现动量现象完全由残差收益的动量驱动。我们发现 Grundy 和 Martin（2001）的结论很可能是由因子模型错误指定导致的，由于可观察因子的滚动窗口贝塔估计。使用具有缓慢移动的贝塔和错误因子的模型几乎可以确保残差继承了预期收益的重要变化，从而给人一种误导性的印象，即动量是异质收益的一个特征。相比之下，一旦我们考虑到潜在因素和条件贝塔动态，我们就会发现残差动量的微弱证据。我们论证并表明，正是这种经过改进的模型导致了与 Grundy 和 Martin（2001）不同的结论。

第三，Chordia 和 Shivakumar（2002）将股票收益分解为一个可通过宏观经济预测变量和不可预测的冲击进行预测的组成部分。他们得出结论，动量回报最好通过宏观经济变量预测的条件预期回报而不是残差来获得。他们推测可预测成分代表动态因素风险溢价（与 Grundy 和 Martin（2001）的结论相反）。然而，他们没有验证这个猜想。此外，预先设定的宏观因素也为错误指定提供了空间，可能无法捕捉有条件的风险敞口。我们的报告提供了动量回报和因子风险敞口之间的明确缺失联系。

历史回报预测贝塔

在本节中，我们展示了一个稳健的事实，即股票最近的历史回报可以预测其未来在总体风险因素上的贝塔系数。

数据

我们的数据集是在 KPS 中研究的数据集，由 Freyberger（2020）中的股票收益和 36 个特征组成。该样本从 1966 年至 2014 年，将注意力限制在所有 36 个特征均未缺失的股票月度观察值上，最终包括 12813 只股票和 1403544 个股票月份观察值。为了处理异常值，对每个特征进行横截面排序，然后将这些排序除以该横截面中的股票数量，然后对它们进行横截面去均值，使其保持在

[-0.5,0.5]区间内。

市场贝塔预测结果

我们首先检查与产生正异常回报的各种交易策略相关的特征，尤其是与历史回报相关的特征，是否对未来市场贝塔系数的变化具有可预测性。大量文献表明，这些特征产生了静态 CAPM 无法捕捉到的异常回报可预测性，这意味着与这些特征相关的无条件市场贝塔系数的变化不足以解释它们的回报。在许多情况下，基于这些特征的多头/空头投资组合的无条件市场贝塔系数接近于零。但是，如果风险敞口发生变化，这些特征可能与未来的贝塔系数相关，因此条件风险模型可能会更好地捕捉其回报。作为一个简单的起点，我们检查这些特征是否可以预测未来的市场贝塔系数，然后继续检查具有时变风险敞口的多因子模型。

我们使用在第 t 月内的每日回报数据构建股票级别的月度 OLS 市场回报的贝塔系数。我们还根据 t 至 $t+2$ 个月的每日数据构建季度贝塔系数，根据 t 至 $t+5$ 个月的每日数据构建半年度贝塔系数，以及根据 t 至 $t+11$ 个月的每日数据构建年度贝塔系数。然后，我们使用最近的股票动量探索已实现贝塔系数的可预测性。我们在股票月面板中对从 $t-12$ 月到 $t-2$ 月 (Asness(1994), Fama French(1996) 的标准动量) 的累积回报以及其他特征 (按股票和按月对标准误差进行聚类) 对 t 月到 $t+h$ ($h=0,2,5,11$) 月的 β 进行回归。

$$\beta_{t,t+h} = a + b_h r_{t-12,t-2} + C_h' X_{t-1} + \epsilon_{t,t+h} \quad (2)$$

其中 X_{t-1} 是在 $t-1$ 时刻 N 只股票的 L 个特征构成的 $L \times N$ 大小的矩阵， C_h 是将这些特征与未来市场贝塔系数相关联的估计回归系数。动量特征 $r_{t-12,t-2}$ 在此单独列出，以突出其与未来市场贝塔系数的关系。

下图中的结果表明，股票动量是未来实现的市场贝塔系数的有力预测指标。1 个月已实现市场贝塔系数的预测系数为 0.23 ($t=11.88$)。该系数意味着，当股票从第 10 动量百分位过渡到第 90 动量百分位时，其市场贝塔系数增加 0.18 (0.23×0.8)，或等效地，其市场风险溢价增加 18%。根据 3、6 和 12 个月的未来每日回报计算的已实现贝塔系数的结果相似。

虽然市场贝塔可预测性很强，但动量股顶部和底部十分之一之间 0.18 贝塔差异的经济幅度不足以解释其平均回报的差异。即使市场风险溢价为 6%，0.18 的 β 差异也只能解释 8%-9% 动量溢价 1.1 个百分点左右。因此，只有随时间变化的市场贝塔系数的条件 CAPM 无法捕捉动量收益。出于这个原因，我们在下面探索了一个更丰富的条件多因子模型。

动量在预测未来实现的贝塔值方面并不是独一无二的。长期反转，另一个历史回报特征，基于之前三到五年的回报，也显著预测了未来的市场贝塔系数，尽管预测系数是动量的一半，如下图所示。许多其他常见的特征也显著预测了已实现的贝塔系数。自然，最强的贝塔预测器之一是过去实现的贝塔 (市场贝塔)，以及规模 (市值)。然而，正如该图在多因子回归中显示的那样，即使考虑了这些特征，动量和长期反转特征对于预测市场贝塔值仍然非常重要。

最后，短期反转，另一个基于过去一个月回报的历史回报特征，是对未来市场贝塔系数具有统计显著性但在经济上很小的预测性特征。这种微弱的结果与短期反转与流动性影响 (例如 Nagel(2012)) 的联系比时变风险更大是一致的。

图 1: 基于特征预测已实现市场贝塔

We construct stock-level monthly realized OLS betas on the market return using daily returns data within month t . We also construct quarterly betas from daily data in months t to $t+2$, semiannual betas from daily data in months t to $t+5$, and annual betas from daily data in months t to $t+11$. We regress betas during months t to $t+h$ ($h=0, 2, 5$ or 11) on cumulative returns from month $t-12$ to $t-2$ in a stock-month panel, along with other characteristics. Results are reported below and slope coefficients in regressions using ranks are multiplied by 100 for readability. Standard errors are clustered by month and firm. We use *** to denote statistical significance at the 0.1% level, ** denotes significance at the 1% level, and * denotes significance at the 5% level.

Characteristic	Realized beta			
	One-month	Three-month	Six-month	Twelve-month
Assets	-0.28***	-0.31***	-0.33***	-0.32***
Assets-to-market	0.16***	0.14***	0.14***	0.14***
Bid-ask spread	0.08***	0.05**	0.03*	0.02
Book-to-market	-0.02	-0.02	0.01	0.03
Capital intensity	0.02	0.01	0.01	0.01
Capital turnover	0.21***	0.18***	0.14***	0.11***
Cash-flow-to-book	-0.01	-0.01	-0.01	-0.01
Cash-to-short-term-inv.	0.01	0.01	0.02	0.02
Earnings-to-price	0.02	0.01	-0.00	-0.01
FF3 Idio. vol.	0.07***	0.08***	0.08***	0.07***
Fixed costs-of-sales	0.12***	0.11***	0.11***	0.11***
Gross profitability	-0.05*	-0.05**	-0.05*	-0.04
Intermed. mom	-0.02	-0.02	-0.02*	-0.03**
Investment	-0.01	0.00	0.01	0.02*
Leverage	0.03	0.04*	0.04**	0.05***
Long-term reversal	0.11***	0.11***	0.10***	0.08***
Market beta	0.77***	0.76***	0.75***	0.72***
Market cap.	0.83***	0.81***	0.81***	0.80***
Momentum	0.23***	0.23***	0.23***	0.20***
Net operating assets	-0.03*	-0.03*	-0.02	-0.02
Operating accruals	0.01	0.01*	0.01*	0.02**
Operating leverage	-0.17***	-0.16***	-0.13***	-0.10***
PPE-chg-to-Assets-chg	-0.03**	-0.02**	-0.02*	-0.01
Price rel. 52wk high	-0.20***	-0.18***	-0.16***	-0.14***
Price-to-cost-margin	-0.01	-0.01	-0.01	-0.01
Profit margin	0.01	0.01	0.01	-0.00
Return on NOA	-0.04**	-0.05***	-0.05***	-0.05***
Return on assets	-0.13***	-0.16***	-0.17***	-0.17***
Return on equity	0.05*	0.08***	0.09***	0.10***
SGA-to-sales	-0.13***	-0.11***	-0.10***	-0.12***
Sales-to-assets	0.03*	0.04**	0.04**	0.04**
Sales-to-price	0.06	0.06	0.07*	0.08*
Short-term reversal	0.03**	0.04***	0.05***	0.04***
Tobin's Q	0.01	0.01	0.03	0.05
Turnover	0.42***	0.41***	0.40***	0.38***
Unexplained volume	0.01	0.01	0.00	-0.00
Constant	0.77***	0.78***	0.79***	0.78***
R^2 (%)	7.78	17.53	22.76	25.55

资料来源: Journal of Financial Economics, 国信证券经济研究所整理

多因子贝塔预测结果

由于我们将在下面考虑多因子模型, 因此评估历史回报如何相对于通常用于代表总风险的其他因子预测贝塔值是有用的。下图报告了运行回归方程的结果。公式(2) 使用 Fama 和 French (2015) 中的因子 Small Minus Big (SMB)、High Minus Low (HML)、Robust Minus Weak (RMW) 和 Conservative Minus Aggressive (CMA) 的年度 Beta 值代替市场 Beta, 其中贝塔值是以相同的方式使用每日回报计算的。除了 SMB 之外, 动量显著预测 HML、RMW 和 CMA 中的每一个的 beta 敞口, 即使在控制账面市值比、毛利率和投资时也是如此, 它们分别是 HML、RMW 和 CMA 所基于的特征。长期反转还显示出对所有四个因子的未来贝塔系数的显著可预测性。最后, 短期反转对未来贝塔系数的可预测性很小且微不足道, 这与其对市场贝塔系数的缺乏可预测性及其主要是流动性驱动的现象一致。这些贝塔预测结果的结论是, 许多“异常”特征, 特别是那些基于历史回报(例如动量和长期反转)的特征, 是未来已实现风险

的有力指标，即使仅通过简单的视角来看待风险、一维 CAPM 或通过多因子模型，例如 Fama 和 French (2015) 五因子模型。因子贝塔值随时间变化显著，股票特征对于跟踪贝塔值变化似乎很有用。这一发现暗示了在风险和回报的动态条件模型中调和与股票特征相关的平均回报模式的途径，即那些基于历史回报的模式。我们接下来通过查看动态多因子模型来探索这条路线。

图 2: 基于特征预测多因子贝塔

We construct stock-level monthly realized OLS annual betas on the nonmarket Fama-French (2015) factor returns return using daily data in months t to $t+11$. We regress betas during months t to $t+11$ on cumulative returns from month $t-12$ to $t-2$ in a stock-month panel, along with other characteristics. Results are reported below. Standard errors are clustered by month and firm. We use *** to denote statistical significance at the 0.1% level, ** denotes significance at the 1% level, and * denotes significance at the 5% level.

Characteristic	Realized beta			
	SMB	HML	RMW	CMA
Assets	-0.97***	0.13	0.81***	0.33**
Assets-to-market	0.52***	0.35***	-0.87***	0.04
Bid-ask spread	-0.56***	-0.20***	0.92***	-0.23***
Book-to-market	-0.15*	0.03	0.32***	-0.12
Capital intensity	-0.07**	-0.05	0.04	-0.00
Capital turnover	0.12*	-0.22**	-0.35***	0.30***
Cash-flow-to-book	0.09***	0.05*	-0.07**	0.08***
Cash-to-short-term-inv.	0.07*	-0.08**	-0.18***	0.08**
Constant	0.45***	-0.51***	-0.60***	-0.53***
Earnings-to-price	0.24***	0.31***	-0.29***	0.37***
FF3 Idio. vol.	0.17***	-0.17***	-0.48***	-0.14***
Fixed costs-of-sales	-0.29***	-0.47***	-0.03	-0.16*
Gross profitability	-0.02	0.21***	0.12	0.00
Intermed. mom	-0.03	-0.02	0.04	-0.05
Investment	-0.03	-0.13***	0.08*	-0.41***
Leverage	0.02	-0.04	0.06	-0.05
Long-term reversal	-0.12***	-0.23***	0.23***	-0.51***
Market beta	0.46***	-0.41***	-0.55***	-0.46***
Market cap.	-0.01	-0.57***	-0.31**	-0.54***
Momentum	-0.02	-0.34***	0.21***	-0.38***
Net operating assets	0.12***	0.11**	-0.16***	0.13***
Operating accruals	0.01	-0.03*	-0.03	-0.00
Operating leverage	-0.07	0.39***	0.33***	-0.14
PPE-chg-to-assets-chg	-0.02	0.02	0.14***	-0.08**
Price rel. 52wk high	-0.06**	0.05*	0.20***	0.06
Price-to-cost-margin	0.14**	0.15**	0.01	-0.10
Profit margin	-0.23***	-0.21***	0.39***	-0.11*
Return on NOA	-0.01	0.10**	0.07	0.09**
Return on assets	-0.06	0.25***	-0.06	-0.08
Return on equity	-0.23***	-0.35***	0.61***	-0.30***
SGA-to-sales	0.02	-0.10	0.09	0.25***
Sales-to-assets	0.03	-0.17***	-0.10*	-0.12**
Sales-to-price	-0.16*	-0.25**	0.30**	-0.27**
Short-term reversal	0.01	-0.04*	0.06**	-0.05
Tobin's Q	0.08	-0.19*	-0.14	-0.06
Turnover	0.11***	-0.45***	-0.11**	-0.49***
Unexplained volume	0.05***	0.06***	-0.02*	0.06***
R^2 (%)	4.78	8.77	3.77	5.55

资料来源: Journal of Financial Economics, 国信证券经济研究所整理

模型

我们为个股假设了一个条件因子定价模型，并研究该模型解释预期回报的动量和长期反转效应的可行性。条件通过因子载荷进入我们的模型，我们将其指定为股票特征的函数。随着股票的特征发生变化，其条件风险敞口也会发生变化，因此其模型隐含的预期收益也会发生变化。从模型的角度来看，股票表现的任何相对持久性——例如由动量策略捕获的——必须源自风险敞口的相对持久性。主要的实证挑战是建立一个条件资产定价模型。我们使用股票特征作为工具来帮助识别股票难以衡量的动态因子敞口，我们探索了两种模型变体。第一种使

用 IPCA，它将因子视为潜在因子，并估计与基于特征的风险敞口最相关的因子。第二个和更具限制性的模型依赖于可观察的预指定因子，例如 Fama-French 因子。

IPCA

KPS 提供了对 IPCA 模型的详细分析，我们在此进行了总结。他们将超额收益的 $N \times T$ 面板建模为以下形式的条件定价模型

$$r_{i,t+1} = \underbrace{(z'_{i,t}\Gamma)}_{\beta_{i,t}} f_{t+1} + \epsilon_{i,t+1} \quad (3)$$

资产暴露于一组 K 个不可观察因素，表示为 f_{t+1} 。股票特征与未来市场贝塔系数之间的强关联（图 1）激发了特征是条件风险的良好工具的假设。IPCA 直接将此功能嵌入到 $\beta_{i,t}$ 的规范中。特别的，资产的动态条件因子载荷可能取决于 $L \times 1$ 工具向量 $z_{i,t}$ （包括常数）中包含的可观察资产特征。 $L \times K$ 的矩阵 Γ 定义了潜在大量特征和少量风险因素暴露之间的映射。尤其是 Γ 是一组最能预测 beta 的候选特征的线性组合。模型 (3) 中的潜在因子和载荷是通过最小化模型误差平方和来估计的。KPS 为估计提供了一种有效的计算算法，Kelly (2020) 分析了其渐近特性。

特征和载荷之间的 IPCA 映射提供了特征和因子 beta 之间的统计桥梁。公式 (1) 中所示模型的“受限”形式也强加了特征影响预期收益是因为它们决定了 beta。这种形式的模型将因子模型截距 (alpha) 设为零，强加了经济限制，即风险溢价仅反映对协方差风险敞口的补偿。在此限制下，如果模型代表因子风险，则该模型只能适应动量效应，定义为与此估计程序恢复的潜在因子的协方差。共同风险是否产生动量（和长期反转）是一个经验问题。如果由资产特定回报产生的异常 alpha 能够更好地解释动量或其他过去的回报效应，则上述受限模型将不会产生动量，并且会被其他模型超越。我们在下文中研究这些测试结果。

工具化 Fama-French 模型

KPS 研究的最佳条件模型使用潜在因子模型。然而，他们还发现具有可观察因子的标准模型，例如 Fama-French 五因子模型，当其载荷具有可观察特征时得到了显著改善。在 Fama-French 载荷规范中包含特征，将可观察因子模型置于与 IPCA 相同的信息基础上。

特别地，我们对公式 (3) 的变体用五因子 Fama-French 因子替换了 f_{t+1} ，而不是将 f_{t+1} 视为潜在的。在这种情况下，可以方便地重写公式 (3)：

$$r_{i,t+1} = \text{vec}(\Gamma)'(f_{t+1} \otimes z_{i,t}) + \epsilon_{i,t+1} \quad (4)$$

其中 $f_{t+1} \otimes z_{i,t}$ 是 $KL \times 1$ 维的向量，每一个因子与一个特征交互。因为这些因子是可观察的，所以对因子/特征交互作用的回报的 OLS 回归可以恢复 Γ ，进而恢复条件载荷 $\beta_{i,t}$ 。因此， Γ 可以通过对与滞后特征相互作用的综合因子的单只股票回报的面板 OLS 回归来确定。在稳健性分析中，我们还考虑了文献中使用滚动 60 个月时间序列回归来估计条件 Beta 的传统动态 Beta 估计。我们的主要 IPCA 分析使用五因子 IPCA 规范。这一选择是由 KPS 中的分析推动的，并使我们的模型与 Fama-French 五因子模型可比。

动量模型

为了研究资产定价模型捕捉动量效应的能力，我们分析了三个相互竞争的预测变量，每个预测变量都作为真实的条件预期资产回报 $E_t[r_{i,t+1}]$ 的代理变量。

第一个预测变量是传统的动量信号。它使用每个资产最近的历史回报表现——定义为先前回报的移动平均值——作为条件预期未来回报的信号。我们用 $\bar{r}_{i,t} = \Sigma_{j=2}^{12} r_{i,t-j}$ 来估计 $E_t[r_{i,t+1}]$ ，其是标准的 2-12 动量，最初由 Jegadeesh 和 Titman (1993) 以及 Asness (1994) 提出并由 Fama 和 French (1996) 以及 Carhart (1997) 推广。

第二个预测变量是基于模型的预测器，定义为回报的因子成分的条件期望 $\beta'_{i,t}\lambda_t$ ，其中 $\lambda_t = E_t[f_{t+1}]$ 。为了直接关注时变风险敞口的作用，我们的分析将预期因子回报视为常数： $E_t[f_{t+1}] = \lambda$ 。因此，资产的时变风险溢价仅通过其时变因子载荷或贝塔值发生。我们对这个静态风险价格的估计是估计样本中因子实现的简单平均值：对于样本内的计算，它是 $\hat{\lambda} = \frac{1}{T} \Sigma_{t=1}^T f_t$ 。对于样本外的计算，它是 $\hat{\lambda}_t =$

$\frac{1}{t} \Sigma_{\tau=1}^t f_\tau$ ，从技术上讲，它可以看到时间变化，但只是由于估计样本的变化。

第三个预测变量是最近无法解释的股票表现——定义为公式 (1) 中的模型残差 $\epsilon_{i,t}$ 的移动平均值。我们在控制条件因子模型后使用残差股票收益，因此将残差动量定义为 $\bar{\epsilon}_{i,t} = \Sigma_{j=2}^{12} \epsilon_{i,t-j}$ 。

我们比较这三个预测变量的回报可预测性，以评估资产定价模型在描述动量异常方面的成败。 $\bar{r}_{i,t}$ 在我们的样本中建立了基线动量效应。如果资产定价模型成功解释了动量效应，那么原始动量的所有预测内容都应该归因于 $\beta'_{i,t}\lambda_t$ ，而 $\bar{\epsilon}_{i,t}$ 的增量预测能力为零。相反，如果模型在捕捉动量方面做得很差，那么股票动量的信号内容将被残差继承，因此残差动量将作为定义盈利策略的重要预测因素进入。如果对 $\beta'_{i,t}\lambda_t$ 的控制可以排除与具有正预期回报的动量负相关的因素，则残差动量也可能超过原始动量。

我们以多种方式进行预测测试。首先，我们在 $\bar{r}_{i,t}, \beta'_{i,t}\lambda_t, \bar{\epsilon}_{i,t}$ 上运行 $r_{i,t+1}$ 的面板预测回归。我们还考虑使用这些预测变量中的每一个的横截面排序的预测回归，这与文献中经常研究的横截面排序更接近。同样，为了轻松地将我们的发现与先前的文献进行比较，我们分析了根据每个信号将股票分类到投资组合中的交易策略，以跟踪和比较信号表现。

条件模型是否能解释动量和反转？

我们评估了 IPCA 在大量规范和数据集中解释动量的能力，包括样本内和样本外。我们还研究了在使用 2-12 以外的一系列替代形式窗口时我们的发现有何不同，并发现我们基于模型的条件预期解释了大部分动量和长期反转现象。我们还发现短期反转是 IPCA 没有捕捉到的一种独特现象。

IPCA 模型

下图展示了 IPCA 模型解释动量效应的实验结果。其中 Panel A 采用如下的面板回归模型来预测：

$$r_{i,t+1} = c_0 + c_1 s_{i,t} + e_{i,t+1}$$

其中 $s_{i,t}$ 表示 2-12 收益动量 ($\bar{r}$)，模型预测收益 ($\beta'\lambda$)，残差动量 ($\bar{\epsilon}$)。在所有回归中，我们按月对标准误差进行聚类，以解释回报的横截面相关性。真实条件预期回报的完美代理将具有零截距、1 斜率和相对较高的 R2 (Mincer 和 Zarnowitz(1969))。虽然这对于原始预测变量是可能的，但对于排名预测变

量不适用，因为它们的缩放比例。

图 3: 动量和 IPCA 模型

Panels A and C report coefficient estimates, t -statistics, and R^2 (in percentage) of univariate and bivariate panel regressions, respectively, of the next month's excess stock returns on the current month's signal (left three columns) or signal rank (right three columns), where t -statistics use standard errors clustered by month. Panel B reports annualized average returns (left three columns) and Sharpe ratios (right three columns) of equal-weighted quintile portfolios (Q1, Q2, etc.) sorted on each of the three signals. The row labeled Q5-Q1 denotes the spread portfolio that is long Q5 and short Q1, and t -statistics are provided for these averages and Sharpe ratios. Average returns are reported in annualized percentage. Slope coefficients in regressions using ranks are multiplied by 100 for readability.

A. Univariate regressions						
	Raw signal			Rank signal		
	$\bar{r}$	$\beta'\lambda$	ϵ	$\bar{r}$	$\beta'\lambda$	ϵ
Constant	0.01	0.00	0.01	0.01	0.01	0.01
(t -stat)	(3.59)	(0.13)	(3.70)	(3.70)	(3.70)	(3.70)
Coeff	-0.00	0.99	-0.00	0.72	3.24	0.30
(t -stat)	(-0.29)	(14.02)	(-0.18)	(2.52)	(13.91)	(1.26)
R^2 (%)	0.00	0.37	0.00	0.02	0.32	0.00
B. Portfolio sorts						
	Average return			Sharpe ratio		
	$\bar{r}$	$\beta'\lambda$	ϵ	$\bar{r}$	$\beta'\lambda$	ϵ
Q1	7.96	-4.59	10.17	0.30	-0.22	0.38
Q2	8.59	5.59	10.14	0.43	0.29	0.51
Q3	10.26	9.76	10.21	0.55	0.49	0.55
Q4	12.64	15.93	10.61	0.67	0.75	0.57
Q5	16.25	29.01	14.57	0.69	1.14	0.64
Q5-Q1	8.29	33.59	4.39	0.48	2.39	0.30
(t -stat)	(3.30)	(16.47)	(2.09)	(3.29)	(14.81)	(1.88)
C. Bivariate regressions						
	Raw signal			Rank signal		
	1	2	3	4	5	6
Constant	0.00	-0.00	0.01	0.01	0.01	0.01
(t -stat)	(0.11)	(-0.03)	(3.24)	(3.70)	(3.70)	(3.70)
$\bar{r}$	-0.01		-0.00	-0.14		3.10
(t -stat)	(-1.45)		(-0.29)	(-0.42)		(3.13)
$\beta'\lambda$	1.06	1.03		3.27	3.30	
(t -stat)	(11.83)	(12.96)		(11.88)	(12.62)	
ϵ		-0.00	0.00		-0.34	-2.57
(t -stat)		(-2.40)	(0.28)		(-1.29)	(-2.90)
R^2 (%)	0.40	0.39	0.00	0.32	0.32	0.05

资料来源: Journal of Financial Economics, 国信证券经济研究所整理

面板 A 的“ $\bar{r}$ ”列建立了样本中股票动量的基线行为。有趣的是，原始回报动量信号对未来回报没有预测能力。它的预测斜率系数和面板 R2 几乎都为零。只有在将其转换为横截面排名（第四列）之后，回报动量才能预测未来的回报，在这种情况下，过去动量排名的月面板 R2 为 0.02%，斜率系数为 0.72（ t -stat=2.5）。这个斜率系数的解释是，最高动量股票的月回报率预计比最低动量股票高 0.72%。尽管如此，这种低预测 R2 仍可以转化为有效的交易策略表现，如面板 B 的投资组合类型所示。 $\bar{r}$ 上的排序产生了两个最极端的五分之一排序投资组合之间的年化收益率差，Q5-Q1，平均为 8.3%（ t -stat=3.3）夏普比率为 0.48（ t -stat=3.3）。夏普比率 t 统计量基于 Lo (2002) 的渐近标准误差公式。与回报动量相比，基于模型的条件预期回报（面板 A 的“ $\beta'\lambda$ ”列）具有更强的预测能力。在其原始形式中，预测斜率为 0.99（ t -stat=14）。虽然这个斜率在 0.1% 的水平上与 0 显著不同，但它与 1.0 没有显著差异，截距与 0 无法区分。因此，我们不能拒绝模型给出条件预期股票收益的无偏估计的假设。对应的月面板 R2 为 0.37%，是回报动量排名版本的 18 倍。与动量不同，将 $\beta'\lambda$ 转换为横截面排序会略微削弱其预测信号，R2 下降到 0.32%。尽管如此，斜率系数意味着最高 $\beta'\lambda$ 股票的月回报率预计比最低 $\beta'\lambda$ 股票高 3.24%。根据模型的（样本内）条件预期估计形成 Q5-Q1 投资组合价差，产生 33.6%（ t -stat=16.5）的年化平均回报和 2.39（ t -stat=14.8）的夏普比率。

最后，我们考虑 IPCA 预测残差的动量。在单变量分析中，残差动量的预测能

力弱于总回报动量的预测能力。排序信号的单变量斜率系数降至微不足道的 0.30 ($t\text{-stat}=1.3$), 而 Q5-Q1 夏普比率降至微不足道的 0.30 ($t\text{-stat}=1.9$)。转到面板 B, 我们发现我们的基于因子模型的策略比原始动量更有利可图, 而残差动量策略产生的利润微乎其微。

单变量测试表明, 该模型比简单的动量信号产生更有效的回报预测。对条件模型解释动量的能力的更直接测试是同时进行控制动量和基于模型的预期回报的联合预测回归。这些二元回归显示在面板 C 中。我们发现动量的预测效果主要包含在基于模型的预期回报中。控制条件模型, 动量信号失去显著性, 甚至切换方向。无论我们是比较原始动量信号还是横截面排序动量信号 (第 1 和第 4 列), 这一事实都成立。基于模型的预期回报似乎包含了动量信号提供的所有预测信息。这些结果表明, 源自动态因子敞口的条件预期收益是动量体现的可预测性的主要原因。

IPCA 样本外

我们模型的时间安排确保市场参与者在时间 t 或之前完全了解进入 $\beta_{i,t}$ 的条件特征。然而, 静态参数矩阵 Γ 的估计使用来自整个样本的信息。因此, 虽然上图中没有前视偏差, 但基于模型的结果是样本内的。

在下图中, 我们使用完全基于样本外模型的预测进行相同的比较预测分析。特别是, 在预测已实现回报 $r_{i,t+1}$ 时, 我们仅使用日期 t 中的数据来估计 Γ 。我们的初始估计窗口使用 1966 年 1 月至 1971 年 6 月的数据来预测 1971 年 7 月的回报 (即, 我们需要至少 5 年的估计窗口)。在随后的每个月, 我们都会递归地重新估计模型并使用不断扩大的后向样本构建预测。由于完整样本 (1966-2014) 和样本外 (1971-2014) 评估期之间的差异, 上图和下图之间总回报动量的表现存在微小差异。

IPCA 条件期望的样本外预测能力与样本内发现非常相似。 $\beta'\lambda$ 的原始版本和排序版本的单变量样本外 R^2 为 0.28%。斜率系数下降至 0.77, 表明样本外 $\beta'\lambda$ 存在衰减偏差。稍低的预测能力可能是样本外性能较差, 或者仅仅是由于用于构建每个预测的数据较少。同时, 残差动量在原始和排名情况下都提供了微不足道的预测斜率 (分别为 $t\text{-stat}=0.0$ 和 $t\text{-stat}=1.5$)。

图 B 显示基于模型的预测的交易策略性能不是样本内过度拟合的产物。虽然样本外 Q5-Q1 年化平均回报率 30.9% 和夏普比率 2.29 (分别与样本内 33.6% 和 2.39 相比) 略有衰减, 但它仍然是简单动量的四倍多。残差动量策略的年化夏普比率为 0.33 ($t\text{-stat}=1.96$), 带来了略微显著的盈利能力。

与上图的面板 C 中一样, $\bar{r}$ 和 $\bar{\epsilon}$ 的预测系数在原始或排序信号情况下都很小且不显著。这些结果表明, 即使在样本外的基础上, 基于模型的条件预期回报也将预测信息包含在动量中。上图和下图之间的相似性表明我们的发现不是由样本内偏差驱动的。

图 4: 动量和 IPCA 模型 (样本外)

We estimate the IPCA model recursively out of sample with an initial training sample of 1966-1971. For more table details, see Table 2's notes.

A. Univariate regressions						
	Raw signal			Rank signal		
	r	$\beta^T \lambda$	ϵ	r	$\beta^T \lambda$	ϵ
Constant	0.01	0.00	0.01	0.01	0.01	0.01
(t-stat)	(3.73)	(1.42)	(3.81)	(3.82)	(3.82)	(3.82)
Coeff	-0.00	0.77	-0.00	0.09	3.03	0.35
(t-stat)	(-0.49)	(12.15)	(-0.00)	(2.37)	(13.46)	(1.45)
R^2 (%)	0.00	0.28	0.00	0.01	0.28	0.00
B. Portfolio sorts						
	Average return			Sharpe ratio		
	r	$\beta^T \lambda$	ϵ	r	$\beta^T \lambda$	ϵ
Q1	9.24	-2.90	10.63	0.34	-0.14	0.40
Q2	9.19	7.03	10.48	0.46	0.37	0.53
Q3	11.12	10.85	11.25	0.61	0.56	0.62
Q4	11.35	16.48	11.73	0.72	0.79	0.64
Q5	16.55	27.99	15.36	0.71	1.13	0.69
Q5-Q1	7.30	30.89	4.74	0.42	2.29	0.33
(t-stat)	(2.79)	(15.17)	(2.16)	(2.78)	(13.76)	(1.96)
C. Bivariate regressions						
	Raw signal			Rank signal		
	1	2	3	4	5	6
Constant	0.00	0.00	0.01	0.01	0.01	0.01
(t-stat)	(1.45)	(1.33)	(3.46)	(3.82)	(3.82)	(3.82)
r	-0.01		-0.01	-0.08		2.74
(t-stat)	(-1.56)		(-0.62)	(-0.24)		(2.66)
$\beta^T \lambda$	0.84	0.80		3.05	3.07	
(t-stat)	(11.26)	(11.45)		(11.60)	(12.19)	
ϵ		-0.00	0.01		-0.24	-2.20
(t-stat)		(-1.97)	(0.66)		(-0.91)	(-2.40)
R^2 (%)	0.32	0.30	0.01	0.28	0.28	0.03

资料来源: Journal of Financial Economics, 国信证券经济研究所整理

解释

我们需要了解我们所说的 IPCA 模型“解释”动量的含义。我们的结果意味着动量特征 (过去 12 个月的回报) 反映了潜在因子风险的时变暴露, 通过回报的协方差矩阵定义。对过去 12 个月的回报进行排序是对经济中定价因子的条件 Beta 敞口进行排序的一种嘈杂的衡量方法。因此, 控制这种随时间变化的风险敞口的准确度量可以捕获大部分动量溢价。过去的回报是捕捉定价因素的协方差风险的一种简单的临时方法。从经济上讲, 这些结果意味着过去的回报异象会受到定价因子的条件协方差的影响, 但我们还不知道为什么这些因子被定价。换句话说, 我们的模型使用已知与来自大量经验文献的平均回报相关的特征来构建潜在因子暴露, 其动态恰好被简单的回报移动平均线合理地吸收。但是我们的框架 (和文献) 对于为什么这些特征与市场平均回报相关, 或者它们代表什么经济风险或状态变量保持沉默。这个问题仍然难以捉摸, 超出了本文的范围。

结论

股票动量、长期反转和其他预测未来回报的历史回报特征同样可以用来预测未来的贝塔值，表明这些特征捕捉到了随时间变化的风险补偿。我们用条件因子定价模型将这一论点形式化。我们基于 IPCA 并依靠可观察到的股票特征来估计潜在因子及其时变因子载荷。我们发现即使在短期范围内（一年），因子载荷也会发生显著变化，并且这种变化捕获了现有文献中常用因子模型所捕捉不到的显著条件风险溢价。我们对条件风险敞口的估计可以解释相当大一部分动量和长期反转的回报，并可用于产生非常显著的回报预测。

国信证券投资评级

类别	级别	定义
股票 投资评级	买入	预计 6 个月内，股价表现优于市场指数 20%以上
	增持	预计 6 个月内，股价表现优于市场指数 10%-20%之间
	中性	预计 6 个月内，股价表现介于市场指数 $\pm 10\%$ 之间
	卖出	预计 6 个月内，股价表现弱于市场指数 10%以上
行业 投资评级	超配	预计 6 个月内，行业指数表现优于市场指数 10%以上
	中性	预计 6 个月内，行业指数表现介于市场指数 $\pm 10\%$ 之间
	低配	预计 6 个月内，行业指数表现弱于市场指数 10%以上

分析师承诺

作者保证报告所采用的数据均来自合规渠道，分析逻辑基于本人的职业理解，通过合理判断并得出结论，力求客观、公正，结论不受任何第三方的授意、影响，特此声明。

风险提示

本报告版权归国信证券股份有限公司（以下简称“我公司”）所有，仅供我公司客户使用。未经书面许可任何机构和个人不得以任何形式使用、复制或传播。任何有关本报告的摘要或节选都不代表本报告正式完整的观点，一切须以我公司向客户发布的本报告完整版本为准。本报告基于已公开的资料或信息撰写，但我公司不保证该资料及信息的完整性、准确性。本报告所载的信息、资料、建议及推测仅反映我公司于本报告公开发布当日的判断，在不同时期，我公司可能撰写并发布与本报告所载资料、建议及推测不一致的报告。我公司或关联机构可能会持有本报告中所提到的公司所发行的证券头寸并进行交易，还可能为这些公司提供或争取提供投资银行业务服务。我公司不保证本报告所含信息及资料处于最新状态；我公司将随时补充、更新和修订有关信息及资料，但不保证及时公开发布。

本报告仅供参考之用，不构成出售或购买证券或其他投资标的的要约或邀请。在任何情况下，本报告中的信息和意见均不构成对任何个人的投资建议。任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。投资者应结合自己的投资目标和财务状况自行判断是否采用本报告所载内容和信息并自行承担风险，我公司及雇员对投资者使用本报告及其内容而造成的一切后果不承担任何法律责任。

证券投资咨询业务的说明

本公司具备中国证监会核准的证券投资咨询业务资格。证券投资咨询业务是指取得监管部门颁发的相关资格的机构及其咨询人员为证券投资者或客户提供证券投资的相关信息、分析、预测或建议，并直接或间接收取服务费用的活动。

证券研究报告是证券投资咨询业务的一种基本形式，指证券公司、证券投资咨询机构对证券及证券相关产品的价值、市场走势或者相关影响因素进行分析，形成证券估值、投资评级等投资分析意见，制作证券研究报告，并向客户发布的行为。

国信证券经济研究所

.....

深圳

深圳市罗湖区红岭中路 1012 号国信证券大厦 18 层

邮编：518001 总机：0755-82130833

上海

上海浦东民生路 1199 弄证大五道口广场 1 号楼 12 楼

邮编：200135

北京

北京西城区金融大街兴盛街 6 号国信证券 9 层

邮编：100032