

个股研究报告—专题报告

金融工程

数量化投资

学术文献研究系列第 30 期

2022 年 01 月 11 日

金融工程报告

相关研究报告:

《港股投资周报: 静待来年, 港股精选组合 2021 年超恒生指数 21.71%》——2022-01-02
 《数量化投资周报: 多因子选股周报—超预期因子表现出色, 沪深 300 指数增强组合本年超额 7.98%》——2022-01-02
 《主动量化策略周报: 全年收官, 超预期精选组合今年以来满仓收益 40.57%》——2022-01-03
 《ETF 周报: 军工 ETF 再次走强, 宽基 ETF 持续迎来净申购》——2022-01-03
 《金融工程专题研究: ETF 新风口——南方中证 500 增强策略 ETF 投资价值分析》——2022-01-05

证券分析师: 张欣慰

电话: 021-60933159

E-MAIL: zhangxinwei1@guosen.com.cn

证券投资咨询执业资格证书编码: S0980520060001

联系人: 杨北锋

电话: 021-60875136

E-MAIL: yangbeifeng@guosen.com.cn

主导跟随模型: 利用因子模型进行指数跟踪

● 研究背景

被动管理基金通常密切复制跟踪指数的投资组合。完全复制指数策略在很多情况下由于指数权重变化产生的股票交易成本, 以及较小权重股票的流动性成本, 导致成本高昂。部分指数复制的方法能够极大降低交易和流动性成本, 因此在实践中被普遍使用。

● 部分复制指数方法介绍

简单选择: 根据特定选择标准对成分股排名, 选择排名最高固定数量的成分股构建组合, 缺点是可能无法完全复制指数。优化选择: 通过解决具有条件约束的优化问题来选择跟踪投资组合中的资产, 缺点是模型复杂并且计算量很大, 可能包含冗余资产。覆盖指数结构: 通过分层抽样和分层聚类等方法选择资产来模拟指数结构, 缺点是面临决定资产数量及指数跨期跟踪风险。

● Follow-the-Leader: 主导跟随方法

主导跟随方法通过追踪驱动指数回报的因子, 选择一组完全捕捉标的指数因子结构的资产来实现指数跟踪。实现步骤: 首先估计跟踪指数回报的系统性因子的数量, 其次通过主成分方法估计因子载荷, 最后通过迭代过程选择主导个股构建跟踪组合。主导跟随方法计算简单, 能够完全代表指数的因子空间。蒙特卡洛模拟结果显示, 相较于其它方法, Follow-the-Leader 方法在模拟测试中表现更好, 跟踪误差低, 并且参数灵敏度较低。

● 实证研究

跟踪标准普尔 500 等权重指数: 时间区间为 2015 年至 2016 年, 使用滚动窗口进行样本外分析, 样本期为 1 年, 样本外为 1 个月, 选取整个样本期间始终保留在指数中 421 只成分股。通过主导跟随方法计算得到主导个股组合, 使用 CM-2006 和简单选择方法作为对比, 主导跟随方法平均选择 28 只主导个股, 跟踪误差、换手率及其他跟踪效果指标也好于对照组。

接下来通过将第一期的 17 只个股作为整个样本期的基础投资组合进行改进, 改进后的方法换手率从 3.18 降低到 1.11, 平均持股个数减少到 23 只。

跟踪 MSCI 美国小盘股指数: 时间区间为 2016 年至 2019 年, 每期样本区间为 2 年, 样本外为 1 个月, 指数成分股数量为 1391 只, 远多于标普 500 指数, 并且流动性更低。结果显示主导跟随方法平均使用 38 只主导个股。与 CM-2006 相比, 主导跟随方法 MSE 降低了大约 20%, 换手率大约降低 40%。

● 结论

本文提出了一种新的基于因子的主导跟随方法, 用于构建跟踪指数的成分股组合。该方法易于执行并且计算相对简单, 通过选择较少的成分股选择构建投资组合, 能够以非常小的跟踪误差跟踪基础指数, 并且选定的主导个股随着时间的推移是稳定的。主导跟随方法由于复制指数所需的换手率更低, 指数基金使用该方法可以极大地节省交易成本。

风险提示: 本报告基于相关文献, 不构成投资建议。

独立性声明:

作者保证报告所采用的数据均来自合规渠道, 分析逻辑基于本人的职业理解, 通过合理判断并得出结论, 力求客观、公正, 结论不受任何第三方的授意、影响, 特此声明。

内容目录

文献来源	4
摘要	4
1. 介绍	4
2. 指数追踪方法	5
2.1 指数跟踪问题	5
2.2 Follow-the-Leader: 主导跟随	7
2.3 Follow-the-Leader 选择方法的实现	8
3. 蒙特卡洛模拟	9
4. 实证应用	14
4.1 跟踪标准普尔 500 等权重指数	14
4.2 跟踪 MSCI 美国小盘股指数	16
5. 结论	18
分析师承诺	19
风险提示	19
个股投资咨询业务的说明	19

图表目录

图 1: 蒙特卡洛模拟结果 (Follow-the-Leader VS CM-2006)	11
图 2: Follow-the-Leader 方法有限样本测试结果	13
图 3: 弱因子测试结果.....	14
图 4: 跟踪标准普尔 500 等权重指数实证结果	15
图 5: 改进的 Follow-the-Leader 方法跟踪标普 500 指数实证结果.....	16
图 6: 改进的 Follow-the-Leader 方法跟踪标普 500 指数与指数走势对比	16
图 7: 跟踪 MSCI 美国小盘股指数实证结果.....	17
图 8: 跟踪 MSCI 美国小盘股指数与指数走势对比	17

文献来源

文献来源: XIN ZHANG, LANWU and ZHIXUE CHEN, “Follow the leader: Index tracking with factor models (Nov, 2021)”, Journal of Empirical Finance.

文献亮点:

基于因子模型的新进展, 本文提出了一种新的方法——主导跟随方法——来选择部分成分股来复制指数的投资组合。本文的方法基于因子模型, 并采用了一个独立的资产选择过程, 该过程可以得到一个稳定的代表指数因子空间的资产子集。此外, 本文构建的方法可以很容易地用于合成复制指数, 其中不属于该指数的资产(比如期权或期货)可以加入到复制投资组合中。

摘要

本文构建的模型选择了一组主导股票, 这些股票组合完全代表了要复制的指数的因子结构。蒙特卡洛实验表明, 因子模型构造的指数副本能够以非常小的跟踪误差跟踪基础指数。实证研究中, 本文通过跟踪标准普尔 500 等权指数和摩根士丹利资本国际美国小盘股指数的样本外表现, 展示了该方法的适用性。本文构造的方法可以很容易地适用于综合指数复制, 并纳入流动性或交易成本的控制措施。

1. 介绍

被动管理基金通常密切复制跟踪指数的投资组合。例如, 交易型开放式指数基金(ETF)可以低成本复制跟踪指数投资组合, 并且可以像股票一样交易。最简单的指数跟踪策略是完全复制指数策略, 该策略构建包含指数中所有成分股的投资组合。然而, 由于指数权重变化产生的股票交易成本, 以及较小权重股票的流动性成本, 这种复制指数的成本高昂(Beasley 等人, 2003 年)。另一种策略是部分复制指数, 即仅使用指数中的有限数量的成分股构建复制投资组合。部分指数复制的方法能够极大降低交易和流动性成本, 因此在实践中被普遍使用。例如, 跟踪 CRSP 美国总市场指数表现的 Vanguard Total Stock Market ETF (股票代码 VTI) 仅使用约 3600 种资产来复制基准指数中的约 7000 种资产。同样, 由于固定收益 ETF 的基准指数通常持有数以千计的债券, 其中许多债券几乎没有交易活动, 因此大多数固定收益 ETF 使用部分复制的方法。

在本文中, 我们提出了一种新方法, 该方法选择部分指数成分股来复制指数。我们方法的基本前提是追踪推动指数回报的系统性因子, 而不是追踪指数本身。具体而言, 该方法是基于选择一组完全捕捉标的指数因子结构的资产。我们将这组资产称为主导资产, 将我们的方法称为“主导跟随”(Follow-the-Leader)法。本文的主要贡献是基于对多维度因子模型的最新研究, 提出了一种一致的方法来选择主导资产集。

本文构造的方法只需要估计资产收益协方差矩阵的特征值和特征向量, 因此计算简单。首先估计解释指数回报的系统性因子的数量。通过 Bai 和 Ng (2002 年)、Hallin 和 Liška (2007 年)、Onatski (2009 年, 2010 年) 或 Ahn 和 Horenstein (2013 年) 提出的方法, 可以稳定地计算出这一步的结果。接下来, 本文使用

Bai 和 Ng (2002) 和 Bai (2003) 的主成分方法估计因子大小 (或因子载荷)。最后, 对于前两步得到的估计因子, 本文通过一个迭代过程, 通过公因子在指数成分股样本空间内选择资产集。

迭代结果表明, 当样本数据的维度很大时, Follow-the-Leader 方法会得到一组资产, 这些资产始终能够跨越样本空间来解释指数 (即 $N, T \rightarrow \infty$)。这样的一致性结果得益于 Parker and Sul (2016) 的公因子识别方法。此外, 本文的蒙特卡罗模拟结果表明, 与其它方法相比, Follow-the-Leader 方法在有限样本中表现良好, 跟踪误差低, 并且参数灵敏度也低得多。

为了验证本文提出的方法在实际中的有效性, 接下来本文进行了一项复制 S&P500 等权重指数的实证研究。实证研究结果表明, 与其它资产选择方法相比, Follow-the-Leader 方法的结果相对较好。构建的跟踪指数投资组合最多包含 27 只主导股票, 可以以非常低的均方误差跟踪标准普尔 500 等权重指数。此外, 与其它方法相比, Follow-the-Leader 方法具有相对较低的投资组合换手率, 因此可以有效地降低交易成本。MSCI 美国小盘股指数包括更多的资产, 平均流动性低于标准普尔 500 指数, 当使用这个方法跟踪 MSCI 美国小盘股指数时, 得到了类似的结果。

Follow-the-Leader 方法的另一个优势是它可以很容易地用于合成复制指数, 其中不属于该指数的资产 (比如期权或期货) 可以加入到复制投资组合中。此外, 该方法可以将流动性或交易成本纳入到组合的衡量标准中, 以便确保所选资产是交易成本最低的资产。

本文并不是首个研究指数部分复制问题的文章。一般来说, 由于计算简单, 指数跟踪问题分为两个步骤: 第一是选择要包含在跟踪投资组合中的资产集, 第二是估计跟踪投资组合中的资产权重。但是, 试图联合解决这两个问题的方法计算很繁琐, 甚至往往无法得到可行的解决方案。之前的大多数文献只关注第二个问题, 而对资产选择的关注相对较少, Corielli 和 Marcellino (2006 年) (下文的 CM-2006) 做了关于资产选择方法的最新研究。CM-2006 提出了将资产包含在复制投资组合中的选择标准, 该标准取决于这些资产的价格与估计的潜在因子的相关性。此过程通过特定的相关性阈值水平来选择哪些资产应该包含在复制组合中。本文的方法基于因子模型, 这是受到了 CM-2006 的启发。但是, 本文采用了一个独立的资产选择过程, 该过程可以得到一个稳定跨越指数因子空间的资产子集。与 CM-2006 方法相比, 本文的蒙特卡罗模拟和实证研究结果证明了本文提出的独立资产选择过程的重要性。

本文的其余部分组织如下: 在第 2 节中, 简要回顾了有关指数跟踪的文献, 然后介绍构造的方法并研究其大样本特性, 在第 3 节中, 通过蒙特卡罗模拟总结了该方法的有限样本特性, 第 4 节介绍了实证研究, 第 5 节是总结。

2. 指数追踪方法

2.1 指数跟踪问题

在本节中, 我们将指数跟踪问题形式化。时间 t 的指数价格定义如下:

$$V_t = \omega P_t \quad (1)$$

其中 P_t 和 ω 分别是股票价格和指数权重的 $N \times 1$ 和 $1 \times N$ 向量, 时间 $t=1, \dots, T$ 。在

本文中，假设权重在时间 t 是已知的。市场上可用的大多数基准指数都报告了成分股的权重或构建方法，也可以放宽这一假设而不影响本文的理论结果。本文专注于通过使用 $Q \times 1$ 资产价格向量 q_t 来复制 V_t 的问题，它是 P_t 的子集；因此， $Q < N$ 。这个问题也被称为抽样复制，通过使用包含较少数量的指数资产的跟踪投资组合来复制指数。在交易成本成为一个重要问题的情况下，基金经理将考虑对那些非常大的、流动性差或国际市场指数使用抽样复制。

跟踪组合定义如下：

$$\hat{V}_t = \omega q_t \quad (2)$$

其中 ω 是一个 $1 \times Q$ 的跟踪投资组合权重向量。

一般来说，由于计算简单，指数跟踪问题分为两部分：第一，选择要包含在跟踪投资组合中的资产集（估计 q_t ）；第二，估计跟踪投资组合的资产权重（即估计 ω ）。

试图联合解决这两个问题的方法计算很繁琐，甚至往往无法得到可行的解决方案。之前的大多数文献只关注第二个问题，而对资产选择的关注相对较少，即估计跟踪的投资组合的资产权重，该投资组合为指数投资组合的资产子集。权重是通过优化跟踪质量的度量来估计的，最常用的方法是最小化跟踪误差。以前的研究提出了基于简单启发式算法的最小化跟踪误差方法，如等权重、市值加权、或价格加权，（例如 Beasley 等人，2003 年；Li 等人，2014 年），但也可以通过更复杂的数学方法，包括分级非凸方法（例如 Coleman 等人，2006 年）和基于聚类的方法（例如 Focardi 和 Fabozzi，2004 年）。

资产选择问题的关注相对较少，该问题涉及确定跟踪投资组合中应包含多少资产和哪些资产。Karlow (2012)回顾了相关工作，将选择方法分为三类：第一是简单选择标准，第二是优化选择，第三是覆盖指数结构的方法。在“简单选择标准”方法下，根据给定的选择标准对资产进行排名，选择排名最高的资产纳入跟踪投资组合中。常见的选择标准是指数中的资产权重、市值（例如 van Montfort 等人，2008 年）、业绩（例如 Larsen 和 Resnick，1998 年）、与指数的相关性或协整程度（例如 van Montfort 等人，2008 年）、交易量（Rey 和 Seiler，2001 年）和市场贝塔系数（van Montfort 等人，2008 年）等。这些启发式方法易于应用，但它们存在三个主要缺点：对资产数量的任意决定、包含过多具有重复信息的资产的风险以及无法捕获所有系统风险的可能性。

“优化选择”方法通过解决具有条件约束的优化问题来选择跟踪投资组合中的资产。优化问题尝试根据某种相似性度量对资产进行分组，然后仅选择一组具有代表性的资产。这些方法通常很复杂并且计算量很大。此外，由于跟踪投资组合在设计上将包含与指数非常相似并且可能是多余的资产，这些方法可能会产生缺乏多样化代表水平的复制投资组合。

“覆盖指数结构”方法旨在通过使用分层抽样（Maginn 等人，2007 年）和分层聚类（Focardi 和 Fabozzi，2004 年；Dose 和 Cincotti，2005 年）等方法选择资产来模拟指数结构。这些方法大多保留了“简单选择标准”的简单性，同时也大大减轻了“优化选择”方法中包含冗余资产的可能性。然而，他们仍然面临决定资产数量以及指数跨期风险的挑战。“覆盖指数结构”方法下的第三种替代方法是基于降维的方法。而 CM-2006 和本文中提出的方法属于基于因子的方法。由于本文将 CM-2006 用作模拟的基准，因此在第 3 节中详细描述了这个方法。在下一节中，将介绍本文构建的 Follow-the-Leader 方法，以便稳定一

致地选择要包含在跟踪投资组合中的资产子集 (q_t)。

2.2 Follow-the-Leader: 主导跟随

在本节中，我们将描述 Follow-the-Leader 方法，以识别跟踪投资组合中具有价格 q_t 的资产集。假设指数中资产的收益可以用线性因子模型来描述，

$$r_{it} = \lambda_i F_t + \varepsilon_{it} \quad (3)$$

其中 r_{it} 是资产 i 在时间 t 的回报，其中 $i=1, \dots, N$ 和 $t=1, \dots, T$ ， F_t 是关于因子 $f_{1t} \dots f_{kt}$ 的 $k \times 1$ 收益向量， λ_i 是因子载荷， ε_{it} 是残差。因子收益 F_t ，因子载荷 λ_i 和因子数量 k 是未知的。我们假设方程中的因子模型是一个多维度的线性因子模型，由 Bai 和 Ng (2002) 定义，其中渐近理论是在假设 N 和 T 都很大的情况下发展起来的。

主导跟随方法的基本前提是追踪驱动指数回报的因子，而不是追踪指数本身。我们将确定一组能够捕捉驱动因子 F_t 变化的个股（主导个股），并且用这组个股构建跟踪投资组合。接下来在本节中将展示如何始终如一地识别这些主导个股。

首先用一个简单的例子来解释主导跟随的方法。假设方程中的因子数是两个 ($k=2$) 并且有一组 5 只主导个股能够完全代表这两个因子。考虑以下对每个主导个股的资产回报的回归方程：

$$r_{it} = a_i + b_{i1} leader_{1t} + \dots + b_{i5} leader_{5t} + \varepsilon_{it} \quad (4)$$

当 5 个主导个股的集合完全复制了这两个因子空间，方程 (4) 中的回归残差将不再包含因子结构。因此，这些残差中因子数的估计值等于零。

假设现在要测试一组给定股票的收益，比如 $r_{1t}, \dots, r_{5t}$ ，是否可以完全代表因子空间。假设因子 f_1 和 f_2 是可观察的，对每个资产回报 $i=1, \dots, N$ 进行回归：

$$r_{it} = a_{1,i} + b_{1,i1} r_{1t} + \dots + b_{1,i5} r_{5t} + \lambda_{1,i} f_{1t} + \varepsilon_{1,it} \quad (5.1)$$

$$r_{it} = a_{2,i} + b_{2,i1} r_{1t} + \dots + b_{2,i5} r_{5t} + \lambda_{2,i} f_{2t} + \varepsilon_{2,it} \quad (5.2)$$

如果 $r_{1t}, \dots, r_{5t}$ 能够完全代表因子空间（即它们是主导因子），那么残差面板 $\varepsilon_{1,it}$ 和 $\varepsilon_{2,it}$ 应该不包含因子结构，其中 $i=1, \dots, N$ ， $t=1, \dots, T$ 。然而，如果 $r_{1t}, \dots, r_{5t}$ 只能代表第一个因子 f_{1t} 所代表的空间，那么只有等式 (5.1) 中的残差具有零因子结构。等式 (5.2) 中的残差仍可由一个公因子来解释。类似地，如果 $r_{1t}, \dots, r_{5t}$ 只能代表 f_{2t} 的空间，那么只有等式 (5.2) 中的残差具有零因子结构，等式 (5.1) 可由一个公因子来解释。因此，测试 (5.1) 和 (5.2) 等式残差中的因子数量将提供有关一组主导个股在捕获跨空间系统因子能力的信息。

在正式介绍本文的方法之前，先简要做一些说明。首先，本文的方法依赖于对因子收益和因子数量的估计。通过 Bai 和 Ng(2002) 和 Bai(2003) 提出的主成分 (PC) 方法可以获得等式 (3) 中因子收益和因子载荷的一致估计，通过使用 Bai 和 Ng(2002)、Hallin 和 Liška(2007)、Onatski(2009,2010) 以及 Ahn 和 Horenstein (2013) 中多维度因子模型提出的方法来估计因子数量。

其次，本文的结果提供了一个范围，如果 $r_{1t}, \dots, r_{5t}$ 被视为主导个股，则方程中 (5.1) 和 (5.2) 中的残差不会有公因子结构；然而，这并不意味着 $r_{1t}, \dots, r_{5t}$ 中的所有股票都是主导个股。例如，假设 $r_{1t}, \dots, r_{4t}$ 是唯一真正的主导个股，而 r_{5t} 没有起解释这些因子的主要作用，只要在回归中包含 $r_{1t}, \dots, r_{4t}$ ，方程中 (5.1) 和 (5.2) 中的残差仍然会有零因子结构。因此，本文构建的方法需要精心设计迭代测试程序，以

避免包含在解释因子中起无关作用的资产。在下一节中，本文提供了一个循序渐进的方法来选择用于测试的资产，以提高计算效率并保持一致性。

接下来，正式介绍本文构建的方法。令 $P_{jt} = [r_{j,1t}, \dots, r_{j,mt}]'$ 为给定的一组来自指数 m 个资产回报中的 j 个。然后定义 P_{jt} 作为因子 f_{jt} 近似主导，当且仅当 $f_{jt} - \gamma_j P_{jt} = \zeta_{jt} (j=1, \dots, k)$ 和 $\zeta_{jt} = v_{jt}/\sqrt{T}$ ，其中当 $N, T \rightarrow \infty$ ， v_{jt} 具有有限的方差， γ_{jt} 是定义了 P_{jt} 中资产线性组合的 $1 \times m$ 系数向量。因此， P_{jt} 可以近似地表征 f_{jt} 。

对于一个给定的因子，如果想测试任何给定的资产集 P_{jt} 是否是给定因子的近似主导个股，下面的方程给出了基于对回归残差中因子数量的估计：

$$r_{it} = \beta_{i,j}(\gamma_j P_{jt}) + \alpha_{i,-j} \hat{f}_{-j,t} + \varepsilon_{j,it}, j = 1, \dots, k \quad (6)$$

其中， $\hat{f}_{-j,t}$ 是一个包含除 $\hat{f}_{j,t}$ 之外的估计因子集合， $\alpha_{i,-j}$ 是维度 i 因子的回归系数。在只有一个因子 ($k=1$) 的情况下，则 $\hat{f}_{-j,t}$ 和 $\alpha_{i,-j}$ 不包含在方程 (6) 中， $\beta_{i,j}$ 是 $\gamma_j P_{jt}$ 的回归系数。

证明略。

上面的理论结果保证了 Follow-the-Leader 方法将对跟踪投资组合中的资产子集提供一致的估计，即跟踪投资组合中包含的资产将完全表征跨越指数的因子空间。

2.3 Follow-the-Leader 选择方法的实现

本节将逐步介绍利用主导跟随方法进行资产选择的过程。如上一节所述，该方法的理论结果是一个方向性的结果。它保证了在跟踪投资组合中选择的资产可以完全捕捉指数的因子结构，但有可能出现一些被选择的资产是冗余的。因此，接下来需要精心设计一个测试程序，选择表征指数所需的最少资产数量，同时保持一致性和计算效率。

在估计了方程(3)中的因子数量后，下面的分步过程旨在选择资产主导集 $\hat{P}_{jt}$ 来表征因子 $\hat{f}_{jt}$ 。对每个因子重复该过程，跟踪投资组合将是包含所有 $\hat{P}_{jt}$ 中的资产的集合。

假设估计因子数为 $\hat{k}$ ，估计因子 $\hat{f}_{1t}, \dots, \hat{f}_{\hat{k}t}$ 。

第一，选择第一个被纳入 P_{jt} 的资产：根据其收益与 $\hat{f}_{jt}$ 的相关性对资产进行排序，排名后的资产的收益为 $r_{1t}, \dots, r_{Nt}$ ，设 $P_{jt} = r_{1t}$ 。

第二，测试 P_{jt} 是否是主导个股集：将前文的主导个股测试方法应用于 P_{jt} ，即估计每个资产对 P_{jt} 中所有收益的回归以及除 $\hat{f}_{jt}$ 之外的所有因子的回归残差，并估计这些残差中的因子数。如果残差中的因子数=0，则设置 $\hat{P}_{jt} = P_{jt}$ ，估计完成，否则（如果残差中的因子数>0），转到下一步。

第三，将资产添加到 P_{jt} ：使用前一步中的 P_{jt} ，估计辅助回归 $\hat{f}_{jt} = a + bP_{jt} + \varepsilon_t$ ，通过残差对不包含在 P_{jt} 的个股收益进行排序，设残差排序集为 $\tilde{r}_{1t}, \dots, \tilde{r}_{Nt}$ 。通过添加与残差相关性最高的股票来更新主导个股集， $P_{jt} = [P_{jt}, \tilde{r}_{1t}]'$ ，然后返回到上一步。

在第一步中，选择第一个要测试的资产作为回报与估计因子 $\hat{f}_{jt}$ 相关性最高的资产。在第二步中，测试所选资产是否足以解释因子 $\hat{f}_{jt}$ 。如果不是，在第三步中添加一个额外的资产，在剔除了 P_{jt} 中已有的资产后，选择其回报与 $\hat{f}_{jt}$ 相关性最高的资产。这个过程保证了任何添加到 P_{jt} 的额外资产都增加了 $\hat{f}_{jt}$ 的解释能力，即扩展了 $\hat{f}_{jt}$ 中的资产已解释内容。重复上面的算法，直到第二步中估计的因子个数等于 0，最终得到 $\hat{P}_{jt}$ 。

可以通过现有文献中介绍的用于多维度因子模型的任何方法来估计因子数量。在本文中，我们使用 Bai 和 Ng(2002)的主成分方法。

上面介绍的 Follow-the-Leader 步骤使用来自指数成分股的资产子集来构建副本投资组合。此外，上述方法可以很方便地修改用来实现对于合成指数的复制，包含跟踪投资组合可能包括不属于指数的资产，比如其他股票、股票期权或期货。具体地，可以在第二步和第三步中，可以使用任何资产集，对它们进行排名，然后继续执行其余步骤。

基金经理往往希望优先考虑包含在跟踪投资组合中的股票子集——例如流动性最强的股票或交易成本最低的股票。通过修改步骤第二步和第三步中根据与因子的相关性排序，而是根据给定的流动性或交易成本衡量标准对股票进行排名，轻松地将此条件纳入算法。这个修改后的步骤将选择所需的股票，并仍然保证指数的因子空间可以被跟踪投资组合解释。

一旦根据 Follow-the-Leader 方法选择了要包含在复制投资组合中的股票子集，下一步就是确定投资组合的权重。权重估计方法不是本文的重点，因此下文将遵循以前的文献进行模拟和实证测试。具体来再使用 CM-2006 中的方法，通过最小化平方和误差来估计投资组合权重，该方法有两个约束条件：因子跨期约束和初始值约束。具体优化方法如下：

$$\begin{aligned} \min_{\omega} \quad & \sum_{t=1}^T (\hat{V}_t - \hat{V}_t)^2 \\ \text{s.t.} \quad & \omega S \Lambda = w \Lambda \\ & \omega S p_0 = w p_0 \end{aligned}$$

其中 V_t 是指数值， $\hat{V}_t$ 是等式 (1) 和 (2) 中定义的时间 t 处的指数副本值。 ω 是 Q 个主导个股集的权重 $1 \times Q$ ，而 w 是其指数成分股的指数权重 $1 \times N$ 。 S 是 $Q \times N$ 维的选择矩阵，它从 N 只股票中选择 Q 只主导个股。 Λ 是估计的 k 个因子的因子载荷的 $N \times k$ 。 p_0 是最新可观察价格的 $N \times 1$ 向量。

3. 蒙特卡洛模拟

在本节中，我们将测试 Follow-the-Leader 方法的小样本属性，其中的数据生成过程旨在捕捉动态因子模型对价格的影响。指数中的每只股票价格都是根据以下因子模型生成的：

$$p_{it} = \Lambda_{1i} F_{1t} + \Lambda_{2i} F_{2t} + e_{it}, e_{it} \sim N(0,1) \quad (9)$$

$$\text{随机游走因子: } F_{1t} = F_{1,t-1} + \xi_{1,t}, \xi_{1,t} \sim N(0,1) \quad (10)$$

$$\text{平稳因子: } F_{2t} = \xi_{2,t}, \xi_{2,t} \sim N(0,1) \quad (11)$$

其中 p_{it} 是股票价格，其中 $i = 1, \dots, N$, $t = 1, \dots, T$; F_{1t} 是一个 $k_1 \times 1$ 的向量，包含具有独立同分布残差为 $\xi_{1,t}$ 的 k_1 维随机游走因子。 F_{2t} 是一个 $k_2 \times 1$ 向量， k_2 是由独立同分布且标准正态随机数为 $\xi_{2,t}$ 生成的平稳因子。真实因子的数量是 $k = k_1 + k_2$ 。因子载荷 Λ_1 和 Λ_2 以及误差项 e_t 都是从标准正态分布中随机抽取的，剔除其中产生的数值为负的价格。接下来，使用 N 个生成的价格来构建一个等权重的指数。在整个模拟过程中选择 $k_1 = k_2 = 5$ ，因此真实因子的总数为 10。最后生成 $N \times T$ 的面板观察值，并将它们复制到 1000 次蒙特卡洛模拟中。使用 Bai 和 Ng (2002) 的因子数方法和 IC2 标准，则最大可能的因子数 $k_{max} = 30$ 。

最后将模拟的结果与 CM-2006 方法进行比较。CM-2006 首先估计资产价格因子模型中的因子，而要估计的因子数量取决于选择的需要由因子解释的特定变异百分比，他们使用 90% 和 99% 的解释力来选择在模拟中的选择的因子数量。当估计出这些因子，接着执行以下步骤：

1. 根据因子与指数的相关性对因子进行排序。
2. 为每个复制因子的选择最小的 R^2 。
3. 从因子 1 开始。
4. 将股票按与因子的相关性顺序排列。
5. 对第一个股票的因子进行回归。
6. 如果回归的 R^2 大于目标值，则跳过下一步。
7. 将与残差相关性最高的股票添加到回归中，然后转到步骤 6。
8. 对当前分析中包含的所有变量对下一个因子进行回归，然后转到步骤 6。
9. 如果所有的所需因子都达到目标精度值，则停止。

前面的过程还需要临时选择最小的 R^2 值来复制每个因子。在本文的模拟中，使用最小值 $R^2 = 0.80$ ，这个取值和 CM-2006 论文中保持一致。最后一步是确定投资组合的权重。

为了衡量模拟结果的跟踪性能，对跟踪误差 $\hat{V}_t - V_t$ 使用了五个损失函数：平均误差 (MEAN)、标准偏差 (STD.DEV.)、平均绝对偏差 (MAD)、最大值误差的绝对值 (SUPMOD) 和均方误差 (MSE)：

$$\begin{aligned} error_t &= \hat{V}_t - V_t, MEAN = \frac{1}{T} \sum_t error_t \\ STD.DEV. &= \sqrt{\frac{1}{T-1} \sum_t (error_t - \overline{error_t})^2}, MAD = \frac{1}{T} \sum_t |error_t| \\ SUPMOD &= \max(|error_t|), MSE = \frac{1}{T} \sum_t (error_t)^2 \end{aligned}$$

对每个模拟数据集计算这些指标值，并计算 1000 次模拟和蒙特卡洛标准误差的平均值。此外，还计算了指数与副本投资组合 (Correl) 之间的相关系数。

我们分别了样本内和样本外样本的模拟结果。对于样本内的结果，使用 N 个资产生成 T 个时期的数据，并估计副本投资组合中的资产及其权重。对于样本外

情况，我们使用 N 个资产在 T 期间生成的数据，但使用从样本内数据估计的资产和权重。

表 1 给出了 $N=100$ 和 $T=500$ 的模拟结果，并与 CM-2006 方法进行了比较。结果可以看出，主导跟随方法始终能够准确估计真实因子数量 $k=10$ ，而 CM-2006 中使用的启发式规则对事先选择的阈值比较敏感。具体来说，当解释方差阈值设置为 90% 时，它捕获的因子太少， $k=3$ ，当解释方差阈值设置为 99.9% 时，捕获的因子又太多， $k=45$ 。这导致 CM-2006 方法跟踪的结果非常不同。例如，在 99.9% 的解释方差阈值的情况下，投资组合看似良好的表现是因为该方法几乎完全复制了指数，具体来说对于成分股数量 $N=100$ 的指数，复制投资组合中的资产平均数量为 95.4。而主导跟随方法更能准确估计因子数量，构建的投资组合平均资产数量为 30.03 个，本文倾向于认为这对于 $N=100$ 是合理的替代。此外，跟踪性能指标表明，无论在样本内还是样本外，方差阈值为 90% 时，主导跟随方法好于 CM-2006，方差阈值为 99.9% 时，主导跟随方法与 CM-2006 表现不相上下。主导跟随方法仅使用 30 种资产就能够构建与指数相关性为 99.98% 的副本投资组合，其 MSE 值较低，为 0.0071。主导跟随方法的另一个优点是计算速度。表 1 中的结果显示，使用 CM-2006 需要运行 190 小时，而使用主导跟随方法只需要不到 5 小时的时间。总之，通过前文构建因子和资产选择的步骤，主导跟随方法提高了计算效率并提供了更好的部分复制，而且在参数敏感性测试表现优异。

图 1: 蒙特卡洛模拟结果 (Follow-the-Leader VS CM-2006)

Table 1 Monte Carlo simulations: Follow-the-Leader vs CM-2006.			
	Follow-the-Leader	CM-2006 EV cutoff at 99.9%	CM-2006 EV cutoff at 90%
<i>In sample ($T=[1,500]$)</i>			
MEAN	0.0000 (0.0004)	0.0000 (0.0001)	0.3286 (7.7024)
STD.DEV.	0.1426 (0.0179)	0.0218 (0.0444)	7.1326 (71.9540)
MAD	0.1137 (0.0144)	0.0173 (0.0354)	6.2544 (57.6602)
SUPMOD	0.4645 (0.0763)	0.0710 (0.1474)	23.6025 (270.8345)
Nfactors	10.0000 (0.0000)	45.1510 (13.3892)	3.0400 (0.6425)
Nleaders	30.0320 (2.7609)	95.4040 (11.0503)	3.5550 (1.1800)
<i>Out of sample ($T=[501, 1000]$)</i>			
MEAN	-0.0003 (0.0445)	0.0004 (0.0135)	-3.4493 (131.5669)
STD.DEV.	0.1536 (0.0195)	0.0269 (0.0468)	11.6491 (139.4152)
MAD	0.1272 (0.0199)	0.0222 (0.0383)	14.9012 (157.8817)
SUPMOD	0.5115 (0.0879)	0.0903 (0.1632)	39.7893 (460.3028)
MSE	0.0071 (0.0011)	0.0012 (0.0022)	0.8421 (0.2623)
Correl.	0.9998 (0.0002)	1.0000 (0.0002)	0.7881 (8.5492)

资料来源: Journal of Empirical Finance, 国信证券经济研究所整理

接下来，评估了主导跟随方法的有限样本性能。首先分析两种一般情况，分别为 $T>N$ 和 $N>T$ 的情况。表 2 中显示了样本内和样本外的测试结果。

对于 $T>N$ 的情况，测试了 $N=50$ 和 100， $T=125$ 、250 和 500 的结果。测试包含了较小的投资组合，数据使用 6 个月、1 年和 2 年的日度数据。测试结果表

明，对于所有测试的样本，因子数量的估计都是准确的。副本投资组合（主导个股集）中的资产数量在 $N=50$ 时不到 N 的一半，在 $N=100$ 时约为 N 的25%-30%。因此，主导个股的数量增加明显少于资产总数的增加，不会随着 N 的增加而成比例增加。 T 的增加对主导个股数量的影响较小。正如理论所预测的那样，无论是在样本中还是样本外，所有跟踪误差度量都会随着样本大小的增加而改善。例如，当 $N=50$ 时，当样本中的 T 从125增加到500时，均方误差(MSE)从0.0235减少到0.0089。类似地，对于 $T=500$ ，当 N 从50增加到100时，MSE从0.0089减少到0.0071。

对于 $N>T$ 的情况，测试了 $N=125$ 、250和500的结果，其中 $T=50$ 、100和250，涵盖了大约两个月到一年的日度数据的较大容量的投资组合。在 $T>N$ 的情况下，测试的结果显示，主导个股方法对所有样本大小的因子数量的估计非常可靠。副本投资组合（主导个股集）中的资产数量与 N 相比相对较少，低至从 N 的10%（ $N=500$ ， $T=250$ ）到 N 的48%（ $N=250$ ， $T=50$ ）。模拟结果表明，当 $N>T$ 时且 $T\geq 100$ 时该方法是可靠的。例如， $T=100$ 时，MAD分别从 $N=125$ 时的0.1346、 $N=205$ 时的0.1076和 $N=550$ 时0.0963，样本内呈现单调递减的规律。此外，当 $T=250$ 时， N 分别为125、250和500时，MAD值分别为0.1143、0.0992和0.0811，同样呈现递减规律。

模拟测试还表明主导个股方法对于非常小的 T 和较大的 N （比如 $T=50$ ）的情况有一定局限性，原因在于在选择投资组合时，要求复制投资组合中的股票数量小于 T 。对于 N 比较大的情况，需要复制的投资组合中股票数量应该更多。例如（如表2所示），在 $N=250$ 、 $T=50$ 的情况下，模拟结果显示副本投资组合中平均需要120.61只股票。在这种情况下，不可能在给定较小的 T （比如 $T=50$ ）的情况下找到副本投资组合的最佳权重。但是此限制与本文中提出的Follow-the-Leader方法无关，因为该方法仅被设计考虑选择要包含在复制投资组合中的股票子集，而不考虑投资组合权重。权重估计方法不是本文考虑的重点，因此我们遵循以前的文献，当在参数数量（投资组合权重）小于 T 时利用最小化残差平方和求解。

图 2: Follow-the-Leader 方法有限样本测试结果

In sample							
N	T	Factors	Leaders	MEAN	STD.DEV.	MAD	SUPMOD
50	125	10.00	20.99	-0.0011	0.2001	0.1596	0.5544
		(0)	(5.7635)	(0.0244)	(0.3635)	(0.3187)	(0.8144)
50	250	10.00	20.82	0.0000	0.1861	0.1481	0.5662
		(0)	(3.3932)	(0.0005)	(0.0592)	(0.0468)	(0.1949)
50	500	10.00	21.26	0.0000	0.1815	0.1446	0.5861
		(0)	(2.7587)	(0.0005)	(0.0394)	(0.0314)	(0.1426)
100	125	10.00	21.77	0.0000	0.1757	0.1393	0.4942
		(0)	(2.4772)	(0.0005)	(0.0408)	(0.0326)	(0.1329)
100	250	10.00	26.95	0.0000	0.1514	0.1205	0.4566
		(0)	(2.6954)	(0.0004)	(0.0221)	(0.0178)	(0.079)
100	500	10.00	30.03	0.0000	0.1426	0.1137	0.4645
		(0)	(2.7609)	(0.0004)	(0.0179)	(0.0144)	(0.0763)
125	50	10.00	49.58	NA	NA	NA	NA
		(0)	(20.697)	NA	NA	NA	NA
250	50	10.00	120.61	NA	NA	NA	NA
		(0)	(18.019)	NA	NA	NA	NA
500	50	10.00	157.07	NA	NA	NA	NA
		(0)	(6.8939)	NA	NA	NA	NA
125	100	10.00	21.78	0.0000	0.1699	0.1346	0.4681
		(0)	(2.4939)	(0.0005)	(0.0383)	(0.0305)	(0.1221)
250	100	10.00	26.97	0.0000	0.1358	0.1076	0.3735
		(0)	(2.7889)	(0.0004)	(0.0252)	(0.02)	(0.0873)
500	100	10.00	29.49	0.0000	0.1217	0.0963	0.3348
		(0)	(2.7421)	(0.0003)	(0.0199)	(0.016)	(0.0697)
125	250	10.00	29.14	0.0000	0.1437	0.1143	0.4354
		(0)	(2.75839)	(0.00038)	(0.02057)	(0.01647)	(0.08035)
250	250	10.00	35.40	0.0000	0.1246	0.0992	0.3789
		(0)	(2.8821)	(0.00032)	(0.01521)	(0.01213)	(0.06483)
500	250	10.00	45.34	0.0000	0.1020	0.0811	0.3081
		(0)	(3.16477)	(0.00026)	(0.01061)	(0.00853)	(0.04677)
Out of sample							
N	T	MEAN	STD.DEV.	MAD	SUPMOD	MSE	Correl.
50	125	-0.0089	0.2386	0.2126	0.7145	0.0235	0.9964
		(0.1362)	(0.2185)	(0.1945)	(0.5363)	(0.0207)	(0.0257)
50	250	-0.0064	0.2057	0.1747	0.6529	0.0138	0.9991
		(0.0791)	(0.0639)	(0.0575)	(0.2126)	(0.0045)	(0.0013)
50	500	0.0017	0.1916	0.1585	0.6364	0.0089	0.9997
		(0.0562)	(0.0418)	(0.0385)	(0.1556)	(0.0021)	(0.0004)
100	125	-0.0059	0.2220	0.1977	0.6678	0.0219	0.9977
		(0.1163)	(0.0522)	(0.0607)	(0.1879)	(0.0064)	(0.0024)
100	250	0.0005	0.1725	0.1472	0.5488	0.0116	0.9994
		(0.0648)	(0.0256)	(0.0278)	(0.1099)	(0.0021)	(0.0006)
100	500	-0.0003	0.1536	0.1272	0.5115	0.0071	0.9998
		(0.0445)	(0.0195)	(0.0199)	(0.0879)	(0.0011)	(0.0002)
125	100	-0.0027	0.2295	0.2100	0.6882	0.0260	0.9970
		(0.1377)	(0.0537)	(0.0703)	(0.2001)	(0.0081)	(0.0028)
250	100	0.0025	0.1981	0.1798	0.5906	0.0222	0.9978
		(0.1155)	(0.0392)	(0.0571)	(0.1607)	(0.0065)	(0.0021)
500	100	0.0014	0.1844	0.1685	0.5507	0.0208	0.9980
		(0.1090)	(0.0324)	(0.0497)	(0.1326)	(0.0056)	(0.0018)
125	250	-0.0027	0.1668	0.1422	0.5338	0.0112	0.9994
		(0.064986)	(0.02404)	(0.02735)	(0.1069)	(0.00207)	(0.0005)
250	250	-0.0039	0.1485	0.1264	0.4738	0.0100	0.9996
		(0.057252)	(0.01853)	(0.02303)	(0.08695)	(0.00171)	(0.00041)
500	250	-0.0040	0.1278	0.1088	0.4085	0.0086	0.9997
		(0.049002)	(0.01329)	(0.0178)	(0.07081)	(0.00133)	(0.00029)

资料来源: Journal of Empirical Finance, 国信证券经济研究所整理

最后, 通过模拟实验评估了弱因子 (Weak Factors, 具有小信噪比的因子) 对得到的副本投资组合的影响。若干估计因子数量的研究证明了识别弱因子的重要性。本文使用 Ahn 和 Horenstein(2013)的数据生成过程, 并使用 1、2 和 3 个弱因子进行模拟。具体来说, 通过修改平稳因子的信噪比来创建如下弱因子:

$$\text{弱因子: } F_{2t}^{weak} = \sqrt{\theta} \xi_{2,t}, \xi_{2,t} \sim N(0,1)$$

其中, θ 是信噪比, 在给定模型中的误差是标准正态分布。本文将 θ 设置为 0.17, 和 Ahn 与 Horenstein(2013)的设定一致。在表 3 中, 与没有弱因子的基础情况相比, 本文测试了具有 1、2 和 3 个弱因子的结果。测试结果表明, 估计的因子数量不受影响, 但随着弱因子数量的增加, 主导个股的数量减少, 但这种减少并不显著, 从基础情况测试结果的平均 30.032 个主导个股到具有 3 个弱因子的情况的 28.118 个。此外, 样本内的 MAD 和样本外的 MSE 的准确性没有受到

显著影响。

图 3：弱因子测试结果

Table 3
The effect of Weak Factors.

	Baseline: no weak factors	1 weak factor	2 weak factors	3 weak factors
<i>In sample (T={1,500})</i>				
MEAN	0.0000 (0.0004)	0.0000 (0.0004)	0.0000 (0.0004)	0.0000 (0.0004)
STD.DEV.	0.1426 (0.0179)	0.1454 (0.0189)	0.1478 (0.0206)	0.1509 (0.022)
MAD	0.1137 (0.0144)	0.1158 (0.0151)	0.1178 (0.0165)	0.1202 (0.0176)
SUPMOD	0.4645 (0.0763)	0.4703 (0.077)	0.4787 (0.0832)	0.4902 (0.0878)
Factors	10.0000 (0.0000)	10.0000 (0.0000)	10.0000 (0.0000)	10.0000 (0.0000)
Leaders	30.0320 (2.7609)	29.3510 (2.6651)	28.7730 (2.7146)	28.1180 (2.7415)
<i>Out of sample (T={501, 1000})</i>				
MEAN	-0.0003 (0.0445)	-0.0002 (0.0443)	0.0000 (0.0447)	0.0027 (0.0479)
STD.DEV.	0.1536 (0.0195)	0.1565 (0.0205)	0.1590 (0.0222)	0.1617 (0.0236)
MAD	0.1272 (0.0199)	0.1294 (0.0209)	0.1313 (0.0226)	0.1339 (0.0247)
SUPMOD	0.5115 (0.0879)	0.5182 (0.087)	0.5318 (0.0988)	0.5418 (0.1047)
MSE	0.0071 (0.0011)	0.0072 (0.0011)	0.0073 (0.0012)	0.0075 (0.0013)
Correl	0.9998	0.9998	0.9998	0.9998

资料来源：Journal of Empirical Finance，国信证券经济研究所整理

蒙特卡洛模拟结果证实了主导个股方法的一致性，并提供了有限样本中良好性能的证据。当时间序列维度的观察值数量大于副本投资组合中的资产数量，本文所构建的方法在 $T > N$ 和 $N > T$ 的大样本测试中表现良好。在大多数情况下，可以取较大的 T 值用于估计，例如只有六个月的每日数据， $T = 125$ ，因此时间数量大于资产梳理的这种限制在实际中影响并不大。

4. 实证应用

4.1 跟踪标准普尔 500 等权重指数

在本节中，将前文构建的主导跟随方法应用于构建 2015 年至 2016 年期间的标准普尔 500 等权重指数的复制投资组合。鉴于指数基金很少进行日内交易，选择日度回报数据进行实证分析。指数和成分股收益收益数据来源于证券价格研究中心 (CRSP) 数据库。指数的成分股变化数据来源于 Compustat。为简单起见，仅使用在整个样本期间保留在指数中的股票，从而得到 421 只股票。我们使用滚动窗口进行样本外分析，每期样本区间为 1 年，样本外为 1 个月。因此，第一个窗口为从 2015 年 1 月开始的 250 天样本数据，从中挑选主导个股并计算得到投资组合权重，将该交易策略应用于接下来的 21 个交易日的样本外分析。计算滚动的每期估计因子数、主导个股数和跟踪效果指标(均值、STD.DEV.、MAD 和 SUPMOD)，并计算整个结果 MSE、相关性和换手率 (Turnover)。当投资组合较大或权重调整幅度较大时，换手率通常会更高。因此，换手度量被定义为副本权重的平均绝对变化：

$$Turnover = \frac{1}{T} \sum_{t=1}^T \sum_{j=1}^N |\omega_{j,t+1} - \omega_{j,t}|$$

使用 CM-2006 方法设置样本外效果的对照组,按照该方法建议的参数,即解释方差阈值设置为 99.9%, R2 阈值设置为 80%。接下来还设置了“简单选择标准”的相关方法作为另一个对照组,该方法简单地选择与指数回报相关性最高的固定数量的股票来构建副本,本文选取了 100 只股票。

在表 4 中,我们使用主导跟随方法测试了 12 个样本外窗口中的两个对照组的跟踪效果。主导跟随的方法平均选择 28 只主导个股,复制投资组合中最多有 45 只股票,最少有 17 只股票。这意味着副本投资组合中只有指数中成分股数量的 6.7%。即使得到的副本投资组合数量很少,但是相对于 CM-2006 和简单选择标准的相关方法,副本投资组合也具有较低的跟踪误差。

在表 4 中,我们还测试了主导跟随方法与整个 12 个样本外窗口期的基准相比的平均效果。使用 Follow-the-Leader 方法构建的副本投资组合在跟踪指数方面表现最好,在三种方法的测试结果中 MSE 最低(0.0635),相关性水平最高(0.9835)。使用 CM-2006 方法构建的复制投资组合具有较大的 MSE (0.1107) 和较小的相关性。使用简单选择标准相关方法构建的复制投资组合具有相对较低的 MSE (0.0656),但需要 100 只股票才能达到这样的结果。正如预期的那样,大量股票影响了这个简单选择跟随副本投资组合的换手率 (4.0452),使其比主导跟随方法的投资组合副本的换手率(3.1846)高出 30%,更大的换手率将导致更高的基金交易成本。

图 4: 跟踪标准普尔 500 等权重指数实证结果

Table 4 Tracking the S&P 500 equally weighted index.								
Window	Follow-the-Leader			CM-2006			Naive correl.	
	Factors	Leaders	MAD	Factors	Leaders	MAD	Leaders	MAD
1st	5	17	0.5239	5	8	1.3599	100	0.8945
2nd	5	20	2.1593	6	12	0.705	100	0.7392
3rd	6	29	0.2058	6	11	0.3373	100	0.8959
4th	6	31	0.879	5	9	0.5489	100	0.4483
5th	6	25	0.3857	5	10	1.6513	100	0.5733
6th	7	27	0.3165	6	14	0.4724	100	0.525
7th	7	26	1.0982	6	14	0.758	100	0.3242
8th	7	25	0.7742	5	9	1.4195	100	0.764
9th	7	31	0.428	5	10	2.2218	100	1.1175
10th	7	29	0.4875	5	9	1.4753	100	0.4173
11th	7	45	0.3502	5	8	3.3583	100	2.2692
12th	8	30	0.8669	6	14	1.1037	100	0.2479
Overall out-of-sample performance for all 12 windows								
	Follow-the-Leader approach			CM-2006			Naive correlation	
MSE	0.0635			0.1107			0.0656	
Correl.	0.9835			0.9154			0.9688	
Turnover	3.1846			2.9834			4.0452	

资料来源: Journal of Empirical Finance, 国信证券经济研究所整理

最后,本文提出了一种改进的实用方法,可以进一步降低 Follow-the-Leader 副本投资组合的换手率。具体来说,将在第 1 个窗口(表 4)中挑选的 17 只股票作为接下来 11 个窗口的基础投资组合,并且仅当这 17 只股票无法跨越以下估计的因子空间时才将股票添加到该基础投资组合窗口中。换句话说,基金经理将在第一个月构建一个 Follow-the-Leader 副本投资组合,然后在下个月简单地添加股票,以防该投资组合无法捕获所有系统因子。在这种方法下,一个合理的假设是认为因子和跟踪这些因子的主导个股随着时间的推移相对稳定。这个修改方法的结果显示在表 5 和图 1 中。正如预期的那样,改进后的方法的换手率从 3.1846 降低到 1.1123,效果明显。此外, MSE=0.0528, 相关性为 0.9832, 总体跟踪误差和与指标的相关性也有所改善。由于投资组合中持有第一个窗口的 17 只股票,捕捉系统风险所需的平均主导个股数量也从 28 只减少到 23 只。

图 5: 改进的 Follow-the-Leader 方法跟踪标普 500 指数实证结果

Table 5
Tracking S&P 500 equally weighted index-holding the initial portfolio.
Out-of-sample performance for each window

Window	Follow-the-Leader approach-hold 1st-window portfolio to the rest of the windows					
	Factors	Leaders	MEAN	STD	MAD	SUPMOD
1st	5	17	-0.2985	0.5339	0.5239	1.1269
2nd	5	19	-0.1309	0.4035	0.3313	0.8289
3rd	6	22	-0.7748	0.3722	0.7848	1.2060
4th	6	22	-1.7749	0.5975	1.7749	2.4722
5th	6	22	0.6788	0.2541	0.6788	1.0873
6th	7	24	-0.0536	0.2122	0.1890	0.3626
7th	7	24	0.5626	0.4251	0.6141	1.2422
8th	7	25	0.1517	0.1621	0.1758	0.4126
9th	7	24	-0.4244	0.2557	0.4380	0.8652
10th	7	23	0.1822	0.4640	0.3733	1.1038
11th	7	26	-0.2523	0.5894	0.4439	1.5249
12th	8	27	1.1011	0.7034	1.1184	1.9251
Out-of-sample performance for all 12 windows						
MSE				0.0528		
Correl				0.9832		
Turnover				1.1123		

资料来源: Journal of Empirical Finance, 国信证券经济研究所整理

图 6: 改进的 Follow-the-Leader 方法跟踪标普 500 指数与指数走势对比




Fig. 1. Tracking the S&P 500 equally weighted index.
The figure shows the tracking performance of the Follow-the-Leader method. The S&P 500 equally weighted index is in blue (Index) and the Follow-the-Leader-replica is in red (tracking portfolio) for the 12-month out-of-sample period. The replica is constructed with the Follow-the-Leader method as in Table 5.

资料来源: Journal of Empirical Finance, 国信证券经济研究所整理

4.2 跟踪 MSCI 美国小盘股指数

本文的第二个实证分析实现了对 2016 年至 2019 年期间 MSCI 美国小盘股指数的复制。此次指数的复制与标准普尔 500 等权重指数的复制在三个方面有所不同。首先, 本次复制专注于拥有大量资产的投资组合。MSCI 美国小盘股指数旨在衡量美国股票市场小盘股的表现, 该股票指数成分股约占美国自由流通调整后市值的 14%, 平均每年大约包含 1700 只成分股。其次, 该指数包含的成分股平均流动性低于标准普尔 500 指数成分股。第三, 本次实证研究从 2016 年到 2019 年, 包括了更长的时间段。指数成分股和权重数据来自 MSCI 网站, 为简单起见, 本文只考虑了整个样本期间留在指数中的 1391 只股票。股票收益数据来自证券价格研究中心 (CRSP) 数据库。同样使用滚动窗口进行样本外分析, 每个样本内窗口期为 2 年, 样本外为 1 个月。因此, 第一个窗口期包含从 2016 年 1 月开始的 504 天样本数据, 从中选出主导个股并计算出投资组合权重, 并将该交易策略应用于接下来的 21 个交易日进行样本外分析。表 6 为实证分析

结果，同样选择了两个对照组，第一个对照组为 CM-2006 方法，解释方差阈值为 99.9%，R2 阈值为 80%，第二个对照组为“简单选择标准”相关方法，使用与该指数最相关的 80 只股票。我们还提供了指数与副本投资组合结果的对比图，如图 2 所示。结果显示，Follow-the-Leader 方法相对于其他方法产生了更好的结果。与 CM-2006 相比，主导跟随方法 MSE 从 0.0569 到 0.0475，降低了大约 20%，MAD 变化不大，换手率大约降低 40%。与在复制投资组合中使用 80 只股票的简单选择标准相关方法相比，主导跟随的方法产生了类似 MSE，换手率降低一半，平均使用 38 只主导个股。

图 7: 跟踪 MSCI 美国小盘股指数实证结果

Table 6 Tracking MSCI US SMALL CAP index								
Window	Follow-the-Leader			CM (2006)			Naive correlation	
	Factors	Leaders	MAD	Factors	Leaders	MAD	Leaders	MAD
1st	5	31	1.1383	6	12	1.7824	80	0.5650
2nd	5	32	0.5303	6	14	1.6109	80	1.2931
3rd	5	35	0.2464	5	10	0.3073	80	0.2695
4th	5	125	0.2350	5	9	0.6414	80	0.6323
5th	6	33	0.6986	5	9	2.7488	80	0.9933
6th	6	32	1.3110	5	9	0.9359	80	1.1226
7th	6	33	1.0897	5	8	0.5076	80	0.3662
8th	6	34	2.6919	5	8	1.4234	80	2.0886
9th	6	34	1.0718	5	8	0.9122	80	0.9675
10th	5	32	0.9855	5	9	0.5925	80	1.2817
11th	5	32	1.4960	5	8	0.3789	80	1.4956
12th	5	32	0.3741	6	12	0.3205	80	1.4345
13th	5	33	0.4708	6	10	0.3424	80	0.2685
14th	5	35	0.3681	5	7	1.1250	80	0.8114
15th	5	35	0.7249	5	7	0.9100	80	0.8199
16th	5	34	0.5453	6	12	0.5264	80	0.2765
17th	5	35	1.2239	6	12	0.7443	80	1.7108
18th	5	35	0.6017	6	13	0.5198	80	0.7468
19th	5	35	0.5182	6	12	0.9560	80	0.3298
20th	5	35	0.6565	6	9	1.5341	80	0.2500
21st	4	36	0.4264	6	11	1.2150	80	0.7398
22nd	4	37	0.3476	6	11	0.5379	80	0.7605
23rd	4	37	0.5668	6	10	0.8793	80	0.3712
24th	5	36	0.5687	6	9	2.0488	80	0.2789
Overall out-of-sample performance for all 24 windows								
	Follow-the-Leader approach			CM (2006)			Naive correlation	
MSE	0.0475			0.0569			0.0483	
Correl	0.9325			0.9281			0.9369	
Turnover	1.7218			3.0695			3.6221	

资料来源: Journal of Empirical Finance, 国信证券经济研究所整理

图 8: 跟踪 MSCI 美国小盘股指数与指数走势对比




Fig. 2. Tracking the MSCI US SMALL CAP index.
The figure shows the tracking performance of the Follow-the-Leader method. The US SMALL CAP index is in blue (Index) and the Follow-the-Leader-Replica is in red (tracking portfolio) for the 24-month out-of-sample period of 2018-2019. The replica is constructed with the Follow-the-Leader method as in Table 6.

资料来源: Journal of Empirical Finance, 国信证券经济研究所整理

5. 结论

本文提出了一种新的基于因子的主导跟随方法，用于构建跟踪指数的有限成分股组合。主导跟随方法采用严格的资产选择步骤，因此不受其他方法中由于启发式选择规则而出现的参数敏感性问题的影响。该方法的步骤基于风险因子的估计，因此在收益上市直观的。此外，该方法易于执行并且计算相对简单。本文的蒙特卡洛模拟实验和实证研究结果表明，主导跟随方法通过捕获指数成分股所有系统因子得到估计指数副本投资组合（主导个股集），能够以非常小的跟踪误差跟踪基础指数。

实证研究还表明，主导跟随方法平均仅使用 28 只主导个股，就可以跟踪由 421 只成分股组成的等权重标普 500 指数，并且相对于其他研究提出的方法具有更低的均方误差。此外，对 MSCI 美国小盘股指数跟踪的实证研究结果表明，该指数由 1391 只股票组成，主导跟随方法平均只需要 38 只主导个股即可准确跟踪该指数。实证分析结果表明选定的主导个股随着时间的推移是稳定的。主导跟随方法由于复制指数所需的换手率更低，指数基金使用该方法可以极大地节省交易成本。

分析师承诺

作者保证报告所采用的数据均来自合规渠道，分析逻辑基于本人的职业理解，通过合理判断并得出结论，力求客观、公正，结论不受任何第三方的授意、影响，特此声明。

风险提示

本报告版权归国信证券股份有限公司（以下简称“我公司”）所有，仅供我公司客户使用。未经书面许可任何机构和个人不得以任何形式使用、复制或传播。任何有关本报告的摘要或节选都不代表本报告正式完整的观点，一切须以我公司向客户发布的本报告完整版本为准。本报告基于已公开的资料或信息撰写，但我公司不保证该资料及信息的完整性、准确性。本报告所载的信息、资料、建议及推测仅反映我公司于本报告公开发布当日的判断，在不同时期，我公司可能撰写并发布与本报告所载资料、建议及推测不一致的报告。我公司或关联机构可能会持有本报告中所提到的公司所发行的证券头寸并进行交易，还可能为这些公司提供或争取提供投资银行业务服务。我公司不保证本报告所含信息及资料处于最新状态；我公司将随时补充、更新和修订有关信息及资料，但不保证及时公开发布。

本报告仅供参考之用，不构成出售或购买证券或其他投资标的的要约或邀请。在任何情况下，本报告中的信息和意见均不构成对任何个人的投资建议。任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。投资者应结合自己的投资目标和财务状况自行判断是否采用本报告所载内容和信息并自行承担风险，我公司及雇员对投资者使用本报告及其内容而造成的一切后果不承担任何法律责任。

个股投资咨询业务的说明

本公司具备中国证监会核准的证券投资咨询业务资格。证券投资咨询业务是指取得监管部门颁发的相关资格的机构及其咨询人员为证券投资者或客户提供证券投资的相关信息、分析、预测或建议，并直接或间接收取服务费用的活动。

证券研究报告是证券投资咨询业务的一种基本形式，指证券公司、证券投资咨询机构对证券及证券相关产品的价值、市场走势或者相关影响因素进行分析，形成证券估值、投资评级等投资分析意见，制作证券研究报告，并向客户发布的行为。

国信个股经济研究所

.....

深圳

深圳市罗湖区红岭中路 1012 号国信个股大厦 18 层

邮编: 518001 总机: 0755-82130833

上海

上海浦东民生路 1199 弄证大五道口广场 1 号楼 12 楼

邮编: 200135

北京

北京西城区金融大街兴盛街 6 号国信个股 9 层

邮编: 100032