

分析师：曹春晓
登记编号：S1220522030005

相关研究

投资要点

基金相似度问题在学界和业界都有相关的研究和讨论，但这些研究中关于比较不同计算方法的差异以及基金相似度在实际投资中的应用探讨并不多。

本篇报告总结了业界和学界常见的几类基金相似度算法，提出几类应用场景，并尝试在一些实际应用场景下进行探讨和比较。从基金相似度的计算方法来看，余弦相似度、欧式距离等方法各有优劣。基金相似度的衡量应该取决于投资者对于“基金相似”的定义以及应用场景，例如是选择定义“基金相似”为持仓结构的形似，还是持仓权重的神似。

应用场景一：寻找限制申购的替代基金。通过计算基金与其他基金的相似度，找到与限购基金最相似且处于正常申购状态的基金。从结果来看，除基于持仓交叉程度、行业维度相似度方法外，其他方法计算出的限购基金与替代基金的差距较小。

应用场景二：构建市场相似度最低的组合。利用相似度构建市场相似度最低的组合，将不同方法下构建的组合进行回测和对比。从结果可以看到，基于收益余弦相似度和收益相关系数构建的组合，最大回撤（-39.46%和-41.01%）小于动量策略的最大回撤（-53.42%）；夏普比率（0.72 和 0.72）高于动量策略（0.53），且在所有计算方法中组合夏普最高；此外市场相似度最低组合呈现行业分散、风格均衡等特点。

应用场景三：求解最大分散化的权重。通过最大化分散模型对已有组合进行权重优化。可以发现，加权方式下的组合年化夏普均高于等权组合（0.53）。其中基于收益维度的相关系数构建的组合，最大回撤较小（-43.45%）、夏普比率较高（0.59），并且权重在截面上更为集中，时序上与大盘呈负相关。

应用场景四：预估高换手基金的行业分布。通过找到相似收益的同类基金，再根据历史持仓和同类持仓去推测高换手率基金的行业持仓动向。结果发现，基于收益维度的各种方法平均上优于单纯依赖滞后持仓推断的行业分布。

应用场景五：预测下期收益相关系数。计算不同相似度与下季度收益相关系数的关系。可以发现，用当期收益相关系数去预测下期收益相关系数效果更好。

风险提示

本报告基于历史数据分析，历史规律未来可能存在失效的风险；市场可能发生超预期变化；基金相似关系发生变化风险。

目录

1	引言.....	4
2	基金相似度：多维度多方法衡量.....	4
2.1	相似度的计算方法.....	4
2.2	相似度的相关性.....	6
2.3	相似度的自相关性.....	7
3	相似度应用场景一：寻找限制申购基金的替代基金.....	8
3.1	应用场景.....	8
3.2	方法比较.....	8
4	相似度应用场景二：构建市场相似度最低组合.....	9
4.1	基金回测.....	9
4.2	组合特征.....	11
5	相似度应用场景三：求解最大分散化的权重.....	11
5.1	基金回测.....	11
5.2	权重分布.....	12
5.3	扩大基金池.....	13
6	相似度应用场景四：预估高换手基金的行业分布.....	14
6.1	应用场景.....	14
6.2	方法比较.....	15
7	相似度应用场景五：预测下期收益相关系数.....	16
8	总结.....	16
9	参考文献.....	17
10	附录.....	17
11	风险提示.....	17

图表目录

图表 1:	相似度的实际应用场景算法比较概览	4
图表 2:	基于 3 种维度不同方法下的相似度计算.....	6
图表 3:	基于 3 种维度不同方法下的相似度的秩相关系数.....	7
图表 4:	收益和持仓维度相似度的自相关性	7
图表 5:	行业和持仓维度相似度的自相关性	7
图表 6:	近年主动权益基金交易状态统计（只）	8
图表 7:	基金 A 与替代基金的季度收益对比	8
图表 8:	收益和持仓维度相似度限购替代效果	9
图表 9:	行业和持仓维度相似度限购替代效果	9
图表 10:	市场相似最低组合的绩效指标比较.....	10
图表 11:	市场相似最低组合的净值走势比较.....	10
图表 12:	收益相关系数组合的年度收益比较.....	10
图表 13:	市场相似最低组合的风格分布	11
图表 14:	市场相似最低组合的行业分布	11
图表 15:	最大化分散模型的绩效指标比较	12
图表 16:	截面权重集中度（只）	13
图表 17:	时序权重集中度与沪深 300 涨跌幅	13
图表 18:	扩大基金池后最大化分散模型的绩效指标比较.....	14
图表 19:	换手率第 10、第 1-5 组数量（只）	15
图表 20:	同类基金与基金 A 持仓的相似度	15
图表 21:	基于收益维度不同方法下的相似度预测效果.....	16
图表 22:	收益和持仓维度相似度预测效果	16
图表 23:	行业和持仓维度相似度预测效果	16
图表 24:	基于季报披露日期和季初计算的市场相似最低组合	17
图表 25:	基于季报披露日期和季初计算的最大化分散模型.....	17

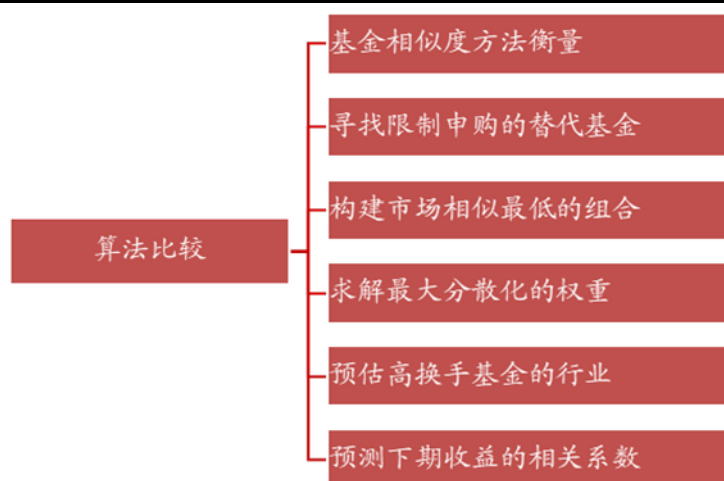
1 引言

近年来随着资本市场一系列改革措施逐步展开、国内居民财富管理需求进一步增长，权益类基金数量和规模迎来了爆发式的增长。截至2022年一季度末，主动权益类基金规模合计50218.92亿元，数量达3875只。一方面基金凭借其专业的投资和相对理性的运作对稳定市场起着一定的作用，另一方面由于在信息渠道、投资策略等方面相对一致，很多基金具有相似的特征¹。

基金相似度这个问题在国内学界和业界都过相关的讨论。（1）学界中主要集中在基金公司的共同持股策略和基金市场中的羊群行为等研究。例如陆蓉和李良松（2006）²研究了基金的共同持股行为的影响，屈源育和吴卫星（2014）³研究了明星家族基金在共同持有股票上的收益率差异及原因。（2）业界中基金相似度研究主要应用在寻找同类替代基金，或者构造不同风格的基金池等方面。

基金相似度从结果上刻画了两两基金之间的投资策略、操作风格等相近程度，可以为投资者提供更多的参考信息。但是不同计算方式下基金相似度指标有何差异？如何应用基金相似度进行投资决策？本文通过总结业界和学界常见的几类基金相似度的算法，提出几种创新应用场景，尝试在一些实际应用场景下进行探讨和比较。

图表1：相似度的实际应用场景算法比较概览



资料来源：方正证券研究所

2 基金相似度：多维度多方法衡量

2.1 相似度的计算方法

关于相似程度的衡量，这里介绍几种常见的推荐系统中相似程度的计算方法。部分算法可用 Python 中 sklearn.metrics.pairwise 或 scipy.spatial.distance 相关函数进行运算。

(1) 余弦相似度：通过计算两个向量夹角的余弦值来度量它们的相似程度。

$$\text{余弦相似度} = \cos(A, B) = \frac{A \cdot B}{\|A\| \cdot \|B\|} = \frac{\sum_{i=1}^n a_i \times b_i}{\sqrt{\sum_{i=1}^n a_i^2} \times \sqrt{\sum_{i=1}^n b_i^2}}$$

取值范围为[-1,1]。优点在于：计算简便；不受绝对值大小影响，关注向量之间的相对角度关系；高维可用。缺点在于：没有均值化处理；

严格要求维度数据不能缺少。

(2) 皮尔逊相关系数：先对向量的每一个分量做中心化，再计算余弦相似度¹。

$$\text{相关系数} = \rho(A, B) = \frac{A \cdot B}{\|A\| \cdot \|B\|} = \frac{\sum_{i=1}^n (a_i - \bar{a}) \times (b_i - \bar{b})}{\sqrt{\sum_{i=1}^n (a_i - \bar{a})^2} \times \sqrt{\sum_{i=1}^n (b_i - \bar{b})^2}}$$

取值范围为[-1,1]。特点在于改进余弦相似度维度数据缺失和无中心化的问题。

(3) 杰卡德相似系数：两集合中相似个体占总个体数比例，衡量两集合的交叉重叠程度。

$$\text{交叉程度} = J(A, B) = \frac{a \cap b}{a \cup b}$$

取值范围为[0,1]。缺点在于只关心共同特征的个体，并没有考虑向量中潜在数值的大小。

(4) 欧式距离：计算两点之间最短的直线距离。

$$\text{欧式距离} = d(A, B) = \|A - B\| = \sqrt{\sum_{i=1}^n (a_i - b_i)^2}$$

这里将距离转换为相似度：欧式相似度 = $\frac{1}{1+d(A,B)}$ 。取值范围为(0,1]。

优点在于易于理解，计算简单；考虑向量的绝对大小。缺点在于距离可能受各维度量纲不同而影响。

(5) 标准欧式距离：标准化处理后的欧氏距离。

$$\text{标准欧式距离} = sd(A, B) = \|A - B\| = \sqrt{\sum_{i=1}^n \frac{(a_i - b_i)^2}{s_i}}$$

这里将距离转换为相似度：标准欧式相似度 = $\frac{1}{1+sd(A,B)}$ 。取值范围为(0,1]。

优点在于改进欧式距离；缺点在于没有考虑到各个维度间的相关性。

(6) 马氏距离：在标准化欧式距离上考虑各维度之间的相互关系，将数据投影到 N(0,1) 区间并求其欧式距离

$$\text{马氏距离} = md(A, B) = \sqrt{(a - b)^T \Sigma^{-1} (a - b)}$$

这里将距离转换为相似度：马氏相似度 = $\frac{1}{1+md(A,B)}$ 。取值范围为(0, 1]。

优点在于解决量纲和相关性的问题，缺点在于要求整体样本数大于样本的维数，否则获得的整体样本协方差矩阵逆矩阵不存在；夸大了变化微小的变量的作用。

以上为常用相似度计算方法，具体在基金相似度研究中，学界中提出了几种衡量共同持股程度的方法：

(1) Cohold: Elton 等 (2007) 构建的指标，通过计算两只基金持有股票的最小权重之和，用于度量两只基金共同持股程度。

$$\text{Cohold}(A, B) = \sum_{i=1}^n \min(a_i, b_i)$$

(2) Meanstock 和 Meanfund: 陆蓉和李良松 (2006) 提出用 Meanstock

¹ 后文将皮尔逊相关系数简称为相关系数，杰卡德相似系数简称为交叉程度

和 Meanfund 衡量基金家族共同持股的严重程度。Meanstock 表示每只基金平均共同持有多少只股票，Meanfund 表示每只股票被多少基金持有²。

上述方法各有优劣，部分方法彼此联系、相互改进。但基金相似度的衡量应该取决于使用者对于“基金相似”的定义以及具体的应用场景，例如究竟是定义“基金相似”为持仓结构的形似，还是持仓权重的神似，考虑权重的大小相似还是方向相似，是否需要标准化等。

除方法差异外，我们还可以用多种维度衡量基金相似度。这里我们通过基金收益、股票持仓和行业分布的角度，分析基金的相似程度：(1) 收益维度：根据季度内基金的日度复权单位净值增长率计算基金相似度；(2) 持仓维度：根据季度基金重仓股的名称和权重计算基金相似度；(3) 行业维度：根据季度基金重仓股所属的中信一级行业的名称和权重计算基金相似度。

本文研究基于收益、持仓和行业维度，在不同的相似度算法下计算主动权益基金季度表现的相似程度。每季度计算所有主动权益基金³两两之间的相似指标，研究在不同的应用场景下，哪种维度的哪种指标效果最好。

图表2： 基于3种维度不同方法下的相似度计算

收益维度	持仓维度	行业维度
•余弦相似度 •欧氏相似度 •标准欧式相似度 •马氏相似度 •相关系数	•余弦相似度 •欧氏相似度 •标准欧式相似度 •交叉程度 •Cohold •相关系数	•余弦相似度 •欧氏相似度 •标准欧式相似度 •马氏相似度 •相关系数

资料来源：方正证券研究所

注：后文以“维度+方法”简称，例如基于收益维度的余弦相似度方法，简称收益余弦相似度

2.2 相似度的相关性

不同相似度方法计算得到的基金相似度，可能存在一定差异，我们通过考察不同计算方法的相关性，来比较不同方法所蕴含的信息的差异和联系。具体来看，我们计算每季度两两基金在不同方法下的相似度，并将不同方法得到的相似度求秩相关系数，再在时序上求均值，各维度基金相似度的相关性如下表所示。

² 本篇报告研究基金市场面的相似程度，Meanstock 和 Meanfund 指标暂不计算

³ 本篇报告主动权益基金的范围为股票仓位超过 60%、港股占比低于 50%、已上市、未到期的普通股票型、偏股混合型、灵活配置和平衡混合型的初始基金。

图表3： 基于3种维度不同方法下的相似度的秩相关系数

维度	指标1	指标2	相关性	维度	指标1	指标2	相关性	维度	指标1	指标2	相关性
持仓	余弦相似度	交叉程度	98.32%	行业	相关系数	欧氏相似度	45.71%	多维度	收益马氏相似度	收益相关系数	52.50%
	余弦相似度	Cohold	98.39%		相关系数	标准欧式相似度	47.97%		收益马氏相似度	持仓余弦相似度	25.80%
	欧氏相似度	余弦相似度	24.96%		标准欧式相似度	余弦相似度	50.53%		收益马氏相似度	持仓欧氏相似度	52.09%
	欧氏相似度	标准欧式相似度	32.64%		马氏相似度	余弦相似度	47.39%		收益相关系数	持仓余弦相似度	24.18%
	欧氏相似度	交叉程度	24.65%		马氏相似度	欧氏相似度	67.25%		收益相关系数	持仓欧氏相似度	34.12%
	欧氏相似度	Cohold	18.65%		马氏相似度	标准欧式相似度	98.81%		持仓欧氏相似度	持仓余弦相似度	24.96%
	标准欧式相似度	余弦相似度	39.21%		马氏相似度	相关系数	45.10%		行业余弦相似度	收益马氏相似度	19.52%
	标准欧式相似度	交叉程度	38.46%		欧氏相似度	余弦相似度	84.32%		行业余弦相似度	收益相关系数	32.13%
	标准欧式相似度	Cohold	37.49%		欧氏相似度	标准欧式相似度	96.72%		行业余弦相似度	持仓余弦相似度	47.38%
	交叉程度	Cohold	96.97%		标准欧式相似度	余弦相似度	81.97%		行业余弦相似度	持仓欧氏相似度	18.63%
	相关系数	余弦相似度	84.93%		马氏相似度	余弦相似度	52.44%		行业马氏相似度	收益马氏相似度	45.10%
	相关系数	欧氏相似度	13.46%		马氏相似度	欧氏相似度	62.74%		行业马氏相似度	收益相关系数	32.03%
	相关系数	标准欧式相似度	35.97%		马氏相似度	标准欧式相似度	69.93%		行业马氏相似度	持仓余弦相似度	28.14%
	相关系数	交叉程度	83.39%		马氏相似度	相关系数	52.50%		行业马氏相似度	持仓欧氏相似度	65.72%
	相关系数	Cohold	83.47%		相关系数	余弦相似度	99.85%		行业马氏相似度	行业余弦相似度	47.39%
行业	欧氏相似度	余弦相似度	55.62%		相关系数	欧氏相似度	84.21%				
	欧氏相似度	标准欧式相似度	69.54%		相关系数	标准欧式相似度	81.89%				
	相关系数	余弦相似度	97.80%								

资料来源：Wind, 方正证券研究所

从相关性结果来看：


(1)持仓维度，相关系数、余弦相似度、交叉程度和 Cohold 这四个指标的相关性较高，与欧式、标准欧式差异较大；(2)收益维度，马氏相似度和其他指标的相关性不高，其余指标相关性较高；(3)行业维度，马氏相似度与欧式、标准欧式高相关，相关系数和余弦相似度高度相关，但其余指标相关性较低；(4)多维度之间（每维度选2种），行业马氏相似度与持仓欧式相似度相关性较高外，其余关系维度之间相关性不高。

综上所述，除相关系数和余弦相似度在各个维度下呈现高度相关关系外，其余方法由于不同的数据特点和计算方式，各维度下并不是一定高度相关，部分指标之间仍然蕴含着不同程度上的相似度信息。

2.3 相似度的自相关性


接下来我们关注不同计算方法的自相关性，以衡量相似度指标的稳定性，计算每季度相似指标相邻两期之间秩相关系数。

图表4： 收益和持仓维度相似度的自相关性



资料来源：Wind, 方正证券研究所

图表5： 行业和持仓维度相似度的自相关性



资料来源：Wind, 方正证券研究所

从结果来看，采用欧式相似度计算而来的指标，自相关性较高，其中持仓维度的欧式相似度方法相邻两期之间的相关性最高。

3 相似度应用场景一：寻找限制申购基金的替代基金


3.1 应用场景

2018 年以来，市场行情波动较大，为了保护投资者的权益，较多基金开启了限制申购的措施。

而对于这些限制申购的基金，我们可以待其恢复正常申购状态再进行买入，也可以通过寻找与限制申购基金相似的基金作为替代。这里我们考虑寻找限制申购基金的替代基金，通过计算基金与其他基金的相似度，找到与限购基金最相似且处于正常申购状态的基金。

例如基金 A 在 2018 年至 2021 年处于暂停申购状态，我们可以通过基于收益维度的欧式相似度指标，找到当前季度相似度最高且正常申购状态的一只基金作为替代，比较两只基金下季度的收益。如图表 7 所示，可以发现限购基金和替代基金的季度收益接近、累计收益相似（80.15% 和 84.24%），可以用替代基金来实现投资基金 A 的目的。

图表6： 近年主动权益基金交易状态统计（只）



资料来源：Wind, 方正证券研究所

注：定义限制申购为处于封闭期、暂停申购和限制大额申购的基金。由于 2018 年以来限购基金明显增多，本节主要研究时间区间为 2018 年至 2021 年。

图表7： 基金 A 与替代基金的季度收益对比

季度	交易状态	替代基金	限购基金季度收益	替代基金季度收益
2018/3/31	暂停申购	基金1	2.59%	-7.83%
2018/6/30	暂停申购	基金2	-1.96%	-5.01%
2018/9/30	暂停申购	基金3	-11.29%	-13.51%
2018/12/31	暂停申购	基金3	23.74%	26.32%
2019/3/31	暂停申购	基金4	7.56%	0.88%
2019/6/30	暂停申购	基金5	7.64%	12.29%
2019/9/30	暂停申购	基金5	6.26%	11.01%
2019/12/31	暂停申购	基金5	4.57%	6.68%
2020/3/31	暂停申购	基金6	28.42%	28.21%
2020/6/30	暂停申购	基金7	10.20%	12.58%
2020/9/30	暂停申购	基金8	11.95%	17.85%
2020/12/31	暂停申购	基金9	-3.03%	-5.47%
2021/3/31	暂停申购	基金9	14.49%	17.56%
2021/6/30	暂停申购	基金9	-10.37%	-11.18%
2021/9/30	暂停申购	基金10	-2.36%	8.18%
2021/12/31	暂停申购	基金9	-17.61%	-20.94%
累计收益			80.15%	84.24%


资料来源：Wind, 方正证券研究所

3.2 方法比较

同理可对其他相似度指标进行相同操作，匹配每期所有限制申购基金，比较替代基金与限购基金的未来季度收益差异。为了对比不同维度不同方法相似度，我们计算限制申购基金与替代基金下季度真实收益差的平方和，衡量不同相似度指标的替换效果。


$$\text{替换效果}^{t+1} = \sum_j \left(r_{\text{限购基金}j}^{t+1} - r_{\text{替代基金}}^{t+1} \right)^2$$

图表8： 收益和持仓维度相似度限购替代效果



资料来源：Wind, 方正证券研究所

图表9： 行业和持仓维度相似度限购替代效果



资料来源：Wind, 方正证券研究所

从结果来看，基于持仓交叉程度、行业维度的各种方法计算出的替代基金与目标基金差异较大，可能是因为持仓交叉程度只统计共同持股数量，没有关注持股权重，而基于行业维度只关注行业层面的相似性，实际每只股票的持仓和涨跌可能差异较大，因此导致替代基金与限购基金的走势差异较大。而基于收益维度和基于持仓维度的其他方法计算出的限购基金与替代基金的差距较小，是较好的替代选择。

4 相似度应用场景二：构建市场相似度最低组合

4.1 基金回测

基金相似度从结果上刻画两两基金之间的投资策略、操作风格等方面的相近程度。综合利用所有基金的相似度信息，我们可以构建与市场相似度最低的组合。

例如我们可以将基金 A 与所有基金的相似度的均值定义为基金 A 的市场相似度。通过计算 16 种方法下基金 A 的市场相似程度，每季度根据所有基金的市场相似程度的因子大小排序，选出市场相似程度最低的 50 只基金进行等权投资。季初调仓，将基于 16 种相似度方法下的基金回测与动量策略（选季度收益最高的 50 只基金）进行比较。


图表10: 市场相似最低组合的绩效指标比较

方法	总收益率	年化收益	最大回撤	年化波动	年化夏普	日度胜率	平均年换手率
动量策略	247.52%	10.71%	-53.42%	20.37%	0.53	52.99%	348.77%
偏股混合基金	157.58%	8.03%	-43.35%	20.71%	0.39	52.96%	
收益余弦相似度	223.32%	10.06%	-39.46%	14.05%	0.72	53.12%	227.23%
收益欧氏相似度	162.15%	8.19%	-57.09%	17.79%	0.46	52.68%	206.30%
收益标准欧式相似度	173.28%	8.56%	-55.90%	17.87%	0.48	52.45%	194.72%
收益马氏相似度	140.89%	7.44%	-53.94%	17.77%	0.42	53.59%	238.30%
收益相关系数	229.97%	10.24%	-41.01%	14.14%	0.72	52.99%	228.77%
持仓余弦相似度	256.80%	10.95%	-47.21%	18.14%	0.6	54.59%	208.85%
持仓欧氏相似度	202.85%	9.47%	-49.85%	18.54%	0.51	53.05%	176.68%
持仓标准欧式相似度	193.88%	9.20%	-48.96%	18.07%	0.51	54.15%	216.00%
持仓交叉程度	247.03%	10.69%	-50.77%	18.41%	0.58	54.18%	199.83%
持仓Cohold	198.47%	9.34%	-48.87%	17.97%	0.52	54.08%	189.28%
持仓相关系数	265.14%	11.15%	-46.98%	18.19%	0.61	54.72%	206.47%
行业余弦相似度	218.51%	9.92%	-45.69%	17.29%	0.57	53.70%	194.38%
行业欧氏相似度	221.49%	10.01%	-47.96%	18.48%	0.54	52.99%	161.87%
行业标准欧式相似度	208.38%	9.63%	-46.38%	17.81%	0.54	53.05%	196.26%
行业马氏相似度	202.10%	9.45%	-46.18%	17.77%	0.53	53.19%	198.13%
行业相关系数	255.06%	10.90%	-45.22%	17.35%	0.63	54.07%	221.11%

资料来源: Wind, 方正证券研究所

注: 回测时间为 2010.1.1-2022.3.31。按照季初调仓。但实际投资中基金于季末结束第十五个工作日前公布重仓股, 故附录一采用季度披露后第一交易日进行持仓维度和行业维度的调仓。

图表11: 市场相似最低组合的净值走势比较



资料来源: Wind, 方正证券研究所

图表12: 收益相关系数组合的年度收益比较

年份	动量策略	收益相关系数	偏股基金指数
2010	10.75%	3.52%	5.31%
2011	-20.71%	-20.00%	-22.70%
2012	5.60%	7.18%	3.65%
2013	18.52%	16.57%	12.73%
2014	28.96%	26.94%	22.24%
2015	33.66%	36.29%	43.17%
2016	-17.37%	-13.74%	-13.03%
2017	16.82%	18.14%	14.12%
2018	-23.59%	-19.54%	-23.58%
2019	52.74%	40.67%	45.02%
2020	78.56%	47.69%	55.91%
2021	11.02%	12.02%	7.68%
2022	-17.85%	-3.40%	-16.69%

资料来源: Wind, 方正证券研究所

从组合的回测结果可以发现:

- (1) 从风险控制角度, 收益余弦相似度和收益相关系数构建的组合的最大回撤(-39.46%和-41.01%)小于动量策略的最大回撤(-53.42%);
- (2) 从风险收益比来看, 收益余弦相似度和收益相关系数组合夏普比率(0.72 和 0.72) 高于动量策略(0.53), 且在所有方法回测中夏普比率最高;

- (3) 从收益角度, 持仓相关系数组合的收益最高(11.15%)。

综上所述, 基于收益维度的余弦相似度和相关系数构建的市场相似最小组合, 最大回撤较小、夏普比率较高。结合后文的结论, 这可能与他们预测未来收益相似度的效果最好有关。

从年份收益来看, 如图表 12 所示, 收益相关系数构建的组合在市场下跌区间(2011 年、2016 年和 2018 年、2022 年期间)表现更好, 可能的原因在于市场相似程度最低的基金呈现行业分散、风格均衡的特点, 因此实现了风险分散化投资。

4.2 组合特征

市场相似最小的基金组合在市场下跌时表现较好可能与其行业和风格分布相关。

(1) 风格均衡

利用重仓股的财务、估值等指标，计算出每只基金的持股风格及分位数，等权单只基金的分位数，得到组合风格的分位数水平。

以 2022 年一季度、基于收益相关系数构建的组合为例，可以发现，组合在市值、估值、盈利、成长性等风格上，位于所有基金的中位数水平、风格表现均衡。风格时序上，沪深 300 收益与市值分位数的相关性为负 ($\rho(\text{流通市值, 沪深 300}) = -17.06\%$)，与估值分位数的相关性为正 ($\rho(\text{PE_TTM, 沪深 300}) = 33.93\%$)。即市场下跌时，组合会更倾向于市值较高、估值较低的风格。


(2) 行业分散

计算基金在中信一级行业的持股数量，求出组合平均在每个行业的持股数量。

以 2022 年一季度的持仓、基于收益相关系数构建的组合为例，可以发现，组合行业分布分散，大部分一级行业均有涉及。组合时序上，当市场下跌时，组合行业分布可能会更多向金融地产、有色金属等行业倾斜。


综上所述，由于市场相似最低组合呈现风格均衡、行业分散的特点，并且在市场下跌中，风格会更向高市值、低估值倾斜，分布可能会更测重于金融地产、有色金属等行业，因此组合夏普较高且在市场下跌区间表现更好。

图表13： 市场相似最低组合的风格分布



资料来源：Wind, 方正证券研究所

图表14： 市场相似最低组合的行业分布



资料来源：Wind, 方正证券研究所

5 相似度应用场景三：求解最大分散化的权重

5.1 基金回测

Choueifaty 和 Coignard 在 2008 年提出最大化分散模型⁴，提出考虑不同资产之间的相关性来降低整个组合风险。最大化分散模型的目标是使得组合的加权标准差与组合标准差之比最大：

$$w = \operatorname{argmax} \left(\frac{\delta'w}{\sqrt{w'\Sigma w}} \right), \text{ 其中, } w'I = 1, w_i \in (0, 100\%]$$

在最大化分散模型中，我们可以进一步将协方差拆解为相关性和标准

差，通过替换最大化分散模型中的相关性为上文中 16 种方法下的相关程度，以此来重新估计协方差矩阵。通过最优化模型求解得到 50 只基金的权重，再根据不同基金的权重对组合进行加权投资。为避免权重过小，这里设置单只基金下限为 0.01%；为更贴近实际情况，将单只基金的上限调整为 20%。

$$w = \operatorname{argmax} \left(\frac{\delta'w}{w'\Sigma w} \right), \text{ 其中 } \Sigma = \delta'\rho\delta, w'I = 1, w_i \in (0.01\%, 20\%]$$

由于本节侧重于利用相似度优化组合权重，如何选基不是本节的重点，这里我们选用常见的动量策略构成我们的基础组合，考虑季度收益最高的 50 只基金作为基金池，利用最大化分散模型进行权重优化，并与等权组合进行比较。

图表15： 最大化分散模型的性能指标比较

方法	总收益率	年化收益	最大回撤	年化波动	年化夏普	日度胜率
等权	247.52%	10.71%	-53.42%	20.37%	0.53	52.99%
加权收益余弦相似度	241.88%	10.56%	-43.82%	18.07%	0.58	52.82%
加权收益欧氏相似度	238.31%	10.46%	-47.45%	19.42%	0.54	53.05%
加权收益标准欧式相似度	261.58%	11.07%	-50.83%	19.61%	0.56	53.12%
加权收益马氏相似度	244.86%	10.64%	-52.12%	19.94%	0.53	52.55%
加权收益相关系数	242.31%	10.57%	-43.45%	18.00%	0.59	52.89%
加权持仓余弦相似度	239.89%	10.51%	-50.38%	19.33%	0.54	53.80%
加权持仓欧氏相似度	263.19%	11.11%	-53.44%	19.82%	0.56	53.26%
加权持仓标准欧式相似度	262.67%	11.09%	-52.46%	19.84%	0.56	53.29%
加权持仓交叉程度	240.81%	10.53%	-50.59%	19.37%	0.54	53.86%
加权持仓Cohold	239.22%	10.49%	-49.89%	19.33%	0.54	53.83%
加权持仓相关系数	239.86%	10.51%	-50.38%	19.34%	0.54	53.80%
加权行业余弦相似度	246.37%	10.68%	-52.10%	19.67%	0.54	53.63%
加权行业欧氏相似度	255.62%	10.92%	-53.71%	19.69%	0.55	53.32%
加权行业标准欧式相似度	269.27%	11.26%	-51.87%	19.57%	0.58	53.53%
加权行业马氏相似度	266.66%	11.19%	-51.89%	19.59%	0.57	53.39%
加权行业相关系数	265.52%	11.16%	-48.61%	19.42%	0.58	54.27%

资料来源：Wind, 方正证券研究所

从回测结果中可以发现：

- (1) 最大回撤端，基于收益维度的余弦相似度、收益相关系数的最大回撤（-43.82%和-43.45%）较等权组合的（-53.42%）更小；
- (2) 风险收益端，加权方式下的组合年化夏普高于等权组合（0.53）。其中基于收益相关系数的组合，最大回撤较小（-43.45%）、夏普比率较高（0.59）。与前节一致，这可能与基于收益维度的相关系数预测未来收益相似度的效果最好有关。

5.2 权重分布

最大化分散模型改进了组合权重，接下来我们对权重的分布进行分析。

（1）截面上：基于相关系数的加权方式的权重更为集中，基于标准欧式和马氏的权重更为分散。

最优化模型中 50 只基金权重限制在(0.01%,20%)之间，我们统计每期权重大于 0.02%的基金数量，来衡量权重的集中度。权重大于 0.02%的基金数量越少，认为权重越集中，反之亦然。

图表 16 为 2022/3/31 不同加权方法下，权重大于 0.02%的基金数量。结果可以发现，基于相关系数和余弦相似度的权重更为集中（收益维度，6 只和 6 只），基于标准欧式和马氏的权重更为分散(50 只和 50

只)。这可能与指标的标准化程度有关。权重集中意味着组合中较少的基金占据了更多的权重。例如我们利用基于收益的相关系数衡量相似度，计算最大化分散模型的权重后，大于 0.02% 的数量为 6 只，其余 44 只权重占比均小于 0.02%。


(2) 时序上：权重集中度、基金相关性与大盘指数呈负相关。

以收益维度的相关系数为例，计算权重集中度与沪深 300 涨跌幅的关系。从图表 17 的计算结果看，权重集中度与大盘指数呈负相关关系，秩相关系数为-15%。即市场下跌，权重更为分散，市场上涨，权重更集中。

这点可能跟基金相关性与市场大盘呈负相关有关。计算收益相关系数均值与沪深 300 季度涨跌幅的关系，可以求出两者的相关性为-30%。即在大部分时间内，市场上涨，基金相关性下降；市场下跌，基金相关性上涨。


而当市场下跌，相关性提高时，最大化分散模型将原来的权重更多地集中在低相关性资产中，权重集中度上升。因此股市下跌，基金相关性提高，权重更为分散。

图表16: 截面权重集中度 (只)



资料来源: Wind, 方正证券研究所

图表17: 时序权重集中度与沪深 300 涨跌幅



资料来源: Wind, 方正证券研究所

5.3 扩大基金池

前节中 50 只基金作为基金池可能存在风格和行业上具有聚集的特点。若我们扩大选定的基金池，将基于动量策略的 50 只基金，扩为 200 只。从图表 18 的结果中可以发现，基于收益的余弦相似度和相关系数的组合表现仍然稳健，具有较低的最大回撤和较高的年化夏普比率。权重截面上，也与前文结论类似。

图表18: 扩大基金池后最大化分散模型的性能指标比较

方法	总收益率	年化收益	最大回撤	年化波动	年化夏普	日度胜率
等权	217.20%	9.88%	-51.25%	19.38%	0.51	52.99%
加权收益余弦相似度	305.73%	12.12%	-42.65%	15.79%	0.77	52.82%
加权收益欧氏相似度	240.82%	10.53%	-45.77%	17.94%	0.59	53.09%
加权收益标准欧式相似度	249.84%	10.77%	-48.83%	18.43%	0.58	53.22%
加权收益马氏相似度	237.79%	10.45%	-49.86%	19.27%	0.54	53.02%
加权收益相关系数	337.95%	12.82%	-42.81%	15.73%	0.81	52.58%
加权持仓余弦相似度	261.34%	11.06%	-49.16%	18.83%	0.59	53.83%
加权持仓欧氏相似度	239.83%	10.50%	-51.12%	19.21%	0.55	53.29%
加权持仓标准欧式相似度	242.63%	10.58%	-50.31%	19.08%	0.55	53.32%
加权持仓交叉程度	262.19%	11.08%	-48.98%	18.82%	0.59	53.83%
加权持仓Cohold	258.66%	10.99%	-49.07%	18.79%	0.59	53.80%
加权持仓相关系数	259.15%	11.00%	-49.17%	18.84%	0.58	53.83%
加权行业余弦相似度	251.27%	10.80%	-53.21%	19.26%	0.56	53.49%
加权行业欧氏相似度	221.86%	10.02%	-52.04%	19.11%	0.52	53.22%
加权行业标准欧式相似度	259.13%	11.00%	-51.52%	19.09%	0.58	53.43%
加权行业马氏相似度	252.77%	10.84%	-51.36%	19.06%	0.57	53.46%
加权行业相关系数	219.20%	9.94%	-51.88%	18.77%	0.53	54.03%

资料来源: Wind, 方正证券研究所

6 相似度应用场景四: 预估高换手基金的行业分布

6.1 应用场景

判断基金持仓的行业分布, 可以通过追溯基金历史持股的行业风格来进行分析。而对于高换手率的基金, 滞后的持仓数据往往不能反映真实持仓的行业变化, 通常我们可以利用收益数据和行业数据进行回归, 通过回归系数估计基金的行业分布, 但是系数可能不稳定。

这里我们尝试另一种做法, 融合持仓和收益的信息, 通过找到收益相似的同类基金, 利用历史持仓和同类基金持仓去推测高换手率基金的持仓动向。

例如 2020/12/31, 我们想预估基金 A 在 2020 年四季度的行业分布, 但基金 A 的 2020 年四季报、2020 年报暂未公布。那我们可以按照下述三个步骤寻找同类基金, 预测基金 A 的行业配置:

(1) 匹配同类基金

首先根据 2020 年半年报的换手率, 将所有基金分为 10 组。假设基金 A 属于第 10 组高换手率基金, 将第 1 组至第 5 组的基金合并为同类低换手率基金池。计算 2020/09/30 至 2021/12/31 高换手率基金与同类低换手率基金池两两之间的收益相似度, 从低换手率基金池中找到与基金 A 收益相似的 50 只基金。

单独分类第 10 组、合并分类第 1 组至第 5 组是为了避免低换手率基金数量过少导致基金池在行业、风格上分布不均匀, 从而影响寻找第 10 组同类基金的准确性。

(2) 以相似度加权

以收益相似度对 50 只基金在 2020 年三季报的行业分布进行加权。采用普通的加权方式计算其行业分布, r_i 表示基金 A 与基金 i 的收益相似度, 则基金 A 在行业 x 估计权重为:


$$u_{A*}^t = \sum_{i=1}^{50} \left(\frac{r_i}{\sum_{i=1}^{50} r_i} * d_i^{t-1} \right),$$

其中加权算法的逻辑在于: 如果两只基金在收益表现上更相似, 则持仓可能更为相近。例如计算某基金与同类基金当期持仓的相似度的关

系，如图 20 所示，横轴为 50 只基金按照收益相似度从左到右排序，纵轴为基金 A 与每只基金的持仓的余弦相似度。可以发现，整体上，随着收益相似度降低，持仓相似度也相应降低。


但其实也可采用等权的做法，计算更为简洁，两者结果差异不大。

图表19： 换手率第 10、第 1-5 组数量（只）



资料来源：Wind, 方正证券研究所

图表20： 同类基金与基金 A 持仓的相似度



资料来源：Wind, 方正证券研究所

(3) 结合上期分布

将 (2) 中得到的同类低换手率基金的行业分布与上季度基金 A 的重仓行业分布求平均值, 得到基金 A 在 2020/12/31 的行业配置预测结果:

$$d_{A*}^t = (u_{A*}^t + d_A^{t-1})/2$$

结合基金 A 上期行业分布的原因有二: 1. 弥补换手率风格变化风险。如果我们直接用同类低换手率基金的行业推测高换手率基金, 即是认为历史换手率风格会延续, 高换手率基金仍然会高换手, 低换手率基金仍然会低换手。若换手率延续, 高换手率基金的行业分布与上期发生明显差异; 但若换手率不延续, 高换手率基金的上期历史持仓则具有参考价值。由于我们事前不知道换手率风格是否延续, 因此采用同类低换手率基金与基金 A 上期历史持仓相结合的方式。2. 校准数据偏差, 避免同类低换手率基金的行业风格过于极端。

根据上述做法, 基金 A 在 2020/12/31 某行业的预测配置为:

$$d_{A*}^t = 0.5 * \sum_{i=1}^{50} \left(\frac{r_i}{\sum_{i=1}^{50} r_i} * d_i^{t-1} \right) + 0.5 * d_A^{t-1}$$

6.2 方法比较

我们按照上述步骤计算所有高换手基金的行业分布, 然后再计算预测的行业分布与真实行业分布的余弦相似度, 最后与直接利用滞后重仓股行业分布的预测结果做比较。

对于每季度所有基金重复上述操作, 统计每期预测方法超过滞后持仓预测方法的比例:


$$\text{胜率} = \frac{\text{num} \left(\text{持仓余弦相似度}_{(\text{预测}, \text{真实})} > \text{持仓余弦相似度}_{(\text{历史}, \text{真实})} \right)}{\text{num}(\text{基金总数})}$$

对于基于收益维度的不同方法计算每期的胜率, 从结果中可以发现:

- (1) 收益相似度指标下的比较胜率均超过 40%, 时序均值为 74%;
- (2) 5 种计算方式中, 马氏相似度胜率较低, 其余四类指标胜率相近且高于马氏相似度。

因此从结果来看，基于收益维度的各种方法平均来看均优于单纯依靠滞后持仓计算的结果，余弦相似度、欧式相似度、标准欧式相似度的预测效果比马氏相似度更好。

图表21： 基于收益维度不同方法下的相似度预测效果



资料来源：Wind, 方正证券研究所


上述以季度末节点时间为基础，以高换手率为条件，预测当季度末披露的重仓股概况。读者亦可尝试在指定时间，滚动找出目标基金的同类型基金，综合短、长期信息，推测目标基金的重仓/全部行业分布特点。

7 相似度应用场景五：预测下期收益相关系数

计算所有基金不同方法下相似度与下季度收益相关系数的秩相关系数，比较各种相似度指标对于未来收益相似的预测效果。


从结果可以发现，用当期收益相关系数或余弦相似度去预测下期收益相关系数效果最好。

图表22： 收益和持仓维度相似度预测效果



资料来源：Wind, 方正证券研究所

图表23： 行业和持仓维度相似度预测效果



资料来源：Wind, 方正证券研究所

8 总结

基金相似度问题在学界和业界都有过相关的讨论。但是关于不同计算方式的基金相似度的差异、基金相似度在实际投资中的运用，这方面的研究并不多。

本篇报告中将不同相似度算法进行比较，并提出了几个创新的应用场

景，希望能给读者一些想法和启发。

同时本篇报告仅从单维度单个方法进行比较，后续可以尝试将不同维度的相似度进行组合，综合利用各种相似信息，构建基金相似度体系。此外本篇报告利用了季度收益、持仓、行业等信息，读者也可尝试从股票仓位、持股集中度、持股风格等角度比较基金相似性。

9 参考文献

- [1]祁斌, 袁克, 胡倩,等. 我国证券投资基金羊群行为的实证研究[J]. 证券市场导报, 2006(12):9.
- [2]陆蓉, 李良松. 家族共同持股对基金管理公司业绩与风险的影响研究[J]. 金融研究, 2008(2):12.
- [3]屈源育, 吴卫星. 基金家族的造星策略——基于共同持股股票收益率差异视角[J]. 财经研究, 2014(4):14.
- [4] Choueifaty Y, Coignard Y. Toward Maximum Diversification[J]. Journal of Portfolio Management, 2008, 35(1):40-51.

10 附录

附录一：考虑季报披露日期的持仓和行业数据后，结论与前文一致。

图表24： 基于季报披露日期和季初计算的市场相似最低组合

方法	总收益率	年化收益	最大回撤	年化波动	年化夏普	日度胜率	平均年换手率
动量策略	247.52%	10.71%	-53.42%	20.37%	0.53	52.99%	348.77%
收益余弦相似度	223.32%	10.06%	-39.46%	14.05%	0.72	53.12%	227.23%
收益欧氏相似度	162.15%	8.19%	-57.09%	17.79%	0.46	52.68%	206.30%
收益标准欧式相似度	173.28%	8.56%	-55.90%	17.87%	0.48	52.45%	194.72%
收益马氏相似度	140.89%	7.44%	-53.94%	17.77%	0.42	53.59%	238.30%
收益相关系数	229.97%	10.24%	-41.01%	14.14%	0.72	52.99%	228.77%
持仓余弦相似度	232.99%	10.32%	-47.46%	18.02%	0.57	54.36%	208.85%
持仓欧氏相似度	221.39%	10.00%	-48.77%	18.42%	0.54	52.92%	176.68%
持仓标准欧式相似度	181.78%	8.83%	-48.73%	17.95%	0.49	53.98%	216.00%
持仓交叉程度	229.99%	10.24%	-49.63%	18.28%	0.56	53.92%	199.83%
持仓Cohold	195.53%	9.25%	-46.99%	17.82%	0.52	54.02%	189.28%
持仓相关系数	238.21%	10.46%	-47.42%	18.09%	0.58	54.32%	206.47%
行业余弦相似度	211.75%	9.73%	-44.64%	17.35%	0.56	53.93%	194.38%
行业欧氏相似度	206.31%	9.57%	-48.73%	18.33%	0.52	53.02%	161.87%
行业标准欧式相似度	211.82%	9.73%	-46.32%	17.78%	0.55	53.26%	196.26%
行业马氏相似度	203.81%	9.50%	-46.34%	17.71%	0.54	53.46%	198.13%
行业相关系数	265.04%	11.15%	-44.77%	17.35%	0.64	54.31%	221.11%

资料来源：Wind, 方正证券研究所

附录二：考虑季度披露的持仓数据和行业后，基于持仓和行业维度的组合夏普有了一定的提升。

图表25： 基于季报披露日期和季初计算的最大化分散模型

方法	总收益率	年化收益	最大回撤	年化波动	年化夏普	日度胜率
等权	247.52%	10.71%	-53.42%	20.37%	0.53	52.99%
加权收益余弦相似度	241.88%	10.56%	-43.82%	18.07%	0.58	52.82%
加权收益欧氏相似度	238.31%	10.46%	-47.45%	19.42%	0.54	53.05%
加权收益标准欧式相似度	261.58%	11.07%	-50.83%	19.61%	0.56	53.12%
加权收益马氏相似度	244.86%	10.64%	-52.12%	19.94%	0.53	52.55%
加权收益相关系数	242.31%	10.57%	-43.45%	18.00%	0.59	52.89%
加权持仓余弦相似度	304.76%	12.09%	-48.05%	18.95%	0.64	54.41%
加权持仓欧氏相似度	309.49%	12.20%	-49.97%	19.45%	0.63	53.49%
加权持仓标准欧式相似度	314.61%	12.31%	-49.49%	19.42%	0.63	53.46%
加权持仓交叉程度	308.85%	12.19%	-48.14%	18.98%	0.64	54.44%
加权持仓Cohold	294.87%	11.87%	-47.92%	18.94%	0.63	54.31%
加权持仓相关系数	305.19%	12.10%	-48.04%	18.95%	0.64	54.41%
加权行业余弦相似度	347.71%	13.02%	-49.42%	19.62%	0.66	53.87%
加权行业欧氏相似度	311.20%	12.24%	-49.73%	19.39%	0.63	53.56%
加权行业标准欧式相似度	324.39%	12.53%	-48.44%	19.26%	0.65	53.80%
加权行业马氏相似度	319.80%	12.43%	-48.51%	19.29%	0.64	53.77%
加权行业相关系数	364.85%	13.37%	-46.78%	19.23%	0.7	54.75%

资料来源：Wind, 方正证券研究所

11 风险提示

本报告基于历史数据分析，历史规律未来可能存在失效的风险；市场可能发生超预期变化；基金相似关系发生变化风险。

分析师声明

作者具有中国证券业协会授予的证券投资咨询执业资格，保证报告所采用的数据和信息均来自公开合规渠道，分析逻辑基于作者的职业理解，本报告清晰准确地反映了作者的研究观点，力求独立、客观和公正，结论不受任何第三方的授意或影响。研究报告对所涉及的证券或发行人的评价是分析师本人通过财务分析预测、数量化方法、或行业比较分析所得出的结论，但使用以上信息和分析方法存在局限性。特此声明。

免责声明

本研究报告由方正证券制作及在中国（香港和澳门特别行政区、台湾省除外）发布。根据《证券期货投资者适当性管理办法》，本报告内容仅供我公司适当性评级为C3及以上等级的投资者使用，本公司不会因接收人收到本报告而视其为本公司的当然客户。若您并非前述等级的投资者，为保证服务质量、控制风险，请勿订阅本报告中的信息，本资料难以设置访问权限，若给您造成不便，敬请谅解。

在任何情况下，本报告的内容不构成对任何人的投资建议，也没有考虑到个别客户特殊的投资目标、财务状况或需求，方正证券不对任何人因使用本报告所载任何内容所引致的任何损失负任何责任，投资者需自行承担风险。

本报告版权仅为方正证券所有，本公司对本报告保留一切法律权利。未经本公司事先书面授权，任何机构或个人不得以任何形式复制、转发或公开传播本报告的全部或部分内容，不得将报告内容作为诉讼、仲裁、传媒所引用之证明或依据，不得用于营利或用于未经允许的其它用途。如需引用、刊发或转载本报告，需注明出处且不得进行任何有悖原意的引用、删节和修改。

公司投资评级的说明：

强烈推荐：分析师预测未来半年公司股价有20%以上的涨幅；
 推荐：分析师预测未来半年公司股价有10%以上的涨幅；
 中性：分析师预测未来半年公司股价在-10%和10%之间波动；
 减持：分析师预测未来半年公司股价有10%以上的跌幅。

行业投资评级的说明：

推荐：分析师预测未来半年行业表现强于沪深300指数；
 中性：分析师预测未来半年行业表现与沪深300指数持平；
 减持：分析师预测未来半年行业表现弱于沪深300指数。

地址	网址： https://www.foundersc.com	E-mail: yjzx@foundersc.com
北京	西城区展览馆路48号新联写字楼6层	
上海	静安区延平路71号延平大厦2楼	
上海	浦东新区世纪大道1168号东方金融广场A栋1001室	
深圳	福田区竹子林紫竹七道光大银行大厦31层	
广州	天河区兴盛路12号楼 隽峰苑2期3层方正证券	
长沙	天心区湘江中路二段36号华远国际中心37层	