

AlphaCY 系统优化系列报告（一）

——引入多时间维度特征对市场短期状态分类优化

✎ : 邱冠华 执业证书编号: S1230520010003
☎ : 021-80106037
✉ : qiuguanhua@stocke.com.cn

报告导读

本文对 1.0 版本进行了优化，并在多个投资场景进行了应用测试。优化的内容主要涉及更多维度的价量信息以及更具解释性的网络结构。优化之后，2.0 版在识别短期市场状态上的精度较 1.0 版提升了约 10%。

报告摘要

□ 借助深度学习对个股的市场短期状态进行有效识别

将 A 股市场赛道择优模型应用于对个股的短期状态预测，并测试引入短期和中长期时间维度的同类型特征对模型进行优化。

□ 不同时间维度数据特征带来的增益

在现有的股票日级别量价数据基础上，为了让状态分类模型能对价量变化做出更及时的反应，引入更高频的数据；同时我们考虑市场变化偏离预期的情况，引入低频数据，让模型适应更长时间历史数据中的行情特征。

□ 利用卷积网络内部参数观察股票价量微结构

训练完成所得到的卷积核参数在部分特征上的集中分布，揭示了股票的价量特征之间的内在联系，而这种短期市场微结构正是特征工程要提取的有用信息。

□ 对市场状态预测与跟踪的应用意义

对个股市场状态的预测结果已经能直观体现其在不同的价格变动趋势，并且在价格拉升或者下跌的早期就能做出比较准确的判断，也为后续通过强化学习模型进行投资决策奠定了机器视觉基础。此外，在不同类型的资产上进行简单择时策略的回测也证明了系统的广阔应用前景。

相关报告

《回归初心，专注市场——做人人能懂的金融工程》

《“成绩”的赛道 0.1.0 版》

正文目录

1. 研究背景.....	4
1.1. 深度学习模型.....	4
1.2. 预测个股的市场短期状态.....	4
2. 优化市场状态分类模型.....	5
2.1. 特征转换方法: GAF 与 NT.....	5
2.2. 扩充不同时间维度的数据特征.....	6
2.3. 优化卷积网络结构.....	8
3. 模型测试表现对比.....	12
3.1. 个股市场状态预测准确度.....	12
3.2. 个股市场状态预测结果对股价波动的提示效果.....	13
4. 市场状态预测应用案例.....	14
4.1. 基于市场状态预测的择时策略.....	14
4.2. 策略应用于不同类型资产的表现结果.....	15
5. 总结.....	18
参考文献.....	19

图表目录

图 1: 用历史数据生成样本特征的采样原理.....	6
图 2: 股票样本 000498.SZ 日级别 K 线及对应的 NT 转换.....	7
图 3: 股票样本 000498.SZ 日级别 K 线对应的 GAF 转换.....	7
图 4: 股票样本 000498.SZ 周级别 K 线及对应的 NT 转换.....	7
图 5: 股票样本 000498.SZ 周级别 K 线对应的 GAF 转换.....	7
图 6: 股票样本 000498.SZ 60min 级别 K 线及对应的 NT 转换.....	8
图 7: 股票样本 000498.SZ 60min 级别 K 线对应的 GAF 转换.....	8
图 8: 优化后的股票市场状态预测模型的网络结构图.....	8
图 9: NT-CNN 第一层卷积层核参数训练结果.....	9
图 10: NT-CNN 第一层卷积层特定通道的核参数展示.....	10
图 11: NT-CNN 第二层卷积层核参数训练结果 (已采样).....	10
图 12: NT-CNN 第三层卷积层核参数训练结果 (已采样).....	11
图 13: GAF-CNN 第一层卷积层核参数训练结果.....	11
图 14: GAF-CNN 第一层卷积层特定通道的核参数展示.....	12
图 15: 原有模型和改进后的 NT-CNN/GAF-CNN 对个股状态的预测准确度.....	13
图 16: NT-CNN 2021 各季度预测准确度.....	13
图 17: GAF-CNN 2021 各季度预测准确度.....	13
图 18: 预测所得市场状态随股票样本上价格变化的示例.....	14
图 19: 识别沪深 300 指数的市场状态和策略回测结果.....	15

图 20: 识别宁德时代 300750.SZ 的市场状态和策略回测结果.....	16
图 21: 识别中债新综合财富总值 CBA00101.SZ 的市场状态和策略回测结果.....	17
图 22: 识别万孚转债 123064.SZ 的市场状态和策略回测结果.....	18
表 1: 个股涨跌形态向量值与其市场状态对应表	4
表 2: 原有模型和改进后的 NT-CNN/GAF-CNN 对个股状态的预测准确度表	13
表 3: 不同类型资产的策略回测结果统计表	15

1. 研究背景

借助深度强化学习的方法对 A 股市场 67 个赛道进行轮动跟踪，排名靠前的赛道组合相对于全赛道等权配置具有明显的超额回报，深度强化学习的赛道选择方法得到了检验。研究背景论述和强化学习模型框架的选取详见报告《“成绩”的赛道 0.1.0 版》

本系列报告将运用相同的系统模型对 A 股市场的个股进行优选并构建投资组合进行回测，本文将展示现有模型在多个场景上的短期状态预测效果，并测试引入短期和中长期时间维度的同类型特征对模型的提升效果。

1.1. 深度学习模型

在此前的研究报告中我们对比了 GAF-CNN，NT-CNN，LSTM-RNN 三种识别市场状态的方法。其中，前两者相较于 LSTM-RNN 能更好的从价量信息对应的蜡烛图中提取信息，对相应的短、中、长期涨跌状态预测有更高的准确率。此外，GAF 将 OHLC+Volume 5 个时间序列分别进行转换变形，得到比 NT 转换更加丰富的信息交给卷积神经网络去识别；但另一方面，NT 变化将 5 个价量序列标注在同一张图中，能提供更多特征间的关系信息。

本文以前期报告中预测准确度最高，表现最优的 GAF-CNN 模型作为参照（以下标注为 Baseline 模型），并在原有的网络结构基础上进行特征工程优化和初步的卷积层优化，并通过实验对比不同模型对个股市场短期状态的预测结果。

1.2. 预测个股的市场短期状态

与行业赛道的状态预测相似，利用个股的价量（OHLC+Volume）数据构建分类模型，定义市场状态作为后续强化学习模型的输入。本文沿用了对 A 股市场行业赛道的市场短期状态的定义方法，由相应个股的短、中、长期涨跌状态来确定，标记为 [S1, S5, S10]，映射到 8 种不同的市场状态，见表 1，详细论述请见前期报告《“成绩”的赛道 0.1.0 版》。

表 1：个股涨跌形态向量值与其市场状态对应表

S1	S5	S10	State
0	0	0	0
0	0	1	1
0	1	0	2
0	1	1	3
1	0	0	4
1	0	1	5
1	1	0	6
1	1	1	7

资料来源：浙商证券研究所

2. 优化市场状态分类模型

从两个方面优化对个股的市场状态预测，一方面为模型提供更多的数据特征，另一方面，将原来的卷积网络模型加深，并使用不同的核尺寸去扫描特征。

2.1. 特征转换方法：GAF 与 NT

在构建个股的特征数据集时，想要通过量价形态来划分市场状态，我们首先要能准确的识别出量价形态。而量价形态的判断不仅仅是简单数字分析，而是需要通过对蜡烛图的形状做出视觉上的判断。对于图像识别，运用卷积神经网络（CNN）来实现是广为应用的方法。这里使用卷积神经网络的难点在于，卷积神经网络主要是用于处理 2D 图像的，而我们的量价数据是 1D 的时间序列。如何将 1D 的时间序列转化成 2D 的数据？本文借鉴了 Chen&Tsai（2020）采用的技术方法，我们尝试使用以下两种转换变形方法。

Gramian Angular Field

Gramian Angular Field (GAF) 是由 Wang & Oates (2015) 提出的一种用极坐标表示时间序列的方法。GAF 转换变形分为三个步骤：第一步，先对时间序列做归一化 (normalization)，假设我们的时间序列是 X ，归一化如下式所示：

$$\tilde{x}_t = \frac{x_t - \min(X)}{\max(X) - \min(X)}$$

第二步，在归一化之后用极坐标表示归一化之后的 $\tilde{x}_t$ ：

$$\begin{cases} \phi = \arccos(\tilde{x}_t), -1 \leq \tilde{x}_t \leq 1, \tilde{x}_t \in X_t \\ r = \frac{t_i}{N}, t_i \in \mathbb{N} \end{cases}$$

最后，基于极坐标，可以得到时间序列的 Gramian Angular Field:

$$GAF = \begin{bmatrix} \cos(\phi_1 + \phi_1) & \cdots & \cos(\phi_1 + \phi_n) \\ \vdots & \ddots & \vdots \\ \cos(\phi_n + \phi_1) & \cdots & \cos(\phi_n + \phi_n) \end{bmatrix}$$

将 OHLCV 5 个时间序列分别做 GAF 转换后再叠加在一起就得到了 CNN 可以处理的 $2D * 5$ 数据。本文将在 2.2 中结合不同时间维度特征展示 GAF 转换后的图像。

Naïve Transformation

本文将采用另一种特征转换的方法，即 Naïve Transformation(NT)。和 GAF 不同，将 OHLCV 不再拆成 5 个独立的时间序列，而是看作一个整体。这样我们把时间看作一个维度，OHLCV 的读数看作另一个维度，则将一个 10-time step 的 OHLCV 序列直接转化为一个 $10*5*1$ 的图片。同上，本文将在 2.2 节中结合不同时间维度特征展示 NT 转换后的图像。


2.2. 扩充不同时间维度的数据特征

在构建个股的特征数据集时，对股票价量数据的 5 个 10-time step 时间序列（OHLC+Volume）进行 GAF 转换，得到 $2D * 5$ 的特征向量；或者进行 NT 变换，将价量信息编织在同一张 2D 特征图中。

在现有的股票日级别价量数据基础上，为了让状态分类模型能对价量变化做出更及时的反应，引入更高频的数据，即 60 分钟线价量信息；同时我们考虑市场变化偏离预期的情况，即当前需要进行状态预测的行情，与训练模型所用的上一个季度的历史行情走势大相径庭，为了让模型适应更长时间的历史数据中的行情特征，引入涵盖更长时间段的低频数据，即周线价量信息。对三种时间维度的价量信息再采取相同的方式进行特征提取。

详细的特征提取方式为，对每只股票的每个采样交易日 d ，选取 $[d-9, d]$ 的 10-time step 的日线 OHLCV 数据；以当日 15:00 点为时刻 t ，选取 $[t-9, t]$ 的 10-time step 的 60min 级别的历史数据；再选取 $[w-9, w]$ 的 10-time step 的周线历史数据，其中，周线数据是在日线价量数据基础上以每 5 日为一个时间间隔进行计算得到。

图 1：用历史数据生成样本特征的采样原理




资料来源：浙商证券研究所

依据图 1 中时间戳对齐的方法，对任意股票样本的任意交易日，取得相应的历史数据，即 60min 级别、日级别和周级别 OHLCV 序列，再采用 2.1 中所介绍的 GAF/NT 转换，即可得到相应的特征数据。


以股票样本（000498.SZ）为例，选取交易日 2021 年 5 月 21 日，对样本进行特征提取，其三种时间维度的价量图和对应的特征转换结果，由图 2-7 展示。

图 2：股票样本 000498.SZ 日级别 K 线及对应的 NT 转换




资料来源：浙商证券研究所

图 3：股票样本 000498.SZ 日级别 K 线对应的 GAF 转换




资料来源：浙商证券研究所

图 4：股票样本 000498.SZ 周级别 K 线及对应的 NT 转换




资料来源：浙商证券研究所

图 5：股票样本 000498.SZ 周级别 K 线对应的 GAF 转换




资料来源：浙商证券研究所

图 6：股票样本 000498.SZ 60min 级别 K 线及对应的 NT 转换



资料来源：浙商证券研究所

图 7：股票样本 000498.SZ 60min 级别 K 线对应的 GAF 转换




资料来源：浙商证券研究所

2.3. 优化卷积网络结构

在原来的 NT-CNN/GAF-CNN 模型结构上修改得到的市场状态分类模型如下图所示，对 60min，日线，周线变换得到的特征分别用相同结构的 CNN 网络进行训练，得到三组市场状态的概率预测结果，通过一个全连接层预测出最终的市场状态。

图 8：优化后的股票市场状态预测模型的网络结构图




资料来源：浙商证券研究所

在 Baseline 模型中的网络结构基础上，增加了卷积网络的深度，并使用不同的核（kernel）去扫描特征图所包含的信息。在每个周期内，观察训练完成的模型中卷积核的参数揭示了股票价量信息之间的关系。为了便于分析，保留权重最大的三个参数及其相应的位置信息，分别展示如下。

对于 NT-CNN 改进模型，其第一层卷积层的核参数（左）及对最大的三个参数采样后的示意图（右）已展示在图 9 中。

分析第一层卷积层的核参数权重分布可知，有效信息集中于最近 3 个 time-step 的数据特征，从不同通道的扫描结果来看，上一个 time-step（上一个小小时，或交易日、周）的收盘价与成交量要结合起来观测（通道 5，7），而开盘价结合之前的最高价、最低价所呈现的微结构也提供重要信息（通道 0，4，8，9）。第二层卷积网络的核在扫描特征图时，在时序上，依然体现出最近的数据特征提供主要信息的特点。而在第三层，权值较大的核参数已经不具有明显的分布特征。


图 9：NT-CNN 第一层卷积层核参数训练结果



资料来源：浙商证券研究所


观察 NT-CNN 第一层核参数的具体的通道 4 对应的核参数，见图 10，最大的三个核参数对应到特征图的 OHLCV 时间序列则体现了如下信息： (O_{t-1}, H_t, L_t) ，即对当前时刻 t ，通过 $t-1$ 时刻的开盘价（O），和 t 时刻的最高价（H）和最低价（L）所体现的价量微结构，为该通道的核提供最多的有用信息。

图 10：NT-CNN 第一层卷积层特定通道的核参数展示




资料来源：浙商证券研究所

图 11：NT-CNN 第二层卷积层核参数训练结果（已采样）




资料来源：浙商证券研究所

图 12: NT-CNN 第三层卷积层核参数训练结果 (已采样)




资料来源: 浙商证券研究所

图 13: GAF-CNN 第一层卷积层核参数训练结果



资料来源: 浙商证券研究所

图 14: GAF-CNN 第一层卷积层特定通道的核参数展示



资料来源: 浙商证券研究所

相比之下, GAF 的特征图是对 OHLC+Volume 每个时间序列形成的特征图分别进行扫描, 从第一层卷积层开始, 核参数没有明显的时间分布特征。

GAF 转换更加关注每个时间序列自身与历史数据之间的关系, 它抽取的是时间序列上前后相异性构造出的特征。观察 GAF-CNN 第一层卷积层的通道 0, 经过训练得到的 5 个核, 见图 14。左起第一个核在扫描对应的开盘价 (O) 序列时, 对任意时刻 t , 从 $(O_{t-4}, O_{t-2}), (O_{t-4}, O_t), (O_{t-3}, O_t)$ 的微结构抽取对模型有用的信息较为重要。再观察与收盘价 (C) 对应的核参数, 则提示模型优先关注 $(C_{t-4}, C_{t-3}), (C_{t-4}, C_{t-2}), (C_{t-2}, C_t)$, 之所以强调优先关注是因为图 14 只展示了参数值大小前三的特征含义。


3. 模型测试表现对比

3.1. 个股市场状态预测准确度

对 A 股市场随机抽取了在 750 只股票作为样本池, 训练集和验证集在此股票池内进行划分, 用 2021 年各季度的历史数据进行模型训练, 改造后的 GAF-CNN/NT-CNN 模型与原有模型 Baseline 的预测准确度比较如图 15 所示。

可见, 对特征进行了时间维度的扩充, 并且加深卷积网络结构, 提升了模型对个股市场状态预测的准确率, 在验证集上的预测准确率都在 60% 以上, 即使是在样本外数据上的表现也达到了 57% 的准确度, 即, 在不同于上一季度的市场状态下, 模型仍然能对股票的市场状态进行评估。

图 15：原有模型和改进后的 NT-CNN/GAF-CNN 对个股状态的预测准确度



资料来源：浙商证券研究所


表 2：原有模型和改进后的 NT-CNN/GAF-CNN 对个股状态的预测准确度表

	Baseline	NT-CNN	GAF-CNN
train	55.4275%	65.5700%	63.8603%
valid	54.2079%	62.5716%	61.7250%
test	51.8710%	57.6542%	56.5534%

资料来源：浙商证券研究所


两种不同的特征提取方法，NT 和 GAF，在改进后的卷积神经网络模型下表现十分接近，但 NT-CNN 在不同的市场特征下表现较为稳定，而 GAF-CNN 在不同的行情下预测准确率会有更明显的波动，除了第一季度，在 2021 下半年 GAF-CNN 的预测准确度都略为逊色。可参见图 16-17 中 NT-CNN/GAF-CNN 在 2021 年各个季度的回测结果。

图 16：NT-CNN 2021 各季度预测准确度



资料来源：浙商证券研究所

图 17：GAF-CNN 2021 各季度预测准确度




资料来源：浙商证券研究所

3.2. 个股市场状态预测结果对股价波动的提示效果

为了进一步体现当前市场状态作为下一步强化学习模型的输入，能体现股票价格变动的信息与趋势，用改进后的最优模型预测所得的市场状态数据，进行如下可视化处理：将当前模型预测的市场状态以不同颜色表示在相应的股票收盘价序列上，如图 18 所示。

个股市场状态的预测结果已经能直观体现其在不同的价格变动趋势，并且在价格拉升或者下跌的早期就能做出比较准确的判断，也为后续通过强化学习模型进行投资决策提供了极高的可信度。

图 18：预测所得市场状态随股票样本上价格变化的示例



资料来源：浙商证券研究所

从回测结果可以看到，对个股进行市场状态预测的准确率还有很大提升空间，在后续优化报告中将对深度强化学习框架进行网络结构优化，让模型更好地捕捉价量数据及其他特征中的相关关系和趋势变化，从而对 A 股市场的个股所处的市场状态有更准确的刻画。

4. 市场状态预测应用案例

4.1. 基于市场状态预测的择时策略

基于表 1 中对市场状态的划分，本文将利用状态 0（预测未来 1, 5, 10 天均为下跌）和状态 7（预测未来 1, 5, 10 天均为上涨）构成一个基础的择时策略，即：预测状态为 7 且无持仓时，买入标的；而预测状态为 0 且有持仓时，卖出标的。不追加仓，不做空。其他状态下均不做操作。

结合图 15 可知，在出现第一个深蓝色点代表的状态 7 时，买入，并在出现第一个深红色点代表的状态 0 时，卖出。由此构成一个对单一标的物的择时策略。

4.2. 策略应用于不同类型资产的表现结果

本文选取了沪深 300 指数，和倍受市场关注的股票标的，宁德时代 (300750.SZ)，中债-新综合财富总值 (CBA00101.SZ)，以及可转债市场上的样本标的万孚转债 (123064.SZ) 为例，应用市场状态预测结果对 4.1 中的策略进行回测，结果如表 3 所示。


表 3：不同类型资产的策略回测结果统计表

	夏普比率	累积收益	交易次数	平均持仓天数
沪深 300	3.60	88.23%	17	7.41
宁德时代	2.96	510.03%	12	11.25
中债-总财富指数	3.42	6.19%	6	31.20
万孚转债	3.14	51.08%	12	7.92

资料来源：浙商证券研究所

对应每个指数/股票/可转债，详细的市场状态预测结果，按照 4.1 策略得到的持仓状态，以及最终得到的累积净值曲线，分别展示如图 19-22。


图 19：识别沪深 300 指数的市场状态和策略回测结果



资料来源：浙商证券研究所

由图 19 的累积净值曲线可知，在 2021 年沪深 300 指数全年走跌的行情下，利用市场状态预测结果进行择时，在春节后的市场大幅回调和 6、7 月的两次波段下跌行情下，模型判断出的状态 0，使得策略空仓而不承受下跌带来的利润损失。相比于沪深 300 指数 2021 年的指数收益，策略回测结果实现了 94% 左右的超额收益。持仓期间也承受浮亏，但是整体的夏普比率达到了 3.60（见表 3）。


图 20：识别宁德时代 300750.SZ 的市场状态和策略回测结果



资料来源：浙商证券研究所

由图 20 中宁德时代 (300750.SZ) 累积净值曲线可知，利用市场状态预测结果进行择时，在宁德时代股价春节后的大幅回调以及年底下跌行情下，策略也做出了正确的空仓决策。2021 年，在宁德时代自身表现十分亮眼的前提下，策略回测结果实现了 464% 左右的超额收益。

图 21：识别中债新综合财富总值 CBA00101.SZ 的市场状态和策略回测结果




资料来源：浙商证券研究所

中债总财富指数的回测结果由图 21 展示，其 2021 年整体行情都十分平滑，更容易跟踪，因此利用市场状态预测结果进行择时并没有明显的优势，取得了 6% 左右的累积收益，略优于指数收益。在这种容易跟踪并且行情连续平稳的资产上用市场状态预测进行择时，得到了交易频率低，平均持仓时间长的投资策略。

以万孚转债（123064.SZ）为例，市场状态预测进行择时在可转债上的回测结果由图 22 展示。与前面的指数和个股不同，万孚转债行情展现出了明显的震荡行情，而 4.1 节构造的简易择时策略充分适应了这样的震荡行情，在多个波段的下跌中都准确进行了状态 0 的预测，空仓度过，最终在标的年化只有 -5% 的情况下取得了 88% 的累积收益。

图 22：识别万孚转债 123064.SZ 的市场状态和策略回测结果



资料来源：浙商证券研究所

5. 总结

本文对前期报告中用深度强化学习模型预测 A 股市场赛道轮动的方法进行了优化，并应用在 A 股股票上。经过对特征数据的补充和网络结构的优化，对个股的市场短期状态预测准确度有明显提升，高频信息使得模型对市场状态日内变化更加敏感，快速反应，另外长周期的数据也使得模型在不同的市场风格切换之下有较为稳定的表现。模型内部参数的训练结果也对于股票价量特征之间的关系，及市场微结构的不同形态对于股票价格趋势的影响提供了重要信息。通过构造简单的择时策略，并对不同类型的资产进行回测，证明了市场短期状态预测的应用价值。

参考文献

- [1] Zhiguang Wang, Tim Oates. Encoding time series as images for visual inspection and classification using tiled convolutional neural networks. Proceedings of the 2015 Association for the Advancement of Artificial Intelligence (AAAI) Workshops, pages 40–46, 2015.
- [2] Zhiguang Wang, Tim Oates. Imaging time-series to improve classification and imputation. In Twenty-Fourth International Joint Conference on Artificial Intelligence, 2015.
- [3] Jun-Hao Chen, Samuel Yen-Chi Chen, Yun-Cheng Tsai, and Chih-Shiang Shur. Explainable deep convolutional candlestick learner. arXiv preprint arXiv:2001.02767, 2020.
- [4] Jun-Hao Chen, Samuel Yen-Chi Chen, Yun-Cheng Tsai, and Chih-Shiang Shur. Adversarial Robustness of Deep Convolutional Candlestick Learner. arXiv preprint arXiv: 2006.03686, 2020.

风险提示

通过 AI 模型构建的策略基于历史数据的统计归纳，模型力求自适应跟踪市场规律和趋势，但仍存失效可能，须谨慎使用。AI 系列模型量化结果，不构成任何投资建议。

法律声明

本报告由浙商证券股份有限公司（已具备中国证监会批复的证券投资咨询业务资格，经营许可证编号为：Z39833000）制作。本报告中的信息均来源于我们认为可靠的已公开资料，但浙商证券股份有限公司及其关联机构（以下统称“本公司”）对这些信息的真实性、准确性及完整性不作任何保证，也不保证所包含的信息和建议不发生任何变更。本公司没有将变更的信息和建议向报告所有接收者进行更新的义务。

本报告仅供本公司的客户作参考之用。本公司不会因接收人收到本报告而视其为本公司的当然客户。

本报告仅反映报告作者的出具日的观点和判断，在任何情况下，本报告中的信息或所表述的意见均不构成对任何人的投资建议，投资者应当对本报告中的信息和意见进行独立评估，并应同时考量各自的投资目的、财务状况和特定需求。对依据或者使用本报告所造成的一切后果，本公司及/或其关联人员均不承担任何法律责任。

本公司的交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。本公司没有将此意见及建议向报告所有接收者进行更新的义务。本公司的资产管理公司、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。

本报告版权均归本公司所有，未经本公司事先书面授权，任何机构或个人不得以任何形式复制、发布、传播本报告的全部或部分内容。经授权刊载、转发本报告或者摘要的，应当注明本报告发布人和发布日期，并提示使用本报告的风险。未经授权或未按要求刊载、转发本报告的，应当承担相应的法律责任。本公司将保留向其追究法律责任的权利。

浙商证券研究所

上海总部地址：杨高南路 729 号陆家嘴世纪金融广场 1 号楼 25 层
北京地址：北京市东城区朝阳门北大街 8 号富华大厦 E 座 4 层 4 楼
深圳地址：广东省深圳市福田区广电金融中心 33 层
邮政编码：200127
电话：(8621) 80108518
传真：(8621) 80106010
浙商证券研究所：http://research.stocke.com.cn