

2022.07.13

量化建模需放下“奥卡姆剃刀”

	陈奥林(分析师)	杨能(分析师)
	021-38674835	021-38032685
	chenaolin@gtjas.com	yangneng@gtjas.com
证书编号	S0880516100001	S0880519080008

本报告导读:

如何理解机器学习模型的良好效果?

摘要:

- 良性过拟合现象是指通过大量参数构成的复杂非线性模型在样本外表现更佳的这一反直觉现象。我们该如何理解反直觉的良性过拟合?
- 本篇报告推荐学者 Bryan Kelly、Semyon Malamud 和 Kangying Zhou 合作的《THE VIRTUE OF COMPLEXITY IN RETURN PREDICTION》。文献不仅实证了机器学习模型的样本外效果,而且基于随机矩阵理论证明了样本外预测精度和策略表现随着模型复杂度的提升而提升,帮助我们更好理解良性过拟合现象。
- 结论 1: 对于机器学习模型,投资者应当尽可能在模型中加入有效信息,提升模型复杂度,从而逼近真实的收益生成过程。换言之,在真实的收益生成过程是未知的情况下,通过增强模型复杂度带来的好处大于严重参数化带来的坏处。因为金融资产的真正收益生成过程极度复杂,其未知真实特征数量理应远大于样本点数量。
- 结论 2: 样本外拟合优度 R 方不能反映策略的优劣。即使预测 R 方为负,我们依然能够通过收益预测获取利润。这是因为 R² 受到预测方差的严重影响。R 方过低只是表明策略波动较大。
- 结论 3: 策略表现受益于正则化,随着正则化的加大,预期收益下降,但策略波动下降更快,策略夏普有一定提升。

金融工程团队:

陈奥林: (分析师)

电话: 021-38674835

邮箱: chenaolin@gtjas.com

证书编号: S0880516100001

杨能: (分析师)

电话: 021-38032685

邮箱: yangneng@gtjas.com

证书编号: S0880519080008

殷钦怡: (分析师)

电话: 021-38675855

邮箱: yinqinyi@gtjas.com

证书编号: S08805190800013

徐忠亚: (分析师)

电话: 021-38032692

邮箱: xuzhongya@gtjas.com

证书编号: S0880519090002

刘晔: (分析师)

电话: 021-38677309

邮箱: liubingyi@gtjas.com

证书编号: S0880520050001

赵展成: (研究助理)

电话: 021-38676911

邮箱: zhaozhancheng@gtjas.com

证书编号: S0880120110019

张烨坤: (研究助理)

电话: 021-38038427

邮箱: zhangyekun@gtjas.com

证书编号: S0880121070118

徐浩天: (研究助理)

电话: 021-38038430

邮箱: xuhaotian@gtjas.com

证书编号: S0880121070119

相关报告

市盈率、商业周期和股市择时 2022.06.27

危机经历与个人风险偏好 2022.05.17

基于机器学习方法的股债相关性预测
2022.04.26

基于波动率分解的高频波动率预测模型
2022.04.22

基于非层次聚类的风险平价资产配置模型
2022.04.14

目 录

1. 引言	3
2. 问题的提出	3
3. 研究结论	4
4. 实证检验	5
5. 总结	7

1. 引言

如无必要，勿增实体。

——威廉·奥卡姆

良性过拟合现象的提出。大量的文献通过实证分析验证了更加复杂的机器学习模型相对于简单的线性模型能够带来更高的组合收益。直觉上，根据奥卡姆剃刀原理，简约的模型似乎更加可靠，更不容易过拟合。这种通过大量参数构成的复杂非线性模型在样本外表现更佳这一反直觉现象被称之为“良性过拟合”(Bartlett et al., 2020; Tsigler and Bartlett, 2020)，我们该如何理解反直觉的良性过拟合？

本篇报告推荐学者 Bryan Kelly、Semyon Malamud 和 Kangying Zhou 合作的《THE VIRTUE OF COMPLEXITY IN RETURN PREDICTION》。文献不仅实证了机器学习模型的样本外效果，而且基于随机矩阵理论证明了样本外预测精度和策略表现随着模型复杂度的提升而提升，帮助我们更好理解良性过拟合现象。

换言之，奥卡姆剃刀原理在收益预测中并不适用。

2. 问题的提出

假设真实金融资产收益由下式构成：

$$R_{t+1} = f(G_t) + \varepsilon_{t+1}$$

R 为资产收益，G 为一组已知的有预测能力的投资信号，f 为未知的函数。与其徒劳地猜测 f 的具体形式，我们不如使用 Hornik et al. (1990) 提出的近似法则，f 可近似为：

$$f(G_t) \approx \sum_{i=1}^P S_{i,t} \beta_i \quad (1)$$

其中，S 是一个已知的非线性激活函数，P 需足够大。

由此，资产收益可由以下线性回归表示：

$$R_{t+1} = \sum_{i=1}^P S_{i,t} \beta_i + \varepsilon_{t+1}$$

假设我们有 T 个训练样本点，投资者需要确定特征数量 P，即模型的复杂度。

表 1 模型复杂度特点对比


简单模型	复杂模型
$P \ll T$	$P > T$
低方差	高方差
高偏差	低偏差

数据来源：国泰君安证券研究

一个简单的模型通常满足特征数量 P 远小于样本数量 T ，此时模型具有较低的方差，但是对于式 1 中 f 形式的估计比较粗糙。相反，在一个复杂模型中， P 大于 T ，模型具备更准确估计 f 的潜力，但是也会带来更大的方差，更需要进行特征压缩。因此，我们的核心问题是：

投资者该如何选择模型的复杂度 P ？复杂模型是真能增强预测效果还是仅会带来更大的预测方差和偏差？

图 1 方差与偏差图示



数据来源：机器学习与 TensorFlow 实战

3. 研究结论

基于理论假设，在 P 大于 T 的复杂模型中，随着复杂度 P 的提升，样本外预测精度和策略表现线性上升，且使用合理的特征压缩技术后，模型预测表现进一步提升。

因此，投资者应当尽可能在模型中加入有效信息，提升模型复杂度，从

而逼近真实的收益生成过程。换言之，在真实的收益生成过程是未知的情况下，通过增强模型复杂度带来的好处（更加精确的 f 估计等）大于严重参数化带来的坏处（更大的方差等）。

上述结论的理论证明主要基于以下两点假设：一是机器学习模型简化为高维线性回归；二是仅对于单一资产收益率进行预测。上述简化使得理论证明更加方便，并不影响核心结论。

上述结论不适用于传统线性回归 OLS。在传统 OLS 中，当 P 接近 T 时，协方差阵变得不稳定，导致预测方差大幅上升，样本外拟合优度快速下降，是常见的过拟合现象。而在机器学习模型中，金融资产的真实收益生成过程

$$R_{t+1} = \sum_{i=1}^P S_{i,t} \beta_i + \varepsilon_{t+1}$$

极度复杂，其未知真实特征数量 P 理应远大于样本点数量 T 。因为正确的模型形式本应满足 P 大于 T ，所以，机器学习建立的 P 大于 T 的模型不应被看做过拟合，所谓的良性过拟合只是合理参数化。

文章的第二个结论是：样本外拟合优度 R^2 不能反映策略的优劣。即使预测 R^2 为负，我们依然能够通过收益预测获取利润。这是因为 R^2 受到预测方差的严重影响。 R^2 过低只是表明策略波动较大。


文章的第三个结论是：策略表现受益于正则化，随着正则化的加大，预期收益下降，但策略波动下降更快，策略夏普有一定提升。

4. 实证检验

文章使用 15 个预测指标用于预测美股权益市场指数 CRSP 月度收益。为了生成大量特征，文章采用了傅里叶随机特征 RFF 算法，其本质为两层神经网络，第一层神经网络权重随机生成，第二层权重通过回归得到。


定义 $c=P/T$ ，由下图 2、3 可知，随着 c 由 1 上升至 1000，组合预期收益和夏普比率等指标均有显著提升。其结果可通过稳健性检验如图 4 分样本检验。

图 2 收益预测策略样本外表现




数据来源: THE VIRTUE OF COMPLEXITY IN RETURN PREDICTION

图 3 收益预测策略样本外表现



数据来源: THE VIRTUE OF COMPLEXITY IN RETURN PREDICTION

图 4 收益预测策略分区间样本外表现



数据来源：THE VIRTUE OF COMPLEXITY IN RETURN PREDICTION

5. 总结

AI 在资产管理中快速发展，但是基于机器学习模型的组合性质尚未能被充分理解。

研究发现，通过生成远大于训练集样本点个数的特征能够提升策略样本外的表现，而不用过于担心过拟合问题。

研究结论并不表明我们可以在模型中加入随机的投资信号，相反，作者鼓励：1.加入所有可获得的相关特征（因子）2.使用大量非线性模型，而非简单的线性模型。即使训练集数据不足，这样做同样能够带来更好的

预测效果，特别是在使用了特征压缩技术后。

收益预测时，奥卡姆剃刀原则并不正确。这是因为从理论上说，只有当模型形式是正确的时候，简约模型才更可取，但正如 BOX（1976）强调的，模型形式几乎从来都是错误的。因此，合乎逻辑的结论是，在相当一般的条件下，机器学习模型更可取。机器学习文献证明了大型非线性模型在广泛领域的成功，本篇文献结果再一次表明，机器学习模型在金融市场中同样适用。

本公司具有中国证监会核准的证券投资咨询业务资格

分析师声明

作者具有中国证券业协会授予的证券投资咨询执业资格或相当的专业胜任能力，保证报告所采用的数据均来自合规渠道，分析逻辑基于作者的职业理解，本报告清晰准确地反映了作者的研究观点，力求独立、客观和公正，结论不受任何第三方的授意或影响，特此声明。

免责声明

本报告仅供国泰君安证券股份有限公司（以下简称“本公司”）的客户使用。本公司不会因接收人收到本报告而视其为本公司的当然客户。本报告仅在相关法律许可的情况下发放，并仅为提供信息而发放，概不构成任何广告。

本报告的信息来源于已公开的资料，本公司对该等信息的准确性、完整性或可靠性不作任何保证。本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可升可跌。过往表现不应作为日后的表现依据。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。本公司不保证本报告所含信息保持在最新状态。同时，本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。在任何情况下，本报告中的信息或所表述的意见均不构成对任何人的投资建议。在任何情况下，本公司、本公司员工或者关联机构不承诺投资者一定获利，不与投资者分享投资收益，也不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。投资者务必注意，其据此做出的任何投资决策与本公司、本公司员工或者关联机构无关。

本公司利用信息隔离墙控制内部一个或多个领域、部门或关联机构之间的信息流动。因此，投资者应注意，在法律许可的情况下，本公司及其所属关联机构可能会持有报告中提到的公司所发行的证券或期权并进行证券或期权交易，也可能为这些公司提供或者争取提供投资银行、财务顾问或者金融产品等相关服务。在法律许可的情况下，本公司的员工可能担任本报告所提到的公司的董事。

市场有风险，投资需谨慎。投资者不应将本报告作为作出投资决策的唯一参考因素，亦不应认为本报告可以取代自己的判断。在决定投资前，如有需要，投资者务必向专业人士咨询并谨慎决策。

本报告版权仅为本公司所有，未经书面许可，任何机构和个人不得以任何形式翻版、复制、发表或引用。如征得本公司同意进行引用、刊发的，需在允许范围内使用，并注明出处为“国泰君安证券研究”，且不得对本报告进行任何有悖原意的引用、删节和修改。

若本公司以外的其他机构（以下简称“该机构”）发送本报告，则由该机构独自为此发送行为负责。通过此途径获得本报告的投资者应自行联系该机构以要求获悉更详细信息或进而交易本报告中提及的证券。本报告不构成本公司向该机构之客户提供的投资建议，本公司、本公司员工或者关联机构亦不为该机构之客户因使用本报告或报告所载内容引起的任何损失承担任何责任。

评级说明

	评级	说明
股票投资评级	增持	相对沪深 300 指数涨幅 15%以上
	谨慎增持	相对沪深 300 指数涨幅介于 5%~15%之间
	中性	相对沪深 300 指数涨幅介于-5%~5%
	减持	相对沪深 300 指数下跌 5%以上
行业投资评级	增持	明显强于沪深 300 指数
	中性	基本与沪深 300 指数持平
	减持	明显弱于沪深 300 指数

国泰君安证券研究所

	上海	深圳	北京
地址	上海市静安区新闻路 669 号博华广场 20 层	深圳市福田区益田路 6009 号新世界商务中心 34 层	北京市西城区金融大街甲 9 号 金融街中心南楼 18 层
邮编	200041	518026	100032
电话	(021) 38676666	(0755) 23976888	(010) 83939888
E-mail:	gtjaresearch@gtjas.com		