

证券研究报告 / 金融工程研究报告

基于 cVAE 的数据增强对下行风险预测的提升

—— 机器学习系列之二

报告摘要：

本文介绍了用条件变分自编码器模型 cVAE 进行数据增强的方法，利用 cVAE 在不同下行风险等级下学习多维期权相关指标的分布，并尝试将其应用在依靠期权风险指标对未来下行风险预测评估的任务中，较大程度地提升了预测效果，也使得基于风险预测的策略表现更为优异。

本文大致分为三个部分：

第一部分介绍数据增强、生成模型以及 VAE、cVAE。数据增强是一种对数据集进行处理的技术，目的是在保留数据本质特征的同时丰富原始数据集，提升模型的稳健性和泛化性。生成模型可以作为数据增强的一种方式。它更加关注于数据本身的特征，通过对数据分布的学习，从而生成与原始样本同分布的数据来补充原始数据集。VAE 与 cVAE 作为重要的生成模型，有着较为简单的模型架构以及不错的模型表现，另外，cVAE 模型与不同标签下的特征分布学习及数据生成更为契合。

第二部分介绍期权市场的相关指标与未来下行风险的关系。经典的 VIX 与 SKEW 指标，以及我们选择的 PCR 成交额指标，在逻辑上和实证检验上对未来的下行风险均有着一定的预测意义。使用未来一个月的最大回撤对未来下行风险进行评估，并对风险等级进行划分。实证结果表明，指标与未来收益率和下行风险均有一定的时序相关性，但与下行风险更为相关；在不同高低等级的指标下，未来收益率与未来下行风险的分布均有差异；在不同的风险等级下，指标的联合分布有着较显著的差异。

第三部分通过数据增强的方式将 cVAE 应用在指标对下行风险的评估中。首先验证了 cVAE 模型在不同风险等级即标签下对特征的分布学习效果，结果表明训练好的 cVAE 在测试集上重构表现良好。接下来分别使用线性模型和非线性模型作为预测器，使用滚动训练预测评估的方式，制定风险控制择时策略；另外对于初始策略进行改进，即对滚动窗口内的数据集进行数据增强。策略的回测结果表明数据增强后的策略在各项指标上更为优异，年化收益 10.3%，Sharpe ratio 1.03，在预测器的准确率以及稳健性方面得到了明显的提升。

本文的创新之处包括，使用未来一月最大回撤划分的风险等级作为预测评估目标，而非直接使用未来收益率；使用 cVAE 学习不同标签下指标的分布，并用于对训练集的数据增强，提升策略的表现，这种探索未来可以在更多的量化领域进行。

风险提示：以上分析基于模型结果和历史测算，存在模型失效风险。



相关报告

《上月价值、红利、技术因子表现较优》

--20221205

《行业轮动五——如何更好的描述行业趋势》

--20221205

《成长分类定价和未被分析师覆盖股票的预测数据填充》

--20221130

《基于异常现金流模型的真实盈余管理因子（一）》

--20221107

《东北金工双月报：资产表现回顾及市场展望》

--20221103

证券分析师：王琦

执业证书编号：S0550521100001

021-61002390 wangqi_5636@nesc.cn

研究助理：贾英

执业证书编号：S0550122060006

13666061675 jiaying@nesc.cn

目 录

1.	引言	4
2.	数据增强理论与模型介绍	4
2.1.	数据增强与生成模型	4
2.2.	变分自编码器 (VAE)	5
2.2.1.	模型结构	6
2.2.2.	优化目标与损失函数	8
2.3.	条件变分自编码器 (cVAE)	10
3.	期权衍生指标与标的风险的关系	11
3.1.	指标介绍	11
3.2.	实证结果	14
4.	基于 cVAE 和风险指标的策略	20
4.1.	模型表现及测试	20
4.2.	策略构建及回测结果	24
5.	总结	28
6.	参考文献	29
7.	风险提示	29

图表目录

图 1: 编码器解码器架构示意图	6
图 2: Gaussian 混合模型示意图	7
图 3: VAE 示意图	7
图 4: VAE 架构示意图	8
图 5: cVAE 架构示意图	10
图 6: VIX 指数与上证 50 ETF 收盘价走势	12
图 7: SKEW 指数与上证 50 ETF 收盘价走势	13
图 8: PCR 成交量比率与上证 50 ETF 收盘价走势	13
图 9: PCR 持仓量比率与上证 50 ETF 收盘价走势	14
图 10: PCR 成交额比率与上证 50 ETF 收盘价走势	14
图 11: 风险指标与未来一月收益率时序相关系数	15
图 12: 风险指标与未来一月最大回撤相关系数	15
图 13: 风险指标与未来下行风险等级相关系数	16
图 14: 不同 VIX 下未来一月收益率分布	17
图 15: 不同 VIX 下未来一月最大回撤分布	17
图 16: 不同 SKEW 下未来一月收益率分布	17

图 17: 不同 SKEW 下未来一月最大回撤分布	17
图 18: 不同 PCR 成交额下未来一月收益率分布	17
图 19: 不同 PCR 成交额下未来一月最大回撤分布	17
图 20: 不同风险等级下 VIX 的分布	18
图 21: 不同风险等级下 SKEW 的分布	19
图 22: 不同风险等级下 PCR 成交额比率的分布	19
图 23: 在测试集中风险等级 0 时 VIX 原始分布与重构分布对比	21
图 24: 在测试集中风险等级 0 时 SKEW 原始分布与重构分布对比	21
图 25: 在测试集中风险等级 0 时 PCR 成交额原始分布与重构分布对比	21
图 26: 在测试集中风险等级 0 时各指标原始数据与对应重构数据热力图	21
图 27: 在测试集中风险等级 1 时 VIX 原始分布与重构分布对比	22
图 28: 在测试集中风险等级 1 时 SKEW 原始分布与重构分布对比	22
图 29: 在测试集中风险等级 1 时 PCR 成交额原始分布与重构分布对比	22
图 30: 在测试集中风险等级 1 时各指标原始数据与对应重构数据热力图	22
图 31: 在测试集中风险等级 2 时 VIX 原始分布与重构分布对比	23
图 32: 在测试集中风险等级 2 时 SKEW 原始分布与重构分布对比	23
图 33: 在测试集中风险等级 2 时 PCR 成交额原始分布与重构分布对比	23
图 34: 在测试集中风险等级 2 时各指标原始数据与对应重构数据热力图	23
图 35: 策略净值对比 (预测器: Logistic regression)	25
图 36: 使用数据增强后的策略对未来风险的预测 (预测器: Logistic regression)	25
图 37: 策略净值对比 (预测器: Random forest)	26
图 38: 使用数据增强后的策略对未来风险的预测 (预测器: Random forest)	26
表 1: 不同程度指标下未来一月收益率的均值与标准差	17
表 2: 不同程度指标下未来一月最大回撤的均值与标准差	18
表 3: 不同风险等级下各指标的均值与标准差	19
表 4: 不同风险等级间单指标 Kolmogorov—Smirnov 检验的 p 值	19
表 5: 不同风险等级间多指标联合分布的评估分数	20
表 6: 在测试集中风险等级 0 时各指标的原始分布与重构分布均值与标准差对比	21
表 7: 在测试集中风险等级 1 时各指标的原始分布与重构分布均值与标准差对比	22
表 8: 在测试集中风险等级 2 时各指标的原始分布与重构分布均值与标准差对比	23
表 9: 测试集中不同风险等级下的原始样本与重构样本的分布评估分数	23
表 10: 策略回测结果 (预测器: Logistic regression)	25
表 11: 策略回测结果 (预测器: Random forest)	26
表 12: 策略对持仓限制参数的敏感性 (预测器: Random forest)	27

1. 引言

数据驱动一直是机器学习的重要特征。模型的泛化表现与训练数据有着很强的关联，更加全面、多样化的数据集有助于模型学习到数据的本质特征，或者是数据与目标之间更深刻的内在联系，而并非之间的仅在训练集上显示出的某种“捷径”。但在实践中，模型的训练往往面临着训练集数据不足，或者训练集数据单一、缺乏全面性和广泛性的问题。尤其在金融数据的应用中，由于市场的某种模式如风格，可能会不断发生轮换，所以研究者往往会选择进行滚动训练，即将过去最近一个窗口期的数据作为训练集进行训练，这种小样本的训练方式难免会遇到模型泛化性较差等问题。诸如此类的问题限制着模型的表现，而数据增强（Data Augmentation）便是一种对数据集的处理技术，在扩大数据集的同时提升了数据的多样性和整个模型的稳健性（Robustness）。概率生成模型（Generative Model）通过学习数据特征的概率分布，从而可以随机生成大量与原始样本同分布的数据，生成模型亦可作为数据增强的一种实现方式。

从指数 ETF 期权交易数据中得到的衍生指标对指数未来的下行风险有着较强的预测意义。例如由期权的隐含波动率（Implied Volatility）中计算而来的 VIX 指标，本质上就是期权市场中的交易者对标的未来波动率的一种预期。量化地使用这些指标对未来风险进行评估是必要的。但由于本身的数据量限制，以及由市场状态或者模式变化导致的久远数据的使用淡化，为模型的搭建与训练带来了诸多困难。

我们将数据增强应用到对指数未来下行风险的预测评估领域，使得模型更加稳健，同时也提升了模型的表现。第 2 章介绍数据增强与生成模型的基本理论，以及变分自编码器（Variational AutoEncoder; VAE）和其衍生而来的条件变分自编码器（Conditional Variational AutoEncoder; cVAE）。第 3 章主要介绍 ETF 期权的相关衍生指标，以及通过一些实证结果展示其对指数未来下行风险的预测与评估意义。第 4 章首先验证测试了 cVAE 模型在风险指标数据集上的学习效果，接下来基于风险指标建立了简单的择时策略，发现在进行数据增强后，策略具有更加稳定的表现。第 5 章总结本报告的结论。

2. 数据增强理论与模型介绍

2.1. 数据增强与生成模型

数据增强（Data Augmentation）是一种通过算法来扩展训练数据的技术。影响人工智能应用效果的三大重要因素为数据、模型与算法。对于大量由数据驱动的模式而言，多样化的训练数据是提高模型精度和泛化效果的重要因素。当训练样本量较少或较为单一时，模型更倾向于学习到在训练样本中发现到的联系，这种联系可能并没有任何逻辑或者它只在训练集中适用，例如在图像识别的任务中，如果所有图片中的猫都是白色，那么模型很容易建立猫与白色之间的捷径联系，它倾向于将其它白色的动物识别为猫。但是当我们扩充训练集、增加训练样本的多样性时，例如对此任务中的原始图片样本进行裁剪、旋转、色彩调整等处理，将会得到比原始训练集更为丰富的训练样本，这对于提升模型稳健性有着很大的帮助。

类似于上述例子，传统的数据增强通过对原始数据样本在某种程度上增加扰动来丰

富训练集。数据增强最重要的假设就是不改变原始数据的本质特征。它在尽可能保留本质的同时做出一定形式上的改变来增加样本多样性，其目的便是使得模型学习到某种不变性（Invariance）。[1]介绍了数据增强在计算机视觉领域中的应用，阐述了数据增强技术与特点，以及在扩大有限数据集、提高模型性能方面的贡献。[2]研究了深度学习中对文本数据的数据增强以及对泛化测试集的构建。

除了常规的添加噪声之外，利用生成模型进行数据增强也是一种重要的处理方法。不同于在《机器学习发展历程与量化投资的展望——机器学习系列之一》第一章中介绍的判别模型（Discriminative Model），判别模型更为关注在给定样本特征时目标或者标签的分布即 $p(y|x)$ ，本质上是在训练集上学习到这种潜在的关系，当给定新的 x 时，便可以确定目标的条件分布。生成模型更加注重特征与标签的联合分布 $p(x, y)$ ，或是在没有标签的情况下引入隐变量（Latent Variable） z 辅助进行研究，通常会关注联合分布 $p(x, z)$ 以及似然（Likelihood） $p(x|z)$ ，生成模型对数据本身的性质更感兴趣。

在应用层面，生成模型被广泛用于数据分布的学习以及数据的生成。生成模型涵盖广泛，两个有重要意义的模型包括[3]中提出的变分自编码器（Variational Autoencoder; VAE）以及[4]中提出的生成对抗神经网络模型（Generative Adversarial Network; GAN），VAE 将输入变量通过近似推断网络编码为隐变量的概率分布，然后再利用生成网络还原原始数据的概率分布；GAN 通过判别器（Discriminator）与生成器（Generator）对抗学习，在很多生成任务中都有不错的表现。例如[5]中利用 GAN 族模型学习期权数据分布，并作为一个数据生成器，缓解了由真实数据量不足导致的在其他任务中训练集过小等问题。


在小样本的学习任务中，数据增强就显得更为必要。VAE 的模型架构（Architecture）相比于 GAN 而言更加简单，对于较小的训练集，GAN 本身的训练可能也会有一定的限制，所以本篇报告选择 VAE 作为数据增强的模型，并在之后的两节中详细介绍 VAE 和其衍生模型 cVAE。

2.2. 变分自编码器（VAE）

正如上一节所述，变分自编码器 VAE 是一类生成模型，但类似于自动编码器，VAE 同样有着编码器解码器架构，所以在正式开始介绍 VAE 之前，我们简要回顾自动编码器模型（Autoencoder）。

如图所示，自动编码器由两个神经网络模块组成，分别是编码器（Encoder） f 和解码器（Decoder） g 。编码器 f 的作用是对高维的数据特征 x 进行非线性降维，即将输入编码为 $z = f(x)$ 。解码器 g 的作用是将编码复原为原始特征即 $\tilde{x} = g(z)$ 。损失函数为重构误差（Reconstruction Error）即 $l(x, \tilde{x}) = \|x - \tilde{x}\|_2^2$ ，两个模块同时进行训练。当训练完成后，编码 $z \in \mathbb{R}^d$ 将尽可能在降维的基础上保留原始特征 x 中的信息，解码器 g 将尽可能由低维的编码 z 对原始数据 x 进行还原。

图 1：编码器解码器架构示意图



数据来源：东北证券

然而，自动编码器多用于降维而非生成，这是因为编码的取值空间是 $\mathbb{R}^d$ ，对于数据的随机生成，编码取值空间过大以至于无法抽取合适的编码来生成符合条件的特征。自动编码器存在着特征、编码、复原特征一一对应的关系，但这对于数据生成任务也是一种缺陷，因为有限的训练集无法覆盖庞大的编码空间，以至于在编码空间中只有小部分编码才能用来生成特征。而变分自编码器 VAE 就解决了这一问题，VAE 关注对编码或者隐变量 z 的条件分布 $p(z|x)$ 进行建模。

2.2.1. 模型结构

类比一类著名的生成模型，Gaussian 混合模型（Gaussian Mixture Model; GMM），它们有着较多的相似之处。Gaussian 混合模型关注 x 的分布，它引入了隐变量 z 来辅助建模，一般而言， z 的先验分布（Prior Distribution）假设为有限取值的离散分布（Categorical Distribution），而似然 $p(x|z)$ 一般假设为 Gaussian 分布。通常可以由 Bayes' formula 导出后验（Posterior Distribution） $p(z|x)$ 从而进行建模。所以，Gaussian 混合模型一般可以看作是有限个 Gaussian 分布的混合。但事实上，这样的隐变量 z 先验假设可能无法满足较为复杂任务的需求，VAE 改进了这一点，它不再限制 z 是有限取值的，而同样也是一个高维的 Gaussian 分布。

为了简便起见，VAE 通常假设隐变量 z 的先验分布是 $\mathcal{N}(0, I)$ ；另外类似于 Gaussian 混合模型，VAE 假设 $x|z$ 服从参数为 θ 的 Gaussian 分布，i.e.

$$p_{\theta}(x|z) = \mathcal{N}(x; \mu_{\theta}(z), \sigma_{\theta}(z)).$$


此时，同样地，可以利用 Bayes' formula 导出隐变量 z 的后验如下，

$$p_{\theta}(z|x) = \frac{p_{\theta}(x|z)p(z)}{p_{\theta}(x)} = \frac{p_{\theta}(x|z)p(z)}{\int_z p_{\theta}(x|z)p(z)dz}.$$

事实上，在高维的情形，分母中的积分计算极其困难， $p_{\theta}(z|x)$ 的显性形式在数学上是棘手的（Intractable），我们也难以通过数值算法去处理。所以 VAE 选择利用另一个 Gaussian 分布 $q_{\phi}(z|x)$ 去逼近 $p_{\theta}(z|x)$ ，其中 ϕ 是分布依赖的参数，并且一般会假设后验分布的各维度是独立的，


$$q_{\phi}(z|x) = \mathcal{N}(z; \mu_{\phi}(x), \sigma_{\phi}(x)).$$

图 2：Gaussian 混合模型示意图



数据来源：东北证券

图 3：VAE 示意图



数据来源：东北证券

事实上， $q_{\phi}(z|x)$ 和 $p_{\theta}(x|z)$ 这两个部分分别表示 VAE 中的编码器和解码器。对于解码器 $p_{\theta}(x|z)$ 而言，VAE 巧妙的用一个神经网络 g_{θ} 去拟合 $x|z$ 的分布，由于 Gaussian 分布仅由其均值和方差确定，所以具体来说拟合过程输入隐变量 z ，输出 $x|z$ 的均值 $\mu_{\theta}(z)$ 和方差协方差矩阵 $\sigma_{\theta}(z)$ ，其中 θ 是网络中需要被优化的参数，即

$$g_{\theta}(z) = (\mu_{\theta}(z), \sigma_{\theta}(z)).$$

同样地，对于编码器 $q_{\phi}(z|x)$ ，VAE 也使用另外一个神经网络 f_{ϕ} 去逼近 $z|x$ 的分布。具体而言，输入特征 x 到编码器，输出 $z|x$ 的均值 $\mu_{\phi}(x)$ 和方差协方差矩阵 $\sigma_{\phi}(x)$ ，其中 ϕ 是网络中需要被优化的参数，即

$$f_{\phi}(x) = (\mu_{\phi}(x), \sigma_{\phi}(x)).$$

考虑 VAE 的具体结构，详细可见[3]。大致可以分为 3 个部分：

1. 编码：

输入样本特征 x 到编码器中，可以得到近似后验分布 $q_{\phi}(z|x)$ 的参数 $\mu_{\phi}(x)$ 和 $\log \sigma_{\phi}^2(x)$ 。事实上，由于假设后验各维度独立，所以方差协方差矩阵为对角矩阵，由编码器输出时便可以直接得到向量的形式；另外为了不限制输出的符号，输出方差时一般使用对数值。


2. 采样:

从近似后验分布 $q_{\phi}(z|x)$ 中随机采样一个隐变量 z 的值。采样使用重参数化技巧 (Reparameterization Trick), 即 $z = \mu_{\phi}(x) + \sigma_{\phi}(x) \odot \epsilon$, 其中 $\epsilon \sim \mathcal{N}(0, I)$ 维数与隐变量相同, $\odot$ 表示逐元素相乘。这种方式将随机值以外变量的形式引入, 使得梯度可以在采样过程中传播。

3. 解码:

将采样得到的隐变量 z 输入到解码器中, 得到 $p_{\theta}(x|z)$ 的两个参数 $\mu_{\theta}(z)$ 和 $\log \sigma_{\theta}^2(z)$ 。与编码器类似, 通常也假设 $x|z$ 各维度独立, 所以 $\log \sigma_{\theta}^2(z)$ 同样为向量的形式。但一般来说, 在实践中会省略再次采样的步骤, 而直接将解码器输出的 $\mu_{\theta}(z)$ 作为重构样本 $\tilde{x}$ 。

图 4: VAE 架构示意图



数据来源: 东北证券

2.2.2. 优化目标与损失函数

模型的优化目标自然是调整模型中的参数最大化对数似然函数 $\log p_{\theta}(x)$ 。事实上, 由全概率公式 (Law of Total Probability) 以及 Bayes 公式 (Bayes' formula), $\log p_{\theta}(x)$ 可以写成如下形式 (以下推导过程详见[3], 这里仅概述思路),

$$\begin{aligned} \log p_{\theta}(x) &= \int_{\mathbf{z}} q_{\phi}(\mathbf{z}|\mathbf{x}) \log \frac{p_{\theta}(\mathbf{x}, \mathbf{z})}{q_{\phi}(\mathbf{z}|\mathbf{x})} d\mathbf{z} + \int_{\mathbf{z}} q_{\phi}(\mathbf{z}|\mathbf{x}) \log \frac{q_{\phi}(\mathbf{z}|\mathbf{x})}{p_{\theta}(\mathbf{z}|\mathbf{x})} d\mathbf{z} \\ &= ELBO + KL(q_{\phi}(\mathbf{z}|\mathbf{x}) || p_{\theta}(\mathbf{z}|\mathbf{x})). \end{aligned}$$

其中, $KL(\cdot || \cdot)$ 表示两个分布的 Kullback—Leibler 散度, 简称 KL 散度 (KL divergence), 衡量两个分布之间的差异, 并且是非负的。由于 KL 散度的性质, ELBO (Evidence Lower Bound) 便是 $\log p_{\theta}(x)$ 的一个下界。所以优化目标转为最大化 ELBO。事实上, 经过简单的变形, ELBO 可以写成如下形式,

$$\begin{aligned} ELBO &= \int_z q_\phi(z|x) \log p_\theta(x|z) dz - \int_z q_\phi(z|x) \log \frac{q_\phi(z|x)}{p(z)} dz \\ &= \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] - KL(q_\phi(z|x) || p(z)). \end{aligned}$$

这便是总体的目标函数。最大化 ELBO 的意义一方面是最小化重构误差，第一项的含义是对于给定的 x ，从编码器 $q_\phi(z|x)$ 中采样得到隐变量 z ，然后可以得到此时的对数似然 $\log p_\theta(x|z)$ ，最大化这个对数似然的期望的意义就是减小重构误差。另一方面是最小化近似后验分布 $q_\phi(z|x)$ 和先验分布 $p(z)$ 的 KL 散度，即 ELBO 的第二项。综合来看，总体的优化目标就是在保证模型有着编码和解码能力的同时，后验分布也需要向先验分布靠近。实际上，KL 散度这一项可以看作是优化目标的正则项 (Regularization)，如果没有这一项，那么总体的目标就只有最小化重构损失，最终得到的模型编码器对方差的输出将接近于 0，可能丧失了随机采样的能力，这种情况下模型很有可能退化为自动编码器。正则项对后验分布进行了限制，使得在优化过程中需要考虑后验与先验的距离，避免了模型的退化。

接下来考虑经验损失函数，由于已经假设 $q_\phi(z|x) = \mathcal{N}(z; \mu_\phi(x), \sigma_\phi(x))$ ， $p(z) = \mathcal{N}(z; 0, I)$ 分别为 d 维的各维度独立的 Gaussian 分布。那么 ELBO 的第二项 KL 散度有显式的形式如下，

$$KL(q_\phi(z|x) || p(z)) = \sum_{i=1}^d \frac{1}{2} \left(-1 + \sigma_{\phi,(i)}^2(x) + \mu_{\phi,(i)}^2(x) - \log \sigma_{\phi,(i)}^2(x) \right).$$

另外，ELBO 的第一项可以利用 $\frac{1}{n} \sum_{i=1}^n \log p_\theta(x|z_i)$ 来进行估计，其中 z_i 从 $q_\phi(z|x)$ 中采样。由 VAE 的假设 $p_\theta(x|z) = \mathcal{N}(x; \mu_\theta(z), \sigma_\theta(z))$ 为 d' 维各维度独立的 Gaussian 分布，那么这个估计式可以写为

$$\frac{1}{n} \sum_{i=1}^n \log p_\theta(x|z_i) = \frac{1}{n} \sum_{i=1}^n \left(-\frac{1}{2} \sum_{j=1}^{d'} \frac{(x_{(j)} - \mu_{\theta,(j)}(z_i))^2}{\sigma_{\theta,(j)}(z_i)} - \log \sqrt{(2\pi)^{d'} \prod_{j=1}^{d'} \sigma_{\theta,(j)}(z_i)} \right).$$

不妨令 $\sigma_{\theta,(j)}(z) = 1/2$ ， $\forall j$ ，那么估计式可以简化为

$$\frac{1}{n} \sum_{i=1}^n \log p_\theta(x|z_i) = \frac{1}{n} \sum_{i=1}^n \left(-\|x - \mu_\theta(z_i)\|_2^2 - \frac{d'}{2} \log \pi \right).$$

综上，在忽略常数的情况下，可以定义损失函数为：

$$l(x) = \frac{1}{n} \sum_{i=1}^n \|x - \mu_{\theta}(z_i)\|_2^2 + \sum_{j=1}^d \frac{1}{2} \left(-1 + \sigma_{\phi, (j)}^2(x) + \mu_{\phi, (j)}^2(x) - \log \sigma_{\phi, (j)}^2(x) \right).$$

损失函数中第一项重构误差的平均，而第二项作为正则项。在一般训练中，对于一个输入 x ，编码器通常只需进行一次采样就可以达到较好的训练效果，另外解码器通常只输出分布的均值作为重构数据 $\tilde{x}$ 。所以在实际过程中的损失函数便简化为如下形式：


$$l(x) = \|x - \tilde{x}\|_2^2 + \sum_{j=1}^d \frac{1}{2} \left(-1 + \sigma_{\phi, (j)}^2(x) + \mu_{\phi, (j)}^2(x) - \log \sigma_{\phi, (j)}^2(x) \right).$$

至此得到了 VAE 训练的损失函数。在训练时，对于数据集 $X = \{x_i\}_{i=1, \dots, N}$ ，通常会对每个 x_i 计算损失函数值然后进行平均，i.e. $L(X) = \frac{1}{N} \sum_{i=1}^N l(x_i)$ 。然后反向传播计算梯度，对参数进行优化。

2.3. 条件变分自编码器（cVAE）

本节介绍条件变分自编码器模型 cVAE，参见[6]。cVAE 的结构与 VAE 相似，然而编码器的输入不仅包含数据特征 x ，还包含特征对应的标签 y ；解码器的输入同样包含隐变量 z 与对应的标签 y 。加入标签的意义是控制不同标签下的数据分布，从而可以在不同的标签下做数据生成。隐含的假设是不同的标签下数据特征的分布不同，而 cVAE 便可以学习特征在不同标签下的分布。

图 5：cVAE 架构示意图



数据来源：Wind，东北证券

cVAE 前向传播的过程是：

1. 编码：

输入样本特征 x 与对应的标签 y 到编码器，首先将离散的标签 y 转为 one-hot 编码，与原始特征 x 进行拼接后输入到网络中，输出对应的隐变量 z 近似后验 $q_{\phi}(z|x, y)$ 的均值向量与对数方差向量（这里仍然假设近似后验是各维度独立的 Gaussian 分布，所以方差协方差矩阵是对角阵，可以写成向量的形式）。

2. 采样：

与 VAE 的采样层相同，利用输出的近似后验参数进行隐变量的采样 z 。

3. 解码：

将采样 z 与对应的标签 y 输入到解码器中，得到 $p_{\theta}(x|z, y)$ 的均值，但与 VAE 相同，一般而言会直接将均值作为重构数据 $\tilde{x}$ 。

cVAE 的损失函数与 VAE 基本相似，

$$l(x, y) = \|x - \tilde{x}\|_2^2 + \sum_{j=1}^d \frac{1}{2} \left(-1 + \sigma_{\phi, (j)}^2(x, y) + \mu_{\phi, (j)}^2(x, y) - \log \sigma_{\phi, (j)}^2(x, y) \right).$$

在训练过程中，对于数据集 $X = \{x_i\}_{i=1, \dots, N}$ ， $Y = \{y_i\}_{i=1, \dots, N}$ ，对每个 (x_i, y_i) 计算损失函数值然后进行平均，i.e. $L(X, Y) = \frac{1}{N} \sum_{i=1}^N l(x_i, y_i)$ 。然后反向传播计算梯度，对参数进行优化。

我们期望 cVAE 模型学习到不同标签下数据特征的分布。整个编码器解码器的过程相当于数据重构，但由于采样层引入的随机性，重构数据不会和原始输入相同，但是相差较小且同分布。直接的数据生成则仅使用解码器，隐变量 z 由先验分布随机生成，然后将 z 与标签 y 输入到解码器，生成这个标签对应特征分布的随机样本。这两种方式均可以在一定程度上对原始数据集进行丰富及补充。

基于 cVAE 模型的数据增强，更契合于在不同标签下的特征（多元随机变量）分布不同的情景，学习到不同标签下特征的分布，进行数据生成，作为一种数据增强的方式提升在数据集上其它任务的表现及稳健性。

3. 期权衍生指标与标的风险的关系


3.1. 指标介绍

期权市场为指数未来下行风险的预测评估提供了多样化的信息，并且为投资者提供对冲（Hedging）与套利（Arbitrage）的平台，所以期权的交易信息包括价格、成交量、成交额、隐含波动率、Greeks 等，都反映着期权市场上的交易者对标的指数的某种预期。另外，对同一时间同一标的，也有着不同行权价（Strike Price）与不同到

期时间（Time to Maturity）的众多品种。按照行权价与到期时间这两个维度可以构建隐含波动率曲面（Volatility Surface），如果关注隐含波动率与到期时间这个维度，那么可以得到隐含波动率的期限结构（Term Structure of Volatility）；如果关注隐含波动率与行权价这个维度，那么可以得到隐含波动率微笑曲线（Volatility Smile），这些信息受到广大投资者的关注，监测跟踪这些量价信息的异常情况对于期权市场的套利或者标的指数的择时，有着非常重要的意义。

本文的主要目的是突出数据增强的作用，所以在数据上选用了传统的期权指标，后续在指标层面可以做出一定的改进。第一个指标是上证 50 期权合约的 VIX 指数，类似于 1993 年美国芝加哥期权交易所（CBOE）推出的波动率指数 VIX 的编制方式，VIX 由当日交易的期权行情数据计算得来，可以作为期权隐含波动率的综合指标。隐含波动率通常可以看作是期权市场上对标的未来波动率的预期，所以 VIX 多用于表征市场情绪，也被称作“恐慌指数”。


图 6：VIX 指数与上证 50 ETF 收盘价走势



数据来源：Wind，东北证券

第二个指标是上证 50 期权合约的 SKEW 指数，类似于 2010 年美国芝加哥期权交易所（CBOE）推出的偏度指数 SKEW 的编制方式。SKEW 主要描述期权隐含波动率曲线斜率的走势，衡量并反映期权市场交易者对于市场收益不对称的预期，以及对于市场尾部风险预期。SKEW 对市场中极端情况的发生有预警功能，所以又称为“黑天鹅指数”。


图 7: SKEW 指数与上证 50 ETF 收盘价走势



数据来源: Wind, 东北证券


其他指标是看跌看涨比率 (Put Call Ratio; PCR), 它衡量看跌期权与看涨期权在成交量、成交额、持仓量等方面的不对称性。一般而言, 当期权市场中对未来下行风险的预期上升时, 这种不对称性可能会超出正常范围, 例如当预期未来指数具有较大的下跌风险时, 看跌期权的交易可能会增加来对冲标的面临的 market 风险。

图 8: PCR 成交量比率与上证 50 ETF 收盘价走势




数据来源: Wind, 东北证券

图 9：PCR 持仓量比率与上证 50 ETF 收盘价走势



数据来源：Wind，东北证券

图 10：PCR 成交额比率与上证 50 ETF 收盘价走势




数据来源：Wind，东北证券

3.2. 实证结果

本节我们主要测试上节介绍的几个期权衍生指标 VIX、SKEW 和 PCR 指标对于未来下行风险预测评估的有效性。首先分析指标与未来一月收益率的时序相关性以及指标与指标之间的相关性。

图 11：风险指标与未来一月收益率时序相关系数




数据来源：Wind，东北证券

从相关系数图中可以看出，VIX 与未来一月收益率呈负相关，而 SKEW 与未来一月收益率呈正相关，几个 PCR 指标与未来收益率的相关性不明显。考虑指标之间的相关性我们发现，PCR 指标中 PCR 成交额比率 PCR_total_turnover 与 PCR 成交量比率 PCR_volume 以及 PCR 持仓量比率 PCR_position 均有较强的相关性。由于这些期权衍生指标本身作为风险指标，对于收益率上行的预测可能并非准确，例如可以发现在 VIX 较高的时间段，指数倾向于出现大涨或者大跌，但可能并无明显的收益率上升的判别意义。期权衍生指标可能更善于预测评估未来的波动或风险水平，所以其重要的应用应该为风险管理规避下跌风险而非直接获取多头收益。

如果将目标由未来一个月收益率替换成未来一个月的下行风险，可以重新测试指标与目标以及指标之间的相关性。这里我们选择指数在未来一个月的最大回撤作为未来下行风险的度量。

图 12：风险指标与未来一月最大回撤相关系数



数据来源：Wind，东北证券


一般而言，模型在分类问题上相较于回归有着更好的表现，也更便于使用。所以更进一步我们将未来下行风险标签进行离散化，分割成若干个组别。我们的分类方式为：

1. 计算未来一个月最大回撤的均值以及标准差；

2. 将均值加减 0.5 倍标准差作为两个分割节点，记为节点 1 和节点 2；
3. 将未来一个月最大回撤小于节点 1 的标签记为 0，即低风险水平；将未来一个月最大回撤在节点 1 与节点 2 之间的标签记为 1，即中风险水平；将未来一个月最大回撤大于节点 2 的标签记为 2，即高风险水平。

这种分类方法使得每个组别中的样本数量大致相同。下图是指标与未来下行风险等级之间的相关性。

图 13：风险指标与未来下行风险等级相关系数




数据来源：Wind，东北证券

从图中可以看出，VIX 与未来下行风险等级存在着显著的正相关，这与 VIX 自身的逻辑一致，即对未来市场恐慌情绪的反应。SKEW 与未来下行风险存在着负相关，SKEW 是隐含偏度，描述期权市场对未来收益率分布的预期，较大的偏离隐含着未来的风险水平以及涨跌行情，其是对 VIX 的有效补充。PCR 类指标中，PCR 成交额比率 PCR_total_turnover 与 PCR 成交量比率 PCR_volume 与未来下行风险等级正相关，而 PCR 持仓量比率 PCR_position 与未来下行风险等级呈负相关。但由于 PCR 指标间存在着较强的相关性，以及与 VIX、SKEW 之间的相关性，这里仅选取 PCR 成交额比率作为另外一个风险指标的补充。PCR 成交额比率与未来下行风险正相关的逻辑在于，当比率较高时，市场对于看跌期权交易的偏好高于看涨期权，这表明市场中的存在着较强的避险情绪。


进一步分析观察指标选择的有效性，下面对不同程度的指标下未来一月收益率经验分布以及未来一月最大回撤经验分布进行统计。这里高位指标表示指标高于时序 80% 分位数，相应地，低位指标表示指标低于时序 20% 分位数。

图 14：不同 VIX 下未来一月收益率分布




数据来源：Wind，东北证券

图 15：不同 VIX 下未来一月最大回撤分布




数据来源：Wind，东北证券

图 16：不同 SKEW 下未来一月收益率分布




数据来源：Wind，东北证券

图 17：不同 SKEW 下未来一月最大回撤分布




数据来源：Wind，东北证券

图 18：不同 PCR 成交额下未来一月收益率分布



数据来源：Wind，东北证券

图 19：不同 PCR 成交额下未来一月最大回撤分布



数据来源：Wind，东北证券

表 1：不同程度指标下未来一月收益率的均值与标准差

	高 VIX	低 VIX	高 SKEW	低 SKEW	高 PCR 成交额	低 PCR 成交额
均值	-0.63%	1.76%	1.82%	-1.17%	-0.04%	0.73%
标准差	7.38%	3.62%	7.45%	6.13%	5.88%	6.79%

数据来源：Wind，东北证券

表 2：不同程度指标下未来一月最大回撤的均值与标准差

	高 VIX	低 VIX	高 SKEW	低 SKEW	高 PCR 成交额	低 PCR 成交额
均值	7.84%	2.82%	5.11%	6.74%	6.24%	5.10%
标准差	6.20%	2.38%	3.77%	5.77%	5.03%	4.27%

数据来源：Wind，东北证券

图表中可以看出高低 VIX 指标下，未来一个月收益率和未来一月最大回撤的分布有着明显的区分，低 VIX 时收益均值更高标准差更小，且最大回撤均值更低标准差更小。在高低 SKEW 指标下，未来一月收益率和最大回撤同样有着不同的分布，总体而言，较高的 SKEW 可能意味着相对更好的表现。高低 PCR 成交额比率对于未来收益和风险表现同样有着一定的区分度。


为了验证风险等级分类的合理性，我们比较不同风险等级下的各指标的分布并评估它们的联合分布。首先通过 Augmented Dickey—Fuller (ADF) 检验验证序列的平稳性。之后用 Kolmogorov—Smirnov (KS) 检验验证单随机变量两两分布是否相同。最后用[5]中对于联合分布的评分方法 (Distributional Scores) 通过高阶矩的差异评估联合分布的差异水平。原因是在金融数据应用中，高阶矩决定着产生极值的倾向[5]。评估计算方式如下：

对于 d 维随机向量 X 和 Y ， $\{x_1, x_2, \dots, x_n\}$ 和 $\{y_1, y_2, \dots, y_n\}$ 分别是 X 和 Y 的 n 个采样， $\mathcal{S}$ 和 $\mathcal{K}$ 分别表示对一组样本计算偏度 (Skewness) 和峰度 (Kurtosis)，那么

$$\begin{aligned}
 \text{Skewness score} &= \|\mathcal{S}(x_1, x_2, \dots, x_n) - \mathcal{S}(y_1, y_2, \dots, y_n)\|_2, \\
 \text{Kurtosis score} &= \|\mathcal{K}(x_1, x_2, \dots, x_n) - \mathcal{K}(y_1, y_2, \dots, y_n)\|_2.
 \end{aligned}$$


ADF 检验结果为三个指标的 p 值均不显著，可以认为序列是平稳的。接下来为了验证风险等级划分的有效性，我们统计了不同风险等级下指标的经验分布。

图 20：不同风险等级下 VIX 的分布




数据来源：Wind，东北证券

图 21：不同风险等级下 SKEW 的分布



数据来源：Wind，东北证券

图 22：不同风险等级下 PCR 成交额比率的分布



数据来源：Wind，东北证券

表 3：不同风险等级下各指标的均值与标准差

风险等级	VIX			SKEW			PCR 成交额		
	0	1	2	0	1	2	0	1	2
均值	17.42	23.05	25.02	101.17	100.92	99.75	0.78	0.89	0.96
标准差	5.29	6.49	8.57	2.58	3.09	4.62	0.38	0.49	0.59

数据来源：Wind，东北证券

表 4：不同风险等级间单指标 Kolmogorov—Smirnov 检验的 p 值

	VIX	SKEW	PCR 成交额
风险等级 0-1	3e-47	0.13	3e-3
风险等级 0-2	1e-15	1e-11	2e-8
风险等级 1-2	3e-7	3e-7	0.02

数据来源：Wind，东北证券

表 5：不同风险等级间多指标联合分布的评估分数

	Skewness score	Kurtosis score
风险等级 0-1	0.46	27.88
风险等级 0-2	1.89	107.20
风险等级 1-2	1.63	89.42

数据来源：Wind，东北证券

从经验分布图以及 Kolmogorov—Smirnov 检验的结果中可以看出，在不同的风险等级下，VIX 指标的分布有着显著的差异；SKEW 指标在除等级 0 和等级 1 的分布对比外，也有着不同等级间的分布差异性；PCR 成交额指标在一定的显著性水平下，在不同风险等级间的分布存在差异。较大的 Skewness score 与 Kurtosis score 表明三个指标在不同风险等级下的联合分布存在着较为明显的差异。以上的分析也表明，我们对于未来风险等级的划分方式较为合理，因为它在很大程度上对应着指标在当前的不同模式。

4. 基于 cVAE 和风险指标的策略

4.1. 模型表现及测试


本节首先检验模型对指标联合分布的学习效果。我们使用条件变分自编码器 cVAE 作为数据生成模型。样本特征为上一章中介绍的 VIX、SKEW 以及 PCR 成交额比率，样本标签是按未来一月最大回撤划分的风险等级。将 2015 年 2 月至 2020 年 9 月的数据作为训练集，2020 年 10 月至 2022 年 11 月的数据作为测试集。让模型在训练集上学习特征的联合分布，并对测试集的样本进行重构，比较在测试集中原始样本分布与重构样本分布的差异。

通过上一章的实证分析，可以认为在不同的未来风险等级下，指标的分布也是不同的。考虑到这种差异性，模型事实上需要学习三种不同的数据分布，这对于 cVAE 而言更为适合，因为有额外的标签输入对不同等级下的数据分布进行区分。

在数据处理层面，为了让模型有更好的训练效果，我们对数据集中的指标进行时序标准化。每个训练样本包含三个指标处理后的值和一个风险等级标签。利用 mini-batch 的方法进行训练，参数优化器选择 Adam。


在测试阶段，将测试集按标签即不同的风险等级分成三组，将每组的数据输入到训练好的 cVAE 模型中，编码器得到隐变量的分布，随机采样后输入到解码器中输出重构样本。比较原始样本与重构样本的分布差异可以作为评估 cVAE 模型分布学习效果的一种方式。

图 23: 在测试集中风险等级 0 时 VIX 原始分布与重构分布对比




数据来源: Wind, 东北证券

图 24: 在测试集中风险等级 0 时 SKEW 原始分布与重构分布对比




数据来源: Wind, 东北证券

图 25: 在测试集中风险等级 0 时 PCR 成交额原始分布与重构分布对比



数据来源: Wind, 东北证券

图 26: 在测试集中风险等级 0 时各指标原始数据与对应重构数据热力图




数据来源: Wind, 东北证券

表 6: 在测试集中风险等级 0 时各指标的原始分布与重构分布均值与标准差对比

	VIX		SKEW		PCR 成交额	
	Origin	Recon	Origin	Recon	Origin	Recon
均值	-0.16	-0.15	-0.02	-0.02	0.09	0.09
标准差	0.22	0.24	0.37	0.39	0.58	0.57


数据来源: Wind, 东北证券

图 27: 在测试集中风险等级 1 时 VIX 原始分布与重构分布对比




数据来源: Wind, 东北证券

图 28: 在测试集中风险等级 1 时 SKEW 原始分布与重构分布对比




数据来源: Wind, 东北证券

图 29: 在测试集中风险等级 1 时 PCR 成交额原始分布与重构分布对比



数据来源: Wind, 东北证券

图 30: 在测试集中风险等级 1 时各指标原始数据与对应重构数据热力图




数据来源: Wind, 东北证券

表 7: 在测试集中风险等级 1 时各指标的原始分布与重构分布均值与标准差对比

	VIX		SKEW		PCR 成交额	
	Origin	Recon	Origin	Recon	Origin	Recon
均值	-0.15	-0.14	-0.17	-0.15	0.19	0.20
标准差	0.33	0.35	0.56	0.55	0.84	0.82


数据来源: Wind, 东北证券

图 31: 在测试集中风险等级 2 时 VIX 原始分布与重构分布对比




数据来源: Wind, 东北证券

图 32: 在测试集中风险等级 2 时 SKEW 原始分布与重构分布对比




数据来源: Wind, 东北证券

图 33: 在测试集中风险等级 2 时 PCR 成交额原始分布与重构分布对比



数据来源: Wind, 东北证券

图 34: 在测试集中风险等级 2 时各指标原始数据与对应重构数据热力图



数据来源: Wind, 东北证券

表 8: 在测试集中风险等级 2 时各指标的原始分布与重构分布均值与标准差对比

	VIX		SKEW		PCR 成交额	
	Origin	Recon	Origin	Recon	Origin	Recon
均值	-0.23	-0.25	-0.03	-0.03	0.39	0.38
标准差	0.30	0.31	0.59	0.58	0.79	0.77

数据来源: Wind, 东北证券

表 9: 测试集中不同风险等级下的原始样本与重构样本的分布评估分数

	Skewness score	Kurtosis score
风险等级 0	0.01	0.08
风险等级 1	0.01	0.09
风险等级 2	0.02	0.08

数据来源: Wind, 东北证券

从在测试集当中不同风险等级下的指标原始样本与重构样本分布对比来看, 各指标的原始分布与学习到的分布差别较小; 从指标差异热力图上来看, 原始数据与其对应的重构数据较为相似; 从分布评估分数来看, 在三个风险等级组别下, 原始样本

与重构样本的高阶矩差异较小。上述结果均表明，cVAE 模型在此分布学习上有着不错的表现，同时也表明从训练集上学习到的分布有着一定的泛化性。

4.2. 策略构建及回测结果


上一节中验证了 cVAE 模型对于指标分布学习的表现。本节中，我们利用期权市场的风险指标对未来下行风险进行预测评估，并根据下行风险预测构建指数的择时策略来验证指标的有效性，策略的想法是控制未来中高风险预期下的持仓。由于市场的隐藏状态可能会发生改变，所以在预测时更加偏好近期的数据，这里可以采用滚动训练的方式。之后在初始策略的基础上对每个训练集进行数据增强，验证改进后策略效果的提升。

初始策略设定是，固定窗口期为 500 个交易日，每 20 个交易日为一个调仓日，在每个调仓日，首先将窗口期内的数据进行时序标准化，之后使用标准化后窗口期数据（不包括当日数据）估计预测器（Predictor）的参数，为了简便起见，预测器选择线性分类器逻辑回归模型（Logistic Regression Model）。然后利用估计好参数的预测器和当日数据对未来风险进行预测，再根据预测结果确定持仓限制。我们这里对持仓限制的参数设定是预测未来下行风险等级 0 时满仓持有，风险等级为 1 或 2 时，持仓比率限制为 0.1。

为了结果的可比性，数据增强改进后的新策略设定除每个调仓日的训练集外，其余与初始策略保持一致。在每个调仓日，用标准化之后的窗口期数据以及标签（不包括当日数据）训练 cVAE 模型，使得 cVAE 学习到不同标签下指标的分布。接下来应用训练好的 cVAE 模型对窗口期内的训练数据进行重构，即生成与原始样本数据同分布的重构样本数据。将重构样本与原始样本以及它们对应的标签重新打包作为这个调仓日的增广训练集，然后用新的训练集对预测器的参数进行估计。最后与初始策略相同，用估计好参数的预测器和当日数据对未来风险进行预测，再根据结果确定持仓。


我们使用 2015 年 2 月至 2022 年 11 月的风险指标数据以及行情数据对策略进行回测。值得注意的是，由于使用滚动窗口，策略回测计算净值的起始日期是数据起始日期往后第 500 个交易日。

图 35：策略净值对比（预测器：Logistic regression）



数据来源：Wind，东北证券

图 36：使用数据增强后的策略对未来风险的预测（预测器：Logistic regression）



数据来源：Wind，东北证券

表 10：策略回测结果（预测器：Logistic regression）


	年化收益	年化波动	Sharpe ratio	最大回撤	累计净值	胜率
指数基准	2.1%	19.4%	0.11	38.4%	1.12	-
初始策略	8.2%	10.4%	0.79	12.8%	1.56	0.55
数据增强后的策略	9.0%	10.8%	0.83	12.8%	1.63	0.60

数据来源：Wind，东北证券

选择预测器为逻辑回归模型，对以上定义的初始策略以及数据增强后的策略进行回测。从净值曲线上可以看出，依靠期权风险指标对未来下行风险进行评估的择时策略的确可以在一定程度上规避市场未来的大幅下跌，从而获得超额收益；而在每个调仓日的训练集经过数据增强后，预测器的稳健性得到提升，对未来风险的预测评估也更为准确，改进后的策略具有更好的表现。在风险预测图中，指数曲线上红色的点表示未来的下行风险等级为低风险，绿色的点表示中风险或高风险，数据来自改进后的策略。策略评估表中可以看出，初始策略与改进后的策略均具有较高的超额和 Sharpe ratio，显著更低的波动以及最大回撤，其中改进后的各项指标更优，这


来自于数据增强在一定程度上为模型提供的泛化性。由于这里仅仅使用了线性模型作为分类器，本身泛化性不错，所以从数据上来看并没有大幅度的效果提升。接下来将预测器改为随机森林模型，并测试策略的表现。

图 37：策略净值对比（预测器：Random forest）



数据来源：Wind，东北证券

图 38：使用数据增强后的策略对未来风险的预测（预测器：Random forest）



数据来源：Wind，东北证券

表 11：策略回测结果（预测器：Random forest）

	年化收益	年化波动	Sharpe ratio	最大回撤	累计净值	胜率
指数基准	2.1%	19.4%	0.11	38.4%	1.12	-
初始策略	7.9%	9.9%	0.80	12.1%	1.53	0.61
数据增强后的策略	10.3%	10.0%	1.03	13.96%	1.74	0.64

数据来源：Wind，东北证券

当使用随机森林模型对未来下行风险进行分类时，从策略净值对比图中可以看出，类似于线性分类器，策略规避掉了很多大幅下跌的情况。风险规避的策略构建方式使其本身较为保守，但仍然没有错失上涨的区间。此时经过 cVAE 模型数据增强后的策略具有显著更优的表现，并且优于预测器为逻辑回归模型时的情况，这在很大程度上是源于更复杂的非线性分类模型对于数据集的较高要求，所以数据增强在相对复杂的训练任务上有更大的效果提升。从未来风险的预测图中来看，预测标注为中高风险等级的点较多分布在短期内有较大回撤的区间，图中数据来自于数据增强改进后的策略。从策略评估表中可以看出，当预测器选为随机森林模型时，初始策略与改进后的策略在各个指标上都有着相对指数显著更优的表现，并且数据增强改进后策略在年化收益率、年化波动率以及 Sharpe ratio 等方面相对初始策略表现优异。

对比不同预测器选择下的初始策略，相对复杂的预测器并没有提升策略的表现，这可能是由于滚动窗口期的数据量过小从而降低了模型的泛化性，即样本外的预测能力，而这对于相对复杂的模型而言更为明显。然而，对于不同预测器下的数据增强改进后的模型，较复杂预测器选择下数据增强使得策略表现有明显提升，这表明了数据增强在提升模型泛化性方面具有不错的贡献，尤其是对于小样本情况下相对复杂模型的训练而言。

上述结果表明，数据增强对于未来下行风险预测评估效果有着明显的提升，尤其是对于滚动训练中较小的数据集情况以及相对复杂的预测模型的情况。另外，数据增强对原始策略进行改进，回测结果在各种指标上表现更好。

最后验证数据增强策略对参数的敏感性，这里我们调整不同的中高风险下持仓限制值，并比较不同持仓限制下的初始策略和改进策略的回测结果。

表 12：策略对持仓限制参数的敏感性（预测器：Random forest）

	年化收益	年化波动	Sharpe ratio	最大回撤	累计净值
指数基准	2.1%	19.4%	0.11	38.4%	1.12
初始策略 (0.1)	7.9%	9.9%	0.80	12.1%	1.53
改进策略 (0.1)	10.3%	10.0%	1.03	14.0%	1.74
初始策略 (0.2)	7.7%	11.1%	0.69	15.3%	1.52
改进策略 (0.2)	9.4%	10.4%	0.91	14.0%	1.67
初始策略 (0.3)	7.3%	11.6%	0.63	17.3%	1.49
改进策略 (0.3)	8.6%	11.1%	0.78	17.3%	1.60
初始策略 (0.4)	6.5%	12.3%	0.53	20.6%	1.43
改进策略 (0.4)	7.7%	11.9%	0.65	20.6%	1.53
初始策略 (0.5)	5.7%	13.3%	0.43	24.6%	1.37
改进策略 (0.5)	6.9%	12.9%	0.53	23.8%	1.46

数据来源：Wind，东北证券

从表中可以看出，一方面随着中高下行风险评估时的持仓限制放松，策略的表现会逐渐变差，这表明期权相关风险指标以及模型的应用对未来下行风险等级的划分具有预测意义；另一方面，对于每一个固定的持仓限制值，经过数据增强改进后的策略表现均优于初始策略，这表明基于 cVAE 的数据增强对于模型预测以及策略效果

的提升具有重要意义。

5. 总结

本文介绍了用 cVAE 模型进行数据增强的方法，并尝试将其应用在期权指标对未来下行风险预测评估的任务中，使得效果有较大幅度的提升。

数据增强是一种对数据集进行处理的技术，目的是在保留数据本质特征的同时丰富原始数据集，尤其在小样本情形中，扩充之后的数据集对提升模型的稳健性有着重要的意义。生成模型可以作为数据增强的一种方式。生成模型更加关注于数据本身的特征，即数据的分布，通过对数据分布的拟合或学习，从而生成所需要的与原始样本同分布的数据来补充原始数据集。VAE 与 cVAE 是有着广泛应用的生成模型，它们相对于 GAN 族模型架构较为简单，可能在较小的数据集中训练更为容易。

期权市场的相关指标中，较为经典的 VIX 与 SKEW 指标，以及我们选择的 PCR 成交额指标，在逻辑上和实证检验上对未来的下行风险均有着一定的预测意义。首先使用未来一个月的最大回撤对未来下行风险等级进行划分，作为标签。然后验证了训练好的 cVAE 在测试集上有良好的重构表现。接下来分别使用线性模型和非线性模型作为预测器，使用滚动训练预测评估的方式，制定风险控制择时策略；另外对于初始策略进行改进，即对滚动窗口内的数据集进行数据增强。策略的回测结果表明数据增强后的策略在各项指标上更为优异，在预测器的准确率以及稳健性方面得到了明显的提升。

本文的创新之处主要有：

并没有直接将未来的收益作为预测或分类目标，而创新性地未来一月最大回撤作为衡量未来风险等级的方式，并将依据其划分的风险等级作为预测目标。我们发现，期权的风险指标与未来下行风险的相关性强于与未来收益率的相关性，所以这些指标更适合用来做风险控制而非直接预测收益。

创新地将 cVAE 用在不同未来风险等级下的多维期权指标分布学习上，在测试集上的检验得到了不错的结果。cVAE 相对于 GAN 族模型结构和训练上更为简单，对原始训练集的要求可能较低。

在其它任务的滚动训练中利用 cVAE 生成数据做数据增强，提高了预测器的稳健性与泛化性，使之具有更好的样本外表现。数据增强改进后策略相比于初始策略有较大的提升，并且对于较复杂的预测器而言提升更为明显。最终构建的风险控制策略规避了多次大幅下跌的时间区间，取得了不错的超额收益。

最后，本文作为生成模型在多维指标分布学习的初探，而类似于 cVAE 的大量生成模型未来可能会被应用在更多的领域。一方面，其作为数据增强的方式对选股或者择时中的模型进行数据补充，让模型获得更好的样本外表现。另一方面，强化学习在量化中的一个限制是真实数据的不足，生成模型如果与强化学习进行配合，将大幅扩展其应用范围。另外，期权的相关风险指标也不仅限于此，合理的构造新的有

效指标，或是将指数自身的技术指标以及宏观经济指标进行结合，可能会对结果有进一步的提升。

6. 参考文献

- [1] Yang, S. et al. Image Data Augmentation for Deep Learning: A Survey. 2022.
- [2] Shorten, C., Khoshgoftaar, T.M. & Furht, B. Text Data Augmentation for Deep Learning. 2021.
- [3] Kingma, D. P. & Welling, M. Auto-Encoding Variational Bayes. 2013.
- [4] Goodfellow, I. J. et al. Generative Adversarial Networks. 2014.
- [5] Wiese, M., Bai, L., Wood, B. & Buehler, H. Deep Hedging: Learning to Simulate Equity Option Markets. 2019.
- [6] Sohn, K., Lee, H. & Yan, X. Learning Structured Output Representation using Deep Conditional Generative Models. 2015.

7. 风险提示

分析基于历史数据与模型，存在模型失效风险，历史数据回测结果不代表未来表现。

研究团队简介:

王琦：帝国理工学院数学与金融荣誉硕士，南开大学统计学学士。2021 年加入东北证券上海证券研究咨询分公司任金融工程首席分析师，研究方向为金融工程。曾任职于兴业财富资产管理有限公司，任 FOF 投资经理。

李严：中山大学统计学本科、复旦大学应用统计硕士，主要研究基金产品、行业轮动方向，2020 年加入东北证券，现任东北证券上海证券研究咨询分公司金融工程组分析师。

贾英：伦敦大学学院金融数学荣誉硕士，厦门大学数学与应用数学本科。2022 年加入东北证券，研究方向为金融工程、因子选股。现任东北证券上海证券研究咨询分公司金融工程组研究助理。

张栋梁：复旦大学金融硕士，南京大学金融学本科，2022 年加入东北证券，研究方向为因子选股，现任东北证券上海证券研究咨询分公司金融工程组研究助理。

重要声明

本报告由东北证券股份有限公司（以下称“本公司”）制作并仅向本公司客户发布，本公司不会因任何机构或个人接收到本报告而视其为本公司的当然客户。

本公司具有中国证监会核准的证券投资咨询业务资格。

本报告中的信息均来源于公开资料，本公司对这些信息的准确性和完整性不作任何保证。报告中的内容和意见仅反映本公司于发布本报告当日的判断，不保证所包含的内容和意见不发生变化。

本报告仅供参考，并不构成对所述证券买卖的出价或征价。在任何情况下，本报告中的信息或所表述的意见均不构成对任何人的证券买卖建议。本公司及其雇员不承诺投资者一定获利，不与投资者分享投资收益，在任何情况下，我公司及其雇员对任何人使用本报告及其内容所引发的任何直接或间接损失概不负责。

本公司或其关联机构可能会持有本报告中涉及到的公司所发行的证券头寸并进行交易，并在法律许可的情况下不进行披露；可能为这些公司提供或争取提供投资银行业务、财务顾问等相关服务。

本报告版权归本公司所有。未经本公司书面许可，任何机构和个人不得以任何形式翻版、复制、发表或引用。如征得本公司同意进行引用、刊发的，须在本公司允许的范围内使用，并注明本报告的发布人和发布日期，提示使用本报告的风险。

若本公司客户（以下称“该客户”）向第三方发送本报告，则由该客户独自为此发送行为负责。提醒通过此途径获得本报告的投资者注意，本公司不对通过此种途径获得本报告所引起的任何损失承担任何责任。

分析师声明

作者具有中国证券业协会授予的证券投资咨询执业资格，并在中国证券业协会注册登记为证券分析师。本报告遵循合规、客观、专业、审慎的制作原则，所采用数据、资料的来源合法合规，文字阐述反映了作者的真实观点，报告结论未受任何第三方的授意或影响，特此声明。

投资评级说明

股票 投资 评级 说明	买入	未来 6 个月内，股价涨幅超越市场基准 15% 以上。	投资评级中所涉及的市场基准： A 股市场以沪深 300 指数为市场基准，新三板市场以三板成指（针对协议转让标的）或三板做市指数（针对做市转让标的）为市场基准；香港市场以摩根士丹利中国指数为市场基准；美国市场以纳斯达克综合指数或标普 500 指数为市场基准。
	增持	未来 6 个月内，股价涨幅超越市场基准 5% 至 15% 之间。	
	中性	未来 6 个月内，股价涨幅介于市场基准-5% 至 5% 之间。	
	减持	未来 6 个月内，股价涨幅落后市场基准 5% 至 15% 之间。	
	卖出	未来 6 个月内，股价涨幅落后市场基准 15% 以上。	
行业 投资 评级 说明	优于大势	未来 6 个月内，行业指数的收益超越市场基准。	
	同步大势	未来 6 个月内，行业指数的收益与市场基准持平。	
	落后大势	未来 6 个月内，行业指数的收益落后于市场基准。	

东北证券股份有限公司

 网址: <http://www.nesc.cn> 电话: 400-600-0686

地址	邮编
中国吉林省长春市生态大街 6666 号	130119
中国北京市西城区锦什坊街 28 号恒奥中心 D 座	100033
中国上海市浦东新区杨高南路 799 号	200127
中国深圳市福田区福中三路 1006 号诺德中心 34D	518038
中国广东省广州市天河区冼村街道黄埔大道西 122 号之二星辉中心 15 楼	510630

机构销售联系方式

姓名	办公电话	手机	邮箱
公募销售			
华东地区机构销售			
王一 (副总监)	021-61001802	13761867866	wangyi1@nesc.cn
吴肖寅	021-61001803	17717370432	wuxiaoyin@nesc.cn
李瑞暄	021-61001802	18801903156	lirx@nesc.cn
周嘉茜	021-61001827	18516728369	zhoujq@nesc.cn
陈梓佳	021-61001887	19512360962	chen_zj@nesc.cn
屠诚	021-61001986	13120615210	tucheng@nesc.cn
康杭	021-61001986	18815275517	kangh@nesc.cn
丁园	021-61001986	19514638854	dingyuan@nesc.cn
吴一凡	021-20361258	19821564226	wuyifan@nesc.cn
王若舟	021-61002073	17720152425	wangrz@nesc.cn
华北地区机构销售			
李航 (总监)	010-58034553	18515018255	lihang@nesc.cn
殷璐璐	010-58034557	18501954588	yinlulu@nesc.cn
曾彦戈	010-58034563	18501944669	zengyg@nesc.cn
吕奕伟	010-58034553	15533699982	lyyw@nesc.com
孙伟豪	010-58034553	18811582591	sunwh@nesc.cn
陈思	010-58034553	18388039903	chen_si@nesc.cn
徐鹏程	010-58034553	18210496816	xupc@nesc.cn
曲浩蕴	010-58034555	18810920858	quhy@nesc.cn
华南地区机构销售			
刘璇 (总监)	0755-33975865	13760273833	liu_xuan@nesc.cn
刘曼	0755-33975865	15989508876	liuman@nesc.cn
王泉	0755-33975865	18516772531	wangquan@nesc.cn
王谷雨	0755-33975865	13641400353	wanggy@nesc.cn
张瀚波	0755-33975865	15906062728	zhang_hb@nesc.cn
王熙然	0755-33975865	13266512936	wangxr_7561@nesc.cn
阳晶晶	0755-33975865	18565707197	yang_jj@nesc.cn
张楠淇	0755-33975865	13823218716	zhangnq@nesc.cn
钟云柯	0755-33975865	13923804000	zhongyk@nesc.cn
杨婧	010-63210892	18817867663	yangjing2@nesc.cn
梁家滢	0755-33975865	13242061327	liangjy@nesc.cn
非公募销售			
华东地区机构销售			
李茵茵 (总监)	021-61002151	18616369028	liyinyin@nesc.cn
杜嘉琛	021-61002136	15618139803	dujiachen@nesc.cn
王天鸽	021-61002152	19512216027	wangtg@nesc.cn
王家豪	021-61002135	18258963370	wangjiahao@nesc.cn
白梅柯	021-20361229	18717982570	baimk@nesc.cn
刘刚	021-61002151	18817570273	liugang@nesc.cn
曹李阳	021-61002151	13506279099	caoly@nesc.cn
曲林峰	021-61002151	18717828970	qulf@nesc.cn
华北地区机构销售			
温中朝 (副总监)	010-58034555	13701194494	wenzc@nesc.cn
王动	010-58034555	18514201710	wang_dong@nesc.cn
闫琳	010-58034555	17862705380	yanlin@nesc.cn
张煜苑	010-58034553	13701150680	zhangyy2@nesc.cn