

2022 年 06 月 01 日

小样本机器学习技术实现指数择时

机器学习择时系列之二

投资要点：

► 在量化策略中运用机器学习技术

机器学习技术已广泛运用于数据驱动业务场景下的方方面面，例如图像识别、智能推荐等。在金融领域，机器学习技术的应用也愈加广泛。量化策略亦是数据驱动，机器学习与量化策略的结合是当前策略迭代的重要方向。

► 生成对抗网络（GAN）扩充小样本

在训练数据较少的情况下，可以训练一个生成对抗网络，通过给小样本数据集加上扰动来生成新样本。通过 GAN 网络对小样本进行数据增强，能够有效解决模型因数据量少而欠拟合的问题。

► 基于生成对抗网络的择时策略表现良好

逻辑回归模型依赖于前期特征工程的贡献，对数据的要求较高。利用 GAN 模型实现数据扩充可以帮助做出好的特征，提高数据质量。同时逻辑回归模型可以预测指数的涨跌趋势，择时策略的回测结果表明，对样本扩充后逻辑回归模型的表现有明显提升。

风险提示

模型基于对历史数据统计，仅作为投资参考。

评级及分析师信息

证券分析师：王祥宇
SAC NO: S1120520080004

证券分析师：杨国平
SAC NO: S1120520070002

助理分析师：周游
邮箱：zhouyou2@hx168.com.cn

正文目录

1. 小样本学习基本理论.....	4
1.1. 小样本学习的定义.....	4
1.2. 小样本学习在证券择时场景下的应用.....	4
2. 生成对抗网络与线性回归（FSL-LR）模型.....	5
2.1.1. 基于生成对抗网络的数据增强.....	5
2.1.2. 广义线性模型与逻辑回归.....	6
2.1.3. 逻辑回归目标函数的推导.....	7
3. 基于 FSL-LR 模型的择时建模.....	8
3.1. FSL-LR 模型提出的背景.....	8
3.2. 基于 FSL-LR 模型的策略设计思路.....	8
3.2.1. 建模方法.....	8
3.2.2. 模型预测目标.....	9
3.2.3. 数据及参数选择.....	9
3.3. 策略具体过程及回测分析.....	11
3.3.1. 技术指标与股票涨跌趋势的相关性分析.....	11
3.3.2. FSL-LR 模型的优化.....	14
3.3.3. 窗长窗移滚动训练模式分析.....	15
3.3.4. FSL-LR 模型评估.....	15
4. 总结.....	16
5. 风险提示.....	17

图目录

图 1: GAN 原理示意图	5
图 2: GAN 的训练过程	6
图 3: SIGNAL_MACD 指标与沪深 300 股价趋势图	11
图 4: CCI 指标与沪深 300 股价趋势图	12
图 5: RSI 指标与沪深 300 股价趋势图	13
图 6: ADX 指标与沪深 300 股价趋势图	13
图 7: FSL-LR 模型对比基准的净值走势图	15
图 8: FSL-LR 模型季度收益率	15
图 9: 模型 ROC 曲线图	16

表目录

表 1: 14 个技术指标及其含义	10
表 2: 14 个技术指标的权重值	11
表 3: 随机断开输入神经元比例对回测结果的影响	14
表 4: 训练批次对回测结果的影响	14
表 5: 逻辑回归阈值对回测结果的影响	14
表 6: 择时策略评价指标	15

1. 小样本学习基本理论

小样本学习 (Few-Shot Learning, FSL) 是一种新颖的机器学习方法, 在过去两年中流行起来, 它旨在从少量的标记数据中学习。深度神经网络在大数据上取得了骄人的成绩, 但在仅有少量样本时表现得不尽如人意, 而在很多实际情况中, 数据难以取样或大量累积。为了解决该问题, 小样本学习被越来越多的研究者所关注。这一节, 我们主要介绍小样本的基本理论, 包含小样本学习的定义和方法。

1.1. 小样本学习的定义

随着大数据时代的到来, 深度学习模型已经在图像分类、文本分类等任务中取得了先进成果。一般来讲, 深度学习的成功可以归结于三个关键因素: 强大的计算资源、复杂的神经网络和大规模数据集。

但是, 由于诸如隐私, 安全性或数据的高标签成本等一系列因素, 许多现实的应用场景 (例如在医学, 军事和金融领域) 没有条件获取足够的带标签的训练样本, 或者需要消耗大量的时间和人力对无标签数据进行标注。面对这类问题, 一个专门的机器学习分支—小样本学习应运而生。

计算机程序基于与任务 T 相关的经验 E 进行学习, 使用度量指标 P 得到改进。基于此, 小样本学习定义为: 小样本学习是一类机器学习问题, 其经验 E 中仅包含有限数量的监督信息。总结起来, 机器学习就是从数据中学习, 从而使完成任务的表现越来越好。小样本学习是具有有限监督数据的机器学习。

1.2. 小样本学习在证券择时场景下的应用

证券交易的过程通常是以动态的方式完成, 一次成功的交易一般包括两个步骤: 首先了解市场然后做出正确的决定。了解市场状况通常需要调查过去的时间序列数据, 这些数据通常是复杂的, 不稳定的, 并且存在很多不确定性。随着影响市场因素的增多, 精确地预测金融市场也变得愈加艰难。机器学习方法以其强大的非线性拟合能力和灵活的结构设计, 在金融场景的应用也越来越受到专业投资者的重视。

近年来, 各种机器学习方法已经被广泛地应用到金融时间序列预测方面。这些基于机器学习的方法往往是基于历史大样本数据进行训练, 并且假设训练样本和预测样本的分布是一致的。但是股市的分布其实并不稳定, 在不同的时间段, 其分布是不同的。为了避免股市数据分布变化的问题, 一个有效的方法是基于近期数据训练模型 (增加近期历史数据的训练权重)。然而由于近期数据样本量较少, 模型容易欠拟合。基于数据增强的小样本学习方法可以对训练数据进行扩充, 使得机器学习模型尽可能收敛。

量化投资策略的主要思想是利用证券价格的历史趋势来判断证券的未来价格, 并制定相应的投资策略。本文将讨论小样本学习策略在择时场景中的应用。择时策略作为量化投资的策略之一, 是通过对未来市场走势的判断, 增加或减少某一特定资产仓位的投资策略。其目的是通过对未来走势的判断, 改变持仓仓位, 从而获取相对于基准的超额收益。

在下一节中, 本文将介绍一种新颖的基于小样本学习的择时策略框架。


2.生成对抗网络与线性回归（FSL-LR）模型

这里将生成对抗网络与线性回归模型组合使用（FSL-LR）构建市场择时策略，具体地，首先通过生成对抗网络扩充训练样本，然后输入给逻辑回归模型预测股票的下一个持仓周期的收益率。

2.1.1. 基于生成对抗网络的数据增强

数据增强是实现小样本学习的方法之一，是一种对数据集规模进行扩充的行之有效的办法。由于数据增强的存在，数据的规模更大，质量也越高，使得网络模型可以具备更强大的泛化能力。在数据量不足的情况下，可以训练一个生成对抗网络，通过学习过程给小样本数据集加上扰动来生成新样本，从而达到扩充数据的目的。本次的策略主要采用生成对抗网络针对部分训练数据进行数据扩充，再与逻辑回归分类模型结合构建市场择时策略。这里给出生成对抗网络的定义和训练过程。

图 1：GAN 原理示意图



资料来源：华西证券研究所

（1）生成对抗网络的定义

生成对抗网络（Generative Adversarial Network, GAN）是非监督式学习的一种方法，通过让两个神经网络相互博弈的方式进行学习。该方法由伊恩·古德费洛等人于 2014 年提出。

生成对抗网络由一个生成网络与一个判别网络组成：

- 生成网络从潜在空间（latent space）中随机取样作为输入，其输出结果需要尽量模仿训练集中的真实样本。
- 判别网络的输入则为真实样本或生成网络的输出，其目的是将生成网络的输出从真实样本中尽可能分辨出来。而生成网络则要尽可能地欺骗判别网络。


两个网络相互对抗、不断调整参数，最终目的是使判别网络无法判断生成网络的输出结果是否真实。其原理示意图如图 1 所示。

（2）生成对抗网络的训练

请仔细阅读在本报告尾部的重要法律声明

在这里，判别器和生成器的更新交替进行，但判别器的更新次数是生成器的 k 倍，其想法是将判别器训练地更好有利于生成器的学习。可以令 $k = 1$ 来减少计算代价，但在一些不同的应用中 k 的取值往往不同。为了更直观地说明这个问题，图 2 显示了 GAN 的训练过程变化。图 2a 表示一开始的训练情况，此时目标数据的分布和生成器所生成的数据分布差异很大，判别器对这两个分布的概率判断也不准确，在完全属于真实样本的时候，也即图中最左边黑色和绿色曲线不相交部分，判别器的输出不是恒定为 1，对完全属于生成样本的时候，也即图中最右边，其概率判断也不是恒定为 0。随后在图 2b 中，当判别器训练的较为准确但生成器未训练时，此时判别器对完全属于真实样本的部分概率输出恒为 1，对完全属于生成样本的部分输出恒为 0，对这两者的相交部分则根据其可能的概率情况，输出相应的值。当生成器得到训练时，也即图 2c 所示，其输出分布进一步靠近目标分布。最后，当 GAN 训练完成时候，如图 2d 所示，生成器的输出分布和判别器的输出分布完全一致，而判别器的输出恒定为 0.5。

图 2：GAN 的训练过程



资料来源：华西证券研究所

基于数据增强的小样本学习方法是目前几乎所有机器学习任务的前置工作，在具体的定义上，数据增强是指通过预处理在数据集中引入视觉不变性，对训练数据进行扩增的过程。通过数据增强，模型可以学习到更多元化更接近真实的数据分布的特征，从而在具体的应用场景中获得更优秀的性能，模型更加鲁棒。

2.1.2. 广义线性模型与逻辑回归

逻辑回归模型是基于统计的学习模型有着良好的统计学基础和解释性。其来源于指数族，指数族的定义： $p(y; \eta) = b(y) \exp(\eta^T T(y) - a(\eta))$ ，其中 η 是分布的特征参数， $T(y)$ 是所考虑的分布的充分统计量，一般情况下 $T(y) = y$ ， $a(\eta)$ 被称作对数分区函数通常 $e^{-a(\eta)}$ 在归一化参数的时候扮演着重要的角色，它确保了分布 $p(y; \eta)$ 关于 y 的积分或者和等于 1。

对于选定的 T ， a 和 b 两个函数决定了该分布属于家族中的种类。首先考虑伯努利分布。

伯努利分布通常又叫做二项分布，均值为 ϕ 的伯努利分布写作 $B(\phi)$ ，由伯努利的分布知道 $y \in \{0, 1\}$ ，因此 $p(y = 1; \phi) = \phi$ ； $p(y = 0; \phi) = 1 - \phi$ ，当 ϕ 改变时就能得到不同的伯努利分布，令：

$$\begin{cases} T(y) = y \\ a(\eta) = -\log(1 - \phi) = \log(1 + e^\eta) \\ b(y) = 1 \end{cases}$$

将其带入 $p(y; \eta)$ 式中，得到 $p(y; \eta) = \exp\left(\log\left(\frac{\phi}{1-\phi}\right)y + \log(1 - \phi)\right) = \exp(y \log \phi + (1 - y) \log(1 - \phi)) = \phi^y (1 - \phi)^{1-y}$ ，这正是伯努利的分布公式，因此伯努利分布属于指数族。

通常情况下，指数族的参数估计问题都能通过构建广义线性模型的方式来解决，对于如何构建广义线性模型，在给定样本 x 和参数 θ 的情况下，关于 y 的条件概率 $p(y|x; \theta)$ 给出如下假设：

- (1) $y|x; \theta$ 属于指数族；
- (2) 对于给定的 x ，目标是预测 $T(x)$ 的期望即 $h(x) = E[y|x]$ 这里 $T(y) = y$ ；
- (3) $\eta = \theta^T x$ ，即 η 与 x 是线性相关的。

有了如上假设以后，就可以对一般线性回归和逻辑回归进行构建了，在一般线性回归中假设给定样本 x 和参数 θ 的情况下，关于 y 的条件概率服从高斯分布即， $y|x; \theta \sim N(\mu, \sigma^2)$ ，由前面高斯分布与指数族的关系可知满足第一条假设。按照假设 (2) 和 (3) 以及高斯分布的性质可以得到公式： $h_\theta(x) = E[y|x] = \mu = \eta = \theta^T x$ 。

而在逻辑回归中，假设给定样本 x 和参数 θ 的情况下，关于 y 的条件概率服从伯努利分布即 $y|x; \theta \sim B(\phi)$ ，由前面伯努利分布与指数族的关系可知满足第一条假设，按照假设 2 和 3 以及伯努利分布的性质可以得到公式： $h_\theta(x) = E[y|x] = \phi = 1/(1 + e^{-\eta}) = 1/(1 + e^{-\theta^T x})$ 。

至此，使用高斯分布与广义线性模型得到的公式 $h_\theta(x)$ 和使用伯努利分布与广义线性模型得到的公式，两者在形式上具有高度的相似性，这两个模型恰恰是一般线性模型和逻辑回归模型，这也是为什么一般线性回归与逻辑回归具有非常强的相关性的原因，其中公式 $h_\theta(x) = E[y|x] = \phi = 1/(1 + e^{-\eta}) = 1/(1 + e^{-\theta^T x})$ 又被称作逻辑回归的预测函数。

2.1.3. 逻辑回归目标函数的推导

无论是将模型应用在曲线拟合上还是应用在分类上，逻辑回归首先面临的问题是确定目标函数（即损失函数）。损失函数的作用就是评价模型的好坏，常用的损失函数包括，0-1 损失函数、平方损失函数、绝对值损失函数、对数损失函数几种。

逻辑回归通常使用的是对数损失函数，这是由于逻辑回归应用到分类问题上时，输出值 y 是离散的，而且是二值的，只有 0 或者 1，这就可以对应到二项分布上，而二项分布使用对数损失函数是最直观的。逻辑回归的目标函数推导过程如下所示：

假设有 m 个独立样本 $\{(x^1, y^1)(x^2, y^2)(x^3, y^3), \dots, (x^m, y^m), y \in \{0, 1\}\}$ ，那么，每个样本出现的概率是： $p(x^i, y^i) = p(y^i = 1|x^i)^{y^i} (1 - p(y^i = 1|x^i))^{1-y^i}$

当 $y = 1$ 的时候，后面的一项等于 1，而当 $y = 0$ 的时候前面的一项等于 1，考虑到每个样本是独立的所以 m 个样本出现的概率可以表示成他们的乘积，即： $L(\theta) = \prod_{i=1}^m p(y^i = 1|x^i)^{y^i} (1 - p(y^i = 1|x^i))^{1-y^i}$

这个函数是逻辑回归的似然函数，可以作为损失函数使用，但是其计算复杂且计算精度常受到限制，在实际应用中需要使用对数损失，因此对其使用对数函数进行化简，得到：
$$J(\theta) = \log(L(\theta)) = \log\left(\prod_{i=1}^n p(y^i = 1|x^i)^{y^i} (1 - p(y^i = 1|x^i))^{1-y^i}\right) = \sum_{i=1}^n (y^i \log p(y^i = 1|x^i) + (1 - y^i) \log(1 - p(y^i = 1|x^i))) = \sum_{i=1}^n (y^i \log h_{\theta}(x^i) + (1 - y^i) \log(1 - h_{\theta}(x^i)))$$

这便是最终形式的损失函数，也就是计算中使用的目标函数，逻辑回归中主要的计算就是针对此函数求解最小值，由于没有解析解，因此需要使用迭代算法近似求解。

3. 基于 FSL-LR 模型的择时建模

量化择时是指根据对未来市场走势的估计，来确定下一阶段的仓位大小。在这里为了简化讨论，假设预测的目标为下一个持仓周期的收益率正负（二分类问题）。二分类问题，可以用逻辑回归来解决，它不仅可以提供除类别标签信息外的明确分类概率，而且可以分析所有类型数据的预测值。我们这里来研究在使用了生成对抗网络做数据扩充的情况下基于逻辑回归模型的择时建模。

3.1. FSL-LR 模型提出的背景

股票收益率的分布在长时间维度（样本足够大）可以近似认为对数正态分布，但在较短的时间区间内收益率的分布往往具有一定的偏度（Skewness）和峰度（Kurtosis），因此短时间的收益率分布的估计（均值/期望和标准差）是有意义的。传统方法是在历史时间区间选取资产的特定特征数据来训练收益率的估计模型（假设收益率期望是固定的），而忽略期望收益率的时变特性。这显然是不合理。因为我们可以轻易地观察到在牛市区间和熊市区间，给定持仓周期的资产收益率样本均值显著不同。在观察到这一现象后，相关研究使用移动窗口训练或时间序列加权的方式来建模资产预期收益率的时变特性。

这类方法的主要目的都是减少过早的历史信息对当前的收益率估计的影响。但这样会减少样本的数量和样本的质量。为了解决这一问题，本文提出了使用生成对抗网络（GAN）对移动窗口的特征数据进行数据增强然后结合线性回归模型构建出收益率估计模型。

3.2. 基于 FSL-LR 模型的策略设计思路

3.2.1. 建模方法

对广义的回归模型来说，这类模型探究的重点为自变量和因变量的线性关系是否显著。在实际应用场景，我们通常希望线性模型能给出连续的预测结果。但有时候，我们不需要精确的数值结果，只想知道结果属于哪个区间。例如，明天的大盘上涨或者下跌；下一个操作周期，预期收益率是否大于操作成本。这时，我们一般通过给定一个阈值，来将线性回归的结果进行下一步分类。逻辑回归模型给出了属于正负类的概率预测，那么，在本文的讨论语境（预测下一个持仓周期的收益率正负）需要给定属于正类的概率阈值，这一先验超参数。

这里我们采用窗长窗移滚动训练模式对 FSL-LR 模型进行训练，具体过程为：将第 1-N 个持仓周期的数据作为训练集的一部分，第 N+1 个持仓周期的数据用来测试，

然后将 $2-N+1$ 个持仓周期的数据作为训练集的一部分，第 $N+2$ 天数据用来测试，以此类推。具体的准备训练数据的过程如下：从 N 个样本数据中筛选出正样本 `trainx_pos`（样本收益率为正）和负样本 `trainx_neg`（样本收益率为负），分别输入生成对抗网络 GAN 进行训练，训练次数设置为 20。然后给定一定大小的 noise（noise 的大小为正样本或者负样本长度的 2 倍）输入给训练好的生成器生成新样本 `generated_pos` 和 `generated_neg`，最后将 N 个样本数据和生成的数据拼接起来组成新的训练样本集，将样本量为 N 的样本集合扩充为样本量为 $3N$ 的样本集合。

生成对抗网络通过博弈训练的方式学习数据的分布同时生成可以以假乱真的数据。在数据量较少的情况下，利用生成对抗网络进行数据增强并加入分类器中进行训练可以有效加强分类器模型的鲁棒性。准备好训练集和测试集之后，先对逻辑回归模型进行训练，做参数估计。输入变量是 14 个技术指标对应的计算值，输出变量为 1 表示有获利的可能，可以买入建仓；输出变量为 0 表示此时机可以卖出平仓或保持空仓。

3.2.2. 模型预测目标

标签预测是基于模型学习的信息来对样本外标签的输出。对于逻辑回归模型，正负类判别的阈值默认为 0.5（预测结果大于等于 0.5 则预测样本标签为正类，输出 1，否则输出 0，表示模型判断该样本为负类）。在训练的过程中，该超参数需要通过验证集来选择。

3.2.3. 数据及参数选择

关于数据集的选取我们使用沪深 300 指数（000300）的日线级数据来进行模型的训练和测试。

这里使用生成对抗网络 GAN 对训练数据进行扩充，GAN 的关键参数选择如下：

（1）缓冲区大小（`BUFFER_SIZE`）：该参数配合 `shuffle` 函数可以随机洗牌数据集的元素，构建新的数据集时使用 `BUFFER_SIZE` 大小的元素填充缓冲区，然后从该缓冲区中随机采样元素，实现对数据集元素的洗牌或打乱。

（2）随机断开输入神经元比例（`dropout`）：该参数用来调节 `dropout` 层将部分神经网络单元暂时从网络中筛选出去的概率，`dropout` 层用于减小神经网络模型发生过拟合及性能过低的概率，减少神经网络单元的同时也减少了神经元之间的相关性，增强了神经网络在样本外进行测试时的泛化能力。这里我们将 `dropout` 设置为 0.4。

（3）训练批次（`epochs`）：单次 `epochs` 指的是将 `BATCH_SIZE` 大小的数据输入网络进行一次完整的计算。此参数的设置会较大地影响模型的训练精度和训练时间。滑动窗口训练模式下利用生成对抗网络进行数据扩充时，此参数被确定为 20。

（4）单个训练批次样本数（`BATCH_SIZE`）：`BATCH` 是每次将训练数据输入到网络的批次，而 `BATCH_SIZE` 是每个 `BATCH` 中训练样本的大小。在用相应数据集对生成对抗网络进行训练时，此参数被设置为 5。

（5）损失函数（`gen_loss`, `disc_loss`, `total_loss`）：在训练生成对抗网络时有三种损失函数需要设置，分别是生成器损失函数、判别器损失函数、模型总体的损失函数。生成器损失函数和判别器损失函数均使用了交叉熵函数 `cross_entropy()`，模型总体的损失由生成器损失和判别器损失综合计算得到。

（6）优化器（`generator_optimizer`, `discriminator_optimizer`, `total_opti`

mizer): 优化器的目的是使损失函数最小化, 这里我们将随机梯度下降算法 SGD 作为优化函数, 将此函数的学习率 lr 设置为 0.00001。

FSL-LR 模型特征变量选择: 这里我们选择若干个技术指标。技术指标属于统计类因子, 一般与量价信息有关。技术指标能够在一定程度上帮助投资者判断市场的当前状态, 寻找行情的转折点。这里选取 14 个常用的技术指标作为特征因子。它们分别是 Bollinger_UpperBands、Bollinger_LowBands、WMA、EMA、SAR、CCI、CMO、DX、SIGNAL_MACD、MOM、ROC、RSI、ADX、ATR, 表 1 对它们做出了相应解释。

表 1: 14 个技术指标及其含义

技术指标	含义
Bollinger_UpperBands	布林线上轨: 布林线是指利用统计原理, 求出股价的标准差及其信赖区间, 从而确定股价的波动范围及未来走势, 利用波带显示股价的安全高低价位。布林线指标中的上、中、下轨线所形成的股价信道随着股价的上下波动而变化, 股价信道的上轨是显示股价安全运行的最高价位
Bollinger_LowBands	布林线下轨: 布林线是指利用统计原理, 求出股价的标准差及其信赖区间, 从而确定股价的波动范围及未来走势, 利用波带显示股价的安全高低价位。布林线指标中的上、中、下轨线所形成的股价信道随着股价的上下波动而变化, 股价信道的下轨是显示股价安全运行的最低价位
WMA	移动加权平均: 度量一段时间内的股票价格的加权移动平均, 反映市场趋势和价格倾向
EMA	指数平均线: 体现股价对均线的影响
SAR	抛物线指标: 属于价格与时间并重的指标, 通过对股票价格振幅及时间的分析研究, 随时设立停损点以观察股票卖出时机
CCI	顺势指标: 度量股票价格变化与平均股票价格变化差, 主要识别超买和超卖信号
CMO	钱德动量摆动指标: 计算所有最近收益之和与所有最近损失之和的差
DX	动向指标: 分析股票价格在上升及下跌过程中供需关系的均衡点对股价趋势做出判断
SIGNAL_MACD	平滑异同移动平均线: 识别趋势变化, 以形成买入与卖出信号, 找到买卖信号的拐点
MOM	动量: 度量股票价格的涨跌速率, 正值表示向上趋势, 负值表示向下趋势
ROC	变动率指标: 衡量当前价格与过去价格之间的比, 显示价格变动速度
RSI	相对强弱指数: 通过收盘价连续向上与连续向下运动的比值反映资产价格的力度或速度, 从而衡量市场繁荣程度
ADX	平均趋向指数: 反应趋向变动程度即描述趋势的强弱
ATR	真实波动幅度均值: 取一定时间周期内股价波动幅度的移动平均值来显示股票市场变化率, 主要用于研判买卖时机

资料来源: 华西证券研究所

FSL-LR 模型响应变量选择：本实验 FSL-LR 模型的响应变量选取的是指数的下一期收益率正负（1 代表收益率为正，0 代表收益率为负），通过模型给出的预测结果，策略选择开仓平仓。

夏普率和最大回撤率是衡量策略收益与风险特性的常用指标，这里我们主要以夏普比率和最大回撤率这两个指标来衡量交易结果。

3.3. 策略具体过程及回测分析

Vanston 和 Finnie 在股市预测研究中得出结论：长期预测中基本面指标效果更好；短期的预测模型（日线级别以下），量价类特征更有效。因此，这里选择 14 项技术指标作为特征变量，以下一个持仓周期的收益率正负作为响应变量。利用 FSL-LR 模型，对指数的涨跌趋势进行预测。

3.3.1. 技术指标与股票涨跌趋势的相关性分析

为了说明 14 个技术指标与股票涨跌趋势之间的相关性，在对输入特征进行了标准化的前提下，可以利用逻辑回归模型的 `coef_` 方法输出模型参数，即权重向量。对于权重向量，它的每一个维度的值，代表了这个维度的特征对于最终分类结果的贡献大小。假如这个维度是正，说明这个特征对于结果是有正向的贡献，那么它的值越大，说明这个特征对于分类为正起到的作用越大。因此，权重向量的大小可以在一定程度上说明各个输入特征对股票涨跌趋势的影响程度。我们这里建立的 FSL-LR 模型的权重值如表 2 所示。

表 2：14 个技术指标的权重值

Bollinger_UpperBands	Bollinger_LowBands	WMA	EMA	SAR	CCI	CMO
-0.4488	-0.7658	0.4938	-0.0085	-0.6026	-0.1742	0.9684
DX	SIGNAL_MACD	MOM	ROC	RSI	ADX	ATR
-0.1446	0.1968	0.1471	0.1630	0.9684	-0.1040	-0.2049

资料来源：华西证券研究所

从表 2 可以看出 CMO 指标和 RSI 指标与股价涨跌趋势的相关性最强，并且相对于结果是有正向的贡献。其次是 Bollinger_LowBands 指标，它利用统计原理，求出股价的标准差及其信赖区间，从而确定股价的波动范围及未来走势。权重值最小的是 EMA 指标，说明它对股票涨跌趋势的影响程度较小。

为了进一步说明技术指标与股价涨跌趋势的关系，刻画了技术指标与股价涨跌趋势图。为了便于分析，我们选择 2021 年 1 月到 7 月的数据分别绘制 ADX、MACD、CCI、RSI 技术指标与股价变动趋势图，其他的技术指标与股票变动趋势图可以采用类似的方法绘制。图 3 到图 6 展示了 2021 年 1 月到 7 月的 SIGNAL_MACD、CCI、RSI、ADX 与沪深 300 股票涨跌趋势的关系。

图 3：SIGNAL_MACD 指标与沪深 300 股价趋势图



资料来源：华西证券研究所

在图 3 中，有 DIF 线、DEA 线、SIGNAL_MACD 指标柱状图和从 2021 年 1 月到 7 月的沪深 300 股票收盘价格的 k 线图。可以看出 DEA 在零轴下运行时，若 DIF 由下往上穿过，主要是因为股价下跌探底，抛盘呈现的底部形态后主力开始介入。当两线开始向上多头发散时，股票呈上涨趋势。当 DIF 线在零轴上向下穿过 DEA 线，继续下穿零轴，在零轴以下向上穿过 DEA，则股票价格即将上涨。当 DIF 线高于 DEA 线时，股票会上涨；当 DEA 线与 DIF 线属于同一水平线时，股票属于调整阶段；当 DIF 线低于 DEA 线时，股票会下跌。

图 4: CCI 指标与沪深 300 股价趋势图



资料来源：华西证券研究所

在图 4 中，有 CCI 指标线和从 2021 年 1 月到 7 月的沪深 300 股票收盘价格的 k 线图。CCI 指标的三个运行区间代表着不同的含义：大于 100 视为超买区间，-100 以下为超卖区间，-100 到 100 之间为震荡区间。当 CCI 指标曲线从上往下跌破 100 进入震荡区间时，预示股票价格的上涨阶段可能结束，即将进入一个长时间的震荡整理阶段。当 CCI 指标曲线从上往下突破 -100 进入超卖区时，说明市场处于弱势状态，将进入一个比较长的寻底过程，此时的股价处于一个较低的水平。当 CCI 曲线从下往

上突破-100 时，说明股价有上涨的趋势，适合买入股票。当 CCI 曲线从上往下跌破 100 时，说明股价可能下跌。

图 5: RSI 指标与沪深 300 股价趋势图



资料来源：华西证券研究所

在图 5 中，有 RSI 指标线和从 2021 年 1 月到 7 月的沪深 300 股票收盘价格的 k 线图。RSI 指标大于 50 时对应强势市场，高于 70 进入超买区，容易形成短期回档；小于 50 为弱势市场，低于 20 进入超卖区，容易形成短期反弹。RSI 原本处于 50 以下然后向上扭转突破 50，代表股价已转强；RSI 原本处于 50 以上然后向下扭转跌破 50，代表股价已转弱。

图 6: ADX 指标与沪深 300 股价趋势图



资料来源：华西证券研究所

在图 6 中，有 -DI 线、+DI 线、ADX 线以及从 2021 年 1 月到 7 月的沪深 300 股票收盘价格的 k 线图。当 +DI 线在 -DI 线上方时，表示股价以上涨为主；-DI 线在 +DI 线上方时，表示股价以下跌为主；当 -DI 线、+DI 线、ADX 线以 20 为基准线上下波动时，

请仔细阅读在本报告尾部的重要法律声明

表示股价以整理为主；当 ADX 线的位置高于两条 DI 线，且方向发生改变时，股价发展趋势开始发生反转。

由上述分析可知，这里选取的技术指标与沪深 300 股票收盘价涨跌趋势关系较为密切，可以利用这些指标建立 FSL-LR 模型实现沪深 300 股价涨跌趋势的预测。

3.3.2. FSL-LR 模型的优化

(1) 调整随机断开输入神经元比例 (dropout)

该参数表示在生成对抗网络训练的过程中将部分神经网络单元暂时筛选出去的概率，可减小 GAN 模型发生过拟合及性能过低的可能性。这里在研究 dropout 对回测结果的影响时，使其在数组 [0.2, 0.3, 0.4] 中分别进行取值，以夏普比率、最大回撤率、交易胜率作为评价指标，研究结果如表 3 所示。

表 3：随机断开输入神经元比例对回测结果的影响

随机断开输入神经元比例	夏普比率	最大回撤率	胜率
0.2	0.98	-26.4%	0.59
0.3	0.98	-26.4%	0.59
0.4	0.98	-26.4%	0.59

资料来源：华西证券研究所

从表 3 可以看出此参数从 0.2 到 0.4 的变化不会回测结果产生影响，说明 dropout 参数对模型不敏感。本实验我们将 dropout 设置为 0.4。

(2) 调整训练批次 (epochs)

参数 epochs 代表训练 GAN 模型时的迭代次数，它的设置会较大地影响模型的训练精度和训练时间。研究结果如表 4 所示。

表 4：训练批次对回测结果的影响

训练批次	夏普比率	最大回撤率	胜率
20	0.98	-26.4%	0.59
30	0.90	-32.31%	0.58
40	0.61	-38.00%	0.61

资料来源：华西证券研究所

从表 4 看出，训练批次为 20 可以获得较好结果。随着训练批次增加，夏普比率有一定程度的降低，本实验我们将训练批次 epochs 设置为 20。

(4) 调整逻辑回归阈值

表 5：逻辑回归阈值对回测结果的影响

阈值	夏普比率	年化收益率	总收益率	最大回撤	胜率	交易次数
0.45	0.35	5.21%	33.15%	-45.72%	0.53	36
0.5	0.20	2.46%	15.68%	-45.97%	0.47	36
0.55	0.52	7.67%	48.80%	-43.16%	0.54	37
0.6	0.98	13.4%	131.10%	-26.4%	0.59	37
0.65	0.43	6.50%	41.36%	-31.61%	0.6	35
0.7	0.55	7.83%	49.81%	-25.08%	0.66	35
基准	0.37	5.18%	39.00%	-46.7%		


资料来源：华西证券研究所

我们把逻辑回归看做是对分类概率的直接拟合，所以模型的输出即响应变量的结果值可以看作是将样本分为正例的概率，一般我们会将这个概率值与一个阈值进行比较，输出的概率值大于阈值被判断为正例，反之被判断为反例。显然，阈值的选取对模型预测精度影响很大，一般选择 0.5。这里结合逻辑回归模型是被用来预测指数的涨跌，根据涨跌趋势决定买入卖出的时机来模拟具体的交易过程，我们把这个阈值做了调整，从而对沪深 300 指数进行回测。如表 5 所示，以滚动训练方式为例，把阈值确定为 0.6 可以获得较高的夏普率和较低的最大回撤率。

3.3.3. 窗长窗移滚动训练模式分析


这里滚动训练模式的窗长为 60 的交易日（约为一个季度的自然日时长）

图 7：FSL-LR 模型对比基准的净值走势图



资料来源：华西证券研究所

图 8：FSL-LR 模型季度收益率



资料来源：华西证券研究所

通过对 FSL-LR 模型超参数的选择，逻辑回归模型的判别阈值应为 0.6。为了体现生成对抗网络在本次策略实现过程中发挥的作用，我们将使用了生成对抗网络做数据增强的回测结果与不使用生成对抗网络做数据增强的回测结果进行了对比分析。从表 6 可以看出，这种训练方式可以获得较高的夏普比率，较低的最大回撤率，较高的收益率。图 7 和图 8 展示了累计收益和超额收益率。

表 6：择时策略评价指标

	夏普比率	年化收益率	总收益率	最大回撤	胜率	交易次数
LR	0.78	10.9%	99%	-32.3%	58%	38
FSL-LR	0.98	13.4%	131%	-26.4%	59%	37
基准	0.37	5.18%	39%	-46.7%		


资料来源：华西证券研究所

3.3.4. FSL-LR 模型评估

ROC 曲线是非常重要和常见的统计分析方法，在机器学习领域用来评判分类、检测结果的好坏。AUC 表示 ROC 曲线下的面积，主要用于衡量模型的泛化性能，即分类效果的好坏。在逻辑回归这类分类模型中，预测结果都是以概率的形式表现，如果要计算准确率，通常都会手动设置一个阈值来将对应的概率转化成类别，这个阈值也就

很大程度上影响了模型准确率计算。如表 5 所示，我们将阈值定为 0.6，因为这样得到的回测结果最好。

图 9: 模型 ROC 曲线图



资料来源：华西证券研究所

ROC 曲线下的面积 AUC 可以评价分类器的分类效果：AUC 值越大，分类效果越好。当 $AUC=0.5$ 时，分类器的表现等同于随机猜测；当 $0.5 < AUC < 1$ 时，分类器性能优于随机猜测；当 $AUC < 0.5$ 时，分类器的表现比随机猜测还差。从图 9 的 ROC 曲线以及计算的 $AUC=0.65$ 可以看出，阈值设置为 0.6 时，逻辑回归分类器的性能最优。

4. 总结

本篇报告我们提出使用生成对抗网络 GAN 对训练数据进行扩充，并证明了 GAN 网络的有效性。通过结合 GAN 网络与逻辑回归模型，本文构建了 FSL-LR 模型，并调整超参数进行模型选择，最后通过模型构建了回测过程，通过夏普率、最大回撤率等指标判断策略的有效性。本文介绍了生成对抗网络关键参数的含义和选择方法。策略表现的结果证明了 FSL-LR 模型相比于简单的 LR 模型确有增强。

总结 FSL-LR 模型具有以下特点：

1. 逻辑回归模型非常适用于处理二分类问题，它的预测结果介于 0 到 1 之间，具有概率的意义。
2. 逻辑回归模型训练速度快，计算量仅仅只和特征的数目相关，在计算效率上比其他算法表现更优。然而逻辑回归模型依赖于前期特征工程的贡献，对数据的要求较高。GAN 模型作为生成模型可以用于小样本的样本扩充，这对数据驱动且缺乏合理标注数据集的机器学习方法来说意义重大。利用 GAN 模型实现数据扩充可以帮助做出好的特征，提高数据质量，从而提高模型的泛化能力。

5. 风险提示

模型基于对历史数据统计，仅作为投资参考。

分析师承诺

作者具有中国证券业协会授予的证券投资咨询执业资格或相当的专业胜任能力，保证报告所采用的数据均来自合规渠道，分析逻辑基于作者的职业理解，通过合理判断并得出结论，力求客观、公正，结论不受任何第三方的授意、影响，特此声明。

评级说明

公司评级标准	投资 评级	说明
以报告发布日后的 6 个月内公司股价相对上证指数的涨跌幅为基准。	买入	分析师预测在此期间股价相对强于上证指数达到或超过 15%
	增持	分析师预测在此期间股价相对强于上证指数在 5%—15%之间
	中性	分析师预测在此期间股价相对上证指数在-5%—5%之间
	减持	分析师预测在此期间股价相对弱于上证指数 5%—15%之间
	卖出	分析师预测在此期间股价相对弱于上证指数达到或超过 15%
行业评级标准		
以报告发布日后的 6 个月内行业指数的涨跌幅为基准。	推荐	分析师预测在此期间行业指数相对强于上证指数达到或超过 10%
	中性	分析师预测在此期间行业指数相对上证指数在-10%—10%之间
	回避	分析师预测在此期间行业指数相对弱于上证指数达到或超过 10%

华西证券研究所：

地址：北京市西城区太平桥大街丰汇园 11 号丰汇时代大厦南座 5 层

网址：<http://www.hx168.com.cn/hxzq/hxindex.html>

华西证券免责声明

华西证券股份有限公司（以下简称“本公司”）具备证券投资咨询业务资格。本报告仅供本公司签约客户使用。本公司不会因接收人收到或者经由其他渠道转发收到本报告而直接视其为本公司客户。

本报告基于本公司研究所及其研究人员认为的已经公开的资料或者研究人员的实地调研资料，但本公司对该等信息的准确性、完整性或可靠性不作任何保证。本报告所载资料、意见以及推测仅于本报告发布当日的判断，且这种判断受到研究方法、研究依据等多方面的制约。在不同时期，本公司可发出与本报告所载资料、意见及预测不一致的报告。本公司不保证本报告所含信息始终保持在最新状态。同时，本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者需自行关注相应更新或修改。

在任何情况下，本报告仅提供给签约客户参考使用，任何信息或所表述的意见绝不构成对任何人的投资建议。市场有风险，投资需谨慎。投资者不应将本报告视为做出投资决策的惟一参考因素，亦不应认为本报告可以取代自己的判断。在任何情况下，本报告均未考虑到个别客户的特殊投资目标、财务状况或需求，不能作为客户进行客户买卖、认购证券或者其他金融工具的保证或邀请。在任何情况下，本公司、本公司员工或者其他关联方均不承诺投资者一定获利，不与投资者分享投资收益，也不对任何人因使用本报告而导致的任何可能损失负有任何责任。投资者因使用本公司研究报告做出的任何投资决策均是独立行为，与本公司、本公司员工及其他关联方无关。

本公司建立起信息隔离墙制度、跨墙制度来规范管理跨部门、跨关联机构之间的信息流动。务请投资者注意，在法律许可的前提下，本公司及其所属关联机构可能会持有报告中提到的公司所发行的证券或期权并进行证券或期权交易，也可能为这些公司提供或者争取提供投资银行、财务顾问或者金融产品等相关服务。在法律许可的前提下，本公司的董事、高级职员或员工可能担任本报告所提到的公司的董事。

所有报告版权均归本公司所有。未经本公司事先书面授权，任何机构或个人不得以任何形式复制、转发或公开传播本报告的全部或部分内容，如需引用、刊发或转载本报告，需注明出处为华西证券研究所，且不得对本报告进行任何有悖原意的引用、删节和修改。